


Econometría de Series de Tiempo



Francisco A. Ramírez
Versión: Abril, 2026

© 2026 Francisco A. Ramírez

Todos los derechos reservados.

Ninguna parte de esta publicación puede ser reproducida
sin autorización previa del autor.

ISBN: pendiente

Publicado de manera independiente.

Prefacio

Este libro surge del curso de Econometría de Series de Tiempo impartido en la Pontificia Universidad Católica Madre y Maestra y en la Maestría de Economía Aplicada de UNIBE. Su objetivo es integrar teoría, aplicación empírica y programación en R para el análisis macroeconómico y de políticas. En este sentido, responde a una necesidad pedagógica concreta: ofrecer a los estudiantes y profesionales una herramienta que no solo explique los modelos, sino que los conecte con problemas reales, datos observados y decisiones de política económica.

La motivación central de este texto es contribuir a cerrar la brecha entre la enseñanza tradicional de la econometría de series de tiempo y la práctica contemporánea en bancos centrales, organismos internacionales y centros de investigación. En muchos programas académicos, los modelos se presentan de manera fragmentada: por un lado, los enfoques clásicos; por otro, desarrollos más recientes que rara vez se integran en un mismo marco conceptual. Este libro propone una visión unificada, donde los modelos ARIMA, VAR, cointegración, modelos de volatilidad, no linealidades y métodos de aprendizaje automático se presentan como parte de una misma arquitectura analítica.

Una de las principales contribuciones de esta obra es precisamente la integración en un solo texto de los avances más relevantes de la literatura aplicada de los últimos veinte años. Durante este período, la econometría de series de tiempo

ha experimentado una expansión significativa, incorporando nuevas metodologías para el análisis de datos de alta dimensión, la modelización no lineal, la identificación estructural y el uso de herramientas computacionales avanzadas. Sin embargo, estos desarrollos suelen encontrarse dispersos en artículos especializados o textos avanzados, lo que dificulta su adopción sistemática en cursos de nivel intermedio. Este libro busca organizar, sistematizar y hacer accesible ese conjunto de herramientas.

El enfoque adoptado es deliberadamente integrador. Cada capítulo combina tres dimensiones fundamentales: (i) el desarrollo teórico riguroso, (ii) la implementación computacional en R y (iii) la interpretación económica de los resultados. Esta estructura responde a la convicción de que la econometría no debe entenderse como un conjunto de técnicas aisladas, sino como un lenguaje para analizar fenómenos dinámicos y apoyar la toma de decisiones en contextos de incertidumbre.

Este texto no pretende sustituir a los grandes libros de referencia en cada uno de los temas tratados, sino servir como un puente entre ellos. En particular, puede utilizarse como complemento de obras clásicas y modernas como *Time Series Analysis: Forecasting and Control* de Box, Jenkins, Reinsel y Ljung; *Applied Econometric Time Series* de Walter Enders; *Analysis of Financial Time Series* de Ruey S. Tsay; *New Introduction to Multiple Time Series Analysis* de Helmut Lütkepohl; *Structural Vector Autoregressive Analysis* de Kilian y Lütkepohl; *Forecasting: Principles and Practice* de Hyndman y Athanasopoulos; así como trabajos fundamentales en cointegración de Søren Johansen. Cada uno de estos textos profundiza en aspectos específicos, mientras que el presente libro busca ofrecer una visión articulada que facilite su comprensión conjunta.

Finalmente, este libro está dirigido a estudiantes de economía, analistas de política, investigadores y profesionales que trabajan con datos macroeconómicos y financieros. Se asume una formación previa en econometría, probabilidad y

álgebra lineal, pero se pone especial énfasis en la claridad expositiva y en la reproducibilidad de los resultados mediante código. La aspiración es que el lector no solo aprenda técnicas, sino que desarrolle criterio para seleccionar, implementar e interpretar modelos en función del problema económico que enfrenta.

En última instancia, este libro es una invitación a pensar la econometría de series de tiempo no como un conjunto de herramientas estáticas, sino como un campo en evolución, profundamente conectado con los desafíos empíricos de la economía contemporánea.

Francisco A. Ramírez de León

Santo Domingo

Abril de 2026

Índice general

Prefacio	iii
1. Máxima Verosimilitud	1
1.1. Introducción y motivación	2
1.1.1. ¿Por qué máxima verosimilitud? . . .	2
1.1.2. Hoja de ruta del capítulo	4
1.1.3. Notación y convenciones	4
1.2. La función de verosimilitud	5
1.2.1. Densidad vs. verosimilitud: una distin-	
ción sutil pero fundamental	5
1.2.2. Factorización y log-verosimilitud . . .	6
1.2.3. Ejemplo: muestra normal iid	7
1.2.4. Verosimilitud condicional vs. exacta	
en series de tiempo	8
1.3. Score, información y sus identidades	9
1.3.1. El vector de score	9
1.3.2. La esperanza del score es cero	9
1.3.3. Información de Fisher	10
1.3.4. Información observada vs. esperada .	11
1.3.5. Ejemplo: información en la normal iid	12
1.4. Propiedades asintóticas del EMV	13
1.4.1. Consistencia	14
1.4.2. Normalidad asintótica	15
1.4.3. Eficiencia y la cota de Cramér-Rao .	16
1.4.4. Invariancia	17
1.4.5. Implicaciones operativas	18

1.5.	Tests clásicos	18
1.5.1.	Test de Wald	19
1.5.2.	Test de razón de verosimilitud (LR)	20
1.5.3.	Test de multiplicadores de Lagrange (LM, Score)	21
1.5.4.	Equivalencia asintótica bajo H_0	22
1.5.5.	Guía práctica de selección	22
1.6.	Optimización numérica de la verosimilitud	24
1.6.1.	Newton-Raphson: el método de refe- rencia	24
1.6.2.	Cuasi-Newton: BFGS y L-BFGS-B	25
1.6.3.	Nelder-Mead: cuando no hay gradiente	26
1.6.4.	Reparametrizaciones: una técnica in- fravalorada	26
1.6.5.	Diagnósticos de convergencia	27
1.7.	Implementación en R: MA(1) por MV	28
1.7.1.	El modelo y su log-verosimilitud	28
1.7.2.	Datos simulados	28
1.7.3.	Log-verosimilitud negativa	29
1.7.4.	Optimización	30
1.7.5.	Errores estándar vía información ob- servada	31
1.7.6.	Validación contra <code>arma()</code>	31
1.7.7.	Tests de hipótesis aplicados	32
1.7.8.	Visualización de la superficie de vero- similitud	33
1.8.	Ejercicios	35
	Bibliografía	37
2.	Fundamentos y Análisis Univariado	39
2.1.	Procesos estocásticos y estacionariedad	42
2.1.1.	El objeto central: proceso estocástico	42
2.1.2.	Estacionariedad estricta y débil	43
2.1.3.	Función de autocovarianza y autocor- relación	44
2.1.4.	Ergodicidad	45

2.1.5.	Ruido blanco	46
2.2.	Operador de rezagos y procesos lineales . . .	47
2.2.1.	El operador de rezagos	47
2.2.2.	Procesos lineales y representación de Wold	48
2.3.	Los modelos AR, MA y ARMA	49
2.3.1.	El proceso MA(q)	49
2.3.2.	El proceso AR(p)	51
2.3.3.	El proceso ARMA(p, q)	53
2.3.4.	La función de autocorrelación parcial (PACF)	53
2.4.	La metodología Box-Jenkins	55
2.4.1.	Las cuatro etapas	55
2.4.2.	ACF y PACF muestrales: distribución y bandas de confianza	55
2.4.3.	Test portmanteau de Ljung-Box . . .	56
2.4.4.	Filosofía Box-Jenkins y parsimonia .	57
2.5.	Raíces unitarias e integración	58
2.5.1.	No estacionariedad por raíz unitaria .	58
2.5.2.	Por qué importa: regresiones espurias	58
2.5.3.	Test de Dickey-Fuller (DF) y su ver- sión aumentada (ADF)	59
2.5.4.	Test de Phillips-Perron (PP)	61
2.5.5.	Test de KPSS: la hipótesis inversa . .	61
2.5.6.	Test DF-GLS	62
2.5.7.	Limitaciones y cambios estructurales	63
2.6.	ARIMA y SARIMA	64
2.6.1.	El modelo ARIMA(p, d, q)	64
2.6.2.	Interpretación de d	64
2.6.3.	SARIMA: incorporando estacionalidad	65
2.6.4.	Criterios de información: AIC, BIC y HQC	66
2.7.	Pronóstico y evaluación	67
2.7.1.	Pronóstico óptimo bajo pérdida cua- drática	67
2.7.2.	Pronóstico en un ARMA	67

2.7.3.	Métricas de precisión out-of-sample	68
2.7.4.	Validación rolling-origin	68
2.8.	Implementación en R	70
2.8.1.	Preparación	70
2.8.2.	Simulación de un proceso ARMA	70
2.8.3.	Etapa 1: identificación	71
2.8.4.	Etapa 2: estimación	71
2.8.5.	Etapa 3: diagnóstico	72
2.8.6.	Etapa 4: pronóstico	73
2.8.7.	Aplicación a una serie macro dominicana	74
2.8.8.	Reproducibilidad: estructura de proyecto	76
2.9.	Ejercicios	77
	Bibliografía	80
3.	Volatilidad y Modelos No Lineales	83
3.1.	Hechos estilizados y motivación	87
3.1.1.	Lo que ARMA no puede capturar	87
3.1.2.	El contexto dominicano	89
3.1.3.	El lenguaje: varianza condicional	89
3.1.4.	Diagnóstico de ARCH: ACF de los cuadrados y test ARCH-LM	90
3.2.	El modelo ARCH	92
3.2.1.	Definición y lógica	92
3.2.2.	Momentos del ARCH(1)	92
3.2.3.	Ausencia de autocorrelación	93
3.2.4.	Autocorrelación en los cuadrados	93
3.2.5.	Colas pesadas: la generación de curtosis	94
3.2.6.	Limitaciones del ARCH puro	95
3.3.	El modelo GARCH	96
3.3.1.	Definición	96
3.3.2.	GARCH(1,1): el caballito de batalla	97
3.3.3.	IGARCH: persistencia en la frontera	98
3.3.4.	Estimación por máxima verosimilitud	99
3.3.5.	Cuasi-máxima verosimilitud (QMLE)	100
3.4.	Extensiones del GARCH	101
3.4.1.	EGARCH: Nelson (1991)	101

3.4.2.	GJR-GARCH: Glosten-Jagannathan-Runkle (1993)	102
3.4.3.	APARCH: Ding-Granger-Engle (1993)	103
3.4.4.	Distribuciones alternativas de z_t	103
3.4.5.	Pronóstico multi-paso de volatilidad	105
3.4.6.	Value at Risk (VaR) como aplicación canónica	105
3.5.	Modelos de umbral: TAR y TVAR	106
3.5.1.	Motivación económica	106
3.5.2.	SETAR: Self-Exciting Threshold AR	107
3.5.3.	El problema de Davies: tests de linealidad	108
3.5.4.	TVAR: la extensión multivariada	109
3.6.	Markov-Switching AR	111
3.6.1.	Concepto y diferencia clave con TAR	111
3.6.2.	Aplicación histórica: datar recesiones	111
3.6.3.	Probabilidades filtradas, predichas y suavizadas	112
3.6.4.	Filtro de Hamilton	112
3.6.5.	Suavizado de Kim	113
3.6.6.	Estimación	113
3.7.	Implementación en R	114
3.7.1.	GARCH con <code>rugarch</code> : pipeline completo	114
3.7.2.	TVAR con <code>tsDyn</code>	116
3.7.3.	MS-AR con <code>MSwM</code>	117
3.8.	Ejercicios	119
	Bibliografía	122
4.	Análisis Multivariado	125
4.1.	Del AR al VAR: motivación	129
4.1.1.	La crítica de Sims (1980)	129
4.1.2.	Por qué importa: endogeneidad en política monetaria	129
4.1.3.	Lo que permite el VAR	130
4.2.	El VAR reducido	132
4.2.1.	Definición y notación	132

4.2.2.	Estacionariedad	132
4.2.3.	La forma compañera	133
4.2.4.	Media incondicional y representación MA(∞)	134
4.2.5.	Autocovarianzas del VAR	135
4.2.6.	Estimación por MCO: un resultado notable	135
4.2.7.	Distribución asintótica	136
4.2.8.	Selección del orden p	137
4.2.9.	Diagnóstico	137
4.3.	Causalidad de Granger	139
4.3.1.	Concepto y definición formal	139
4.3.2.	Test en un VAR	139
4.3.3.	Granger $\neq$ causalidad filosófica	139
4.3.4.	Usos legítimos del test de Granger	140
4.4.	VAR estructural: identificación	141
4.4.1.	El problema fundamental de identi- ficación	141
4.4.2.	Identificación recursiva (Cholesky)	142
4.4.3.	Restricciones de corto plazo no recur- sivas	144
4.4.4.	Restricciones de largo plazo: Blanchard- Quah (1989)	145
4.4.5.	Restricciones de signo: Uhlig (2005)	146
4.4.6.	Comparación de estrategias de identi- ficación	148
4.5.	IRFs y descomposición de varianza	149
4.5.1.	Funciones impulso-respuesta estructu- rales	149
4.5.2.	Intervalos de confianza para IRFs	150
4.5.3.	Descomposición de varianza del error de pronóstico (FEVD)	151
4.6.	Cointegración y VECM	152
4.6.1.	El problema motivador	152
4.6.2.	Cointegración: definición y ejemplos	152

4.6.3.	Representación VECM: teorema de Engle-Granger	154
4.6.4.	Procedimiento de Johansen	155
4.6.5.	Engle-Granger vs. Johansen: cuándo usar cada uno	158
4.6.6.	SVECM: identificación en sistemas cointegrados	158
4.7.	Local Projections	159
4.7.1.	Una alternativa a los VAR para construir IRFs	159
4.7.2.	Identificación del shock	159
4.7.3.	Ventajas y desventajas	160
4.7.4.	Inferencia: el problema de la superposición	161
4.7.5.	Identificación del shock: enfoques recientes	161
4.7.6.	Plagborg-Møller & Wolf (2021): equivalencia conceptual	162
4.8.	Implementación en R	163
4.8.1.	Datos: canal de transmisión monetaria RD	163
4.8.2.	Tests de raíz unitaria y decisión de especificación	163
4.8.3.	Estimación del VAR reducido	164
4.8.4.	Diagnóstico	164
4.8.5.	Causalidad de Granger	164
4.8.6.	IRFs por Cholesky	165
4.8.7.	SVAR con restricciones de corto plazo	165
4.8.8.	SVAR con restricciones de signo (Uhlig)	166
4.8.9.	Cointegración y VECM	166
4.8.10.	Local Projections	167
4.8.11.	Reporte final y comparación	167
4.9.	Ejercicios	169
	Bibliografía	172

5. Métodos Bayesianos	175
5.1. Motivación: ¿por qué bayesiano?	179
5.1.1. La maldición de la dimensionalidad en VAR frecuentistas	179
5.1.2. Cuantificación de incertidumbre para- métrica	181
5.1.3. Pronóstico densitario	181
5.2. Fundamentos bayesianos	183
5.2.1. La regla de Bayes aplicada a inferencia	183
5.2.2. Priors: tipos y roles	183
5.2.3. Priors conjugados	184
5.2.4. Posterior normal con normal conjuga- da: caso escalar	185
5.2.5. Intervalos de confianza vs. credibilidad	186
5.3. BVAR: formulación y posterior conjugada	187
5.3.1. El VAR en notación matricial	187
5.3.2. Prior Normal-Inverse-Wishart	187
5.3.3. Posterior en forma cerrada	188
5.3.4. Muestreo de la posterior NIW	189
5.4. El prior Minnesota	190
5.4.1. La intuición de Litterman	190
5.4.2. Especificación	190
5.4.3. Los hiperparámetros λ	191
5.4.4. Elección de los λ : tres enfoques	192
5.4.5. Implementación vía dummy observations	193
5.4.6. Priors adicionales: sum-of-coefficients e initial observation	194
5.5. Muestreadores MCMC	195
5.5.1. Cuándo necesitamos MCMC	195
5.5.2. Gibbs sampler	195
5.5.3. Metropolis-Hastings	196
5.5.4. Diagnóstico de convergencia	198
5.5.5. Trade-offs prácticos	198
5.6. Stochastic volatility en BVAR	199
5.6.1. Motivación: la Gran Moderación	199
5.6.2. El modelo BVAR-SV	199

5.6.3.	SV vs. GARCH: diferencias conceptuales	200
5.6.4.	Estimación de BVAR-SV: el muestreador de Kim-Shephard-Chib	201
5.7.	TVP-VAR	203
5.7.1.	Motivación: cambios estructurales . .	203
5.7.2.	El modelo TVP-VAR	203
5.7.3.	El modelo de Primiceri (2005): TVP-VAR + SV	203
5.7.4.	Estimación	204
5.7.5.	IRFs variables en el tiempo	205
5.8.	Pronóstico densitario y fan charts	206
5.8.1.	La distribución predictiva	206
5.8.2.	Simulación de la distribución predictiva	206
5.8.3.	Fan charts	207
5.9.	Implementación en R	209
5.9.1.	Paquetes principales	209
5.9.2.	BVAR estándar con prior Minnesota jerárquico	209
5.9.3.	Inferencia posterior: IRFs y FEVD .	210
5.9.4.	Pronóstico densitario y fan chart . .	210
5.9.5.	BVAR con stochastic volatility . . .	212
5.9.6.	TVP-VAR con bvarsv	213
5.9.7.	Comparación rigurosa con VAR frecuentista	213
5.10.	Ejercicios	215
	Bibliografía	218
6.	Alta Dimensión y Factores	221
6.1.	Motivación: el problema de alta dimensión .	226
6.1.1.	La riqueza de los datos modernos . .	226
6.1.2.	Por qué los VAR convencionales fallan	226
6.1.3.	Las tres respuestas metodológicas . .	227
6.2.	Modelos de factores dinámicos	229
6.2.1.	La idea fundamental	229
6.2.2.	Modelo de factores estático	229
6.2.3.	Modelo de factores dinámico	230

6.2.4.	Estimación por componentes principales	231
6.2.5.	Propiedades asintóticas	232
6.2.6.	Selección del número de factores . . .	232
6.2.7.	Interpretación económica de los factores	234
6.2.8.	Usos de los factores estimados	234
6.3.	FAVAR	236
6.3.1.	Motivación: el problema de informa- ción en VAR pequeños	236
6.3.2.	Formulación del FAVAR	236
6.3.3.	Estimación en dos pasos	237
6.3.4.	Estimación conjunta bayesiana	238
6.3.5.	Resolución del price puzzle: evidencia empírica	238
6.3.6.	FAVAR en la RD: aplicación potencial	239
6.4.	Nowcasting y MIDAS	240
6.4.1.	El problema del nowcasting	240
6.4.2.	El patrón de ragged edges	240
6.4.3.	DFM para nowcasting: Giannone-Reichlin- Small (2008)	241
6.4.4.	MIDAS: una alternativa parsimoniosa	242
6.4.5.	Estimación MIDAS	244
6.4.6.	DFM vs. MIDAS: trade-offs	244
6.4.7.	Métricas de evaluación de nowcasting	245
6.5.	Regularización: LASSO, ridge, elastic net . .	246
6.5.1.	El enfoque de penalización	246
6.5.2.	Ridge regression	246
6.5.3.	LASSO	247
6.5.4.	Geometría: por qué LASSO selecciona y ridge no	248
6.5.5.	Elastic Net	249
6.5.6.	Selección de λ : validación cruzada tem- poral	249
6.5.7.	VAR-LASSO y extensiones	250
6.5.8.	Inferencia post-selección	251
6.5.9.	Regularización en series de tiempo: consideraciones específicas	252

6.6.	Implementación en R	253
6.6.1.	DFM con <code>dfms</code>	253
6.6.2.	Nowcasting DFM con <code>nowcasting</code>	254
6.6.3.	MIDAS con <code>midasr</code>	254
6.6.4.	LASSO/Ridge/ElasticNet con <code>glmnet</code>	255
6.6.5.	VAR-LASSO con <code>BigVAR</code>	256
6.7.	Ejercicios	258
	Bibliografía	261
7.	Machile Learning	265
7.1.	ML vs. econometría: una discusión metodológica	269
7.1.1.	Las dos culturas de Breiman	269
7.1.2.	¿Cuándo domina cada enfoque?	271
7.1.3.	Evidencia empírica: Medeiros et al. (2021)	272
7.1.4.	Lecciones para el practicante	273
7.2.	Validación cruzada temporal	274
7.2.1.	Por qué el shuffle estándar falla	274
7.2.2.	Rolling-origin: el esquema correcto	275
7.2.3.	Gap entre entrenamiento y prueba	276
7.2.4.	Implementación en R	276
7.3.	Random forest	277
7.3.1.	Árbol de regresión: el ingrediente base	277
7.3.2.	Random forest: construcción	278
7.3.3.	Hiperparámetros	280
7.3.4.	RF para series de tiempo: consideraciones	280
7.4.	Gradient boosting	283
7.4.1.	La idea del boosting	283
7.4.2.	XGBoost: la implementación moderna	284
7.4.3.	Hiperparámetros y tuning	285
7.4.4.	XGBoost vs. Random Forest	286
7.5.	Redes recurrentes: una introducción	287
7.5.1.	Motivación y posicionamiento	287
7.5.2.	Red neuronal feedforward: el precursor	288
7.5.3.	RNN: Recurrent Neural Network	289

7.5.4.	LSTM: la arquitectura que resolvió el problema	290
7.5.5.	GRU: alternativa más simple	291
7.5.6.	Evidencia empírica: RNN vs. métodos clásicos	291
7.6.	Ensamblajes y combinación de pronósticos	292
7.6.1.	La sabiduría de combinar	292
7.6.2.	El forecast combination puzzle	292
7.6.3.	Stacking	293
7.6.4.	Ensamblajes por modelo distinto	294
7.7.	Evaluación formal de pronósticos	296
7.7.1.	El problema	296
7.7.2.	Test de Diebold-Mariano	296
7.7.3.	Test de Giacomini-White	297
7.7.4.	Evaluación de pronóstico densitario	298
7.8.	Implementación integrada en R	301
7.8.1.	Preparación del entorno	301
7.8.2.	Split temporal	301
7.8.3.	Modelos base	302
7.8.4.	Validación rolling-origin	304
7.8.5.	Tabla de modelos y evaluación rolling	304
7.8.6.	Test de Diebold-Mariano	304
7.8.7.	Ensamble	305
7.8.8.	Pronóstico futuro (fuera de muestra)	305
7.8.9.	CRPS para pronóstico densitario	306
7.8.10.	PIT histogram para diagnóstico de calibración	307
7.9.	Ejercicios	308
7.10.	Cierre del curso	311
7.10.1.	El camino recorrido	311
7.10.2.	El mensaje metodológico final	312
7.10.3.	Más allá del curso	313
7.10.4.	Cierre	313
	Bibliografía	315

Capítulo 1

Máxima Verosimilitud y Fundamentos de Inferencia

Resumen

*Este capítulo presenta el marco de máxima verosimilitud (MV) como la columna vertebral metodológica de todo el curso. Se desarrollan, en orden lógico, (i) la noción de función de verosimilitud y su justificación conceptual; (ii) el vector de score y la matriz de información de Fisher, con sus identidades fundamentales; (iii) las propiedades asintóticas del estimador de máxima verosimilitud (EMV) —consistencia, normalidad asintótica, eficiencia, invariancia—; (iv) los tres tests clásicos —Wald, razón de verosimilitud y multiplicadores de Lagrange— con sus equivalencias asintóticas; y (v) la optimización numérica de la función de verosimilitud. Cada resultado se demuestra con el detalle necesario para que el estudiante pueda reproducirlo; cada concepto se acompaña de implementación en R, con un caso de estudio completo de estimación manual de un proceso MA(1) contrastado contra *arima()*. El capítulo cierra con ejercicios y una guía de lectura para el resto del curso.*

1.1. Introducción y motivación

1.1.1. ¿Por qué máxima verosimilitud?

El curso de econometría de series de tiempo cubre una variedad notable de modelos: ARMA, ARIMA, SARIMA, ARCH, GARCH y sus extensiones, VAR, VAR estructural, VECM, modelos bayesianos, modelos de factores dinámicos, y una familia creciente de modelos de machine learning. Estos modelos difieren en estructura: algunos son lineales, otros no; algunos tienen varianza constante, otros heterocedasticidad condicional; algunos son univariados, otros multivariados. Esta heterogeneidad podría sugerir que cada modelo requiere su propia teoría de inferencia.

La realidad es la opuesta. El enfoque de *máxima verosi-*

militud ofrece un lenguaje único, compacto y riguroso para estimar, contrastar y comparar todos estos modelos. Más aún, los tres tests clásicos de la econometría paramétrica —Wald, razón de verosimilitud (LR) y multiplicadores de Lagrange (LM)— se derivan *directamente* del marco de MV. Por eso se dedica este capítulo inicial a construir ese andamiaje con cuidado: una vez claro, solo necesitaremos especializar la log-verosimilitud a cada modelo en los capítulos siguientes¹

Intuición del método. Observamos una muestra $\mathbf{y} = (y_1, \dots, y_T)$ que suponemos proviene de una familia paramétrica de distribuciones $\{f(\cdot; \boldsymbol{\theta}) : \boldsymbol{\theta} \in \Theta\}$. El parámetro verdadero $\boldsymbol{\theta}_0 \in \Theta$ es desconocido. La pregunta de MV es simple: *entre todos los $\boldsymbol{\theta} \in \Theta$, ¿cuál hace más probable lo que efectivamente observamos?* Ese $\boldsymbol{\theta}$ es el estimador de máxima verosimilitud $\hat{\boldsymbol{\theta}}$.

Esta formulación tiene cuatro ventajas metodológicas que nos acompañarán:

1. **Universalidad.** Sirve para cualquier modelo con una densidad paramétrica. No requiere linealidad, homocedasticidad, ni ninguna otra restricción.
2. **Eficiencia asintótica.** Bajo regularidad, el EMV alcanza la cota de Cramér-Rao. Este estimador insesgado puede ser más preciso en muestras grandes.
3. **Inferencia completa.** Los errores estándar salen de la información de Fisher, y los tres tests clásicos se construyen con elementos que ya se calcularon durante la estimación.
4. **Fundamento bayesiano.** El teorema de Bayes multiplica prior por verosimilitud. Entender MV es prerequisite para entender el Módulo 4 del curso.

¹Se recomienda repasar los conceptos de variable aleatoria, probabilidad, distribución de probabilidad (marginal, conjunta y condicional). Algunos textos útiles son: Introducción a la Estadística de Sheldon M. Ross y Estadística Matemática con Aplicaciones de Wackerly et.al.

1.1.2. Hoja de ruta del capítulo

El capítulo está organizado en seis bloques conceptuales. La Sección 1.2 construye el objeto central: la función de verosimilitud y su logaritmo, con cuidado especial en la distinción entre densidad y verosimilitud —una confusión común que se arrastra y contamina razonamientos posteriores—. La Sección 1.3 introduce el vector de score y la matriz de información de Fisher, con las identidades que los conectan y el resultado clave de que la esperanza del score es cero. La Sección 1.4 demuestra las cuatro propiedades asintóticas fundamentales del EMV. La Sección 1.5 desarrolla los tests de Wald, LR y LM, demuestra su equivalencia asintótica bajo H_0 , y ofrece criterios prácticos para elegir entre ellos. La Sección 1.6 trata la optimización numérica de ℓ : algoritmos, diagnósticos, reparametrizaciones. Finalmente, la Sección 1.7 implementa todo el marco sobre un proceso MA(1) en R, contrastando la estimación manual contra la función `arima()` estándar.

1.1.3. Notación y convenciones

Usamos $\boldsymbol{\theta} = (\theta_1, \dots, \theta_k)$ para el vector de parámetros genérico, $k = \dim(\boldsymbol{\theta})$ para su dimensión, y $\boldsymbol{\theta}_0$ para su valor verdadero. La muestra es $\mathbf{y} = (y_1, \dots, y_T)$ con T observaciones. La densidad conjunta es $f(\mathbf{y}; \boldsymbol{\theta})$; la marginal de y_t condicional al pasado es $f(y_t \mid \mathcal{F}_{t-1}; \boldsymbol{\theta})$ donde $\mathcal{F}_{t-1}$ denota la historia hasta $t - 1$. La función de verosimilitud se denota $\mathcal{L}$ y la log-verosimilitud ℓ . El vector de score es $\mathbf{s} = \partial \ell / \partial \boldsymbol{\theta}$; la matriz de información esperada es $\mathcal{I}$ y la observada es $\mathcal{I}_O$. Un sombrero denota estimación (e.g. $\hat{\boldsymbol{\theta}}$) y una tilde denota estimador restringido bajo H_0 (e.g. $\tilde{\boldsymbol{\theta}}$). Convergencia en probabilidad es $\xrightarrow{p}$; en distribución $\xrightarrow{d}$; casi segura $\xrightarrow{a.s.}$.

1.2. La función de verosimilitud

1.2.1. Densidad vs. verosimilitud: una distinción sutil pero fundamental

:

Partamos de una observación fundacional, engañosamente simple:

Definición 1.1 (Función de verosimilitud). Sea $\mathbf{y} = (y_1, \dots, y_T)$ una muestra cuya densidad conjunta bajo el parámetro $\boldsymbol{\theta}$ es $f(\mathbf{y}; \boldsymbol{\theta})$. La *función de verosimilitud* es

$$\mathcal{L}(\boldsymbol{\theta}; \mathbf{y}) = f(\mathbf{y}; \boldsymbol{\theta}), \quad (1.1)$$

vista como función de $\boldsymbol{\theta}$ con $\mathbf{y}$ fijo.

La sutileza está en la frase en negrita. La expresión algebraica $f(\mathbf{y}; \boldsymbol{\theta})$ es la misma en ambos casos, pero el objeto matemático es distinto:

- Como **densidad**, fijamos $\boldsymbol{\theta}$ y dejamos variar $\mathbf{y}$. En este caso $\int f(\mathbf{y}; \boldsymbol{\theta}) d\mathbf{y} = 1$ y $f(\cdot; \boldsymbol{\theta}) \geq 0$, propiedades estándar de densidades.
- Como **verosimilitud**, fijamos $\mathbf{y}$ (los datos ya se observaron) y dejamos variar $\boldsymbol{\theta}$. En este caso, $\int \mathcal{L}(\boldsymbol{\theta}; \mathbf{y}) d\boldsymbol{\theta}$ **no** es necesariamente 1, ni siquiera finito.

La verosimilitud no es una distribución de probabilidad sobre $\boldsymbol{\theta}$. Es simplemente una función real de $\boldsymbol{\theta}$ cuyo argumento máximo, el $\boldsymbol{\theta}$ que hace más probable lo observado, definimos como nuestro estimador.

Observación 1.2. En la inferencia bayesiana, $\mathcal{L}(\boldsymbol{\theta}; \mathbf{y})$ se combina con una densidad prior $\pi(\boldsymbol{\theta})$ vía la regla de Bayes para obtener la posterior $p(\boldsymbol{\theta} | \mathbf{y}) \propto \mathcal{L}(\boldsymbol{\theta}; \mathbf{y})\pi(\boldsymbol{\theta})$. La posterior sí es una distribución de probabilidad sobre $\boldsymbol{\theta}$. La verosimilitud, por sí sola, no lo es.

1.2.2. Factorización y log-verosimilitud

La densidad conjunta $f(\mathbf{y}; \boldsymbol{\theta})$ admite factorización secuencial usando la regla del producto:

$$f(\mathbf{y}; \boldsymbol{\theta}) = f(y_1; \boldsymbol{\theta}) \prod_{t=2}^T f(y_t | y_{t-1}, \dots, y_1; \boldsymbol{\theta}). \quad (1.2)$$

Esta factorización es siempre válida y es especialmente cómoda en series de tiempo, porque tenemos modelos explícitos para $f(y_t | \mathcal{F}_{t-1}; \boldsymbol{\theta})$: un AR(1) dice que $y_t | \mathcal{F}_{t-1} \sim \mathcal{N}(\phi y_{t-1}, \sigma^2)$; un GARCH(1,1) dice que $y_t | \mathcal{F}_{t-1} \sim \mathcal{N}(0, h_t)$ con h_t recursivo.

Si las observaciones son iid, la factorización se simplifica a $f(\mathbf{y}; \boldsymbol{\theta}) = \prod_{t=1}^T f(y_t; \boldsymbol{\theta})$. Tomando logaritmo:

$$\ell(\boldsymbol{\theta}; \mathbf{y}) \equiv \log \mathcal{L}(\boldsymbol{\theta}; \mathbf{y}) = \sum_{t=1}^T \log f(y_t | \mathcal{F}_{t-1}; \boldsymbol{\theta}), \quad (1.3)$$

donde para iid cada término es simplemente $\log f(y_t; \boldsymbol{\theta})$.

¿Por qué trabajar con logaritmos?

Hay tres razones para trabajar con ℓ en vez de $\mathcal{L}$:

1. **Convertir productos en sumas.** Un producto de T términos se vuelve una suma, lo cual es crítico para aplicar leyes de grandes números y teoremas centrales del límite a ℓ/T .
2. **Estabilidad numérica.** Para T grande, $\mathcal{L} = \prod f$ produce underflow: las densidades son típicamente < 1 y su producto colapsa a cero en punto flotante. El logaritmo evita este colapso.
3. **Monotonía.** Como log es estrictamente creciente, $\arg \max_{\boldsymbol{\theta}} \mathcal{L} = \arg \max_{\boldsymbol{\theta}} \ell$. Maximizar una o la otra da el mismo resultado.

1.2.3. Ejemplo: muestra normal iid

Como ilustración del método, consideremos $y_1, \dots, y_T \stackrel{iid}{\sim} \mathcal{N}(\mu, \sigma^2)$. La densidad de cada observación es

$$f(y_t; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_t - \mu)^2}{2\sigma^2}\right).$$

Sumando logaritmos:

$$\ell(\mu, \sigma^2) = -\frac{T}{2} \log(2\pi) - \frac{T}{2} \log \sigma^2 - \frac{1}{2\sigma^2} \sum_{t=1}^T (y_t - \mu)^2. \quad (1.4)$$

Las condiciones de primer orden son:

$$\begin{aligned} \frac{\partial \ell}{\partial \mu} &= \frac{1}{\sigma^2} \sum_{t=1}^T (y_t - \mu) = 0 \implies \hat{\mu}_{MV} = \bar{y} = \frac{1}{T} \sum y_t, \\ \frac{\partial \ell}{\partial \sigma^2} &= -\frac{T}{2\sigma^2} + \frac{1}{2\sigma^4} \sum (y_t - \mu)^2 = 0 \implies \hat{\sigma}_{MV}^2 = \frac{1}{T} \sum (y_t - \bar{y})^2. \end{aligned} \quad (1.5)$$

Dos observaciones vale la pena subrayar sobre este resultado:

1. $\hat{\sigma}_{MV}^2$ es sesgado: $\mathbb{E}[\hat{\sigma}_{MV}^2] = \sigma^2(T-1)/T \neq \sigma^2$. El estimador insesgado, que divide por $T-1$, *no* es el EMV. Esto ilustra que el EMV no es necesariamente insesgado en muestras pequeñas, aunque es consistente.
2. Que $\hat{\mu}_{MV} = \bar{y}$ recupera el estimador intuitivo pero con una justificación más profunda: es el valor que hace más probable la muestra observada bajo el modelo normal.

Este ejemplo se extenderá en secciones posteriores cuando calculemos la información de Fisher y verifiquemos las propiedades asintóticas explícitamente.

1.2.4. Verosimilitud condicional vs. exacta en series de tiempo

En series de tiempo, la factorización (1.2) requiere conocer la densidad marginal $f(y_1; \boldsymbol{\theta})$. Para procesos estacionarios invertibles, esta densidad existe y puede computarse (para un AR(1) gaussiano, $y_1 \sim \mathcal{N}(0, \sigma^2/(1 - \phi^2))$). Pero para modelos MA o ARMA, esta densidad marginal involucra a todos los innovaciones pasadas, y no es trivial de calcular.

Se adoptan entonces dos estrategias:

- **Verosimilitud exacta:** computa $f(y_1; \boldsymbol{\theta})$ explícitamente o vía filtro de Kalman. Más precisa pero más costosa. Es lo que hace `arma()` en R.
- **Verosimilitud condicional:** condiciona en las primeras observaciones (o innovaciones iniciales) y solo computa $\prod_{t=p+1}^T f(y_t | \mathcal{F}_{t-1}; \boldsymbol{\theta})$. Más simple y, para T grande, asintóticamente equivalente.

En este curso usaremos ambas según convenga didácticamente. Para el ejemplo MA(1) de la Sección 1.7, implementaremos la condicional —transparente y suficiente para $T \geq 100$ —.

1.3. Score, información y sus identidades

1.3.1. El vector de score

Definición 1.3 (Score). El *vector de score* asociado a ℓ es su gradiente respecto a $\boldsymbol{\theta}$:

$$\mathbf{s}(\boldsymbol{\theta}; \mathbf{y}) = \frac{\partial \ell(\boldsymbol{\theta}; \mathbf{y})}{\partial \boldsymbol{\theta}} = \begin{pmatrix} \partial \ell / \partial \theta_1 \\ \vdots \\ \partial \ell / \partial \theta_k \end{pmatrix} \in \mathbb{R}^k. \quad (1.6)$$

El EMV satisface $\mathbf{s}(\hat{\boldsymbol{\theta}}; \mathbf{y}) = \mathbf{0}$ por condición de primer orden, siempre que $\hat{\boldsymbol{\theta}}$ esté en el interior de Θ y ℓ sea diferenciable. Esta ecuación se llama *ecuación de verosimilitud* y es el punto de partida para:

- la optimización numérica (Newton-Raphson se basa en hacer $\mathbf{s} \rightarrow \mathbf{0}$);
- el análisis asintótico (expandimos $\mathbf{s}$ alrededor de $\boldsymbol{\theta}_0$);
- la construcción del test LM (evalúa $\mathbf{s}$ en $\tilde{\boldsymbol{\theta}}$ bajo H_0).

1.3.2. La esperanza del score es cero

El resultado más importante sobre el score es que, evaluado en $\boldsymbol{\theta}_0$, tiene esperanza cero. Esto es lo que permite aplicar el teorema central del límite a $\mathbf{s}$ más adelante.

Proposición 1.4 (Esperanza del score). *Bajo condiciones de regularidad que permitan derivar bajo el signo integral:*

$$\mathbb{E}_{\boldsymbol{\theta}_0}[\mathbf{s}(\boldsymbol{\theta}_0; \mathbf{Y})] = \mathbf{0}. \quad (1.7)$$

Demostración. Dado que $f(\cdot; \boldsymbol{\theta})$ es una densidad, $\int f(\mathbf{y}; \boldsymbol{\theta}) d\mathbf{y} = 1$ para todo $\boldsymbol{\theta} \in \Theta$. Derivando ambos lados respecto a $\boldsymbol{\theta}$ (y

asumiendo que podemos intercambiar derivada e integral, la *condición de regularidad* clave aquí):

$$\mathbf{0} = \frac{\partial}{\partial \boldsymbol{\theta}} \int f(\mathbf{y}; \boldsymbol{\theta}) d\mathbf{y} = \int \frac{\partial f(\mathbf{y}; \boldsymbol{\theta})}{\partial \boldsymbol{\theta}} d\mathbf{y}.$$

Multiplicamos y dividimos el integrando por $f(\mathbf{y}; \boldsymbol{\theta})$:

$$\mathbf{0} = \int \frac{1}{f(\mathbf{y}; \boldsymbol{\theta})} \frac{\partial f(\mathbf{y}; \boldsymbol{\theta})}{\partial \boldsymbol{\theta}} \cdot f(\mathbf{y}; \boldsymbol{\theta}) d\mathbf{y} = \int \frac{\partial \log f(\mathbf{y}; \boldsymbol{\theta})}{\partial \boldsymbol{\theta}} \cdot f(\mathbf{y}; \boldsymbol{\theta}) d\mathbf{y}.$$

El lado derecho es $\mathbb{E}_{\boldsymbol{\theta}}[\mathbf{s}(\boldsymbol{\theta}; \mathbf{Y})]$, que es entonces $\mathbf{0}$ para todo $\boldsymbol{\theta}$ (y en particular para $\boldsymbol{\theta}_0$). $\square$

Este resultado tiene una lectura geométrica. En $\boldsymbol{\theta}_0$ —el valor verdadero— la pendiente *promedio* de la log-verosimilitud es cero. Lejos de $\boldsymbol{\theta}_0$, la pendiente promedio típicamente no es cero, y apunta hacia $\boldsymbol{\theta}_0$. El EMV es, en cierto sentido, el parámetro que imita esta propiedad *muestralmente*: $\mathbf{s}(\hat{\boldsymbol{\theta}}; \mathbf{y}) = \mathbf{0}$.

1.3.3. Información de Fisher

Definición 1.5 (Información de Fisher esperada). La *matriz de información de Fisher* es la varianza del score:

$$\mathcal{I}(\boldsymbol{\theta}) = \mathbb{V}_{\boldsymbol{\theta}}[\mathbf{s}(\boldsymbol{\theta}; \mathbf{Y})] = \mathbb{E}_{\boldsymbol{\theta}}[\mathbf{s} \mathbf{s}^{\top}], \quad (1.8)$$

(la segunda igualdad usa que $\mathbb{E}[\mathbf{s}] = \mathbf{0}$).

$\mathcal{I}(\boldsymbol{\theta})$ es simétrica y semidefinida positiva por construcción. En muestras iid, la información por observación es $\mathcal{I}_1(\boldsymbol{\theta}) = \mathbb{E}[\mathbf{s}_t \mathbf{s}_t^{\top}]$ y por independencia, $\mathcal{I}(\boldsymbol{\theta}) = T \cdot \mathcal{I}_1(\boldsymbol{\theta})$; es decir, la información crece linealmente con el tamaño muestral.

La identidad más importante sobre $\mathcal{I}(\boldsymbol{\theta})$ la conecta con el Hessiano:

Teorema 1.6 (Identidad de información). *Bajo regularidad:*

$$\mathcal{I}(\boldsymbol{\theta}) = -\mathbb{E}_{\boldsymbol{\theta}} \left[\frac{\partial^2 \ell(\boldsymbol{\theta}; \mathbf{Y})}{\partial \boldsymbol{\theta} \partial \boldsymbol{\theta}^{\top}} \right]. \quad (1.9)$$

Demostración. Partimos de $\mathbb{E}[\mathbf{s}(\boldsymbol{\theta}; \mathbf{Y})] = \int \mathbf{s}(\boldsymbol{\theta}; \mathbf{y}) f(\mathbf{y}; \boldsymbol{\theta}) d\mathbf{y} = \mathbf{0}$, que es válido para todo $\boldsymbol{\theta}$. Derivando ambos lados respecto a $\boldsymbol{\theta}^\top$:

$$\mathbf{0} = \int \left[\frac{\partial \mathbf{s}(\boldsymbol{\theta}; \mathbf{y})}{\partial \boldsymbol{\theta}^\top} f(\mathbf{y}; \boldsymbol{\theta}) + \mathbf{s}(\boldsymbol{\theta}; \mathbf{y}) \frac{\partial f(\mathbf{y}; \boldsymbol{\theta})}{\partial \boldsymbol{\theta}^\top} \right] d\mathbf{y}.$$

El primer término es la esperanza del Hessiano, $\mathbb{E}[\partial \mathbf{s} / \partial \boldsymbol{\theta}^\top]$. En el segundo, notamos que $\partial f / \partial \boldsymbol{\theta}^\top = f \cdot \mathbf{s}^\top$ (reescritura de la definición del score). Así:

$$\mathbf{0} = \mathbb{E} \left[\frac{\partial \mathbf{s}}{\partial \boldsymbol{\theta}^\top} \right] + \mathbb{E}[\mathbf{s} \mathbf{s}^\top].$$

Como $\partial \mathbf{s} / \partial \boldsymbol{\theta}^\top = \partial^2 \ell / \partial \boldsymbol{\theta} \partial \boldsymbol{\theta}^\top$ es el Hessiano, reordenando obtenemos (1.9). $\square$

Este resultado es operativamente importante: permite calcular $\mathcal{I}(\boldsymbol{\theta})$ vía el Hessiano esperado de ℓ , lo cual suele ser más directo que calcular $\mathbb{E}[\mathbf{s} \mathbf{s}^\top]$ explícitamente.

1.3.4. Información observada vs. esperada

Definición 1.7 (Información observada). La *información observada* evaluada en $\hat{\boldsymbol{\theta}}$ es

$$\mathcal{I}_O(\hat{\boldsymbol{\theta}}; \mathbf{y}) = - \frac{\partial^2 \ell(\boldsymbol{\theta}; \mathbf{y})}{\partial \boldsymbol{\theta} \partial \boldsymbol{\theta}^\top} \Big|_{\boldsymbol{\theta}=\hat{\boldsymbol{\theta}}}. \quad (1.10)$$

Las diferencias clave con $\mathcal{I}(\boldsymbol{\theta}_0)$ son:

- $\mathcal{I}_O$ usa la muestra concreta $\mathbf{y}$; $\mathcal{I}$ promedia sobre todas las muestras posibles.
- $\mathcal{I}_O$ se evalúa en $\hat{\boldsymbol{\theta}}$, no en $\boldsymbol{\theta}_0$ (que es desconocido).
- $\mathcal{I}_O$ es un subproducto natural del optimizador numérico: `optim(..., hessian=TRUE)` en R devuelve directamente $-\mathcal{I}_O$.

Por ley de grandes números, $T^{-1}\mathcal{I}_O(\hat{\boldsymbol{\theta}}; \mathbf{Y}) \xrightarrow{p} \mathcal{I}_1(\boldsymbol{\theta}_0)$, así que $\mathcal{I}_O$ es un estimador consistente de la información. En muestras pequeñas, Efron & Hinkley (1978) argumentan que $\mathcal{I}_O$ suele ser preferible para construir errores estándar, porque refleja mejor la incertidumbre de la muestra concreta. En este curso usamos $\mathcal{I}_O$ por defecto, por la razón pragmática adicional de que es lo que sale de `optim`.

1.3.5. Ejemplo: información en la normal iid

Volvamos al caso $y_t \stackrel{iid}{\sim} \mathcal{N}(\mu, \sigma^2)$ de la Sección 1.2.3. Calculemos la información de Fisher explícitamente. Las segundas derivadas de (1.4) son:

$$\begin{aligned}\frac{\partial^2 \ell}{\partial \mu^2} &= -\frac{T}{\sigma^2}, \\ \frac{\partial^2 \ell}{\partial \mu \partial \sigma^2} &= -\frac{1}{\sigma^4} \sum (y_t - \mu), \\ \frac{\partial^2 \ell}{\partial (\sigma^2)^2} &= \frac{T}{2\sigma^4} - \frac{1}{\sigma^6} \sum (y_t - \mu)^2.\end{aligned}$$

Tomando esperanza en $\boldsymbol{\theta}_0 = (\mu, \sigma^2)$, y usando $\mathbb{E}[(y_t - \mu)] = 0$ y $\mathbb{E}[(y_t - \mu)^2] = \sigma^2$:

$$\begin{aligned}\mathbb{E}\left[-\frac{\partial^2 \ell}{\partial \mu^2}\right] &= \frac{T}{\sigma^2}, \\ \mathbb{E}\left[-\frac{\partial^2 \ell}{\partial \mu \partial \sigma^2}\right] &= 0, \\ \mathbb{E}\left[-\frac{\partial^2 \ell}{\partial (\sigma^2)^2}\right] &= \frac{T}{2\sigma^4}.\end{aligned}$$

De modo que

$$\mathcal{I}(\mu, \sigma^2) = \begin{pmatrix} T/\sigma^2 & 0 \\ 0 & T/(2\sigma^4) \end{pmatrix}, \quad \mathcal{I}(\mu, \sigma^2)^{-1} = \begin{pmatrix} \sigma^2/T & 0 \\ 0 & 2\sigma^4/T \end{pmatrix}.$$

La matriz $\mathcal{I}$ es diagonal, lo que indica que $\hat{\mu}$ y $\hat{\sigma}^2$ son *asintóticamente independientes* bajo normalidad. De la diagonal leemos:

- $\text{Var}(\hat{\mu}) \approx \sigma^2/T$, que coincide con la varianza exacta del promedio muestral.
- $\text{Var}(\hat{\sigma}^2) \approx 2\sigma^4/T$: la precisión de la varianza depende de σ^4 , por eso la estimación es más difícil cuando σ es grande.

Observación 1.8. Este ejemplo ilustra por qué la información de Fisher también puede leerse como una medida local de *cuánta información* aporta la muestra sobre el parámetro: mientras mayor sea $\mathcal{I}$, menor la varianza asintótica del EMV, mayor la curvatura de ℓ en el óptimo, y más “puntuda” la función.

1.4. Propiedades asintóticas del EMV

¿Qué pasa con $\hat{\theta}_T$ cuando $T \rightarrow \infty$? Cuatro resultados, enunciados como un solo teorema, resumen lo esencial.

Teorema 1.9 (Propiedades asintóticas del EMV). *Bajo las siguientes condiciones de regularidad:*

- (R1) **Identificación:** θ_0 es el único maximizador de $\mathbb{E}[\ell(\theta; \mathbf{Y})]$.
- (R2) **Compacidad:** Θ es compacto y θ_0 está en su interior.
- (R3) **Continuidad:** $\ell(\theta; \mathbf{y})$ es continua en θ con probabilidad uno.
- (R4) **Dominación:** existe $M(\mathbf{y})$ con $\mathbb{E}[M(\mathbf{Y})] < \infty$ tal que $|\ell(\theta; \mathbf{y})| \leq M(\mathbf{y})$ para todo $\theta \in \Theta$.
- (R5) **Diferenciabilidad:** ℓ es dos veces continuamente diferenciable en una vecindad de θ_0 , con Hessiano dominado.

entonces:

1. **Consistencia:** $\hat{\theta}_T \xrightarrow{p} \theta_0$.

2. **Normalidad asintótica:**

$$\sqrt{T}(\hat{\theta}_T - \theta_0) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathcal{I}_1(\theta_0)^{-1}), \quad (1.11)$$

donde $\mathcal{I}_1(\theta_0)$ es la información por observación.

3. **Eficiencia:** $\mathcal{I}_1(\theta_0)^{-1}$ es la cota de Cramér-Rao; ningún estimador insesgado alcanza menor varianza asintótica.

4. **Invariancia:** si $g : \Theta \rightarrow \mathbb{R}^m$ es continua, entonces $g(\hat{\theta}_T)$ es el EMV de $g(\theta_0)$. Si g es diferenciable con Jacobiano $\mathbf{G} = \partial g / \partial \theta^\top$:

$$\sqrt{T}(g(\hat{\theta}_T) - g(\theta_0)) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathbf{G}\mathcal{I}_1^{-1}\mathbf{G}^\top).$$

Demostremos cada parte con un nivel de detalle apropiado para el curso. La idea de cada paso es transparente; los tecnicismos completos se encuentran en Hamilton (1994, cap. 14), Newey & McFadden (1994) o Davidson & MacKinnon (2004, cap. 9).

1.4.1. Consistencia

Demostración de consistencia. Sea $Q_T(\theta) = T^{-1}\ell(\theta; \mathbf{Y})$ la log-verosimilitud promedio muestral, y $Q_0(\theta) = \mathbb{E}[\log f(Y_t; \theta)]$ su contraparte poblacional. Por ley de grandes números uniforme —garantizada por (R2)-(R4)— tenemos

$$\sup_{\theta \in \Theta} |Q_T(\theta) - Q_0(\theta)| \xrightarrow{p} 0.$$

Por definición $\hat{\theta}_T = \arg \max Q_T$ y por (R1) $\theta_0 = \arg \max Q_0$. La identificación (R1) más la convergencia uniforme implican que cualquier sucesión de maximizadores de Q_T converge en probabilidad al maximizador de Q_0 : $\hat{\theta}_T \xrightarrow{p} \theta_0$. $\square$

Observación 1.10. La condición (R1) de identificación se traduce en la *desigualdad de información* o *desigualdad de Jensen* aplicada a verosimilitudes: para todo $\boldsymbol{\theta} \neq \boldsymbol{\theta}_0$,

$$\mathbb{E}_{\boldsymbol{\theta}_0}[\log f(Y; \boldsymbol{\theta}_0)] > \mathbb{E}_{\boldsymbol{\theta}_0}[\log f(Y; \boldsymbol{\theta})].$$

La prueba aprovecha $\mathbb{E}_{\boldsymbol{\theta}_0}[\log(f_{\boldsymbol{\theta}}/f_0)] = -D_{KL}(f_0\|f_{\boldsymbol{\theta}}) \leq 0$ con igualdad solo si $f_{\boldsymbol{\theta}} = f_0$ en casi todo punto. La divergencia de Kullback-Leibler es así el fundamento profundo de la consistencia del EMV.

1.4.2. Normalidad asintótica

Demostración de normalidad asintótica. Usamos expansión de Taylor de primer orden del score alrededor de $\boldsymbol{\theta}_0$. Como $\hat{\boldsymbol{\theta}}_T$ es un punto crítico, $\mathbf{s}(\hat{\boldsymbol{\theta}}_T; \mathbf{Y}) = \mathbf{0}$. Expandimos:

$$\mathbf{0} = \mathbf{s}(\hat{\boldsymbol{\theta}}_T; \mathbf{Y}) = \mathbf{s}(\boldsymbol{\theta}_0; \mathbf{Y}) + \mathbf{H}(\tilde{\boldsymbol{\theta}}_T; \mathbf{Y})(\hat{\boldsymbol{\theta}}_T - \boldsymbol{\theta}_0), \quad (1.12)$$

donde $\tilde{\boldsymbol{\theta}}_T$ está entre $\hat{\boldsymbol{\theta}}_T$ y $\boldsymbol{\theta}_0$ (por teorema del valor medio multivariado componente a componente) y $\mathbf{H}$ denota el Hessiano de ℓ .

Reordenando:

$$\hat{\boldsymbol{\theta}}_T - \boldsymbol{\theta}_0 = -\mathbf{H}(\tilde{\boldsymbol{\theta}}_T; \mathbf{Y})^{-1} \mathbf{s}(\boldsymbol{\theta}_0; \mathbf{Y}).$$

Multiplicamos por $\sqrt{T}$ y acomodamos:

$$\sqrt{T}(\hat{\boldsymbol{\theta}}_T - \boldsymbol{\theta}_0) = - \left[\frac{1}{T} \mathbf{H}(\tilde{\boldsymbol{\theta}}_T; \mathbf{Y}) \right]^{-1} \frac{1}{\sqrt{T}} \mathbf{s}(\boldsymbol{\theta}_0; \mathbf{Y}). \quad (1.13)$$

Analizamos los dos factores:

(i) Factor de Hessiano. Por consistencia $\tilde{\boldsymbol{\theta}}_T \xrightarrow{p} \boldsymbol{\theta}_0$. Por ley de grandes números uniforme y continuidad del Hessiano:

$$\frac{1}{T} \mathbf{H}(\tilde{\boldsymbol{\theta}}_T; \mathbf{Y}) \xrightarrow{p} \mathbb{E}[\mathbf{H}_1(\boldsymbol{\theta}_0)] = -\mathcal{I}_1(\boldsymbol{\theta}_0),$$

por la identidad de información (Teorema 1.6).

(ii) **Factor de score.** Dado que $\mathbf{s}(\boldsymbol{\theta}_0; \mathbf{Y}) = \sum_{t=1}^T \mathbf{s}_t(\boldsymbol{\theta}_0)$ donde $\mathbf{s}_t = \partial \log f(Y_t | \mathcal{F}_{t-1}; \boldsymbol{\theta}_0) / \partial \boldsymbol{\theta}$, con $\mathbb{E}[\mathbf{s}_t] = \mathbf{0}$ y $\mathbb{V}[\mathbf{s}_t] = \mathcal{I}_1(\boldsymbol{\theta}_0)$ (información por observación). Por teorema central del límite para sumas iid (o para martingale difference sequences en el caso serial):

$$\frac{1}{\sqrt{T}} \mathbf{s}(\boldsymbol{\theta}_0; \mathbf{Y}) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathcal{I}_1(\boldsymbol{\theta}_0)).$$

(iii) **Combinación por Slutsky.** Sustituyendo en (1.13):

$$\sqrt{T}(\hat{\boldsymbol{\theta}}_T - \boldsymbol{\theta}_0) \xrightarrow{d} \mathcal{I}_1(\boldsymbol{\theta}_0)^{-1} \mathcal{N}(\mathbf{0}, \mathcal{I}_1(\boldsymbol{\theta}_0)) \quad (1.14)$$

$$= \mathcal{N}(\mathbf{0}, \mathcal{I}_1(\boldsymbol{\theta}_0)^{-1} \mathcal{I}_1(\boldsymbol{\theta}_0) \mathcal{I}_1(\boldsymbol{\theta}_0)^{-1}) \quad (1.15)$$

$$= \mathcal{N}(\mathbf{0}, \mathcal{I}_1(\boldsymbol{\theta}_0)^{-1}). \quad (1.16)$$

Esto cierra la demostración. $\square$

Observación 1.11 (Caso dependiente). En series de tiempo, los $\mathbf{s}_t$ no son iid: dependen de la historia $\mathcal{F}_{t-1}$. El TCL anterior aplica sin cambios porque $\{\mathbf{s}_t\}$ forma una *martingale difference sequence* bajo el modelo correcto —es decir, $\mathbb{E}[\mathbf{s}_t | \mathcal{F}_{t-1}] = \mathbf{0}$ —, y existen teoremas centrales del límite para m.d.s. (Hall & Heyde, 1980). El resultado final es idéntico al iid.

1.4.3. Eficiencia y la cota de Cramér-Rao

Teorema 1.12 (Cota de Cramér-Rao). *Sea $\hat{\boldsymbol{\theta}}$ un estimador insesgado de $\boldsymbol{\theta}$, es decir $\mathbb{E}[\hat{\boldsymbol{\theta}}] = \boldsymbol{\theta}$. Entonces*

$$\mathbb{V}(\hat{\boldsymbol{\theta}}) \succeq \mathcal{I}(\boldsymbol{\theta})^{-1} \quad (1.17)$$

en el sentido matricial: la matriz $\mathbb{V}(\hat{\boldsymbol{\theta}}) - \mathcal{I}(\boldsymbol{\theta})^{-1}$ es semidefinida positiva.

Demostración. Basta considerar el caso escalar; la extensión multivariada se obtiene combinando con cualquier vector

unitario. Sea $\hat{\theta}$ insesgado; entonces $\mathbb{E}[\hat{\theta}] = \theta$, y derivando bajo el signo integral (regularidad):

$$\frac{\partial}{\partial \theta} \int \hat{\theta}(\mathbf{y}) f(\mathbf{y}; \theta) d\mathbf{y} = \int \hat{\theta} \frac{\partial f}{\partial \theta} d\mathbf{y} = \int \hat{\theta} \cdot \mathbf{s}(\theta; \mathbf{y}) f(\mathbf{y}; \theta) d\mathbf{y} = \mathbb{E}[\hat{\theta} \cdot \mathbf{s}] = 1.$$

Como $\mathbb{E}[\mathbf{s}] = 0$, $\text{Cov}(\hat{\theta}, \mathbf{s}) = \mathbb{E}[\hat{\theta} \mathbf{s}] = 1$. Por desigualdad de Cauchy-Schwarz:

$$\text{Cov}(\hat{\theta}, \mathbf{s})^2 \leq \mathbb{V}(\hat{\theta}) \mathbb{V}(\mathbf{s}).$$

Sustituyendo $\text{Cov}(\hat{\theta}, \mathbf{s}) = 1$ y $\mathbb{V}(\mathbf{s}) = \mathcal{I}(\theta)$:

$$1 \leq \mathbb{V}(\hat{\theta}) \mathcal{I}(\theta) \implies \mathbb{V}(\hat{\theta}) \geq \mathcal{I}(\theta)^{-1}. \quad \square$$

El Teorema 1.9 establece que el EMV *alcanza* esta cota asintóticamente. En ese sentido limitante, el EMV es *asintóticamente eficiente*: no existe otro estimador insesgado con menor varianza asintótica. Esta es la razón fundamental por la que MV es el método dominante en econometría paramétrica moderna.

1.4.4. Invariancia

Demostración de invariancia. Si $g : \Theta \rightarrow \mathbb{R}^m$ es biyectiva, $\psi = g(\theta)$ parametriza la misma familia, y la verosimilitud bajo ψ es idéntica a la bajo θ —solo cambia el argumento—. Entonces $\arg \max_{\psi} \ell = g(\arg \max_{\theta} \ell) = g(\hat{\theta}_{MV})$.

Si g no es biyectiva, se generaliza vía el EMV en la *imagen* de g : se define $\hat{\psi}_{MV}$ como cualquier valor en $g(\Theta)$ que maximice la verosimilitud perfilada; pero para g continua, la caracterización $\hat{\psi}_{MV} = g(\hat{\theta}_{MV})$ se preserva.

La distribución asintótica de $g(\hat{\theta})$ sigue del método delta: $\sqrt{T}(g(\hat{\theta}) - g(\theta_0)) \xrightarrow{d} \mathbf{G}(\theta_0) \cdot \mathcal{N}(\mathbf{0}, \mathcal{I}_1^{-1}) = \mathcal{N}(\mathbf{0}, \mathbf{G} \mathcal{I}_1^{-1} \mathbf{G}^\top)$. □

La invariancia es crucial en la práctica. Si nos interesa, por ejemplo, la vida media de un shock en un AR(1)

($h = \log(0,5)/\log|\phi|$), basta estimar $\hat{\phi}_{MV}$ y calcular $\hat{h} = \log(0,5)/\log|\hat{\phi}|$; el resultado es automáticamente el EMV de h , sin necesidad de re-estimar el modelo.

1.4.5. Implicaciones operativas

Resumamos lo que las propiedades asintóticas implican para el trabajo aplicado:

1. **Error estándar:** $\widehat{SE}(\hat{\theta}_i) = \sqrt{[\mathcal{I}_O^{-1}]_{ii}}$. Operativamente, se lee del Hessiano del optimizador.
2. **Intervalo de confianza al $(1 - \alpha) \cdot 100\%$:** $\hat{\theta}_i \pm z_{1-\alpha/2}\widehat{SE}$.
3. **p -valores:** se obtienen de la normalidad asintótica para tests individuales; para tests conjuntos usamos Wald, LR o LM (próxima sección).
4. **Transformaciones no lineales:** método delta. Ejemplo típico: reporte del efecto de largo plazo $\alpha/(1 - \beta)$ en un ADL.

1.5. Tests clásicos

Queremos testear hipótesis de la forma

$$H_0 : \mathbf{g}(\boldsymbol{\theta}) = \mathbf{0} \quad \text{vs.} \quad H_1 : \mathbf{g}(\boldsymbol{\theta}) \neq \mathbf{0},$$

donde $\mathbf{g} : \mathbb{R}^k \rightarrow \mathbb{R}^q$ es una función (posiblemente no lineal) que impone q restricciones. Ejemplos típicos en el curso:

- $\phi_2 = 0$ en un AR(2): ¿el segundo rezago aporta? ($q = 1$)
- $\alpha_1 + \beta_1 = 1$ en un GARCH(1,1): ¿IGARCH? ($q = 1$)
- $\Gamma_2 = \mathbf{0}$ en un VAR(2): ¿bastaría un VAR(1)? ($q = n^2$)

- Restricciones de identificación en SVAR. (q varía)

Hay tres formas naturales de testear. Las tres convergen al mismo estadístico asintótico pero difieren en qué estimación requieren.

1.5.1. Test de Wald

Definición 1.13 (Estadístico de Wald). Sea $\hat{\boldsymbol{\theta}}$ el EMV irrestricto. El estadístico de Wald para $H_0 : \mathbf{g}(\boldsymbol{\theta}) = \mathbf{0}$ es

$$W = \mathbf{g}(\hat{\boldsymbol{\theta}})^\top \left[\hat{\mathbf{G}} \hat{\text{Var}}(\hat{\boldsymbol{\theta}}) \hat{\mathbf{G}}^\top \right]^{-1} \mathbf{g}(\hat{\boldsymbol{\theta}}), \quad (1.18)$$

donde $\hat{\mathbf{G}} = \partial \mathbf{g} / \partial \boldsymbol{\theta}^\top \big|_{\hat{\boldsymbol{\theta}}}$ y $\hat{\text{Var}}(\hat{\boldsymbol{\theta}}) = T^{-1} \mathcal{I}_1(\hat{\boldsymbol{\theta}})^{-1}$ o equivalentemente $\mathcal{I}_O(\hat{\boldsymbol{\theta}})^{-1}$.

Teorema 1.14 (Distribución asintótica de Wald). *Bajo H_0 y regularidad, $W \xrightarrow{d} \chi_q^2$.*

Demostración. Por método delta, $\sqrt{T} \mathbf{g}(\hat{\boldsymbol{\theta}}) \xrightarrow{d} \mathcal{N}(\mathbf{g}(\boldsymbol{\theta}_0), \mathbf{G} \mathcal{I}_1^{-1} \mathbf{G}^\top)$. Bajo H_0 , $\mathbf{g}(\boldsymbol{\theta}_0) = \mathbf{0}$, así que

$$\mathbf{Z}_T = \sqrt{T} \left[\mathbf{G} \mathcal{I}_1^{-1} \mathbf{G}^\top \right]^{-1/2} \mathbf{g}(\hat{\boldsymbol{\theta}}) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathbf{I}_q).$$

Entonces $W = \mathbf{Z}_T^\top \mathbf{Z}_T \xrightarrow{d} \chi_q^2$ (suma de q normales estándar al cuadrado). $\square$

Caso escalar

Para $q = 1$ y $\mathbf{g}(\boldsymbol{\theta}) = \theta_i - c$:

$$W = \frac{(\hat{\theta}_i - c)^2}{\widehat{SE}^2(\hat{\theta}_i)}.$$

Tomando raíz cuadrada con signo, $\sqrt{W} = (\hat{\theta}_i - c) / \widehat{SE}$ es el familiar t -estadístico asintótico, distribuido $\mathcal{N}(0, 1)$ bajo H_0 . Así el “test t ” de econometría básica es un caso particular del test de Wald.

Propiedades

Ventajas: (i) solo requiere el modelo irrestricto; (ii) sale gratis del output de estimación; (iii) generalizable fácilmente a hipótesis multi-restricción.

Desventajas: (i) **no invariante a reparametrización:** probar $H_0 : \beta = 1$ vs. $H_0 : \log \beta = 0$ da estadísticos distintos; (ii) sensible a la elección funcional de $\mathbf{g}$; (iii) en muestras pequeñas puede tener rechazo por encima del nominal.

1.5.2. Test de razón de verosimilitud (LR)

Definición 1.15 (Estadístico LR). Sea $\hat{\boldsymbol{\theta}}$ el EMV irrestricto y $\tilde{\boldsymbol{\theta}}$ el EMV bajo $H_0 : \mathbf{g}(\boldsymbol{\theta}) = \mathbf{0}$. El estadístico de razón de verosimilitud es

$$LR = -2 \left[\ell(\tilde{\boldsymbol{\theta}}; \mathbf{y}) - \ell(\hat{\boldsymbol{\theta}}; \mathbf{y}) \right]. \quad (1.19)$$

Teorema 1.16 (Distribución asintótica de LR — Wilks, 1938). *Bajo H_0 y regularidad, $LR \xrightarrow{d} \chi_q^2$.*

Bosquejo. Expandimos $\ell(\tilde{\boldsymbol{\theta}})$ alrededor de $\hat{\boldsymbol{\theta}}$ por Taylor de segundo orden:

$$\ell(\tilde{\boldsymbol{\theta}}) = \ell(\hat{\boldsymbol{\theta}}) + \mathbf{s}(\hat{\boldsymbol{\theta}})^\top (\tilde{\boldsymbol{\theta}} - \hat{\boldsymbol{\theta}}) + \frac{1}{2} (\tilde{\boldsymbol{\theta}} - \hat{\boldsymbol{\theta}})^\top \mathbf{H}(\hat{\boldsymbol{\theta}}) (\tilde{\boldsymbol{\theta}} - \hat{\boldsymbol{\theta}}) + o_p(1).$$

El término lineal se anula porque $\mathbf{s}(\hat{\boldsymbol{\theta}}) = \mathbf{0}$. Entonces:

$$LR = -2[\ell(\tilde{\boldsymbol{\theta}}) - \ell(\hat{\boldsymbol{\theta}})] \approx -(\tilde{\boldsymbol{\theta}} - \hat{\boldsymbol{\theta}})^\top \mathbf{H}(\hat{\boldsymbol{\theta}}) (\tilde{\boldsymbol{\theta}} - \hat{\boldsymbol{\theta}}).$$

Por ley de grandes números $\mathbf{H}(\hat{\boldsymbol{\theta}})/T \xrightarrow{p} -\mathcal{I}_1$, así que

$$LR \approx T(\tilde{\boldsymbol{\theta}} - \hat{\boldsymbol{\theta}})^\top \mathcal{I}_1 (\tilde{\boldsymbol{\theta}} - \hat{\boldsymbol{\theta}}).$$

Por otro lado, bajo H_0 , $\sqrt{T}(\hat{\boldsymbol{\theta}} - \tilde{\boldsymbol{\theta}}) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathcal{I}_1^{-1} - [\mathcal{I}_1 - \mathbf{G}(\mathbf{G}\mathcal{I}_1^{-1}\mathbf{G}^\top)^{-1}\mathbf{G}^\top]^{-1})$, cuya forma cuadrática con $\mathcal{I}_1$ tiende a χ_q^2 (detalles en Davidson & MacKinnon, 2004, §10.6). $\square$

Propiedades

Ventajas: (i) **invariante a reparametrización** —depende solo del valor de ℓ , no del parámetro—; (ii) suele tener mejor comportamiento en muestras pequeñas; (iii) concepto simple: “cuánto pierdo en verosimilitud si impongo H_0 ”.

Desventajas: (i) requiere estimar **ambos** modelos (restringido y no restringido); (ii) requiere que la densidad sea correctamente especificada —no aplica sin ajuste a verosimilitud cuasi-correcta—.

1.5.3. Test de multiplicadores de Lagrange (LM, Score)

Definición 1.17 (Estadístico LM). Sea $\tilde{\boldsymbol{\theta}}$ el EMV bajo H_0 . El estadístico LM es

$$LM = \mathbf{s}(\tilde{\boldsymbol{\theta}}; \mathbf{y})^\top \mathcal{I}(\tilde{\boldsymbol{\theta}})^{-1} \mathbf{s}(\tilde{\boldsymbol{\theta}}; \mathbf{y}). \quad (1.20)$$

Teorema 1.18 (Distribución asintótica de LM). *Bajo H_0 y regularidad, $LM \xrightarrow{d} \chi_q^2$.*

Intuición. Bajo H_0 , el score debería estar cerca de cero en $\tilde{\boldsymbol{\theta}}$ (si $\tilde{\boldsymbol{\theta}} \approx \boldsymbol{\theta}_0$). Sin embargo, $\tilde{\boldsymbol{\theta}} \neq \hat{\boldsymbol{\theta}}$ por la restricción, y el score no se anula en $\tilde{\boldsymbol{\theta}}$ sino solo en $\hat{\boldsymbol{\theta}}$. La magnitud de $\mathbf{s}(\tilde{\boldsymbol{\theta}})$ mide cuánto cuesta, en términos de pendiente, cumplir la restricción.

Por TCL aplicado al score, $T^{-1/2}\mathbf{s}(\tilde{\boldsymbol{\theta}}) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathcal{I}_1)$ bajo H_0 (vía expansión alrededor de $\boldsymbol{\theta}_0$). Entonces:

$$LM = T \cdot [T^{-1/2}\mathbf{s}]^\top [\mathcal{I}_1]^{-1} [T^{-1/2}\mathbf{s}] \xrightarrow{d} \chi_q^2.$$

La dimensión q aparece porque bajo H_0 el score tiene solo q dimensiones efectivamente no nulas (las ortogonales a las restricciones ya son cero por la CPO de $\tilde{\boldsymbol{\theta}}$). $\square$

Por qué el test LM es poderoso en la práctica

LM solo requiere estimar el modelo **restringido** y evaluar el score en ese punto. Esto es clave en dos tipos de aplicación:

1. **Tests de diagnóstico automáticos:** Queremos ver si los residuos de un ARIMA presentan ARCH adicional. El modelo restringido (“no hay ARCH”) ya está estimado —es el ARIMA original—; el modelo irrestricto (con ARCH) sería costoso. LM usa solo lo barato. Ejemplos: Breusch-Godfrey para autocorrelación, ARCH-LM, White para heterocedasticidad.
2. **Exploración sistemática de modelos:** probar si agregar un conjunto adicional de variables o rezagos es necesario, sin estimar el modelo grande.

1.5.4. Equivalencia asintótica bajo H_0

Teorema 1.19 (Engle, 1984). *Bajo H_0 y regularidad, W , LR y LM son asintóticamente equivalentes en el sentido de que $W - LR \xrightarrow{p} 0$, $LR - LM \xrightarrow{p} 0$ y los tres convergen a la misma χ_q^2 .*

Este resultado es profundo pero tiene una implicación práctica matizada: **en muestras finitas los tres estadísticos pueden diferir**, a veces significativamente. Berndt & Savin (1977) mostraron además que en el modelo lineal con errores normales conocidos, se cumple $W \geq LR \geq LM$ por pura aritmética —la ordenación es determinística—. Esto implica que en muestras moderadas, usar Wald puede dar rechazos donde LM no los da, y la elección del test modifica la conclusión.

1.5.5. Guía práctica de selección

En este curso usaremos los tres según convenga:

Situación	Test	Justificación
Modelo irrestricto fácil de estimar, interés en una restricción simple	Wald	Gratis del output
Comparación de modelos jerárquicos (AR(p) vs AR(p+1), GARCH(1,1) vs GARCH(2,2))	LR	Requiere ambos; invariante
Diagnóstico post-estimación (ARCH, autocorrelación, heterocedasticidad)	LM	Solo necesita el restringido
Hipótesis que dependen de reparametrización (ej. restricción no lineal)	LR	Invariante
Muestra pequeña, quieres test conservador	LM	Menor tasa de rechazo típica

Tabla 1.1: Criterios prácticos de selección entre Wald, LR y LM.

- Wald: tests individuales de significancia (Módulos 1, 3).
- LR: elección de orden de ARIMA, VAR y VECM (Módulos 1, 3).
- LM: ARCH-LM (Módulo 2), Breusch-Godfrey (Módulo 1), tests de sobreidentificación en SVAR (Módulo 3).

1.6. Optimización numérica de la verosimilitud

Fuera de casos de texto como la normal iid, casi ninguna verosimilitud de series de tiempo admite forma cerrada. Para ARMA, GARCH, VAR con restricciones no lineales, modelos de estado-espacio, BVAR con hiperparámetros, necesitamos *optimización numérica*. Esta sección cubre los algoritmos, sus trampas habituales, y las heurísticas que hacen la diferencia entre un código que corre y uno que converge al óptimo global.

1.6.1. Newton-Raphson: el método de referencia

Consideremos $\ell(\boldsymbol{\theta})$ suave y con un máximo local único en una vecindad de cualquier $\boldsymbol{\theta}^{(k)}$ razonable. Expandimos por Taylor de segundo orden:

$$\ell(\boldsymbol{\theta}) \approx \ell(\boldsymbol{\theta}^{(k)}) + \mathbf{s}^{(k)\top}(\boldsymbol{\theta} - \boldsymbol{\theta}^{(k)}) + \frac{1}{2}(\boldsymbol{\theta} - \boldsymbol{\theta}^{(k)})^\top \mathbf{H}^{(k)}(\boldsymbol{\theta} - \boldsymbol{\theta}^{(k)}), \quad (1.21)$$

donde $\mathbf{s}^{(k)}$ y $\mathbf{H}^{(k)}$ son score y Hessiano evaluados en $\boldsymbol{\theta}^{(k)}$. Maximizando esta aproximación en $\boldsymbol{\theta}$:

$$\mathbf{0} = \frac{\partial}{\partial \boldsymbol{\theta}}[\dots] = \mathbf{s}^{(k)} + \mathbf{H}^{(k)}(\boldsymbol{\theta} - \boldsymbol{\theta}^{(k)}),$$

lo que despeja el *paso de Newton-Raphson*:

$$\boxed{\boldsymbol{\theta}^{(k+1)} = \boldsymbol{\theta}^{(k)} - [\mathbf{H}^{(k)}]^{-1} \mathbf{s}^{(k)}}. \quad (1.22)$$

Se itera hasta que $\|\boldsymbol{\theta}^{(k+1)} - \boldsymbol{\theta}^{(k)}\|$ o $\|\mathbf{s}^{(k+1)}\|$ caigan por debajo de una tolerancia.

Proposición 1.20 (Convergencia local). *Si $\boldsymbol{\theta}^{(0)}$ está suficientemente cerca de $\hat{\boldsymbol{\theta}}$ y $\mathbf{H}$ es continua y definida negativa en $\hat{\boldsymbol{\theta}}$, Newton-Raphson converge cuadráticamente: $\|\boldsymbol{\theta}^{(k+1)} - \hat{\boldsymbol{\theta}}\| \leq C\|\boldsymbol{\theta}^{(k)} - \hat{\boldsymbol{\theta}}\|^2$ para alguna constante C .*

La convergencia cuadrática es extremadamente rápida: si el error en la iteración k es 10^{-2} , en la siguiente será aproximadamente 10^{-4} , luego 10^{-8} . En la práctica, Newton-Raphson converge en 5–15 iteraciones cuando funciona.

Los modos de fallo

Newton-Raphson falla cuando:

1. $\mathbf{H}^{(k)}$ no es invertible o está mal condicionada.
2. $\mathbf{H}^{(k)}$ no es definida negativa —el paso apunta en dirección equivocada—.
3. $\boldsymbol{\theta}^{(0)}$ está lejos del óptimo y la aproximación cuadrática es mala.
4. Hay múltiples máximos locales: convergemos al local más cercano, no al global.

1.6.2. Cuasi-Newton: BFGS y L-BFGS-B

Calcular $\mathbf{H}$ analíticamente es a veces difícil. El método BFGS (Broyden-Fletcher-Goldfarb-Shanno) aproxima $\mathbf{H}^{(k)}$ iterativamente usando solo gradientes sucesivos: define una matriz $\mathbf{B}^{(k)}$ actualizada en cada paso mediante

$$\mathbf{B}^{(k+1)} = \mathbf{B}^{(k)} + \frac{\mathbf{y}^{(k)}\mathbf{y}^{(k)\top}}{\mathbf{y}^{(k)\top}\mathbf{s}^{(k)}} - \frac{\mathbf{B}^{(k)}\mathbf{s}^{(k)}\mathbf{s}^{(k)\top}\mathbf{B}^{(k)}}{\mathbf{s}^{(k)\top}\mathbf{B}^{(k)}\mathbf{s}^{(k)}},$$

donde $\mathbf{s}^{(k)} = \boldsymbol{\theta}^{(k+1)} - \boldsymbol{\theta}^{(k)}$ y $\mathbf{y}^{(k)} = \mathbf{s}^{(k+1)} - \mathbf{s}^{(k)}$. Aunque la fórmula se vea densa, la idea es: usar el cambio observado en el gradiente para estimar curvatura.

En R, `optim(method="BFGS")` implementa esta idea. Para problemas con restricciones de caja ($\ell_i \leq \theta_i \leq u_i$), L-BFGS-B es la opción.

1.6.3. Nelder-Mead: cuando no hay gradiente

Si el gradiente es imposible o costoso de calcular (por ejemplo, funciones objetivo con discontinuidades suaves), Nelder-Mead usa un *simplex* $k + 1$ -dimensional que se refleja, expandido, contraído, y reducido para moverse hacia el óptimo. Es lento pero robusto. En R, `optim(method="Nelder-Mead")` es el default.

1.6.4. Reparametrizaciones: una técnica infravalorada

Muchos parámetros de series de tiempo tienen dominios restringidos: $\sigma^2 > 0$, $|\phi| < 1$, $0 < \alpha < 1$ en GARCH, matrices positivo-definidas, etc. Optimizar con restricciones es numéricamente frágil: el optimizador se puede pegar a la frontera, o tomar un paso que viole la restricción.

Regla de oro: siempre que sea posible, reparametrizar para que el parámetro de optimización viva en $\mathbb{R}$ sin restricciones, y transformar al final.

Restricción	Reparametrización	Transformación inversa
$\sigma^2 > 0$	$\psi = \log \sigma^2 \in \mathbb{R}$	$\sigma^2 = e^\psi$
$ \phi < 1$	$\psi = \operatorname{arctanh}(\phi) \in \mathbb{R}$	$\phi = \tanh(\psi)$
$0 < p < 1$	$\psi = \log(p/(1 - p))$ (logit)	$p = e^\psi / (1 + e^\psi)$
$\alpha + \beta < 1$, ambos ≥ 0	Simplex vía transformación de Dirichlet	
Σ positiva-definida $n \times n$	$\Sigma = LL^\top$, L triang. inf. libre	

Tabla 1.2: Reparametrizaciones comunes para eliminar restricciones.

El costo de la reparametrización es doble: (i) hay que aplicar el método delta si queremos errores estándar en la escala original; (ii) la log-verosimilitud se escribe en la nueva escala. Ambos costos son pequeños comparados con las ganancias de estabilidad.

1.6.5. Diagnósticos de convergencia

Un optimizador que termina sin error *no* garantiza que el resultado es el óptimo global. Revisar siempre:

1. **Código de convergencia:** en `optim`, `fit$convergence == 0` significa que la tolerancia se alcanzó. Códigos distintos indican máximo de iteraciones excedido u otros problemas.
2. **Hessiano negativo-definido:** calcular `eigen(fit$hessian)$values`. Si todos son positivos (porque minimizamos $-\ell$), bien. Si alguno es negativo o cero, no estás en un máximo.
3. **Múltiples valores iniciales:** correr el optimizador con 5–10 puntos de arranque diferentes y verificar que todos convergen al mismo $\hat{\theta}$. Si no, hay múltiples máximos locales.
4. **Comportamiento del score:** al final, $\|\mathbf{s}(\hat{\theta})\|$ debería ser muy pequeño (orden de la tolerancia).
5. **Errores estándar:** diagonales del Hessiano invertido deben ser positivas. Negativos o NaN indican que $\mathcal{I}_O$ no es invertible o que el óptimo es de “silla”.

1.7. Implementación en R: MA(1) por MV

Implementamos todo el marco sobre un proceso MA(1). El código es deliberadamente explícito: cada paso visible, cada elección justificable. El objetivo pedagógico es que el estudiante **entienda** qué hace `arima()` internamente.

1.7.1. El modelo y su log-verosimilitud

Consideremos

$$y_t = \varepsilon_t + \theta \varepsilon_{t-1}, \quad \varepsilon_t \stackrel{iid}{\sim} \mathcal{N}(0, \sigma^2), \quad |\theta| < 1. \quad (1.23)$$

Las ε_t son *innovaciones*, no observables directamente. La estrategia estándar es “filtrarlas” recursivamente, condicionando en $\varepsilon_0 = 0$ (aproximación común, más transparente que el filtro de Kalman):

$$\hat{\varepsilon}_t = y_t - \theta \hat{\varepsilon}_{t-1}, \quad \hat{\varepsilon}_0 = 0. \quad (1.24)$$

Bajo normalidad, la log-verosimilitud condicional es

$$\ell(\theta, \sigma^2) = -\frac{T}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{t=1}^T \hat{\varepsilon}_t^2. \quad (1.25)$$

Observación 1.21. La condición $|\theta| < 1$ (invertibilidad) garantiza que la recursión (1.24) sea estable: los errores de la condición inicial $\varepsilon_0 = 0$ decaen geométricamente y no contaminan $\hat{\varepsilon}_t$ para t grande. Sin invertibilidad, la recursión diverge.

1.7.2. Datos simulados

Antes de estimar, simulamos datos con parámetros conocidos para verificar que el código recupera lo correcto.

```

1  #
  =====
2  # Modulo 0: Estimacion MA(1) por MV desde cero
3  #
  =====
4  set.seed(42)
5
6  # --- 1. Simular un MA(1) con parametros conocidos ---
7  T_sim <- 500
8  sigma_0 <- 1.2
9  theta_0 <- 0.6
10
11  eps <- rnorm(T_sim, 0, sigma_0)
12  y <- eps + theta_0 * c(0, eps[-T_sim])
13
14  # Verificacion rapida
15  mean(y); var(y) # deberia ~0 y ~sigma_0^2 * (1 +
    theta_0^2)
16  sigma_0^2 * (1 + theta_0^2) # 1.44 * 1.36 = 1.9584

```

1.7.3. Log-verosimilitud negativa

Implementamos la negativa porque `optim` minimiza por defecto. Reparametrizamos $\sigma^2 = e^\psi$ para no tener que imponer $\sigma^2 > 0$.

```

1  # --- 2. Log-verosimilitud negativa ---
2  # Parametros de optimizacion: par = c(theta, psi)
  donde psi = log(sigma^2)
3  neg_loglik_ma1 <- function(par, y) {
4    theta <- par[1]
5    sigma2 <- exp(par[2]) # siempre > 0 por construccion
6    T_obs <- length(y)
7
8    # Filtrar innovaciones: e_t = y_t - theta * e_{t-1}
9    e <- numeric(T_obs)
10   e[1] <- y[1] # condicion inicial: e_0 = 0
11   for (t in 2:T_obs) {
12     e[t] <- y[t] - theta * e[t-1]

```

```

13   }
14
15   # Log-verosimilitud (negativa)
16   0.5 * T_obs * log(2 * pi * sigma2) + 0.5 * sum(e^2)
      / sigma2
17 }

```

1.7.4. Optimización

```

1  # --- 3. Maximizar (minimizar la negativa) ---
2  # Valores iniciales: theta = 0.1, psi = log(1) = 0
3  init <- c(theta = 0.1, psi = 0)
4
5  fit <- optim(
6    par = init,
7    fn = neg_loglik_ma1,
8    y = y,
9    method = "BFGS",
10   hessian = TRUE,
11   control = list(reltol = 1e-10, maxit = 200)
12 )
13
14 # Convergencia?
15 fit$convergence # 0 = éxito
16 fit$counts # cuantas evaluaciones de f y gradiente
17
18 # Estimados en la escala original
19 theta_hat <- fit$par[1]
20 sigma2_hat <- exp(fit$par[2])
21 sigma_hat <- sqrt(sigma2_hat)
22
23 cat("theta_hat =", round(theta_hat, 4),
24     "(verdadero =", theta_0, ")\n")
25 cat("sigma_hat =", round(sigma_hat, 4),
26     "(verdadero =", sigma_0, ")\n")

```


1.7.5. Errores estándar vía información observada

El Hessiano del optimizador es $\mathbf{H} = \partial^2(-\ell)/\partial\theta\partial\theta^\top$, que coincide con $\mathcal{I}_O$ (porque nosotros minimizamos el negativo). Invertimos para obtener la covarianza asintótica:

```

1  # --- 4. Errores estandar ---
2  # Covarianza asintotica en la escala de optimizacion (
    theta, psi)
3  V_opt <- solve(fit$hessian)
4
5  # Error estandar de theta: directo, no cambio de
    escala
6  se_theta <- sqrt(V_opt[1,1])
7
8  # Error estandar de sigma: via metodo delta
9  # sigma = sqrt(exp(psi)) = exp(psi/2), d sigma / d psi
    = 0.5 * exp(psi/2) = 0.5 * sigma
10 jac_sigma <- 0.5 * sigma_hat
11 se_sigma <- sqrt(jac_sigma^2 * V_opt[2,2])
12
13 # Intervalos de confianza al 95%
14 ic_theta <- theta_hat + c(-1,1) * qnorm(0.975) *
    se_theta
15 ic_sigma <- sigma_hat + c(-1,1) * qnorm(0.975) *
    se_sigma
16
17 cat("IC 95% theta: [", round(ic_theta, 4), "]\n")
18 cat("IC 95% sigma: [", round(ic_sigma, 4), "]\n")

```

1.7.6. Validación contra arima()

```

1  # --- 5. Comparacion con la implementacion estandar
    ---
2  fit_std <- arima(y, order = c(0,0,1), include.mean =
    FALSE)
3
4  tabla <- data.frame(
5    Parametro = c("theta", "sigma"),
6    Verdadero = c(theta_0, sigma_0),

```

```

7   MV_manual = c(theta_hat, sigma_hat),
8   SE_manual = c(se_theta, se_sigma),
9   arima_R = c(coef(fit_std)[1], sqrt(fit_std$sigma2)),
10  SE_arima = c(sqrt(fit_std$var.coef[1,1]), NA)
11 )
12 print(tabla, row.names = FALSE)

```

Los resultados esperados son $\hat{\theta} \approx 0,60$, $\hat{\sigma} \approx 1,20$, con pequeñas diferencias entre los dos métodos porque `arima()` usa verosimilitud *exacta* vía filtro de Kalman (no condicional en $\varepsilon_0 = 0$) y distinto algoritmo de optimización. Las diferencias son del orden de la tercera o cuarta cifra decimal.

1.7.7. Tests de hipótesis aplicados

Probemos $H_0 : \theta = 0$ (¿realmente hay MA?).

Wald

```

1   W <- (theta_hat - 0)^2 / se_theta^2
2   p_W <- 1 - pchisq(W, df = 1)
3   cat("Wald =", round(W, 3), "p-valor =", format.pval(
    p_W), "\n")

```

LR

```

1   # Modelo restringido: theta = 0 (ruido blanco)
2   sigma2_restr <- mean(y^2) # MV bajo H_0
3   logLik_restr <- -0.5 * T_sim * log(2*pi*sigma2_restr)
4   -
5   0.5 * sum(y^2) / sigma2_restr
6   # Log-verosimilitud irrestricta (cambio de signo)
7   logLik_irr <- -fit$value
8
9   LR <- -2 * (logLik_restr - logLik_irr)
10  p_LR <- 1 - pchisq(LR, df = 1)
11  cat("LR =", round(LR, 3), "p-valor =", format.pval(
    p_LR), "\n")

```

LM

```

1  # LM evalua el score en theta_restr = 0, sigma2_restr
   = mean(y^2)
2  # Score analítico en H_0: para MA(1), d logLik / d
   theta en theta=0
3  # es (1/sigma^2) * sum(y_t * y_{t-1})
4  score_theta <- sum(y[-1] * y[-T_sim]) / sigma2_restr
5  # Informacion: bajo H_0 la info por obs es 1/(1-theta
   ^2) ~ 1, todo sobre sigma^2
6  info_theta <- (T_sim - 1) / sigma2_restr # aprox, con
   ajuste T-1
7
8  LM <- score_theta^2 / info_theta
9  p_LM <- 1 - pchisq(LM, df = 1)
10 cat("LM =", round(LM, 3), "p-valor =", format.pval(
   p_LM), "\n")

```

Bajo H_0 falsa (porque simulamos con $\theta_0 = 0,6$), esperamos los tres rechazos muy contundentes.

1.7.8. Visualización de la superficie de verosimilitud

```

1  # --- 6. Superficie de log-verosimilitud ---
2  library(ggplot2)
3
4  grid <- expand.grid(
5    theta = seq(-0.9, 0.9, length.out = 80),
6    lsig = seq(log(0.5), log(3), length.out = 80)
7  )
8  grid$loglik <- mapply(
9    function(th, ls) neg_loglik_ma1(c(th, ls), y),
10   grid$theta, grid$lsig
11 )
12
13 ggplot(grid, aes(theta, exp(lsig), z = loglik)) +
14   geom_contour_filled(bins = 25) +
15   geom_point(aes(x = theta_hat, y = sigma_hat^2),
16     inherit.aes = FALSE, colour = "red", size
17     = 3) +

```

```
17 labs(  
18   x = expression(theta),  
19   y = expression(sigma^2),  
20   title = "Log-verosimilitud MA(1) sobre (theta,  
           sigma^2)",  
21   subtitle = paste("Óptimo en (", round(theta_hat,  
           3), ",",  
22               round(sigma_hat^2, 3), ")")  
23 ) +  
24 theme_minimal() +  
25 theme(legend.position = "none")
```

El gráfico resultante muestra un máximo pronunciado —un pico relativamente “afilado”—, lo que refleja cuánta información contienen los datos. En esa visualización está la esencia de la información de Fisher: la curvatura local alrededor del pico.

1.8. Ejercicios

Ejercicio 1.8.1 (Normal con media conocida). Sea $y_1, \dots, y_T \stackrel{iid}{\sim} \mathcal{N}(0, \sigma^2)$.

- (a) Derive el EMV $\hat{\sigma}^2$.
- (b) Calcule la información de Fisher $\mathcal{I}(\sigma^2)$ en su forma tanto vía $\mathbb{E}[\mathbf{s}^2]$ como vía $-\mathbb{E}[\partial^2 \ell / \partial (\sigma^2)^2]$, y verifique la identidad de información.
- (c) Derive la distribución asintótica de $\hat{\sigma}^2$.

Ejercicio 1.8.2 (Exponencial). Sea $y_t \stackrel{iid}{\sim} \text{Exp}(\lambda)$ con densidad $f(y; \lambda) = \lambda e^{-\lambda y}$ para $y > 0$.

- (a) Derive $\hat{\lambda}_{MV}$.
- (b) Calcule $\mathcal{I}(\lambda)$ y compute la varianza asintótica de $\hat{\lambda}$.
- (c) Usando invariancia, derive el EMV y la varianza asintótica de la *vida media* $\mu = 1/\lambda$.

Ejercicio 1.8.3 (AR(1) por MV condicional). Sea $y_t = \phi y_{t-1} + \varepsilon_t$ con $\varepsilon_t \sim \mathcal{N}(0, \sigma^2)$ iid, $|\phi| < 1$, condicional en y_1 fijo.

- (a) Escriba $\ell(\phi, \sigma^2 \mid y_1)$.
- (b) Derive CPO y muestre que $\hat{\phi}_{MV}$ coincide con el estimador MCO de y_t sobre y_{t-1} .
- (c) Calcule $\mathcal{I}_1(\phi, \sigma^2)$ y compare con la varianza asintótica de MCO.

Ejercicio 1.8.4 (MA(1) — ejercicio computacional). Modifique el código de la Sección 1.7 para:

- (a) Probar 10 valores iniciales $\theta^{(0)} \in \{-0.9, -0.7, \dots, 0.9\}$ y verificar si todos convergen al mismo óptimo. ¿Qué encuentra cerca de la raíz unitaria $|\theta| = 1$?

- (b) Aumentar el tamaño muestral $T \in \{100, 500, 2000\}$ y verificar empíricamente que los errores estándar decrecen como $1/\sqrt{T}$.
- (c) Simular 1000 réplicas con $T = 500$, estimar θ en cada una, y verificar que la distribución empírica de $\sqrt{T}(\hat{\theta} - \theta_0)$ se aproxima a $\mathcal{N}(0, 1 - \theta_0^2)$ (la información asintótica de θ en un MA(1) es $1 - \theta^2$).

Ejercicio 1.8.5 (Equivalencia asintótica de los tres tests). Usando el mismo setup del MA(1), simule $T = 500$ observaciones con $\theta_0 = 0,05$ (pequeño pero no cero). Compute los tres estadísticos W , LR y LM para $H_0 : \theta = 0$. Repita con 500 réplicas y grafique la distribución empírica de cada uno. ¿Coinciden con la χ_1^2 ? ¿Hay diferencias sistemáticas en muestras finitas?

Ejercicio 1.8.6 (Cambio de parametrización). En el MA(1), defina $\psi = \arctan(\theta)$, de modo que $\psi \in (-\pi/2, \pi/2)$ sea equivalente a $\theta \in (-1, 1)$. Re-estime el modelo usando ψ como parámetro de optimización. Use el método delta para recuperar el error estándar de θ a partir del de ψ , y verifique que coincide con el original.

Bibliografía

- [1] Berndt, E. R. & Savin, N. E. (1977). Conflict among criteria for testing hypotheses in the multivariate linear regression model. *Econometrica*, 45(5), 1263–1277.
- [2] Davidson, R. & MacKinnon, J. G. (2004). *Econometric Theory and Methods*. Oxford University Press.
- [3] Efron, B. & Hinkley, D. V. (1978). Assessing the accuracy of the maximum likelihood estimator: Observed versus expected Fisher information. *Biometrika*, 65(3), 457–482.
- [4] Engle, R. F. (1984). Wald, likelihood ratio, and Lagrange multiplier tests in econometrics. En Z. Griliches & M. D. Intriligator (eds.), *Handbook of Econometrics*, vol. II, cap. 13. North-Holland.
- [5] Hall, P. & Heyde, C. C. (1980). *Martingale Limit Theory and Its Application*. Academic Press.
- [6] Hamilton, J. D. (1994). *Time Series Analysis*. Princeton University Press. [Capítulos 5 y 14.]
- [7] Kilian, L. & Lütkepohl, H. (2017). *Structural Vector Autoregressive Analysis*. Cambridge University Press. [Capítulo 2.]
- [8] Lütkepohl, H. (2005). *New Introduction to Multiple Time Series Analysis*. Springer.
- [9] Newey, W. K. & McFadden, D. (1994). Large sample estimation and hypothesis testing. En R. F. Engle & D. L. McFadden (eds.), *Handbook of Econometrics*, vol. IV, cap. 36. Elsevier.
- [10] Wilks, S. S. (1938). The large-sample distribution of the likelihood ratio for testing composite hypotheses. *Annals of Mathematical Statistics*, 9(1), 60–62.

Capítulo 2

Fundamentos y Análisis Univariado

Contenido

1.1. Introducción y motivación	2
1.1.1. ¿Por qué máxima verosimilitud?	2
1.1.2. Hoja de ruta del capítulo	4
1.1.3. Notación y convenciones	4
1.2. La función de verosimilitud	5
1.2.1. Densidad vs. verosimilitud: una distinción sutil pero fundamental	5
1.2.2. Factorización y log-verosimilitud	6
1.2.3. Ejemplo: muestra normal iid . . .	7
1.2.4. Verosimilitud condicional vs. exac- ta en series de tiempo	8
1.3. Score, información y sus identi- dades	9
1.3.1. El vector de score	9
1.3.2. La esperanza del score es cero . .	9
1.3.3. Información de Fisher	10
1.3.4. Información observada vs. espe- rada	11
1.3.5. Ejemplo: información en la nor- mal iid	12
1.4. Propiedades asintóticas del EMV	13
1.4.1. Consistencia	14
1.4.2. Normalidad asintótica	15
1.4.3. Eficiencia y la cota de Cramér-Rao	16
1.4.4. Invariancia	17
1.4.5. Implicaciones operativas	18
1.5. Tests clásicos	18
1.5.1. Test de Wald	19

1.5.2.	Test de razón de verosimilitud (LR)	20
1.5.3.	Test de multiplicadores de Lagrange (LM, Score)	21
1.5.4.	Equivalencia asintótica bajo H_0 .	22
1.5.5.	Guía práctica de selección	22
1.6.	Optimización numérica de la verosimilitud	24
1.6.1.	Newton-Raphson: el método de referencia	24
1.6.2.	Cuasi-Newton: BFGS y L-BFGS-B	25
1.6.3.	Nelder-Mead: cuando no hay gradiente	26
1.6.4.	Reparametrizaciones: una técnica infravalorada	26
1.6.5.	Diagnósticos de convergencia . .	27
1.7.	Implementación en R: MA(1) por MV	28
1.7.1.	El modelo y su log-verosimilitud	28
1.7.2.	Datos simulados	28
1.7.3.	Log-verosimilitud negativa	29
1.7.4.	Optimización	30
1.7.5.	Errores estándar vía información observada	31
1.7.6.	Validación contra <code>arima()</code>	31
1.7.7.	Tests de hipótesis aplicados . . .	32
1.7.8.	Visualización de la superficie de verosimilitud	33
1.8.	Ejercicios	35
	Bibliografía	37

Resumen

Este capítulo desarrolla el andamiaje conceptual y operativo de la econometría univariada de series de tiempo. Comenzamos con la teoría de procesos estocásticos: estacionariedad débil y estricta, ergodicidad, la función de autocovarianza, y el teorema de descomposición de Wold, que justifica la centralidad de la familia ARMA. A continuación desarrollamos los procesos MA, AR y ARMA con sus condiciones de estacionariedad e invertibilidad, sus ACF y PACF teóricas, y sus representaciones duales. Presentamos la metodología Box-Jenkins como protocolo de trabajo aplicado: identificación por ACF/PACF, estimación por máxima verosimilitud —usando el marco del Capítulo 0—, diagnóstico por tests de ruido blanco, y pronóstico con intervalos. El capítulo trata rigurosamente la no estacionariedad por raíz unitaria, con la derivación de los tests ADF, PP, KPSS y DF-GLS, incluyendo la distribución asintótica no-estándar y la discusión de su potencia limitada. Introduce SARIMA para estacionalidad. Cierra con implementación completa en R (paquetes `forecast`, `tseries`, `fable`) sobre un proceso simulado y una serie macroeconómica dominicana, incluyendo evaluación rolling-origin y comparación entre criterios de información.

2.1. Procesos estocásticos y estacionariedad

2.1.1. El objeto central: proceso estocástico

Una serie de tiempo es fundamentalmente distinta de una muestra transversal iid. En el caso iid, n observaciones son realizaciones independientes de una misma distribución; la inferencia se basa en replicar el experimento n veces.

En series de tiempo, observamos *una sola* trayectoria, y el desafío metodológico es inferir propiedades poblacionales a partir de esa única realización. Esto solo es posible si se imponen dos condiciones: *estacionariedad* (las propiedades distribucionales no cambian con el tiempo) y *ergodicidad* (promedios temporales convergen a esperanzas).

Definición 2.1 (Proceso estocástico). Un *proceso estocástico* es una familia $\{Y_t(\omega)\}_{t \in \mathbb{Z}}$ de variables aleatorias definidas sobre un espacio de probabilidad común $(\Omega, \mathcal{F}, \mathbb{P})$, indexadas por el tiempo t .

Para cada $\omega \in \Omega$ fijo, $\{Y_t(\omega)\}_t$ es una *trayectoria* o realización. Para cada t fijo, $Y_t(\cdot)$ es una variable aleatoria. Una serie de tiempo observada, $\mathbf{y} = (y_1, \dots, y_T)$, es un fragmento finito de una única trayectoria.

2.1.2. Estacionariedad estricta y débil

Definición 2.2 (Estacionariedad estricta). $\{Y_t\}$ es *estrictamente estacionaria* si para todo $k \in \mathbb{N}$, todo conjunto de tiempos $t_1 < \dots < t_k$, y todo desplazamiento $h \in \mathbb{Z}$, la distribución conjunta de $(Y_{t_1}, \dots, Y_{t_k})$ coincide con la de $(Y_{t_1+h}, \dots, Y_{t_k+h})$.

La estacionariedad estricta es una condición fuerte: requiere invariancia temporal de la distribución completa, no solo sus momentos. Para fines de inferencia basada en varianzas y covarianzas, alcanza una versión más débil.

Definición 2.3 (Estacionariedad débil o de segundo orden). $\{Y_t\}$ es *débilmente estacionaria* (o *estacionaria de covarianza*) si:

1. $\mathbb{E}[Y_t] = \mu$ constante en t ,
2. $\mathbb{V}[Y_t] = \sigma^2 < \infty$ constante en t ,
3. $\text{Cov}(Y_t, Y_{t-h}) = \gamma(h)$ depende solo del rezago h .

Proposición 2.4. *Estacionariedad estricta con segundos momentos finitos $\Rightarrow$ estacionariedad débil. La recíproca es falsa en general, pero es cierta para procesos gaussianos.*

Demostración. La primera afirmación es directa: la invariancia de la distribución conjunta implica la invariancia de $\mathbb{E}$, $\mathbb{V}$ y Cov . La segunda afirmación usa que una distribución gaussiana está completamente caracterizada por sus dos primeros momentos; si estos son invariantes, toda la distribución lo es. $\square$

En lo que sigue, cuando digamos "estacionario" sin calificativo, nos referiremos a estacionariedad débil. Es el concepto operativo central del curso.

2.1.3. Función de autocovarianza y autocorrelación

Definición 2.5. Para un proceso débilmente estacionario, definimos:

$$\gamma(h) = \text{Cov}(Y_t, Y_{t-h}) = \text{Cov}(Y_{t+h}, Y_t), \quad (2.1)$$

$$\rho(h) = \frac{\gamma(h)}{\gamma(0)}. \quad (2.2)$$

$\gamma(h)$ es la *función de autocovarianza* (ACVF); $\rho(h)$ la *función de autocorrelación* (ACF).

Proposición 2.6 (Propiedades básicas). *Para $\gamma(\cdot)$ de un proceso débilmente estacionario:*

1. $\gamma(0) = \mathbb{V}[Y_t] \geq 0$.
2. $|\gamma(h)| \leq \gamma(0)$ (Cauchy-Schwarz).
3. $\gamma(h) = \gamma(-h)$ (simetría).
4. La matriz $\Gamma_T = [\gamma(i-j)]_{i,j=1}^T$ es simétrica y semidefinida positiva.

Demostración. (1)-(3) siguen directamente de las propiedades de la covarianza. Para (4), la forma cuadrática $\mathbf{a}^\top \Gamma_T \mathbf{a} = \mathbb{V}(\sum a_i Y_i) \geq 0$ para todo $\mathbf{a} \in \mathbb{R}^T$. $\square$

La ACF contiene *toda* la estructura de dependencia lineal del proceso y es el objeto central de la identificación Box-Jenkins. Sus estimadores muestrales, usados universalmente en la práctica, son:

$$\hat{\gamma}(h) = \frac{1}{T} \sum_{t=h+1}^T (y_t - \bar{y})(y_{t-h} - \bar{y}), \quad \hat{\rho}(h) = \frac{\hat{\gamma}(h)}{\hat{\gamma}(0)}, \quad (2.3)$$

donde $\bar{y} = T^{-1} \sum y_t$. Dividir por T (en vez de $T-h$) garantiza que $\hat{\Gamma}_T$ sea semidefinida positiva.

2.1.4. Ergodicidad

La estacionariedad nos dice que los momentos no cambian. La ergodicidad nos dice que podemos estimar esos momentos consistentemente a partir de una única trayectoria.

Definición 2.7 (Ergodicidad en media). $\{Y_t\}$ es *ergódico en media* si

$$\bar{Y}_T = \frac{1}{T} \sum_{t=1}^T Y_t \xrightarrow{p} \mathbb{E}[Y_t].$$

Teorema 2.8 (Condición suficiente de ergodicidad). Si $\{Y_t\}$ es débilmente estacionario y $\sum_{h=0}^{\infty} |\gamma(h)| < \infty$, entonces es ergódico en media.

Demostración. Calculamos $\mathbb{V}[\bar{Y}_T]$:

$$\mathbb{V}[\bar{Y}_T] = \frac{1}{T^2} \sum_{i=1}^T \sum_{j=1}^T \gamma(i-j) = \frac{1}{T} \sum_{h=-(T-1)}^{T-1} \left(1 - \frac{|h|}{T}\right) \gamma(h).$$

Bajo la hipótesis $\sum |\gamma(h)| < \infty$, aplicamos convergencia dominada: para cada h , $(1 - |h|/T)\gamma(h) \rightarrow \gamma(h)$ pero dominado por $|\gamma(h)|$ sumable. Entonces $T \cdot \mathbb{V}[\bar{Y}_T] \rightarrow \sum_{h=-\infty}^{\infty} \gamma(h) < \infty$, y por tanto $\mathbb{V}[\bar{Y}_T] = O(1/T) \rightarrow 0$. Por desigualdad de Chebyshev, $\bar{Y}_T \xrightarrow{p} \mu$. $\square$

Observación 2.9. La ergodicidad es una propiedad sutil y no trivial. Un paseo aleatorio $Y_t = Y_{t-1} + \varepsilon_t$ no es estacionario ni ergódico: $\mathbb{V}[\bar{Y}_T]$ no tiende a cero, sino que crece con T . Esta es una de las razones fundamentales por las que la no estacionariedad $I(1)$ exige un tratamiento especial.

2.1.5. Ruido blanco

Definición 2.10 (Ruido blanco). $\{\varepsilon_t\}$ es ruido blanco, denotado $\varepsilon_t \sim \text{WN}(0, \sigma^2)$, si $\mathbb{E}[\varepsilon_t] = 0$, $\mathbb{V}[\varepsilon_t] = \sigma^2 < \infty$ y $\gamma(h) = 0$ para $h \neq 0$.

El ruido blanco es el "átomo" de la econometría de series: es el error teórico, la innovación irreducible, y el objetivo de los residuos de un modelo bien especificado.

Observación 2.11. Ruido blanco **no** implica independencia. La ausencia de correlación es un hecho de segundo momento; la independencia involucra todos los momentos. Un proceso puede tener $\gamma(h) = 0$ para $h \neq 0$ pero $\mathbb{E}[\varepsilon_t \varepsilon_{t-1}^2] \neq 0$ (dependencia no lineal). La coincidencia entre decorrelación e independencia requiere normalidad.

En distinciones prácticas:

- **Ruido blanco gaussiano iid:** $\varepsilon_t \stackrel{iid}{\sim} \mathcal{N}(0, \sigma^2)$. El caso más fuerte; garantiza independencia.
- **Ruido blanco estricto:** ε_t iid pero no necesariamente gaussiano.
- **Ruido blanco débil:** solo decorrelación y primeros dos momentos constantes.

Los modelos GARCH del próximo capítulo producirán residuos que son *ruido blanco débil pero no estricto*: sin autocorrelación lineal, pero con autocorrelación en los cuadrados.

2.2. Operador de rezagos y procesos lineales

2.2.1. El operador de rezagos

Definición 2.12 (Operador de rezagos). Sobre el espacio de procesos estocásticos, definimos el *operador de rezagos* L :

$$LY_t = Y_{t-1}, \quad L^k Y_t = Y_{t-k} \quad \forall k \in \mathbb{Z}.$$

L actúa sobre el proceso, no sobre valores numéricos. Sus propiedades algebraicas son las siguientes:

- **Linealidad:** $L(aX_t + bY_t) = aX_{t-1} + bY_{t-1}$.
- **Sobre constantes:** $Lc = c$ (constante es constante).
- **Potencias:** $L^i L^j = L^{i+j}$.
- **Polinomios:** para $\phi(z) = 1 - \phi_1 z - \dots - \phi_p z^p$, el *polinomio en el operador* es

$$\phi(L) = 1 - \phi_1 L - \dots - \phi_p L^p,$$

que actúa como $\phi(L)Y_t = Y_t - \phi_1 Y_{t-1} - \dots - \phi_p Y_{t-p}$.

Definición 2.13 (Operadores diferencia).

$$\Delta = 1 - L, \quad \Delta^d = (1 - L)^d, \quad \Delta_s = 1 - L^s.$$

Entonces $\Delta Y_t = Y_t - Y_{t-1}$ y $\Delta_s Y_t = Y_t - Y_{t-s}$.

La analogía clave: **los polinomios en L siguen exactamente las mismas reglas algebraicas que los polinomios ordinarios en z** . Esto significa que podemos factorizar, multiplicar, invertir y evaluar raíces como si fueran polinomios numéricos usuales. Esta analogía es el fundamento técnico de todo el análisis que sigue.

2.2.2. Procesos lineales y representación de Wold

Definición 2.14 (Proceso lineal). $\{Y_t\}$ es un *proceso lineal* (representación MA(∞)) si

$$Y_t - \mu = \sum_{j=0}^{\infty} \psi_j \varepsilon_{t-j} = \psi(L)\varepsilon_t, \quad (2.4)$$

con $\varepsilon_t \sim WN(0, \sigma^2)$, $\psi_0 = 1$, y la sumabilidad $\sum_{j=0}^{\infty} \psi_j^2 < \infty$.

Bajo esta definición, $\{Y_t\}$ es débilmente estacionario con

$$\gamma(h) = \sigma^2 \sum_{j=0}^{\infty} \psi_j \psi_{j+h}.$$

Teorema 2.15 (Descomposición de Wold, 1938). *Todo proceso débilmente estacionario $\{Y_t\}$ admite una descomposición única*

$$Y_t = V_t + \sum_{j=0}^{\infty} \psi_j \varepsilon_{t-j},$$

donde $\varepsilon_t \sim WN(0, \sigma^2)$, $\sum \psi_j^2 < \infty$, $\psi_0 = 1$, y $\{V_t\}$ es un proceso linealmente determinístico (*predictible exactamente a partir de su pasado*).

La descomposición de Wold es el justificador teórico de toda la econometría lineal de series de tiempo: afirma que cualquier proceso estacionario tiene una representación MA(∞) (más un componente determinístico que en la práctica es μ constante, tendencia, o estacionalidad determinística). Los modelos ARMA son simplemente aproximaciones parsimoniosas a esa representación infinita. En vez de estimar $\psi_0, \psi_1, \psi_2, \dots$ directamente —algo imposible con datos finitos—, especificamos una razón de polinomios finitos:

$$\psi(L) \approx \frac{\theta(L)}{\phi(L)},$$

con ϕ y θ polinomios de orden modesto.

2.3. Los modelos AR, MA y AR-MA

2.3.1. El proceso MA(q)

Definición 2.16 (Promedio móvil de orden q).

$$Y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q} = \mu + \theta(L) \varepsilon_t,$$

con $\varepsilon_t \sim \text{WN}(0, \sigma^2)$ y $\theta(L) = 1 + \theta_1 L + \cdots + \theta_q L^q$.

Estacionariedad

Un MA(q) es *siempre* débilmente estacionario, sin importar los valores de θ_i . La razón es que es una suma *finita* de términos de ruido blanco, y cualquier combinación lineal finita de variables aleatorias con segundos momentos finitos tiene segundos momentos finitos y no depende de t (por estacionariedad del WN).

Momentos

Proposición 2.17. Para un MA(q):

1. $\mathbb{E}[Y_t] = \mu$.
2. $\gamma(0) = \sigma^2 \sum_{j=0}^q \theta_j^2$ (con $\theta_0 = 1$).
3. $\gamma(h) = \sigma^2 \sum_{j=0}^{q-h} \theta_j \theta_{j+h}$ para $1 \leq h \leq q$.
4. $\gamma(h) = 0$ para $h > q$ (memoria finita).

Demostración. Sea $Z_t = Y_t - \mu = \sum_{j=0}^q \theta_j \varepsilon_{t-j}$ (con $\theta_0 = 1$). Entonces $\mathbb{E}[Z_t] = 0$ y

$$\text{Cov}(Z_t, Z_{t-h}) = \text{Cov} \left(\sum_j \theta_j \varepsilon_{t-j}, \sum_k \theta_k \varepsilon_{t-h-k} \right) = \sum_{j,k} \theta_j \theta_k \text{Cov}(\varepsilon_{t-j}, \varepsilon_{t-h-k})$$

Los ε son WN, así que $\text{Cov}(\varepsilon_{t-j}, \varepsilon_{t-h-k}) = \sigma^2$ si $t - j = t - h - k$, i.e. $k = j - h$, y cero de lo contrario. Sustituyendo: $\gamma(h) = \sigma^2 \sum_j \theta_j \theta_{j-h}$ con $0 \leq j - h \leq q$, es decir $h \leq j \leq q + h$; si $h > q$ no hay j válido y $\gamma(h) = 0$. $\square$

Implicación práctica: el $\text{MA}(q)$ tiene ACF con *corte abrupto* en $h = q$. Si observamos que la ACF empírica "desaparece" súbitamente después de cierto rezago, ese es un signo claro de MA.

Invertibilidad

Definición 2.18 (Invertibilidad). El $\text{MA}(q)$ es *invertible* si todas las raíces de $\theta(z) = 1 + \theta_1 z + \dots + \theta_q z^q = 0$ están estrictamente fuera del círculo unitario: $|z_i| > 1$.

Teorema 2.19. Si el $\text{MA}(q)$ es invertible, admite una representación $\text{AR}(\infty)$:

$$\pi(L)(Y_t - \mu) = \varepsilon_t, \quad \pi(L) = \theta(L)^{-1} = \sum_{j=0}^{\infty} \pi_j L^j,$$

con π_j convergiendo geométricamente a cero.

Bosquejo. La invertibilidad garantiza que $\theta(L)^{-1}$ existe como operador bien definido (serie absolutamente convergente) sobre el espacio de procesos estacionarios. Aplicamos a ambos lados de $Y_t - \mu = \theta(L)\varepsilon_t$: $\theta(L)^{-1}(Y_t - \mu) = \varepsilon_t$. Los coeficientes π_j se calculan recursivamente igualando potencias de L en $\pi(L)\theta(L) = 1$. $\square$

La invertibilidad es crucial para:

- **Identificabilidad:** dos MA con parámetros recíprocos respecto a la unidad producen la misma ACF. Por ejemplo, $\text{MA}(1)$ con $\theta = 2$ y $\sigma^2 = 1$ tiene la misma estructura que $\text{MA}(1)$ con $\theta = 0,5$ y $\sigma^2 = 4$. La restricción $|\theta| < 1$ selecciona la única representación invertible.

- **Pronóstico:** permite expresar ε_t en términos del pasado observable de Y_t .
- **Estimación:** la verosimilitud condicional usa filtrado recursivo (como en el Módulo 0), que converge solo si el proceso es invertible.

2.3.2. El proceso AR(p)

Definición 2.20 (Autorregresivo de orden p).

$$Y_t = c + \phi_1 Y_{t-1} + \cdots + \phi_p Y_{t-p} + \varepsilon_t, \quad \phi(L)Y_t = c + \varepsilon_t,$$

con $\phi(L) = 1 - \phi_1 L - \cdots - \phi_p L^p$ y $\varepsilon_t \sim \text{WN}(0, \sigma^2)$.

Estacionariedad

Teorema 2.21. *El AR(p) admite una solución estacionaria si y solo si todas las raíces de $\phi(z) = 0$ están fuera del círculo unitario.*

Idea. Factoricemos $\phi(z) = \prod_{i=1}^p (1 - z/z_i)$. Si todos los $|z_i| > 1$, el operador $\phi(L)^{-1} = \prod_i (1 - L/z_i)^{-1}$ admite expansión en serie absolutamente convergente. Entonces

$$Y_t = \phi(L)^{-1}(c + \varepsilon_t) = \frac{c}{\phi(1)} + \sum_{j=0}^{\infty} \psi_j \varepsilon_{t-j},$$

que es un proceso lineal estacionario. La recíproca (si alguna raíz está dentro del círculo, no hay solución estacionaria) requiere análisis más técnico, en la línea de Hamilton (1994, cap. 2). $\square$

Caso AR(1) en detalle

Sea $Y_t = \phi Y_{t-1} + \varepsilon_t$ con $|\phi| < 1$. Entonces:

- $\mathbb{E}[Y_t] = 0$.

- Representación MA(∞): $Y_t = \sum_{j=0}^{\infty} \phi^j \varepsilon_{t-j}$.
- $\gamma(0) = \mathbb{V}[Y_t] = \sigma^2 \sum_{j=0}^{\infty} \phi^{2j} = \sigma^2 / (1 - \phi^2)$.
- $\gamma(h) = \phi^h \gamma(0)$, $\rho(h) = \phi^h$.

La ACF del AR(1) decae exponencialmente, a diferencia del corte abrupto del MA. La velocidad de decaimiento está dada por $|\phi|$: cerca de la raíz unitaria ($|\phi| \rightarrow 1$) la persistencia es alta; cerca de cero, la serie es casi ruido.

Vida media

La *vida media* de un shock es el tiempo que tarda la función impulso-respuesta en reducirse a la mitad:

$$\phi^{h^*} = 0,5 \implies h^* = \frac{\log 0,5}{\log |\phi|}.$$

Para $\phi = 0,5$, $h^* = 1$; para $\phi = 0,8$, $h^* \approx 3,1$; para $\phi = 0,95$, $h^* \approx 13,5$. Esta métrica es útil para comunicar persistencia: "un shock monetario se extingue a la mitad en x trimestres".

AR(p): ecuaciones de Yule-Walker

Para un AR(p) estacionario, multiplicar la ecuación por Y_{t-h} y tomar esperanza da, para $h \geq 1$:

$$\gamma(h) = \phi_1 \gamma(h-1) + \cdots + \phi_p \gamma(h-p). \quad (2.5)$$

Estas son las *ecuaciones de Yule-Walker*. Dividiendo por $\gamma(0)$ obtenemos una recurrencia sobre $\rho(h)$ que permite calcular la ACF de forma recursiva. También proveen un método de estimación: reemplazar $\rho(h)$ por $\hat{\rho}(h)$ y resolver para $\hat{\phi}_i$ (aunque para el curso preferiremos MV).

2.3.3. El proceso ARMA(p, q)

Definición 2.22.

$$\phi(L)Y_t = c + \theta(L)\varepsilon_t.$$

Combina memoria finita del MA con memoria infinita geométrica del AR. Tres condiciones relevantes:

1. **Estacionariedad:** raíces de $\phi(z) = 0$ fuera del círculo unitario.
2. **Invertibilidad:** raíces de $\theta(z) = 0$ fuera del círculo unitario.
3. **Identificabilidad:** ϕ y θ sin raíces comunes. Si las tuvieran, podríamos cancelarlas e escribir el mismo proceso con menos parámetros.

ACF y PACF del ARMA

Las ACF y PACF del ARMA son *mixtas*: ambas decaen (exponencial/sinusoidalmente), sin corte abrupto. Esto hace que la identificación de (p, q) sea más difícil que en AR o MA puros. En la práctica, la regla Box-Jenkins sugiere comenzar con modelos parsimoniosos y aumentar complejidad solo si los residuos no son blancos.

2.3.4. La función de autocorrelación parcial (PACF)

Definición 2.23. La *autocorrelación parcial* en el rezago h , ϕ_{hh} , es el coeficiente de Y_{t-h} en la regresión

$$Y_t = \phi_{h1}Y_{t-1} + \phi_{h2}Y_{t-2} + \cdots + \phi_{hh}Y_{t-h} + \text{error}.$$

Es decir, ϕ_{hh} mide la correlación entre Y_t y Y_{t-h} *después de controlar* por los rezagos intermedios $Y_{t-1}, \dots, Y_{t-h+1}$.

Proposición 2.24. *Para un $AR(p)$, $\phi_{hh} = 0$ para todo $h > p$.*

Demostración. Para $h > p$ la regresión ideal sobre $Y_{t-1}, \dots, Y_{t-h}$ debería cargar sus coeficientes sobre $Y_{t-1}, \dots, Y_{t-p}$ (los verdaderos predictores) y poner cero en los demás. Formalmente, las ecuaciones de Yule-Walker determinan ϕ_{hh} y este satisface $\phi_{hh} = 0$ para $h > p$. $\square$

Modelo	ACF	PACF
$AR(p)$	Decae exponencial/sinusoidal	Corta tras p
$MA(q)$	Corta tras q	Decae
$ARMA(p, q)$	Decae tras q	Decae tras p

Esta tabla es el corazón de la identificación Box-Jenkins: inspeccionamos la ACF y PACF muestrales y proponemos (p, q) según los patrones.

2.4. La metodología Box-Jenkins

George Box y Gwilym Jenkins (1970) propusieron un protocolo iterativo de cuatro etapas que sigue siendo el estándar para modelado ARIMA. Es simple, robusto y pedagógicamente claro.

2.4.1. Las cuatro etapas

1. **Identificación.** Se determina el orden (p, d, q) inspeccionando: (i) la serie en niveles, para detectar tendencia o cambios de régimen; (ii) tests de raíz unitaria, para decidir d ; (iii) ACF y PACF de la serie (diferenciada si $d \geq 1$), para proponer (p, q) .
2. **Estimación.** Dados (p, d, q) , estimamos los parámetros por máxima verosimilitud condicional o exacta. En R, `arima()` usa Kalman para la exacta; `forecast::Arima` y `fable::ARIMA` son wrappers.
3. **Diagnóstico.** Verificamos que los residuos se comporten como ruido blanco: ACF residual dentro de bandas, test Ljung-Box no rechaza, distribución aproximadamente normal, ausencia de heterocedasticidad obvia.
4. **Pronóstico.** Si el diagnóstico es satisfactorio, generamos pronósticos puntuales e intervalos. Si no, volvemos al paso 1 con una especificación modificada.

2.4.2. ACF y PACF muestrales: distribución y bandas de confianza

Teorema 2.25 (Distribución asintótica de $\hat{\rho}(h)$ bajo WN). *Si $\{Y_t\}$ es ruido blanco con cuarto momento finito, entonces para $h \neq 0$:*

$$\sqrt{T} \hat{\rho}(h) \xrightarrow{d} \mathcal{N}(0, 1).$$

De este resultado derivan las bandas de confianza estándar: $\pm 1.96/\sqrt{T}$. Una autocorrelación muestral $\hat{\rho}(h)$ que cae fuera de esta banda se interpreta como "significativamente distinta de cero al 5 %" bajo la hipótesis nula de WN.

Observación 2.26. Dos precauciones con las bandas estándar:

- Las bandas suponen que el proceso *es* WN en la población. Si estamos inspeccionando una serie *no* WN, los $\hat{\rho}(h)$ tienen varianzas distintas. Bartlett (1946) da la fórmula general.
- Con 20 rezagos examinados, esperamos ≈ 1 "significativo" por puro azar al 5 %. Un solo $\hat{\rho}$ fuera de la banda no es evidencia de estructura; patrones sistemáticos sí lo son.

2.4.3. Test portmanteau de Ljung-Box

En vez de examinar cada $\hat{\rho}(h)$ individualmente, es útil un test conjunto.

Definición 2.27 (Estadístico Ljung-Box).

$$Q_{LB}(m) = T(T+2) \sum_{h=1}^m \frac{\hat{\rho}(h)^2}{T-h}.$$

Teorema 2.28. *Bajo H_0 : el proceso es WN, $Q_{LB}(m) \xrightarrow{d} \chi_m^2$. Si se aplica a residuos de un ARMA(p,q) estimado con parámetros $k = p + q$, los grados de libertad se ajustan a $m - k$.*

Bosquejo. Bajo WN, los $\sqrt{T}\hat{\rho}(h)$ son asintóticamente $\mathcal{N}(0, 1)$ independientes para $h \neq 0$. La suma de m normales al cuadrado sigue χ_m^2 . El factor $(T+2)/(T-h)$ es una corrección de muestra finita. Cuando los $\hat{\rho}$ provienen de residuos de un modelo estimado, k grados de libertad se consumen.^{en} la estimación. □

La regla práctica para m : aproximadamente $\min(20, T/4)$. En datos mensuales, $m = 24$ es estándar para cubrir dos ciclos anuales.

2.4.4. Filosofía Box-Jenkins y parsimonia

Box-Jenkins no busca "el modelo verdadero"—no existe, en el sentido estricto—, sino el más *parsimonioso* que produce residuos aproximadamente blancos. Tres principios operan:

1. **Parsimonia:** entre dos modelos con residuos aceptables, preferir el de menos parámetros. Criterios como BIC penalizan más la complejidad que AIC.
2. **Iteración:** el procedimiento es iterativo; si el diagnóstico falla, se modifica la especificación y se reestima.
3. **Pragmatismo:** el objetivo último (inferencia, pronóstico, simulación) determina qué trade-offs son aceptables.

Esta filosofía se opone a enfoques "fenomenológicos" que intentan modelar cada detalle de los datos. Para series macroeconómicas dominicanas, un SARIMA simple con 2-4 parámetros suele dominar en pronóstico a modelos más elaborados.

2.5. Raíces unitarias e integración

2.5.1. No estacionariedad por raíz unitaria

Retomemos el paseo aleatorio:

$$Y_t = Y_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim \text{WN}(0, \sigma^2).$$

Por iteración, $Y_t = Y_0 + \sum_{s=1}^t \varepsilon_s$, así que:

$$\mathbb{E}[Y_t | Y_0] = Y_0 \quad (\text{constante}), \quad (2.6)$$

$$\mathbb{V}[Y_t | Y_0] = t\sigma^2 \quad (\text{creciente}), \quad (2.7)$$

$$\text{Cov}(Y_t, Y_{t-h} | Y_0) = (t-h)\sigma^2 \quad (\text{dependiente de } t). \quad (2.8)$$

El proceso no es estacionario (la varianza y covarianzas dependen de t) ni ergódico ($\bar{Y}_T$ no converge a nada constante). Este comportamiento se extiende a cualquier $\text{AR}(p)$ donde $\phi(z) = 0$ tenga una raíz $|z| = 1$.

Definición 2.29 (Proceso integrado). $\{Y_t\}$ es *integrado de orden d* , denotado $Y_t \sim I(d)$, si $\Delta^d Y_t$ es estacionario pero $\Delta^{d-1} Y_t$ no lo es. Convenimos $I(0)$ significa estacionario.

2.5.2. Por qué importa: regresiones espurias

El resultado clásico de Granger y Newbold (1974) ilustra el peligro:

Teorema 2.30 (Regresión espuria). *Sean X_t y Y_t paseos aleatorios independientes. Si estimamos $Y_t = \alpha + \beta X_t + u_t$ por MCO con T grande:*

- R^2 tiende a una variable aleatoria no degenerada (no converge a cero).
- El t -estadístico sobre $\hat{\beta}$ diverge: $|t_{\beta}| \rightarrow \infty$.

- *Los residuos son también $I(1)$.*

Traducción: si regresamos dos series $I(1)$ no relacionadas, obtenemos alta R^2 y significancia espuria. La inferencia clásica falla. Este hallazgo motivó toda la literatura moderna de cointegración (Módulo 3). Mientras tanto, la regla operativa es: **no regresar variables $I(1)$ en niveles sin testear cointegración.**

2.5.3. Test de Dickey-Fuller (DF) y su versión aumentada (ADF)

Consideremos el modelo simple

$$Y_t = \rho Y_{t-1} + \varepsilon_t, \quad \varepsilon_t \sim \text{iid}(0, \sigma^2).$$

Queremos testear $H_0 : \rho = 1$ (raíz unitaria) contra $H_1 : |\rho| < 1$ (estacionario).

La trampa: distribución no estándar bajo la nula

La reparametrización estándar resta Y_{t-1} a ambos lados:

$$\Delta Y_t = \gamma Y_{t-1} + \varepsilon_t, \quad \gamma = \rho - 1. \quad (2.9)$$

$H_0 : \rho = 1$ se traduce en $H_0 : \gamma = 0$. Parecería que podemos usar el t -estadístico usual $t_\gamma = \hat{\gamma}/SE(\hat{\gamma})$. **Pero no funciona bajo H_0 :** la distribución asintótica *no* es normal, sino una funcional de movimientos brownianos.

Teorema 2.31 (Distribución asintótica de Dickey-Fuller).
Bajo $H_0 : \gamma = 0$ (*paseo aleatorio sin deriva*),

$$t_\gamma \xrightarrow{d} \frac{\int_0^1 W(r) dW(r)}{\sqrt{\int_0^1 W(r)^2 dr}},$$

donde $W(\cdot)$ es un movimiento browniano estándar sobre $[0, 1]$.

Esta distribución no tiene forma cerrada estándar; sus cuantiles se tabularon por simulación Monte Carlo. Para un caso "solo con constante", el valor crítico al 5% es aproximadamente $-2,86$; para con constante y tendencia", $-3,41$. Los valores son *más negativos* que los del t estándar ($-1,96$), reflejando que es más difícil rechazar la raíz unitaria.

El test aumentado (ADF)

Si Y_t sigue un $AR(p)$ más general con posible raíz unitaria:

$$Y_t = \alpha + \beta t + \rho Y_{t-1} + \sum_{j=1}^{p-1} \phi_j \Delta Y_{t-j} + \varepsilon_t.$$

Reparametrizando:

$$\Delta Y_t = \alpha + \beta t + \gamma Y_{t-1} + \sum_{j=1}^{p-1} \phi_j \Delta Y_{t-j} + \varepsilon_t. \quad (2.10)$$

Se testea $H_0 : \gamma = 0$ con el t -estadístico, y se comparan con los valores críticos ADF (diferentes según haya constante, tendencia, ambas o ninguna).

Decisiones prácticas

1. **Elección del componente determinístico.** Tres casos:

- Sin constante ni tendencia: raro en economía.
- Con constante, sin tendencia: apropiado para series que oscilan alrededor de una media (tasas, inflación mensual).
- Con constante y tendencia: apropiado para series con tendencia clara (niveles de PIB, precios).
Atención: incluir tendencia innecesariamente reduce potencia.

2. **Elección del orden p .** Reglas comunes: (i) fórmula de Schwert: $p = \lfloor 12(T/100)^{1/4} \rfloor$; (ii) criterio AIC o BIC; (iii) procedimiento general-a-específico: empezar con p grande y eliminar rezagos no significativos.
3. **Tamaño muestral.** El test tiene mala potencia con $T < 100$. Con $T > 200$ el comportamiento es más confiable.

2.5.4. Test de Phillips-Perron (PP)

Phillips y Perron (1988) propusieron una alternativa no paramétrica al ADF. En vez de aumentar la regresión con rezagos, corrigen el estadístico DF directamente por autocorrelación y heterocedasticidad usando un estimador HAC de la varianza de largo plazo.

- **Ventaja:** no requiere elegir p ; maneja heterocedasticidad.
- **Desventaja:** tiene tendencia a sobrerrechazar en muestras pequeñas y series con persistencia cerca de la unidad.

En la práctica, PP y ADF suelen dar resultados similares. Si divergen significativamente, es señal de heterocedasticidad o cambios estructurales.

2.5.5. Test de KPSS: la hipótesis inversa

Kwiatkowski, Phillips, Schmidt y Shin (1992) invirtieron las hipótesis:

$$H_0 : \text{estacionario} \quad \text{vs.} \quad H_1 : \text{raíz unitaria.}$$

El estadístico KPSS mide la dispersión acumulada de los residuos de una regresión de Y_t sobre constante (y quizá

tendencia):

$$KPSS = \frac{1}{T^2 \hat{\omega}^2} \sum_{t=1}^T S_t^2, \quad S_t = \sum_{s=1}^t \hat{e}_s,$$

donde $\hat{\omega}^2$ es un estimador HAC de la varianza de largo plazo. Bajo H_0 estacionaria, $KPSS$ es $O_p(1)$; bajo H_1 de raíz unitaria, $KPSS \rightarrow \infty$.

Estrategia combinada

La práctica estándar moderna es correr **tanto ADF como KPSS**:

ADF	KPSS	Diagnóstico
Rechaza H_0	No rechaza H_0	Estacionario (consenso)
No rechaza	Rechaza	Raíz unitaria (consenso)
Rechaza	Rechaza	Ambigüedad; posible cambio estructural
No rechaza	No rechaza	Baja potencia; muestra pequeña

2.5.6. Test DF-GLS

Elliott, Rothenberg y Stock (1996) propusieron una mejora al ADF mediante "detrending"GLS bajo la nula local. En esencia, antes de correr la regresión ADF, detrendean Y_t usando una regresión GLS con un valor de ρ cercano pero no igual a 1.

- **Ventaja:** tiene **mayor potencia** que ADF, especialmente cerca de la frontera estacionaria/no estacionaria. Es el test recomendado en muestras donde ADF no rechaza por poco.
- **Desventaja:** menos intuitivo; implementado en `urca::ur.ers` en R.

2.5.7. Limitaciones y cambios estructurales

Baja potencia cerca de la raíz

Es matemáticamente imposible distinguir con alta probabilidad un $AR(1)$ con $\phi = 1$ de uno con $\phi = 0,98$ usando $T = 100$. Los tests de raíz unitaria tienen baja potencia cerca de la frontera. Implicación: una "no rechazo" de raíz unitaria no es evidencia de su presencia; puede ser simplemente baja potencia.

Cambios estructurales

Teorema 2.32 (Perron, 1989). *Una serie estacionaria con un cambio estructural no considerado puede aparecer como $I(1)$ en ADF.*

Para la economía dominicana, cambios relevantes incluyen:

- Principios de los 90: apertura comercial y reformas.
- 2003: crisis bancaria.
- 2008-2010: crisis financiera global.
- 2020: pandemia.

Tests con quiebre endógeno (Zivot-Andrews, Lee-Strazicich) incluyen explícitamente un parámetro de fecha de quiebre optimizado bajo la alternativa. En `urca : ur.za`.

Regla de oro del curso

Ante duda razonable, **diferenciar**. El costo de sobre-diferenciar (introducir una raíz MA espuria) es asintóticamente menor que el costo de regresión espuria. Box-Jenkins lo expresa: cuando en duda, diferencia".

2.6. ARIMA y SARIMA

2.6.1. El modelo ARIMA(p, d, q)

Definición 2.33. $\{Y_t\}$ sigue un ARIMA(p, d, q) si $W_t = \Delta^d Y_t$ es ARMA(p, q) estacionario invertible:

$$\phi(L)(1 - L)^d Y_t = c + \theta(L)\varepsilon_t.$$

La I en ARIMA es por *integrado*. Un ARIMA(p, d, q) deshecho por diferenciación d veces da un ARMA(p, q) estacionario.

2.6.2. Interpretación de d

- $d = 0$: serie estacionaria. Ejemplos: tasas de interés reales, spreads, retornos financieros.
- $d = 1$: serie con una tendencia estocástica. Ejemplos típicos: PIB nominal, IPC, tipos de cambio, money supply.
- $d = 2$: serie cuyo crecimiento es $I(1)$. Raro en macro. Ejemplos eventuales: niveles de precios en países con alta inflación (la inflación misma es $I(1)$).

La elección de d se basa en:

1. Inspección visual: ¿hay tendencia obvia?
2. Tests ADF/KPSS sobre Y_t y sobre ΔY_t .
3. Comparación de modelos: ARIMA(0, 1, 1) vs ARIMA(1, 0, 0) con tendencia determinística.

2.6.3. SARIMA: incorporando estacionalidad

Muchas series económicas mensuales o trimestrales exhiben patrones estacionales: IPC con ciclo anual, comercio con picos en diciembre, turismo con estacionalidad tropical. Los modelos SARIMA capturan esto.

Definición 2.34 $(\text{SARIMA}(p, d, q)(P, D, Q)_s)$.

$$\phi(L) \Phi(L^s) (1 - L)^d (1 - L^s)^D Y_t = c + \theta(L) \Theta(L^s) \varepsilon_t,$$

donde $\Phi(\cdot), \Theta(\cdot)$ son polinomios en rezagos estacionales.

Desglose de componentes:

- $(1 - L)^d$: diferenciación regular, para tendencia estocástica.
- $(1 - L^s)^D$: diferenciación estacional, para estacionalidad estocástica. Para datos mensuales, $\Delta_{12} Y_t = Y_t - Y_{t-12}$.
- $\Phi(L^s) = 1 - \Phi_1 L^s - \dots - \Phi_P L^{Ps}$: AR estacional.
- $\Theta(L^s) = 1 + \Theta_1 L^s + \dots + \Theta_Q L^{Qs}$: MA estacional.

El airline model

El modelo más famoso, aplicado por Box y Jenkins al volumen mensual de pasajeros aéreos, es $\text{SARIMA}(0, 1, 1)(0, 1, 1)_{12}$:

$$\Delta \Delta_{12} Y_t = (1 + \theta L)(1 + \Theta L^{12}) \varepsilon_t.$$

Solo tres parámetros $(\theta, \Theta, \sigma^2)$, pero funciona sorprendentemente bien para series mensuales económicas: IPC, turismo, exportaciones por rubro.

2.6.4. Criterios de información: AIC, BIC y HQC

La identificación por ACF/PACF es visual y subjetiva. Criterios de información automatizan la elección entre modelos anidados o no anidados:

Definición 2.35 (Criterios de información).

$$\text{AIC} = -2\ell + 2k, \quad (2.11)$$

$$\text{BIC} = -2\ell + k \log T, \quad (2.12)$$

$$\text{HQC} = -2\ell + 2k \log \log T, \quad (2.13)$$

donde k es el número de parámetros y ℓ la log-verosimilitud maximizada.

Menor es mejor. Las propiedades clave son:

Teorema 2.36 (Propiedades asintóticas). ■ ***BIC es consistente:*** si el modelo verdadero está en el conjunto candidato y $T \rightarrow \infty$, BIC lo selecciona con probabilidad 1.

- ***AIC es eficiente:*** minimiza asintóticamente el error de predicción cuadrático esperado, incluso si ningún modelo candidato es exactamente verdadero.
- *BIC selecciona modelos más parsimoniosos que AIC para T grande (porque $\log T > 2$).*

La función `auto.arima()` del paquete `forecast` usa AIC corregido (AICc) por defecto, que ajusta AIC por tamaño muestral finito:

$$\text{AICc} = \text{AIC} + \frac{2k(k+1)}{T-k-1}.$$

En muestras pequeñas AICc penaliza más fuerte y evita sobre-parametrización.

2.7. Pronóstico y evaluación

2.7.1. Pronóstico óptimo bajo pérdida cuadrática

Teorema 2.37. *Bajo pérdida cuadrática $L(Y, \hat{Y}) = (Y - \hat{Y})^2$, el pronóstico que minimiza el error esperado condicional al pasado $\mathcal{F}_T$ es la esperanza condicional:*

$$\hat{Y}_{T+h|T} = \mathbb{E}[Y_{T+h} \mid \mathcal{F}_T].$$

Demostración. Sea $\hat{Y}$ cualquier pronóstico basado en $\mathcal{F}_T$. Descomponemos:

$$\begin{aligned} \mathbb{E}[(Y_{T+h} - \hat{Y})^2 \mid \mathcal{F}_T] &= \mathbb{E}[(Y_{T+h} - \mathbb{E}[Y_{T+h} \mid \mathcal{F}_T] + \mathbb{E}[Y_{T+h} \mid \mathcal{F}_T] - \hat{Y})^2 \mid \mathcal{F}_T] \\ &= \mathbb{E}[(Y_{T+h} - \mathbb{E}[\cdot])^2 \mid \mathcal{F}_T] + (\mathbb{E}[\cdot] - \hat{Y})^2, \end{aligned}$$

donde el término cruzado se anula porque $(\mathbb{E}[\cdot] - \hat{Y})$ es conocido dado $\mathcal{F}_T$. El primer término no depende de $\hat{Y}$; el segundo es ≥ 0 con igualdad *sii* $\hat{Y} = \mathbb{E}[Y_{T+h} \mid \mathcal{F}_T]$. $\square$

2.7.2. Pronóstico en un ARMA

Para un $\text{ARMA}(p, q)$ estacionario e invertible con representación $\text{MA}(\infty)$ $Y_t = \mu + \sum_{j=0}^{\infty} \psi_j \varepsilon_{t-j}$, el pronóstico a h pasos es:

$$\hat{Y}_{T+h|T} = \mu + \sum_{j=h}^{\infty} \psi_j \varepsilon_{T+h-j}, \quad (2.14)$$

es decir, se descartan los ψ_j asociados a innovaciones futuras (que tienen esperanza cero) y se retienen los asociados a innovaciones pasadas (observables).

El *error de pronóstico* es $e_{T+h|T} = Y_{T+h} - \hat{Y}_{T+h|T} = \sum_{j=0}^{h-1} \psi_j \varepsilon_{T+h-j}$, con varianza

$$\mathbb{V}[e_{T+h|T}] = \sigma^2 \sum_{j=0}^{h-1} \psi_j^2. \quad (2.15)$$

Bajo errores gaussianos, $Y_{T+h} \mid \mathcal{F}_T \sim \mathcal{N}(\hat{Y}_{T+h|T}, \sigma^2 \sum_{j=0}^{h-1} \psi_j^2)$, y los intervalos de pronóstico al $(1 - \alpha)$ de nivel son:

$$\hat{Y}_{T+h|T} \pm z_{1-\alpha/2} \sigma \sqrt{\sum_{j=0}^{h-1} \psi_j^2}.$$

La varianza del error crece con h : más lejos pronosticamos, más ancho el intervalo.

2.7.3. Métricas de precisión out-of-sample

Dadas predicciones $\hat{y}_1, \dots, \hat{y}_H$ y realizaciones $y_1, \dots, y_H$:

- **MSE**: $H^{-1} \sum (y_h - \hat{y}_h)^2$. Penaliza cuadráticamente; sensible a outliers.
- **RMSE**: $\sqrt{\text{MSE}}$. Misma unidad que la serie.
- **MAE**: $H^{-1} \sum |y_h - \hat{y}_h|$. Penaliza linealmente; más robusto.
- **MAPE**: $100 \cdot H^{-1} \sum |y_h - \hat{y}_h| / |y_h|$. En porcentaje; útil para comparar entre series.
- **MASE**: MAE escalado por el MAE de un benchmark naïve (Hyndman & Koehler, 2006). Entre los mejores para series con escalas muy distintas.

2.7.4. Validación rolling-origin

Definición 2.38. Sea T el total de observaciones y T_0 el tamaño inicial de entrenamiento. Para cada $t = T_0, T_0 + 1, \dots, T - 1$:

1. Estimar el modelo usando $\{y_1, \dots, y_t\}$.
2. Pronosticar $\hat{y}_{t+1|t}$ (y a horizontes más largos si se desea).

3. Registrar el error $e_{t+1} = y_{t+1} - \hat{y}_{t+1|t}$.

Reportar métricas sobre los errores recolectados.

La validación rolling-origin respeta la estructura temporal: cada pronóstico solo usa información disponible en el momento. Alternativas:

- **Ventana expandiente:** el entrenamiento crece monótonicamente.
- **Ventana deslizante:** el entrenamiento tiene tamaño fijo y "desliza".

Error común: usar validación cruzada k -fold aleatoria (estándar en ML) **no es válido** en series de tiempo, porque mezcla pasado y futuro. Los paquetes `tsibble`, `modeltime` y `tidymodels` implementan rolling-origin correctamente.

2.8. Implementación en R

Implementamos el pipeline completo Box-Jenkins sobre un proceso ARMA simulado y discutimos cómo adaptarlo a una serie macroeconómica dominicana (IPC o IMAE del BCRD). El código es reproducible y sigue las buenas prácticas que serán entregables del módulo.

2.8.1. Preparación

```

1 # Paquetes principales
2 library(forecast) # arima, auto.arima, forecast
3 library(tseries) # adf.test, kpss.test
4 library(urca) # ur.ers (DF-GLS), ur.kpss
5 library(ggplot2)
6 library(dplyr)
7
8 set.seed(2026)

```

2.8.2. Simulación de un proceso ARMA

Comenzamos con datos simulados: permiten verificar que el pipeline recupera la verdad antes de aplicarlo a datos reales.

```

1 # Simular un ARMA(1,1) con phi=0.7, theta=0.3, sigma=1
2 T_sim <- 300
3 y_sim <- arima.sim(
4   model = list(order = c(1,0,1), ar = 0.7, ma = 0.3),
5   n = T_sim,
6   sd = 1
7 )
8
9 # Guardar como ts para facilitar manipulacion
10 y <- ts(y_sim, frequency = 12)

```


2.8.3. Etapa 1: identificación

Inspección visual y tests de raíz unitaria

```
1 # Grafico de la serie
2 autoplot(y) +
3   labs(title = "Serie simulada ARMA(1,1)", y = "y", x
4         = "Tiempo") +
5   theme_minimal()
6
7 # Tests de raíz unitaria
8 adf.test(y) # H0: raíz unitaria
9 kpss.test(y) # H0: estacionario
10 summary(ur.ers(y, type = "DF-GLS", model = "constant")
11          )
```

Con los parámetros usados, ADF debería rechazar H_0 (el proceso es estacionario con $\phi = 0,7$) y KPSS no rechazar. Para una serie macro real en niveles, típicamente encontraríamos el patrón inverso —una señal de que hay que diferenciar—.

ACF y PACF

```
1 par(mfrow = c(1, 2))
2 Acf(y, lag.max = 24, main = "ACF")
3 Pacf(y, lag.max = 24, main = "PACF")
4 par(mfrow = c(1, 1))
```

Para un ARMA(1,1), tanto ACF como PACF decaerán gradualmente (no habrá corteçlaro), indicando que ambos componentes —AR y MA— son activos. En una serie AR pura, la PACF cortaríabrutamente tras p ; en una MA pura, la ACF cortaríabrutamente tras q .

2.8.4. Etapa 2: estimación

Ajuste manual: múltiples candidatos

```

1 candidatos <- list(
2   Arima(y, order = c(1, 0, 0)),
3   Arima(y, order = c(0, 0, 1)),
4   Arima(y, order = c(1, 0, 1)),
5   Arima(y, order = c(2, 0, 0)),
6   Arima(y, order = c(2, 0, 1))
7 )
8
9 # Tabla comparativa
10 tabla_ic <- data.frame(
11   Modelo = c("AR(1)", "MA(1)", "ARMA(1,1)", "AR(2)", "
12             ARMA(2,1)"),
13   AIC = sapply(candidatos, AIC),
14   BIC = sapply(candidatos, BIC),
15   logLik = sapply(candidatos, function(x) as.numeric(
16     logLik(x)))
17 )
18 print(tabla_ic, row.names = FALSE)

```

Selección automática

```

1 # auto.arima: busca el mejor (p,d,q) por AICc
2 fit_auto <- auto.arima(
3   y,
4   ic = "aicc",
5   stepwise = FALSE, # búsqueda exhaustiva
6   approximation = FALSE, # MV exacta
7   seasonal = FALSE
8 )
9 summary(fit_auto)

```

Con un proceso verdadero ARMA(1,1), `auto.arima` típicamente selecciona ARMA(1,1) o algo cercano, dependiendo del ruido muestral.

2.8.5. Etapa 3: diagnóstico

Análisis de residuos

```

1  # Diagnostico automatico: grafico + test
2  checkresiduals(fit_auto)
3
4  # Tests manuales
5  res <- residuals(fit_auto)
6  Box.test(res, lag = 20, type = "Ljung-Box", fitdf =
7    length(fit_auto$coef))
8  shapiro.test(res) # normalidad
9  jarque.bera.test(res) # asimetria y curtosis conjunta

```

Qué esperar de residuos "limpios":

- ACF dentro de las bandas $\pm 1,96/\sqrt{T}$ para todos los rezagos.
- Ljung-Box: $p\text{-valor} > 0,05$.
- Histograma aproximadamente normal (no obligatorio pero deseable).
- Sin patrones obvios en el gráfico temporal de residuos.

Si el diagnóstico falla, las direcciones de mejora son: (i) aumentar p o q ; (ii) agregar diferenciación; (iii) considerar heterocedasticidad (Módulo 2); (iv) modelar estacionalidad (SARIMA); (v) investigar cambios estructurales.

2.8.6. Etapa 4: pronóstico

Pronóstico puntual e intervalos

```

1  fc <- forecast(fit_auto, h = 24, level = c(80, 95))
2  autoplot(fc) +
3    labs(title = "Pronostico a 24 pasos con bandas al
4      80% y 95%",
5      y = "y", x = "Tiempo") +
6    theme_minimal()
7
8  # Valores numericos
9  as.data.frame(fc)

```

Validación rolling-origin

```

1  # Funcion de validacion rolling
2  rolling_rmse <- function(y, order, window_inicial =
    200, h = 1) {
3    T_obs <- length(y)
4    errores <- numeric(T_obs - window_inicial - h + 1)
5
6    for (t in window_inicial:(T_obs - h)) {
7      y_train <- y[1:t]
8      fit_t <- tryCatch(
9        Arima(y_train, order = order),
10       error = function(e) NULL
11      )
12      if (!is.null(fit_t)) {
13        pred <- forecast(fit_t, h = h)$mean[h]
14        errores[t - window_inicial + 1] <- y[t + h] -
          pred
15      }
16    }
17
18    sqrt(mean(errores^2, na.rm = TRUE))
19  }
20
21  # Comparar RMSE rolling para varios modelos
22  rmse_ar1 <- rolling_rmse(y, order = c(1, 0, 0))
23  rmse_arma11 <- rolling_rmse(y, order = c(1, 0, 1))
24  rmse_naive <- sqrt(mean(diff(y[200:T_sim])^2)) #
    benchmark:  $y_{t+1} = y_t$ 
25
26  cat("RMSE AR(1): ", round(rmse_ar1, 4), "\n")
27  cat("RMSE ARMA(1,1):", round(rmse_arma11, 4), "\n")
28  cat("RMSE naive: ", round(rmse_naive, 4), "\n")

```

2.8.7. Aplicación a una serie macro dominicana

Para el entregable del módulo, el estudiante aplica este pipeline a una serie real del BCRD. Típicamente:

- **IPC general (mensual)**: requiere $d = 1$ (tendencia)

y quizá $D = 1$ (estacionalidad). Airline model suele funcionar bien.

- **IMAE (mensual):** posible $d = 1$, estacionalidad. Diferenciación en logaritmo da la tasa de crecimiento.
- **Tipo de cambio peso/dólar:** casi siempre $d = 1$ (raíz unitaria clara).

Esquema del código:

```

1  # Leer datos (por ejemplo, desde un .xlsx del BCRD)
2  library(readxl)
3  datos <- read_excel("ipc_bcrd.xlsx")
4  ipc <- ts(datos$ipc_general, start = c(2000, 1),
5           frequency = 12)
6
7  # Transformacion: trabajar en logaritmos si es un
8    índice de precios
9
10 l_ipc <- log(ipc)
11
12 # Pipeline estandar
13 autoplot(l_ipc); Acf(l_ipc, 48); Pacf(l_ipc, 48)
14
15 adf.test(l_ipc)
16 kpss.test(l_ipc)
17 # Si no rechaza ADF y rechaza KPSS: diferenciar
18 d_ipc <- diff(l_ipc)
19
20 Acf(d_ipc, 48); Pacf(d_ipc, 48)
21 # Si hay picos cada 12 lags: estacionalidad ->
22   considerar SARIMA
23
24 fit_ipc <- auto.arima(l_ipc, seasonal = TRUE,
25                      stepwise = FALSE, approximation =
26                        FALSE)
27
28 summary(fit_ipc)
29 checkresiduals(fit_ipc)
30
31 fc_ipc <- forecast(fit_ipc, h = 12)
32 autoplot(fc_ipc)

```

2.8.8. Reproducibilidad: estructura de proyecto

El entregable debe venir en una estructura limpia:

```
1 proyecto_m1/  
2 |-- data/  
3 | |-- ipc_bcrd.xlsx  
4 |-- R/  
5 | |-- 01_importar.R  
6 | |-- 02_diagnostico.R  
7 | |-- 03_estimar.R  
8 | |-- 04_evaluar.R  
9 |-- output/  
10 | |-- graficos/  
11 | |-- tablas/  
12 |-- report.qmd  
13 |-- renv.lock  
14 |-- README.md
```

Usando `renv::init()` se captura el estado exacto del entorno R; `report.qmd` produce el reporte final en formato Quarto, combinando texto, código y resultados de forma reproducible. No se aceptan capturas de pantalla ni resultados pegados: todo debe correr de extremo a extremo con un único click.

2.9. Ejercicios

Ejercicio 2.9.1 (ACF de un ARMA(1,1)). Considere $Y_t = \phi Y_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1}$ con $|\phi| < 1$, $|\theta| < 1$, $\varepsilon_t \sim \text{WN}(0, \sigma^2)$.

- (a) Calcule $\gamma(0)$ y $\gamma(1)$.
- (b) Muestre que $\gamma(h) = \phi\gamma(h-1)$ para $h \geq 2$. Interprete.
- (c) Derive $\rho(1)$ y verifique que coincide con la fórmula de Hamilton (1994, ec. 3.4.11).

Ejercicio 2.9.2 (Invertibilidad y raíces). Para el MA(2) $Y_t = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2}$:

- (a) Escriba el polinomio $\theta(z)$ y sus raíces.
- (b) Muestre que el proceso es invertible si y solo si $|\theta_2| < 1$, $\theta_2 - \theta_1 < 1$ y $\theta_2 + \theta_1 > -1$.
- (c) Grafique la región de invertibilidad en el plano (θ_1, θ_2) .

Ejercicio 2.9.3 (Pronóstico AR(2)). Sea $Y_t = 0,5Y_{t-1} + 0,3Y_{t-2} + \varepsilon_t$ con $\varepsilon_t \sim \text{iid}\mathcal{N}(0, 1)$.

- (a) Verifique estacionariedad.
- (b) Calcule $\hat{Y}_{T+1|T}$, $\hat{Y}_{T+2|T}$, $\hat{Y}_{T+3|T}$ en términos de Y_T, Y_{T-1} .
- (c) Compute la varianza del error a 3 pasos.

Ejercicio 2.9.4 (Tests de raíz unitaria: simulación). (a) Simule 1000 series AR(1) con $\phi = 0,95$, $T = 200$. Calcule el porcentaje de rechazos de ADF al 5%. Repita con $\phi = 0,99$. Comente la baja potencia cerca de la raíz.

- (b) Simule 1000 paseos aleatorios con $T = 200$. Calcule el porcentaje de rechazos de KPSS. ¿Coincide con el nominal?

- (c) Regresión espuria: simule dos paseos aleatorios independientes, $T = 500$. Estime $Y_t = \alpha + \beta X_t + u_t$. Reporte $\hat{\beta}$, t_{β} , R^2 . Repita 500 veces y grafique la distribución de t_{β} vs. el t -Student.

Ejercicio 2.9.5 (Metodología Box-Jenkins aplicada). Descargue el IPC general mensual del BCRD (serie desde enero 2000). Aplique el pipeline completo:

- (a) Grafique niveles y log-niveles. ¿Cuál transformación es más natural?
- (b) Aplique ADF y KPSS sobre log IPC y su primera diferencia.
- (c) Identifique (p, q) por ACF/PACF sobre la serie estacionaria.
- (d) Compare con la selección de `auto.arima` bajo AIC y BIC.
- (e) Diagnostique residuos: Ljung-Box, normalidad, ARCH-LM.
- (f) Produzca pronóstico a 12 meses con bandas al 95 %. Interprete.
- (g) Evalúe rolling-origin contra benchmark naïve: ¿el modelo aporta?

Ejercicio 2.9.6 (SARIMA para turismo). Los datos de llegadas mensuales de turistas extranjeros exhiben estacionalidad marcada. Descargue la serie del BCRD y:

- (a) Aplique log y diferencie regular y estacionalmente $(\Delta\Delta_{12})$.
- (b) Identifique un SARIMA $(p, d, q)(P, D, Q)_{12}$ apropiado.
- (c) Compare con el *airline model* $(0,1,1)(0,1,1)_{12}$.

- (d) Para cada modelo, calcule RMSE rolling-origin sobre los últimos 36 meses.

Ejercicio 2.9.7 (AIC vs. BIC: selección de orden). Simule 500 réplicas de un $\text{AR}(2)$ con $\phi_1 = 0,5$, $\phi_2 = 0,3$ y $T \in \{100, 500, 2000\}$. En cada réplica, use AIC, BIC y AICc para seleccionar entre $\text{AR}(1)$, $\text{AR}(2)$, $\text{AR}(3)$, $\text{AR}(4)$. Reporte la distribución de órdenes seleccionados.

- (a) ¿Cuál criterio acierta más con el verdadero $p = 2$ conforme T crece?
- (b) ¿Cuál sobreestima sistemáticamente?
- (c) ¿Cuál subestima?

Bibliografía

- [1] Bartlett, M. S. (1946). On the theoretical specification and sampling properties of autocorrelated time-series. *Supplement to the Journal of the Royal Statistical Society*, 8(1), 27–41.
- [2] Box, G. E. P., Jenkins, G. M., Reinsel, G. C. & Ljung, G. M. (2015). *Time Series Analysis: Forecasting and Control*, 5ta ed. Wiley.
- [3] Dickey, D. A. & Fuller, W. A. (1979). Distribution of the estimators for autoregressive time series with a unit root. *Journal of the American Statistical Association*, 74(366), 427–431.
- [4] Elliott, G., Rothenberg, T. J. & Stock, J. H. (1996). Efficient tests for an autoregressive unit root. *Econometrica*, 64(4), 813–836.
- [5] Granger, C. W. J. & Newbold, P. (1974). Spurious regressions in econometrics. *Journal of Econometrics*, 2(2), 111–120.
- [6] Hamilton, J. D. (1994). *Time Series Analysis*. Princeton University Press. [Capítulos 2–4, 15, 17.]
- [7] Hyndman, R. J. & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice*, 3ra ed. OTexts. Disponible en <https://otexts.com/fpp3/>.
- [8] Hyndman, R. J. & Koehler, A. B. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4), 679–688.
- [9] Kwiatkowski, D., Phillips, P. C. B., Schmidt, P. & Shin, Y. (1992). Testing the null hypothesis of stationarity against the alternative of a unit root. *Journal of Econometrics*, 54(1–3), 159–178.

- [10] Ljung, G. M. & Box, G. E. P. (1978). On a measure of lack of fit in time series models. *Biometrika*, 65(2), 297–303.
- [11] Perron, P. (1989). The great crash, the oil price shock, and the unit root hypothesis. *Econometrica*, 57(6), 1361–1401.
- [12] Phillips, P. C. B. & Perron, P. (1988). Testing for a unit root in time series regression. *Biometrika*, 75(2), 335–346.
- [13] Wold, H. (1938). *A Study in the Analysis of Stationary Time Series*. Almqvist & Wiksell.

Capítulo 3

Volatilidad y Modelos No Lineales

Contenido

2.1. Procesos estocásticos y estacionariedad	42
2.1.1. El objeto central: proceso estocástico	42
2.1.2. Estacionariedad estricta y débil	43
2.1.3. Función de autocovarianza y autocorrelación	44
2.1.4. Ergodicidad	45
2.1.5. Ruido blanco	46
2.2. Operador de rezagos y procesos lineales	47
2.2.1. El operador de rezagos	47
2.2.2. Procesos lineales y representación de Wold	48
2.3. Los modelos AR, MA y ARMA	49
2.3.1. El proceso $MA(q)$	49
2.3.2. El proceso $AR(p)$	51
2.3.3. El proceso $ARMA(p, q)$	53
2.3.4. La función de autocorrelación parcial (PACF)	53
2.4. La metodología Box-Jenkins	55
2.4.1. Las cuatro etapas	55
2.4.2. ACF y PACF muestrales: distribución y bandas de confianza	55
2.4.3. Test portmanteau de Ljung-Box	56
2.4.4. Filosofía Box-Jenkins y parsimonia	57
2.5. Raíces unitarias e integración	58
2.5.1. No estacionariedad por raíz unitaria	58

2.5.2.	Por qué importa: regresiones espurias	58
2.5.3.	Test de Dickey-Fuller (DF) y su versión aumentada (ADF)	59
2.5.4.	Test de Phillips-Perron (PP)	61
2.5.5.	Test de KPSS: la hipótesis inversa	61
2.5.6.	Test DF-GLS	62
2.5.7.	Limitaciones y cambios estructurales	63
2.6.	ARIMA y SARIMA	64
2.6.1.	El modelo $ARIMA(p, d, q)$	64
2.6.2.	Interpretación de d	64
2.6.3.	SARIMA: incorporando estacionalidad	65
2.6.4.	Criterios de información: AIC, BIC y HQC	66
2.7.	Pronóstico y evaluación	67
2.7.1.	Pronóstico óptimo bajo pérdida cuadrática	67
2.7.2.	Pronóstico en un ARMA	67
2.7.3.	Métricas de precisión out-of-sample	68
2.7.4.	Validación rolling-origin	68
2.8.	Implementación en R	70
2.8.1.	Preparación	70
2.8.2.	Simulación de un proceso ARMA	70
2.8.3.	Etapas 1: identificación	71
2.8.4.	Etapas 2: estimación	71
2.8.5.	Etapas 3: diagnóstico	72
2.8.6.	Etapas 4: pronóstico	73
2.8.7.	Aplicación a una serie macro dominicana	74

2.8.8. Reproducibilidad: estructura de proyecto	76
2.9. Ejercicios	77
Bibliografía	80

Resumen

*Este capítulo extiende el marco ARMA del Capítulo 1 en dos direcciones que responden a limitaciones reales en datos económicos y financieros. Primero, la heterocedasticidad condicional: los residuos de un ARMA bien especificado pueden estar decorrelacionados en niveles pero con autocorrelación en sus cuadrados —el fenómeno de volatility clustering—. Se desarrollan los modelos ARCH (Engle, 1982) y GARCH (Bollerslev, 1986) con sus momentos, condiciones de estacionariedad y propiedades de generación de colas pesadas; se demuestra que un ARCH genera curtosis excesiva incluso con innovaciones gaussianas. Se presentan las extensiones asimétricas (EGARCH, GJR, APARCH) motivadas por el efecto leverage, y distribuciones alternativas (*t* de Student, GED). Se deriva la verosimilitud del GARCH con discusión de cuasi-MV y robustez. Segundo, no linealidades por cambios de régimen: los modelos TAR/TVAR de Tong (régimen observable con umbral) y MS-AR de Hamilton (régimen latente markoviano), con atención al problema de Davies (parámetro de ruptura no identificado bajo H_0) y el filtro de Hamilton. El capítulo cierra con implementación completa en R usando **rugarch**, **tsDyn** y **MSuM**, aplicada a retornos del tipo de cambio peso/dólar del BCRD, con énfasis en diagnóstico, pronóstico de volatilidad y cálculo de Value at Risk.*

3.1. Hechos estilizados y motivación

3.1.1. Lo que ARMA no puede capturar

El Capítulo 1 cerró con una frase importante: "un ARMA bien especificado produce residuos blancos en media". La expresión "blancos en media" contiene una reserva crucial.

Los residuos pueden tener $\text{Corr}(\hat{\varepsilon}_t, \hat{\varepsilon}_{t-h}) \approx 0$ —decorrelación— y aun así presentar estructura en sus *cuadrados*: $\text{Corr}(\hat{\varepsilon}_t^2, \hat{\varepsilon}_{t-h}^2) > 0$. Esta estructura refleja que la *varianza condicional* —la incertidumbre sobre el siguiente período dado el pasado— no es constante: varía con el tiempo y depende de información reciente.

En datos financieros, este fenómeno es universal y va acompañado de un conjunto de observaciones empíricas conocidas como *hechos estilizados*:

1. **Retornos aproximadamente no correlacionados en niveles.** El mercado es casi eficiente en el corto plazo: $\text{Corr}(r_t, r_{t-h}) \approx 0$ para $h \geq 1$. Un AR pequeño sobre r_t típicamente no sobrevive diagnóstico.
2. **Cuadrados de retornos con persistencia alta.** $\text{Corr}(r_t^2, r_{t-h}^2)$ puede ser 0,2 o más, y decaer lentamente en h . Equivalentemente, $|r_t|$ también es persistente.
3. **Volatility clustering.** Períodos de alta volatilidad suceden a períodos de alta volatilidad; lo mismo con baja volatilidad. La varianza condicional se agrupa en el tiempo.
4. **Colas pesadas.** Histogramas de retornos estandarizados presentan más masa en las colas que la normal. La curtosis empírica de retornos diarios suele estar entre 4 y 10, contra 3 de la normal.
5. **Asimetría negativa.** La distribución de retornos tiene sesgo negativo moderado: caídas grandes son más frecuentes que subidas grandes del mismo tamaño.
6. **Efecto leverage.** Shocks negativos en retornos elevan la volatilidad más que shocks positivos del mismo tamaño (Black, 1976).

7. **Co-movimientos de volatilidad.** En contextos multivariados, momentos de stress elevan la volatilidad simultáneamente en múltiples activos.

Este módulo aborda los primeros cinco hechos. El sexto motiva los modelos asimétricos. El séptimo pertenece al módulo multivariado de volatilidad (MGARCH), fuera del programa de este curso.

3.1.2. El contexto dominicano

Los hechos estilizados anteriores, desarrollados sobre mercados accionarios anglosajones, aplican también a series financieras dominicanas con matices:

- **Tipo de cambio peso/dólar:** exhibe volatility clustering marcado, especialmente alrededor de eventos como la crisis bancaria de 2003. La literatura de MACROPOL ha documentado que un GARCH(1,1) con t -Student captura la mayoría de la dinámica.
- **Inflación:** aunque es de frecuencia mensual (no diaria), también presenta clusters de alta variabilidad. La inflación de bienes transables vs. no transables tiene dinámicas de varianza distintas.
- **Tasa interbancaria:** períodos de iliquidez (típicamente fin de año) generan clusters de volatilidad en las tasas.

3.1.3. El lenguaje: varianza condicional

Formalicemos el concepto central. Sea $\{Y_t\}$ un proceso con filtración $\{\mathcal{F}_t\}$ (historia hasta t inclusive).

Definición 3.1 (Media y varianza condicional).

$$\mu_t = \mathbb{E}[Y_t \mid \mathcal{F}_{t-1}], \quad (3.1)$$

$$h_t = \mathbb{V}[Y_t \mid \mathcal{F}_{t-1}] = \mathbb{E}[(Y_t - \mu_t)^2 \mid \mathcal{F}_{t-1}]. \quad (3.2)$$

Los modelos ARMA del Capítulo 1 especifican μ_t : por ejemplo, en un AR(1), $\mu_t = \phi Y_{t-1}$. Los modelos GARCH de este capítulo especifican h_t : h_t depende de información pasada de forma explícita.

Definición 3.2 (Descomposición estándar). Se escribe habitualmente

$$Y_t = \mu_t + \varepsilon_t, \quad \varepsilon_t = \sqrt{h_t} z_t, \quad z_t \stackrel{iid}{\sim} (0, 1),$$

donde z_t es una innovación estandarizada con distribución (usualmente $\mathcal{N}(0, 1)$ o t_ν escalada).

Con esta descomposición, modelar $\{Y_t\}$ significa especificar tres cosas: (i) la ecuación de la media μ_t ; (ii) la ecuación de la varianza h_t ; (iii) la distribución de z_t . La primera es ARMA, del Capítulo 1. Las otras dos son el corazón de este capítulo.

3.1.4. Diagnóstico de ARCH: ACF de los cuadrados y test ARCH-LM

Antes de modelar la varianza, necesitamos diagnosticar si hay estructura. Dos herramientas:

ACF de residuos al cuadrado

Tras estimar un ARMA, se examina la ACF y PACF de $\hat{\varepsilon}_t^2$. Si son dentro de bandas $\pm 1.96/\sqrt{T}$, no hay evidencia de ARCH. Si hay picos significativos, hay heterocedasticidad condicional.

Test ARCH-LM de Engle (1982)

Es un test LM puro dentro del marco del Módulo 0. Bajo H_0 : no hay ARCH —la varianza condicional es constante σ^2 —, H_1 : hay ARCH de orden q .

Procedimiento:

1. Estimar el ARMA y obtener residuos $\hat{\varepsilon}_t$.
2. Regresar $\hat{\varepsilon}_t^2$ sobre constante y $\hat{\varepsilon}_{t-1}^2, \dots, \hat{\varepsilon}_{t-q}^2$.
3. Calcular R^2 de esta regresión auxiliar.
4. El estadístico es $LM = T \cdot R^2$.

Teorema 3.3. *Bajo H_0 de no-ARCH, $LM = T \cdot R^2 \xrightarrow{d} \chi_q^2$.*

Bosquejo. Bajo H_0 , los $\hat{\varepsilon}_t^2$ son iid y la regresión auxiliar tiene coeficientes verdaderos cero. $T \cdot R^2$ de una regresión con q regresores bajo coeficientes nulos converge a χ_q^2 (este es el resultado general de Engle, 1984, para tests LM). $\square$

Rechazar H_0 con p -valor bajo es señal inequívoca: es necesario modelar la varianza.

3.2. El modelo ARCH

3.2.1. Definición y lógica

Definición 3.4 (ARCH(q) — Engle, 1982).

$$\varepsilon_t = \sqrt{h_t} z_t, \quad z_t \stackrel{iid}{\sim} \mathcal{N}(0, 1), \quad (3.3)$$

$$h_t = \omega + \alpha_1 \varepsilon_{t-1}^2 + \cdots + \alpha_q \varepsilon_{t-q}^2. \quad (3.4)$$

La idea central es elegante: la varianza condicional depende linealmente de la magnitud de shocks pasados. Si los últimos q shocks fueron grandes, h_t sube; si fueron pequeños, h_t baja. Esto es *exactamente* el mecanismo de volatility clustering.

Restricciones sobre los parámetros

Para que $h_t > 0$ con probabilidad 1, exigimos:

- $\omega > 0$ (varianza base estrictamente positiva),
- $\alpha_i \geq 0$ para $i = 1, \dots, q$ (no-negatividad de los efectos).

Estas restricciones son *suficientes pero no estrictamente necesarias*. Hay generalizaciones que las relajan (Nelson-Cao 1992; EGARCH), pero en ARCH/GARCH estándar son la convención.

3.2.2. Momentos del ARCH(1)

Tomemos el caso $q = 1$ y derivemos las propiedades clave.

Proposición 3.5 (Momentos condicionales). *Bajo* (??)-(??) *con* $q = 1$:

$$\mathbb{E}[\varepsilon_t \mid \mathcal{F}_{t-1}] = 0, \quad \mathbb{V}[\varepsilon_t \mid \mathcal{F}_{t-1}] = h_t = \omega + \alpha_1 \varepsilon_{t-1}^2.$$

Demostración. $\mathbb{E}[\varepsilon_t \mid \mathcal{F}_{t-1}] = \sqrt{h_t} \mathbb{E}[z_t \mid \mathcal{F}_{t-1}] = \sqrt{h_t} \cdot 0 = 0$, porque z_t es independiente de $\mathcal{F}_{t-1}$. $\mathbb{V}[\varepsilon_t \mid \mathcal{F}_{t-1}] = h_t \mathbb{E}[z_t^2 \mid \mathcal{F}_{t-1}] = h_t \cdot 1 = h_t$. $\square$

Proposición 3.6 (Momentos incondicionales). *Si $0 \leq \alpha_1 < 1$, el ARCH(1) es estacionario en segundo momento con*

$$\mathbb{E}[\varepsilon_t] = 0, \quad \mathbb{V}[\varepsilon_t] = \sigma^2 = \frac{\omega}{1 - \alpha_1}.$$

Demostración. $\mathbb{E}[\varepsilon_t] = \mathbb{E}[\mathbb{E}[\varepsilon_t \mid \mathcal{F}_{t-1}]] = \mathbb{E}[0] = 0$ por la ley de esperanzas iteradas (LIE). Para la varianza, como $\mathbb{E}[\varepsilon_t^2 \mid \mathcal{F}_{t-1}] = h_t$:

$$\mathbb{E}[\varepsilon_t^2] = \mathbb{E}[h_t] = \omega + \alpha_1 \mathbb{E}[\varepsilon_{t-1}^2].$$

Si existe un estado estacionario con $\mathbb{E}[\varepsilon_t^2] = \sigma^2$ constante:

$$\sigma^2 = \omega + \alpha_1 \sigma^2 \implies \sigma^2 = \frac{\omega}{1 - \alpha_1},$$

que es positiva y finita $\Leftrightarrow \alpha_1 < 1$. La existencia del estado estacionario requiere convergencia de la iteración, garantizada por $\alpha_1 < 1$. $\square$

3.2.3. Ausencia de autocorrelación

Proposición 3.7. *En un ARCH(1), $\text{Corr}(\varepsilon_t, \varepsilon_{t-h}) = 0$ para todo $h \neq 0$.*

Demostración. $\text{Cov}(\varepsilon_t, \varepsilon_{t-h}) = \mathbb{E}[\varepsilon_t \varepsilon_{t-h}] = \mathbb{E}[\mathbb{E}[\varepsilon_t \varepsilon_{t-h} \mid \mathcal{F}_{t-1}]] = \mathbb{E}[\varepsilon_{t-h} \cdot 0] = 0$, porque $\varepsilon_{t-h} \in \mathcal{F}_{t-1}$ para $h \geq 1$ y $\mathbb{E}[\varepsilon_t \mid \mathcal{F}_{t-1}] = 0$. $\square$

Consecuencia importante: el ARCH es ruido blanco débil en niveles —consistente con retornos financieros—, pero no iid. La estructura está en los segundos momentos.

3.2.4. Autocorrelación en los cuadrados

Proposición 3.8. *En un ARCH(1), $\text{Corr}(\varepsilon_t^2, \varepsilon_{t-h}^2) = \alpha_1^h$ para $h \geq 0$.*

Demostración. Definamos $v_t = \varepsilon_t^2 - h_t$. Por construcción $\mathbb{E}[v_t | \mathcal{F}_{t-1}] = 0$: v_t es una innovación para ε_t^2 . Sustituyendo:

$$\varepsilon_t^2 = h_t + v_t = \omega + \alpha_1 \varepsilon_{t-1}^2 + v_t.$$

Es un AR(1) para ε_t^2 con coeficiente α_1 y innovación v_t . Por la fórmula de ACF del AR(1), $\text{Corr}(\varepsilon_t^2, \varepsilon_{t-h}^2) = \alpha_1^h$. $\square$

Este es el resultado central que justifica el ARCH: la serie es blanca en niveles pero tiene estructura AR en los cuadrados. Exactamente lo observado en datos financieros.

3.2.5. Colas pesadas: la generación de curtos

Teorema 3.9. *En un ARCH(1) con $z_t \sim \mathcal{N}(0, 1)$ y $3\alpha_1^2 < 1$ (para que el cuarto momento exista):*

$$\text{Curtosis}[\varepsilon_t] = \frac{\mathbb{E}[\varepsilon_t^4]}{(\mathbb{E}[\varepsilon_t^2])^2} = 3 \cdot \frac{1 - \alpha_1^2}{1 - 3\alpha_1^2} > 3.$$

Demostración. Calculamos el cuarto momento. Como $\varepsilon_t^4 = z_t^4 h_t^2$ y $\mathbb{E}[z_t^4] = 3$ (normalidad):

$$\mathbb{E}[\varepsilon_t^4] = 3\mathbb{E}[h_t^2].$$

Ahora $h_t^2 = (\omega + \alpha_1 \varepsilon_{t-1}^2)^2 = \omega^2 + 2\omega\alpha_1 \varepsilon_{t-1}^2 + \alpha_1^2 \varepsilon_{t-1}^4$. Tomando esperanza:

$$\mathbb{E}[h_t^2] = \omega^2 + 2\omega\alpha_1 \sigma^2 + \alpha_1^2 \mathbb{E}[\varepsilon_{t-1}^4].$$

En el estado estacionario $\mathbb{E}[\varepsilon_t^4] = \mathbb{E}[\varepsilon_{t-1}^4] = M_4$. Sustituyendo:

$$M_4 = 3(\omega^2 + 2\omega\alpha_1 \sigma^2 + \alpha_1^2 M_4) \implies M_4(1 - 3\alpha_1^2) = 3\omega^2 + 6\omega\alpha_1 \sigma^2.$$

Usando $\sigma^2 = \omega/(1 - \alpha_1)$:

$$3\omega^2 + 6\omega\alpha_1 \sigma^2 = 3\omega^2 \left(1 + \frac{2\alpha_1}{1 - \alpha_1}\right) = 3\omega^2 \cdot \frac{1 + \alpha_1}{1 - \alpha_1}.$$

Entonces

$$M_4 = \frac{3\omega^2(1 + \alpha_1)}{(1 - \alpha_1)(1 - 3\alpha_1^2)}.$$

La curtosis es $M_4/\sigma^4 = M_4 \cdot (1 - \alpha_1)^2/\omega^2$:

$$\frac{M_4}{\sigma^4} = \frac{3(1 + \alpha_1)(1 - \alpha_1)^2}{(1 - \alpha_1)(1 - 3\alpha_1^2)} = 3 \cdot \frac{(1 + \alpha_1)(1 - \alpha_1)}{1 - 3\alpha_1^2} = 3 \cdot \frac{1 - \alpha_1^2}{1 - 3\alpha_1^2}. \quad \square$$

Interpretación del resultado

Para $\alpha_1 = 0$: curtosis = 3 (caso degenerado, innovación gaussiana pura). Para $\alpha_1 = 0,3$: curtosis = $3 \cdot 0,91/0,73 \approx 3,74$. Para $\alpha_1 \rightarrow 1/\sqrt{3} \approx 0,577$: curtosis $\rightarrow \infty$.

El resultado es profundo: **aunque las innovaciones z_t son normales**, la mezcla generada por la varianza condicional variable produce un proceso ε_t con colas más pesadas que la normal. Los modelos ARCH explican endógenamente un hecho estilizado empírico, sin necesidad de imponer distribuciones no gaussianas a nivel de innovación. Esta fue una contribución conceptual fundamental de Engle.

3.2.6. Limitaciones del ARCH puro

ARCH(q) con q pequeño no captura la persistencia observada: en datos reales $\text{Corr}(\varepsilon_t^2, \varepsilon_{t-h}^2)$ puede ser significativa en $h = 10, 20, 50$. Un ARCH(1) decae como α_1^h , que se extingue rápido.

Se necesita q grande —20, 30 rezagos—, lo cual:

- Usa muchos parámetros y pierde eficiencia.
- Hace probable violar $\alpha_i \geq 0$ para algunos i .
- Induce multicolinealidad entre rezagos de ε^2 .

La solución es parsimoniosa: agregar términos autorregresivos a la ecuación de h_t . Eso es GARCH.

3.3. El modelo GARCH

3.3.1. Definición

Definición 3.10 (GARCH(p, q) — Bollerslev, 1986).

$$\varepsilon_t = \sqrt{h_t} z_t, \quad z_t \stackrel{iid}{\sim} (0, 1),$$

$$h_t = \omega + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2 + \sum_{j=1}^p \beta_j h_{t-j}. \quad (3.5)$$

El GARCH añade términos $\beta_j h_{t-j}$ al ARCH: la varianza condicional depende no solo de shocks pasados sino de sus propios rezagos. Usando el operador de rezagos,

$$h_t = \omega + \alpha(L) \varepsilon_t^2 + \beta(L) h_t,$$

con $\alpha(L) = \sum_{i=1}^q \alpha_i L^i$ y $\beta(L) = \sum_{j=1}^p \beta_j L^j$. Reordenando:

$$(1 - \beta(L)) h_t = \omega + \alpha(L) \varepsilon_t^2,$$

y si $(1 - \beta(L))^{-1}$ existe,

$$h_t = \frac{\omega}{1 - \sum \beta_j} + \frac{\alpha(L)}{1 - \beta(L)} \varepsilon_t^2 = \frac{\omega}{1 - \sum \beta_j} + \sum_{k=1}^{\infty} \pi_k \varepsilon_{t-k}^2,$$

lo que muestra que **todo GARCH es un ARCH(∞)**: expande la varianza en términos de toda la historia de ε_t^2 con pesos π_k decrecientes. Esta parsimonia —ARCH(∞) con pocos parámetros— es la razón del éxito empírico del GARCH.

Restricciones estándar

- $\omega > 0$.
- $\alpha_i \geq 0, \beta_j \geq 0$.
- Estacionariedad en segundo momento: $\sum_{i=1}^q \alpha_i + \sum_{j=1}^p \beta_j < 1$.

3.3.2. GARCH(1,1): el caballito de batalla

El GARCH(1,1) es, sin exageración, el modelo de volatilidad más usado en finanzas aplicada:

$$h_t = \omega + \alpha \varepsilon_{t-1}^2 + \beta h_{t-1}. \quad (3.6)$$

Proposición 3.11 (Propiedades del GARCH(1,1)). *Si $\alpha + \beta < 1$:*

1. *Varianza incondicional: $\sigma^2 = \omega / (1 - \alpha - \beta)$.*

2. *$\{\varepsilon_t\}$ es ruido blanco débil.*

3. *$\{\varepsilon_t^2\}$ sigue un ARMA(1,1):*

$$\varepsilon_t^2 = \omega + (\alpha + \beta)\varepsilon_{t-1}^2 - \beta v_{t-1} + v_t,$$

$$\text{con } v_t = \varepsilon_t^2 - h_t.$$

4. *Persistencia de la varianza: shocks decaen a tasa $(\alpha + \beta)^h$.*

Demostración. Punto 1: análogo al ARCH. Tomamos esperanza incondicional en (??) y resolvemos para $\sigma^2 = \mathbb{E}[h_t]$. Punto 2: análogo al ARCH(1) (descomposición con LIE). Punto 3: sumamos y restamos $\beta\varepsilon_{t-1}^2$:

$$\begin{aligned} h_t &= \omega + \alpha \varepsilon_{t-1}^2 + \beta h_{t-1} \\ &= \omega + (\alpha + \beta)\varepsilon_{t-1}^2 - \beta(\varepsilon_{t-1}^2 - h_{t-1}) \\ &= \omega + (\alpha + \beta)\varepsilon_{t-1}^2 - \beta v_{t-1}. \end{aligned}$$

Sustituyendo $h_t = \varepsilon_t^2 - v_t$ en el lado izquierdo:

$$\varepsilon_t^2 - v_t = \omega + (\alpha + \beta)\varepsilon_{t-1}^2 - \beta v_{t-1}.$$

Reordenando da el ARMA(1,1) de ε_t^2 con innovación v_t . Punto 4: la IRF de un ARMA(1,1) decae como $\phi^h = (\alpha + \beta)^h$ en los coeficientes autorregresivos. $\square$

Valores típicos en datos reales

En retornos diarios de activos financieros, valores típicos son:

- $\alpha \approx 0,05 - 0,10$: reacción moderada a shocks recientes.
- $\beta \approx 0,85 - 0,95$: alta persistencia de la varianza.
- $\alpha + \beta \approx 0,95 - 0,99$: muy alta persistencia total.

Con $\alpha + \beta = 0,98$, la vida media de un shock de varianza es $\log(0,5)/\log(0,98) \approx 34$ días: un shock tarda más de un mes en extinguirse a la mitad. Esta es la razón por la que eventos como crisis generan clusters de volatilidad prolongados.

3.3.3. IGARCH: persistencia en la frontera

Si $\alpha + \beta = 1$, el proceso se llama *IGARCH*:

$$h_t = \omega + \alpha \varepsilon_{t-1}^2 + (1 - \alpha)h_{t-1}.$$

La varianza incondicional no existe (denominador cero), pero el proceso es estrictamente estacionario (Nelson 1990). Shocks a la varianza son *permanentes*: no decaen.

Dos lecturas posibles:

- **Interpretación literal**: la volatilidad es integrada, shocks son permanentes. Ocurre en datos intradiarios de alta frecuencia.
- **Interpretación crítica**: la muestra contiene cambios estructurales que un GARCH estacionario no puede acomodar; el modelo los absorbe empujando la persistencia a 1. Diagnosticar con tests de quiebre (ej. Inclán-Tiao, ICSS).

En el contexto dominicano, si un GARCH sobre el peso/dólar que incluye la crisis bancaria de 2003 reporta $\alpha + \beta \approx 1$, probablemente necesitamos dummies de quiebre o estimación por sub-periodos.

3.3.4. Estimación por máxima verosimilitud

Asumiendo $z_t \stackrel{iid}{\sim} \mathcal{N}(0, 1)$, la log-verosimilitud condicional es:

$$\ell(\boldsymbol{\theta}) = -\frac{T}{2} \log(2\pi) - \frac{1}{2} \sum_{t=1}^T \log h_t(\boldsymbol{\theta}) - \frac{1}{2} \sum_{t=1}^T \frac{\varepsilon_t^2}{h_t(\boldsymbol{\theta})}. \quad (3.7)$$

donde $\boldsymbol{\theta} = (\omega, \alpha_1, \dots, \alpha_q, \beta_1, \dots, \beta_p)$. La recursión de h_t hace que ℓ no tenga forma cerrada; se maximiza numéricamente por BFGS o similar.

Inicialización de la recursión

La recursión de h_t requiere valores iniciales $h_0, h_{-1}, \dots, h_{-(p-1)}$ y $\varepsilon_0^2, \varepsilon_{-1}^2, \dots, \varepsilon_{-(q-1)}^2$. Tres opciones estándar:

1. **Varianza muestral incondicional:** $h_0 = \varepsilon_0^2 = T^{-1} \sum \varepsilon_t^2$.
2. **Varianza implicada por parámetros:** $h_0 = \omega / (1 - \alpha - \beta)$ (requiere los parámetros, así que se itera).
3. **Valores cero:** no recomendado; puede generar h_t muy pequeños al inicio.

Con T grande, la influencia de la inicialización decae rápidamente y los resultados son robustos.

El problema práctico de optimización

Optimizar (??) es menos trivial de lo que parece:

- **Restricciones:** $\omega > 0, \alpha \geq 0, \beta \geq 0, \alpha + \beta < 1$. Se suele reparametrizar o usar L-BFGS-B con bounds.
- **Superficie poco amigable:** la log-verosimilitud tiene "zonas planas" a veces múltiples óptimos locales.

- **Sensibilidad a valores iniciales:** correr con varios puntos de arranque.

El paquete `rugarch` gestiona todo esto internamente; `fGarch` es otra alternativa robusta.

3.3.5. Cuasi-máxima verosimilitud (QMLE)

Supongamos que la distribución verdadera de z_t no es normal pero usamos (??) como si lo fuera. ¿Qué pasa?

Teorema 3.12 (Bollerslev-Wooldridge, 1992). *Bajo condiciones de regularidad (estacionariedad estricta del GARCH, momentos cuartos finitos, identificación), el estimador que maximiza (??) bajo una normal mal especificada es consistente y asintóticamente normal:*

$$\sqrt{T}(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta}_0) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathbf{A}^{-1}\mathbf{B}\mathbf{A}^{-1}),$$

con $\mathbf{A} = -\mathbb{E}[\partial^2 \ell_t / \partial \boldsymbol{\theta} \partial \boldsymbol{\theta}^\top]$ y $\mathbf{B} = \mathbb{E}[\mathbf{s}_t \mathbf{s}_t^\top]$.

Esta es la *matriz sándwich* de White (1982). En el caso correctamente especificado, la identidad de información (Módulo 0) da $\mathbf{A} = \mathbf{B}$ y la fórmula colapsa a $\mathbf{A}^{-1}$. En el mal especificado, $\mathbf{A} \neq \mathbf{B}$ y los errores estándar de la MV simple *subestiman* la varianza real.

Observación 3.13 (Recomendación práctica). Cuando se sabe que z_t no es gaussiano (y casi siempre no lo es en datos financieros), usar errores estándar robustos tipo sándwich. En `rugarch`: argumento `fit.control = list(stationarity = 1)`, y los errores estándar reportados por defecto usan la forma robusta.

3.4. Extensiones del GARCH

El GARCH estándar tiene dos limitaciones empíricas:

1. **Simetría:** trata igual a shocks positivos y negativos del mismo tamaño.
2. **Normalidad de z_t :** los residuos estandarizados reales tienen colas más pesadas.

Las extensiones que siguen abordan ambos problemas.

3.4.1. EGARCH: Nelson (1991)

Definición 3.14 (EGARCH(p, q)).

$$\log h_t = \omega + \sum_{i=1}^q \alpha_i g(z_{t-i}) + \sum_{j=1}^p \beta_j \log h_{t-j}, \quad (3.8)$$

con

$$g(z_t) = \theta z_t + \gamma(|z_t| - \mathbb{E}|z_t|).$$

Tres novedades del EGARCH:

1. **Especifica $\log h_t$, no h_t .** Consecuencia: **no requiere restricciones de positividad** sobre ω, α, β , porque $h_t = \exp(\cdot) > 0$ automáticamente.
2. **Depende de z_{t-i} estandarizado** en vez de ε_{t-i}^2 crudo: invarianza de escala.
3. **Captura asimetría** mediante $g(z)$: el término θz_t es lineal en el signo; si $\theta < 0$, $z < 0$ (shocks negativos) *aumenta* g y por tanto h_t .

Anatomía de $g(z_t)$

El término $\gamma(|z_t| - \mathbb{E}|z_t|)$ es simétrico en magnitud. El término θz_t es antisimétrico. La combinación produce:

- Shock positivo grande: $g = \theta z + \gamma(|z| - \mathbb{E}|z|)$ con $\theta z > 0$ y segunda parte positiva.
- Shock negativo grande: $g = \theta z + \gamma(|z| - \mathbb{E}|z|)$ con $\theta z > 0$ (si $\theta < 0$) y segunda parte positiva.

La asimetría se calibra por θ . Empíricamente, θ estimado es típicamente negativo y significativo en datos de equity.

3.4.2. GJR-GARCH: Glosten-Jagannathan-Runkle (1993)

Definición 3.15 (GJR-GARCH(1,1)).

$$h_t = \omega + \alpha \varepsilon_{t-1}^2 + \gamma \varepsilon_{t-1}^2 \mathbf{1}\{\varepsilon_{t-1} < 0\} + \beta h_{t-1}.$$

La estructura es idéntica al GARCH estándar, excepto por el término $\gamma \varepsilon_{t-1}^2 \mathbf{1}\{\varepsilon_{t-1} < 0\}$: activo solo cuando el shock anterior fue negativo.

- Si $\gamma > 0$: shocks negativos tienen impacto $\alpha + \gamma$, positivos solo α . Asimetría capturada.
- Si $\gamma = 0$: GARCH estándar.
- **Test de leverage:** $H_0 : \gamma = 0$ vs. $H_1 : \gamma > 0$. Wald o LR estándar.
- Estacionariedad en varianza: $\alpha + \beta + \gamma/2 < 1$. El $\gamma/2$ viene de que $\mathbb{E}[\mathbf{1}\{\varepsilon < 0\}] = 1/2$ bajo simetría de z .

GJR vs. EGARCH

Ambos capturan asimetría. Comparación pragmática:

- **GJR**: más simple estructuralmente; mantiene la forma $h_t = \omega + \dots$; fácil de interpretar.
- **EGARCH**: más flexible en la forma funcional; sin restricciones de positividad; más sensible a outliers por el logaritmo.

En aplicación empírica se suelen comparar ambos y elegir por AIC/BIC.

3.4.3. APARCH: Ding-Granger-Engle (1993)

Definición 3.16 (APARCH(p, q)).

$$h_t^{\delta/2} = \omega + \sum_{i=1}^q \alpha_i (|\varepsilon_{t-i}| - \gamma_i \varepsilon_{t-i})^\delta + \sum_{j=1}^p \beta_j h_{t-j}^{\delta/2}.$$

El APARCH anida varios modelos como casos especiales:

- $\delta = 2, \gamma = 0$: GARCH estándar.
- $\delta = 1, \gamma = 0$: TGARCH de Taylor (modela $h_t^{1/2}$, la desviación estándar).
- $\delta = 2, \gamma \neq 0$: GJR.

El parámetro δ se estima libre. Datos financieros típicos sugieren $\delta \approx 1$ (TGARCH): la desviación estándar, no la varianza, sigue la dinámica lineal.

3.4.4. Distribuciones alternativas de z_t

t de Student estandarizado

Definición 3.17. $z_t = T_\nu / \sqrt{\nu/(\nu - 2)}$, donde T_ν es t de Student con ν grados de libertad. La división escala la varianza a 1.

La densidad es:

$$f_t(z; \nu) = \frac{\Gamma(\frac{\nu+1}{2})}{\sqrt{\pi(\nu-2)} \Gamma(\frac{\nu}{2})} \left(1 + \frac{z^2}{\nu-2}\right)^{-(\nu+1)/2}.$$

- Curtosis de z_t : $3 + 6/(\nu - 4)$ para $\nu > 4$; tiende a 3 cuando $\nu \rightarrow \infty$.
- ν típicamente estimado entre 5 y 12 en datos financieros.
- Combinado con GARCH, la curtosis del proceso ε_t suma la del modelo y la de z_t : resulta fácil capturar colas muy pesadas.

GED (Generalized Error Distribution)

$$f_{GED}(z; \kappa) = \frac{\kappa}{2\lambda_\kappa \Gamma(1/\kappa)} \exp\left(-\left|\frac{z}{\lambda_\kappa}\right|^\kappa\right), \quad \lambda_\kappa = \sqrt{\frac{2^{-2/\kappa} \Gamma(1/\kappa)}{\Gamma(3/\kappa)}}.$$

- $\kappa = 2$: normal.
- $\kappa < 2$: colas más pesadas.
- $\kappa > 2$: colas más delgadas.

Más flexible que la t pero computacionalmente más costoso.

t asimétrica de Hansen (1994)

Incorpora un parámetro adicional de asimetría ξ para distribuciones con sesgo no cero. Es el estándar cuando la asimetría residual después de GJR/EGARCH persiste.

3.4.5. Pronóstico multi-paso de volatilidad

El pronóstico de $h_{T+h|T}$ en un GARCH(1,1) admite forma cerrada:

$$h_{T+1|T} = \omega + \alpha \varepsilon_T^2 + \beta h_T, \quad (3.9)$$

$$h_{T+2|T} = \omega + \alpha \mathbb{E}[\varepsilon_{T+1}^2 \mid \mathcal{F}_T] + \beta h_{T+1|T} = \omega + (\alpha + \beta) h_{T+1|T}, \quad (3.10)$$

$$h_{T+h|T} = \omega \frac{1 - (\alpha + \beta)^{h-1}}{1 - (\alpha + \beta)} + (\alpha + \beta)^{h-1} h_{T+1|T}. \quad (3.11)$$

El pronóstico converge geométricamente a la varianza incondicional $\sigma^2 = \omega / (1 - \alpha - \beta)$. La velocidad de convergencia es controlada por $\alpha + \beta$: cerca de 1, convergencia muy lenta (alta persistencia).

3.4.6. Value at Risk (VaR) como aplicación canónica

Definición 3.18 (Value at Risk). El VaR al $\alpha \cdot 100\%$ a horizonte h es:

$$\mathbb{P}(r_{T+h} < -VaR_\alpha \mid \mathcal{F}_T) = \alpha.$$

Es el umbral de pérdida tal que la probabilidad condicional de excederlo es α .

Bajo un GARCH con $z_t \sim t_\nu$:

$$VaR_\alpha = -(\hat{\mu}_{T+h|T} + \sqrt{\hat{h}_{T+h|T}} \cdot q_t(\alpha; \nu)),$$

donde $q_t(\alpha; \nu)$ es el cuantil α de la t estandarizada.

El VaR es la medida regulatoria estándar bajo Basel II/III para riesgo de mercado. Implementaciones con GARCH+ t son el estándar en bancos y supervisores.

3.5. Modelos de umbral: TAR y TVAR

Los modelos GARCH capturan no linealidad en la *varianza*. Los modelos TAR/TVAR/MS-AR capturan no linealidad en la *media*: el comportamiento del proceso depende del estado actual del sistema.

3.5.1. Motivación económica

Varias relaciones económicas presentan dinámicas distintas según el estado:

- **Política monetaria:** banco central reacciona asimétricamente a inflación por encima vs. por debajo de su meta.
- **Pass-through cambiario:** la transmisión del tipo de cambio a precios puede ser mayor cuando la devaluación es rápida que cuando es gradual.
- **Ciclo de crédito:** expansión crediticia tiene dinámica distinta a contracción.
- **Ajustes en precios:** reaccionan diferente ante shocks pequeños (no se ajustan) vs. grandes (se ajustan).

Modelar estas no linealidades requiere salir del marco lineal ARMA. Hay dos caminos:

- **Régimen observable:** el régimen depende de una variable medida (TAR, TVAR).
- **Régimen latente:** el régimen es una variable no observada (MS-AR).

3.5.2. SETAR: Self-Exciting Threshold AR

Definición 3.19 (SETAR con dos regímenes).

$$Y_t = \begin{cases} \phi_0^{(1)} + \phi_1^{(1)}Y_{t-1} + \cdots + \phi_p^{(1)}Y_{t-p} + \sigma^{(1)}\varepsilon_t & \text{si } Y_{t-d} \leq c, \\ \phi_0^{(2)} + \phi_1^{(2)}Y_{t-1} + \cdots + \phi_p^{(2)}Y_{t-p} + \sigma^{(2)}\varepsilon_t & \text{si } Y_{t-d} > c, \end{cases} \quad (3.12)$$

con $\varepsilon_t \sim \text{iid}\mathcal{N}(0, 1)$.

Parámetros a estimar: los vectores $(\phi_0^{(r)}, \dots, \phi_p^{(r)}, \sigma^{(r)})$ para cada régimen $r = 1, 2$, el umbral c , y el rezago $d \in \{1, 2, \dots, p\}$. El calificativo "self-exciting" significa que la variable umbral es el propio proceso con rezago d .

Estimación

La log-verosimilitud del SETAR, dado (c, d) , es la suma de las log-verosimilitudes por régimen:

$$\ell(c, d; \phi, \sigma) = \sum_{t: Y_{t-d} \leq c} \ell_t^{(1)} + \sum_{t: Y_{t-d} > c} \ell_t^{(2)}.$$

Dado (c, d) , cada término interno es la verosimilitud gaussiana estándar, que se maximiza por MCO. El procedimiento de estimación completa es:

1. Para cada $d \in \{1, \dots, p\}$ y cada c en una grilla:
 - (a) Dividir la muestra en dos según la regla $Y_{t-d} \leq c$.
 - (b) Estimar por MCO los dos regímenes.
 - (c) Calcular la log-verosimilitud total.
2. Elegir $(\hat{c}, \hat{d})$ que maximice ℓ .

En R, `tsDyn::setar()` implementa esta búsqueda.

Trimming

La grilla de c se restringe a valores entre los cuantiles τ y $1 - \tau$ de Y_{t-d} (típicamente $\tau = 0,15$), para garantizar suficientes observaciones en cada régimen.

3.5.3. El problema de Davies: tests de linealidad

Una pregunta natural: ¿es necesaria la estructura de umbral, o bastaría un AR lineal? Formalmente, probamos

$$H_0 : \phi^{(1)} = \phi^{(2)} \quad (\text{un solo régimen}).$$

Observación 3.20 (Problema de Davies, 1987). Bajo H_0 , el umbral c **no está identificado**: cualquier valor de c produce el mismo modelo. Los tests estándar (Wald, LR) no siguen χ^2 .

Esta es una situación conocida como *parámetro de molestia no identificado bajo H_0* . La solución:

Test sup-Wald

Calculamos el estadístico de Wald para $\phi^{(1)} = \phi^{(2)}$ para cada valor de c , y tomamos el supremo:

$$\sup W = \sup_{c \in [c_L, c_U]} W(c).$$

La distribución asintótica de $\sup W$ no es χ^2 , sino el supremo de un proceso empírico gaussiano. Hansen (1996, 1999) tabuló los cuantiles por simulación Monte Carlo. Alternativamente, *bootstrap*: simular bajo H_0 (un AR lineal estimado), computar $\sup W$ en cada simulación, obtener el cuantil empírico.

En `tsDyn`, `setarTest()` implementa el test con valores críticos bootstrap.

3.5.4. TVAR: la extensión multivariada

Definición 3.21 (Threshold VAR). Para un vector $\mathbf{Y}_t \in \mathbb{R}^n$ y dos regímenes:

$$\mathbf{Y}_t = \mathbf{c}^{(1)} + \mathbf{A}_1^{(1)}\mathbf{Y}_{t-1} + \cdots + \mathbf{A}_p^{(1)}\mathbf{Y}_{t-p} + \boldsymbol{\varepsilon}_t^{(1)}, \quad s_{t-d} \leq c,$$

$$\mathbf{Y}_t = \mathbf{c}^{(2)} + \mathbf{A}_1^{(2)}\mathbf{Y}_{t-1} + \cdots + \mathbf{A}_p^{(2)}\mathbf{Y}_{t-p} + \boldsymbol{\varepsilon}_t^{(2)}, \quad s_{t-d} > c,$$

donde s_t es la variable umbral (una componente de $\mathbf{Y}_t$, una combinación lineal, o una variable exógena).

Implicaciones

- Las matrices $\mathbf{A}^{(r)}$ varían por régimen: la estructura de transmisión cambia.
- Las covarianzas $\Sigma^{(r)} = \text{Cov}(\boldsymbol{\varepsilon}_t^{(r)})$ pueden también diferir.
- **IRFs no lineales:** la respuesta del sistema a un shock depende (i) del estado inicial $\mathbf{Y}_T$ y (ii) del tamaño y signo del shock. Esto contrasta con el VAR lineal, donde las IRF son independientes del estado.

Estimación

Dado (c, d, s) , se estima cada régimen por MCO (o MV gaussiana) separadamente. La búsqueda sobre (c, d) es análoga al SETAR: grilla + maximización. En R: `tsDyn::TVAR()`. El test de linealidad vs. TVAR es `tsDyn::TVAR.LRtest()` con valores críticos bootstrap.

Generalized IRFs (GIRFs)

Koop, Pesaran y Potter (1996) propusieron el concepto de GIRF para sistemas no lineales:

$$\text{GIRF}(h, \mathbf{u}_0, \mathbf{Y}_T) = \mathbb{E}[\mathbf{Y}_{T+h} \mid \boldsymbol{\varepsilon}_{T+1} = \mathbf{u}_0, \mathcal{F}_T] - \mathbb{E}[\mathbf{Y}_{T+h} \mid \mathcal{F}_T].$$

Es la respuesta esperada a un shock específico dado el estado inicial. En sistemas lineales coincide con la IRF tradicional; en no lineales, depende del estado y del shock.

3.6. Markov-Switching AR

3.6.1. Concepto y diferencia clave con TAR

En los modelos TAR/TVAR el régimen se determina por una variable *observable*. En los modelos Markov-Switching el régimen es una variable *latente* —una cadena de Markov no observada directamente—, y su estimación implica inferir probabilidades de estado.

Definición 3.22 (MS-AR de Hamilton, 1989).

$$Y_t = \mu(S_t) + \phi(Y_{t-1} - \mu(S_{t-1})) + \varepsilon_t, \quad \varepsilon_t \sim \mathcal{N}(0, \sigma^2(S_t)),$$

con $S_t \in \{1, \dots, K\}$ una cadena de Markov con probabilidades de transición $p_{ij} = \mathbb{P}(S_t = j \mid S_{t-1} = i)$ y matriz $P = [p_{ij}]$.

La formulación original de Hamilton usa un AR(1) y solo permite que la media cambie con el estado. Variantes más ricas permiten cambios en coeficientes AR, en varianza, o en ambos.

3.6.2. Aplicación histórica: datar recesiones

La motivación original fue el ciclo económico estadounidense. Hamilton modeló el crecimiento del PIB de USA con dos regímenes: $\mu^{(1)} > 0$ (expansión) y $\mu^{(2)} < 0$ (recesión). Las probabilidades *suavizadas* $\mathbb{P}(S_t = \text{recesión} \mid \mathcal{F}_T)$ coincidieron notablemente con las fechas de recesión declaradas ex post por NBER.

Para la RD, aplicaciones naturales serían:

- Dos regímenes de inflación: baja (post-metas, 2004+) vs. alta (pre-metas).
- Dos regímenes cambiarios: tranquilo vs. turbulento.
- Régimen de crédito: expansivo vs. contractivo.

3.6.3. Probabilidades filtradas, predichas y suavizadas

En un modelo con K estados, definimos tres probabilidades:

1. **Filtrada:** $\xi_t^{(j)} = \mathbb{P}(S_t = j \mid \mathcal{F}_t)$. Usa información hasta t .
2. **Predicha:** $\mathbb{P}(S_{t+1} = j \mid \mathcal{F}_t) = \sum_i p_{ij} \xi_t^{(i)}$.
3. **Suavizada:** $\mathbb{P}(S_t = j \mid \mathcal{F}_T)$. Usa toda la muestra (incluyendo futuro de t).

Las suavizadas son las útiles para datación ex post de eventos (recesiones, crisis).

3.6.4. Filtro de Hamilton

El filtro calcula las probabilidades filtradas recursivamente. Sea $f(y_t \mid S_t = j, \mathcal{F}_{t-1})$ la densidad condicional (gaussiana con parámetros del estado j).

Paso 1 — Predicción:

$$\mathbb{P}(S_t = j \mid \mathcal{F}_{t-1}) = \sum_{i=1}^K p_{ij} \xi_{t-1}^{(i)}.$$

Paso 2 — Actualización (Bayes):

$$\xi_t^{(j)} = \frac{f(y_t \mid S_t = j, \mathcal{F}_{t-1}) \cdot \mathbb{P}(S_t = j \mid \mathcal{F}_{t-1})}{\sum_k f(y_t \mid S_t = k, \mathcal{F}_{t-1}) \cdot \mathbb{P}(S_t = k \mid \mathcal{F}_{t-1})}.$$

La verosimilitud de la muestra se obtiene como subproducto:

$$\ell = \sum_{t=1}^T \log \left(\sum_{k=1}^K f(y_t \mid S_t = k, \mathcal{F}_{t-1}) \cdot \mathbb{P}(S_t = k \mid \mathcal{F}_{t-1}) \right).$$

3.6.5. Suavizado de Kim

Dadas las filtradas, las suavizadas se obtienen por una recursión *hacia atrás* (Kim, 1994):

$$\mathbb{P}(S_t = j \mid \mathcal{F}_T) = \xi_t^{(j)} \sum_{k=1}^K \frac{p_{jk} \cdot \mathbb{P}(S_{t+1} = k \mid \mathcal{F}_T)}{\sum_i p_{ik} \xi_t^{(i)}}.$$

3.6.6. Estimación

Dos alternativas comunes:

1. **MV directa:** maximizar ℓ numéricamente con el filtro como subrutina.
2. **Algoritmo EM** (Expectation-Maximization):
 - (a) Paso E: con parámetros actuales, calcular probabilidades suavizadas.
 - (b) Paso M: con las suavizadas, estimar parámetros maximizando la "verosimilitud completa".
 - (c) Iterar hasta convergencia.

Hamilton (1990) muestra que EM es numéricamente más estable que MV directa para estos modelos. En R: `MSwM::msmFit` implementa EM.

3.7. Implementación en R

3.7.1. GARCH con rugarch: pipeline completo

Datos: retornos del tipo de cambio peso/dólar

```

1 library(rugarch)
2 library(quantmod)
3 library(ggplot2)
4
5 # Suponemos un data.frame con columna 'fecha' y 'tc' (
   # tipo de cambio)
6 # En produccion: leer desde fuente BCRD
7 datos <- read.csv("tc_bcrd_diario.csv")
8 datos$fecha <- as.Date(datos$fecha)
9
10 # Retornos log-diferenciales en porcentaje
11 datos$r <- c(NA, 100 * diff(log(datos$tc)))
12 r <- na.omit(datos$r)
13
14 # Hechos estilizados: grafico y resumen
15 par(mfrow=c(1,2))
16 plot(r, type="l", main="Retornos log del TC", xlab="",
   ylab="%")
17 hist(r, breaks=50, main="Histograma de retornos", xlab
   = "")

```

Diagnóstico ARMA + ARCH-LM

```

1 library(tseries)
2 library(FinTS)
3
4 # ARMA para la media
5 fit_mean <- auto.arima(r, seasonal=FALSE, max.p=3, max.
   q=3)
6 summary(fit_mean)
7
8 res <- residuals(fit_mean)
9

```

```

10 # Ljung-Box en residuos (deberia ser WN)
11 Box.test(res, lag=20, type="Ljung-Box")
12
13 # Ljung-Box en cuadrados (indicio de ARCH si rechaza)
14 Box.test(res^2, lag=20, type="Ljung-Box")
15
16 # Test formal ARCH-LM
17 ArchTest(res, lags=10) # H0: no hay ARCH

```

Especificación y estimación del GARCH

```

1 # Especificacion GARCH(1,1) con t-Student
2 spec_g <- ugarchspec(
3   variance.model = list(model = "sGARCH", garchOrder =
4     c(1,1)),
5   mean.model = list(armaOrder = c(1,0), include.mean =
6     TRUE),
7   distribution.model = "std"
8 )
9 fit_g <- ugarchfit(spec_g, data = r, solver = "hybrid"
10 )
11 show(fit_g)
12
13 # Residuos estandarizados
14 z_hat <- residuals(fit_g, standardize = TRUE)
15 par(mfrow=c(1,2))
16 Acf(z_hat, main="ACF z")
17 Acf(z_hat^2, main="ACF z^2")
18 Box.test(z_hat^2, lag=10, type="Ljung-Box") # deberia
19   NO rechazar

```

Comparación de especificaciones

```

1 # GARCH estandar, EGARCH, GJR
2 spec_e <- ugarchspec(
3   variance.model = list(model = "eGARCH", garchOrder =
4     c(1,1)),
5   mean.model = list(armaOrder = c(1,0)),
6   distribution.model = "std"

```

```

6 )
7 spec_j <- ugarchspec(
8   variance.model = list(model = "gjrGARCH", garchOrder
9     = c(1,1)),
10   mean.model = list(armaOrder = c(1,0)),
11   distribution.model = "std"
12 )
13 fit_e <- ugarchfit(spec_e, r)
14 fit_j <- ugarchfit(spec_j, r)
15
16 # Tabla comparativa
17 ic <- rbind(
18   sGARCH = infocriterias(fit_g),
19   eGARCH = infocriterias(fit_e),
20   gjrGARCH = infocriterias(fit_j)
21 )
22 round(ic, 4)

```

Pronóstico y VaR

```

1 # Pronostico a 20 días
2 fc <- ugarchforecast(fit_g, n.ahead = 20)
3 plot(fc, which = 3) # volatilidad esperada
4
5 # VaR al 1%
6 alpha <- 0.01
7 mu_fc <- fitted(fc)
8 sig_fc <- sigma(fc)
9 nu <- as.numeric(coef(fit_g)["shape"])
10
11 # Cuantil de t estandarizada
12 q_t <- qdist("std", p = alpha, shape = nu)
13 VaR <- mu_fc + sig_fc * q_t
14
15 # Backtesting: comparar violaciones historicas con el
    nominal 1%

```

3.7.2. TVAR con tsDyn

```
1 library(tsDyn)
2
3 # Suponemos datos mensuales de inflacion y devaluacion
4   peso/dolar
5 datos_macro <- cbind(inflacion, devaluacion)
6
7 # Test de linealidad vs. TVAR
8 linearity_test <- TVAR.LRtest(
9   datos_macro, lag = 2, nboot = 500,
10  thDelay = 1, thVar = datos_macro[,2]
11 )
12 print(linearity_test)
13
14 # Si rechaza linealidad, estimar TVAR
15 fit_tvar <- TVAR(
16   datos_macro, lag = 2, nthresh = 1,
17   thDelay = 1, thVar = datos_macro[,2],
18   trim = 0.15
19 )
20 summary(fit_tvar)
21
22 # Coeficientes por regimen
23 coef(fit_tvar)
```

3.7.3. MS-AR con MSwM

```
1 library(MSwM)
2
3 # Modelo lineal base: AR(1)
4 fit_lm <- lm(y ~ lag(y), data = datos)
5
6 # MS-AR con 2 regimenes: permite intercepto, AR, y
7   varianza variables
8 fit_ms <- msmFit(fit_lm, k = 2, sw = c(TRUE, TRUE,
9   TRUE))
10 summary(fit_ms)
11
12 # Probabilidades suavizadas
13 plot(fit_ms, which = 3)
14
15 # Datar regimenes
```

```
14 smoothed <- fit_ms@Fit@smoProb  
15 regime_high <- which(smoothed[,2] > 0.5)
```


3.8. Ejercicios

Ejercicio 3.8.1 (Momentos del ARCH(2)). Sea $\varepsilon_t = \sqrt{h_t} z_t$ con $h_t = \omega + \alpha_1 \varepsilon_{t-1}^2 + \alpha_2 \varepsilon_{t-2}^2$, $z_t \sim \mathcal{N}(0, 1)$.

- (a) Derive $\sigma^2 = \mathbb{E}[\varepsilon_t^2]$ y la condición de estacionariedad.
- (b) Calcule $\text{Corr}(\varepsilon_t^2, \varepsilon_{t-h}^2)$ para $h = 1, 2, 3$ (las ecuaciones son Yule-Walker sobre ε^2).
- (c) Identifique el AR(2) equivalente en $\{\varepsilon_t^2\}$.

Ejercicio 3.8.2 (GARCH como ARCH(∞)). Para un GARCH(1,1) con $|\beta| < 1$:

- (a) Derive la expansión $h_t = \omega / (1 - \beta) + \alpha \sum_{k=0}^{\infty} \beta^k \varepsilon_{t-1-k}^2$.
- (b) Interprete los pesos $\pi_k = \alpha \beta^{k-1}$: ¿cómo compara con un ARCH(q) con q grande?
- (c) Muestre que la curtosis de ε_t en un GARCH(1,1) con innovaciones normales es $(3(1 - (\alpha + \beta)^2)) / (1 - (\alpha + \beta)^2 - 2\alpha^2)$, condicional a existencia del cuarto momento.

Ejercicio 3.8.3 (Efecto leverage: simulación). Simule 1000 observaciones de un GJR-GARCH(1,1) con $\omega = 0,05$, $\alpha = 0,05$, $\gamma = 0,10$, $\beta = 0,80$, innovaciones $\mathcal{N}(0, 1)$.

- (a) Grafique la serie ε_t y la varianza condicional h_t .
- (b) Identifique los shocks negativos grandes y verifique que h_{t+1} sube más que tras shocks positivos de igual magnitud.
- (c) Estime un GARCH estándar (sin γ) por `rugarch`. Compute AIC. Estime un GJR-GARCH. Compare AIC y el p -valor del test sobre γ .

Ejercicio 3.8.4 (QMLE y errores estándar robustos). Simule 500 observaciones de un GARCH(1,1) con $z_t \sim t_5$ (colas pesadas). Estime por MV bajo dos especificaciones:

(a) Asumiendo $z_t \sim \mathcal{N}(0, 1)$ (mal especificado).

(b) Asumiendo $z_t \sim t_\nu$ con ν libre.

Compare los estimadores de (ω, α, β) y los errores estándar (MV ordinaria vs. robustos tipo sándwich). Repita 200 veces. ¿Cuál genera cobertura correcta de intervalos al 95 %?

Ejercicio 3.8.5 (VaR y backtesting). Para la serie de retornos del peso/dólar:

(a) Ajuste un GARCH(1,1) con t -Student sobre los primeros T_0 observaciones.

(b) Para cada $t \in \{T_0 + 1, \dots, T\}$, calcule VaR_t al 1 % usando el modelo estimado hasta $t - 1$.

(c) Cuente violaciones: $v_t = \mathbf{1}\{r_t < -VaR_t\}$.

(d) Test de Kupiec: H_0 : tasa de violación igual al nivel nominal (1 %).

Ejercicio 3.8.6 (TAR vs. AR lineal). Simule una SETAR(2) con $p = 1$: $Y_t = 0,8Y_{t-1} + \varepsilon_t$ si $Y_{t-1} \leq 0$, $Y_t = -0,3Y_{t-1} + \varepsilon_t$ si $Y_{t-1} > 0$.

(a) Simule $T = 500$ observaciones.

(b) Estime un AR(1) lineal y examine los residuos: ACF, normalidad.

(c) Estime un SETAR con `tsDyn::setar`; recupere $\hat{c}$.

(d) Aplique el test de linealidad `tsDyn::setarTest`; interprete.

Ejercicio 3.8.7 (MS-AR sobre inflación dominicana). Con datos mensuales de inflación del BCRD (2000–2024):

(a) Estime un AR(2) lineal y un MS-AR(2) con dos regímenes (intercepto y varianza variables).

- (b) Grafique las probabilidades suavizadas de estar en el régimen de alta inflación.
- (c) Compare con el calendario histórico de política monetaria (introducción de metas explícitas en 2012).
- (d) ¿El MS-AR "datea.^{ex} post los períodos de alta inflación correctamente?

Bibliografía

- [1] Black, F. (1976). Studies of stock price volatility changes. *Proceedings of the 1976 Meetings of the American Statistical Association, Business and Economics Statistics Section*, 177–181.
- [2] Bollerslev, T. (1986). Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3), 307–327.
- [3] Bollerslev, T. & Wooldridge, J. M. (1992). Quasimaximum likelihood estimation and inference in dynamic models with time-varying covariances. *Econometric Reviews*, 11(2), 143–172.
- [4] Davies, R. B. (1987). Hypothesis testing when a nuisance parameter is present only under the alternative. *Biometrika*, 74(1), 33–43.
- [5] Ding, Z., Granger, C. W. J. & Engle, R. F. (1993). A long memory property of stock market returns and a new model. *Journal of Empirical Finance*, 1(1), 83–106.
- [6] Engle, R. F. (1982). Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. *Econometrica*, 50(4), 987–1007.
- [7] Glosten, L. R., Jagannathan, R. & Runkle, D. E. (1993). On the relation between the expected value and the volatility of the nominal excess return on stocks. *Journal of Finance*, 48(5), 1779–1801.
- [8] Hamilton, J. D. (1989). A new approach to the economic analysis of nonstationary time series and the business cycle. *Econometrica*, 57(2), 357–384.

- [9] Hamilton, J. D. (1990). Analysis of time series subject to changes in regime. *Journal of Econometrics*, 45(1–2), 39–70.
- [10] Hamilton, J. D. (1994). *Time Series Analysis*. Princeton University Press. [Capítulos 21–22.]
- [11] Hansen, B. E. (1994). Autoregressive conditional density estimation. *International Economic Review*, 35(3), 705–730.
- [12] Hansen, B. E. (1996). Inference when a nuisance parameter is not identified under the null hypothesis. *Econometrica*, 64(2), 413–430.
- [13] Hansen, B. E. (1999). Testing for linearity. *Journal of Economic Surveys*, 13(5), 551–576.
- [14] Kim, C.-J. (1994). Dynamic linear models with Markov-switching. *Journal of Econometrics*, 60(1–2), 1–22.
- [15] Koop, G., Pesaran, M. H. & Potter, S. M. (1996). Impulse response analysis in nonlinear multivariate models. *Journal of Econometrics*, 74(1), 119–147.
- [16] Nelson, D. B. & Cao, C. Q. (1992). Inequality constraints in the univariate GARCH model. *Journal of Business & Economic Statistics*, 10(2), 229–235.
- [17] Nelson, D. B. (1990). Stationarity and persistence in the GARCH(1,1) model. *Econometric Theory*, 6(3), 318–334.
- [18] Nelson, D. B. (1991). Conditional heteroskedasticity in asset returns: A new approach. *Econometrica*, 59(2), 347–370.
- [19] Tong, H. (1990). *Non-linear Time Series: A Dynamical System Approach*. Oxford University Press.

- [20] Tsay, R. S. (2010). *Analysis of Financial Time Series*, 3ra ed. Wiley.
- [21] White, H. (1982). Maximum likelihood estimation of misspecified models. *Econometrica*, 50(1), 1–25.

Capítulo 4

Análisis Multivariado

Contenido

3.1. Hechos estilizados y motivación .	87
3.1.1. Lo que ARMA no puede capturar	87
3.1.2. El contexto dominicano	89
3.1.3. El lenguaje: varianza condicional	89
3.1.4. Diagnóstico de ARCH: ACF de los cuadrados y test ARCH-LM .	90
3.2. El modelo ARCH	92
3.2.1. Definición y lógica	92
3.2.2. Momentos del ARCH(1)	92
3.2.3. Ausencia de autocorrelación . . .	93
3.2.4. Autocorrelación en los cuadrados	93
3.2.5. Colas pesadas: la generación de curtosis	94
3.2.6. Limitaciones del ARCH puro . .	95
3.3. El modelo GARCH	96
3.3.1. Definición	96
3.3.2. GARCH(1,1): el caballito de ba- talla	97
3.3.3. IGARCH: persistencia en la fron- tera	98
3.3.4. Estimación por máxima verosi- militud	99
3.3.5. Cuasi-máxima verosimilitud (QM- LE)	100
3.4. Extensiones del GARCH	101
3.4.1. EGARCH: Nelson (1991)	101
3.4.2. GJR-GARCH: Glosten-Jagannathan- Runkle (1993)	102

3.4.3.	APARCH: Ding-Granger-Engle (1993)	103
3.4.4.	Distribuciones alternativas de z_t	103
3.4.5.	Pronóstico multi-paso de volatilidad	105
3.4.6.	Value at Risk (VaR) como aplicación canónica	105
3.5.	Modelos de umbral: TAR y TVAR	106
3.5.1.	Motivación económica	106
3.5.2.	SETAR: Self-Exciting Threshold AR	107
3.5.3.	El problema de Davies: tests de linealidad	108
3.5.4.	TVAR: la extensión multivariada	109
3.6.	Markov-Switching AR	111
3.6.1.	Concepto y diferencia clave con TAR	111
3.6.2.	Aplicación histórica: datar recepciones	111
3.6.3.	Probabilidades filtradas, predichas y suavizadas	112
3.6.4.	Filtro de Hamilton	112
3.6.5.	Suavizado de Kim	113
3.6.6.	Estimación	113
3.7.	Implementación en R	114
3.7.1.	GARCH con <code>rugarch</code> : pipeline completo	114
3.7.2.	TVAR con <code>tsDyn</code>	116
3.7.3.	MS-AR con <code>MSwM</code>	117
3.8.	Ejercicios	119
	Bibliografía	122

Resumen

Este capítulo —el corazón del curso— desarrolla el andamiaje multivariado estándar de la econometría de series de tiempo. Se construye el VAR reducido como generalización natural del ARMA univariado, con su condición de estacionariedad vía raíces del determinante característico y su representación $MA(\infty)$. Se demuestra que la estimación por máxima verosimilitud gaussiana colapsa a MCO ecuación por ecuación, y se establece la distribución asintótica de los estimadores. El capítulo trata la causalidad de Granger como predictibilidad temporal, con su test de Wald estándar y una discusión crítica de su interpretación. El corazón estructural es la teoría de identificación del SVAR: se derivan las restricciones de corto plazo recursivas (Cholesky) y no recursivas, las restricciones de largo plazo al estilo Blanchard-Quah con su justificación de integración de IRFs, y las restricciones de signo al estilo Uhlig. Se construyen las funciones impulso-respuesta estructurales con sus intervalos bootstrap, y la descomposición de varianza del error de pronóstico (FEVD). La segunda mitad aborda la no estacionariedad multivariada: cointegración en el sentido Engle-Granger, representación vectorial de corrección de errores (VECM), y el procedimiento de Johansen con sus tests de traza y max-eigen. Se introducen las Local Projections de Jordà como alternativa semiparamétrica a las IRFs de VAR. El capítulo cierra con implementación completa en R (`vars`, `urca`, `lpirfs`, `VARsignR`) aplicada al canal de transmisión monetaria dominicano.

4.1. Del AR al VAR: motivación

4.1.1. La crítica de Sims (1980)

A finales de los setenta, la práctica econométrica macroeconómica estaba dominada por los grandes modelos estructurales de ecuaciones simultáneas, en la tradición Cowles-Klein: sistemas de 50 a 400 ecuaciones, con docenas de variables, en los que la identificación descansaba en restricciones *a priori* —variables clasificadas como endógenas o exógenas, rezagos impuestos por consideraciones institucionales, coeficientes fijados por teoría—.

Christopher Sims publicó en 1980 su ensayo "*Macroeconomics and Reality*", que demolió ese programa con un argumento simple: las restricciones invocadas para identificar los modelos estructurales clásicos eran *increíbles* (*incredible*). La afirmación de que cierta variable es ^aexógena. cierto bloque del sistema —requisito para identificación— rara vez resiste escrutinio cuidadoso. En particular, variables como la oferta monetaria, el gasto público, o incluso el producto, tratadas como exógenas en modelos tradicionales, responden en realidad a los movimientos endógenos del sistema.

La alternativa de Sims era metodológica: tratar *todas* las variables simétricamente, como endógenas, y dejar que los datos hablen de la dinámica del sistema sin imponer restricciones sobre quién causa a quién. Este tratamiento simétrico es el VAR —vector autorregresivo—, la generalización natural del AR univariado del Capítulo 1 a sistemas de n variables. Sims recibió el Premio Nobel de Economía en 2011 por este aporte, compartido con Thomas Sargent.

4.1.2. Por qué importa: endogeneidad en política monetaria

La relevancia del cambio metodológico se aprecia en contextos de política. Consideremos el canal de transmisión

monetaria: la tasa de política monetaria del banco central afecta la tasa interbancaria, las tasas activas, el crédito, la actividad real, y en última instancia la inflación. Al mismo tiempo, el banco central observa la inflación actual y la actividad al fijar su tasa. Todo es endógeno.

En un modelo de ecuación única —por ejemplo, una regresión de inflación sobre tasa rezagada— el investigador se pregunta: ¿la tasa es exógena? Si el banco reacciona a la inflación, la respuesta es no. La estimación sufrirá sesgo por simultaneidad. Si intentamos corregir con variables instrumentales, la tarea empírica de encontrar instrumentos válidos es enorme.

El VAR evade este problema por construcción: trata tasa e inflación simétricamente, modelando la dinámica conjunta. La identificación de shocks —necesaria para interpretar los resultados como "efectos de política"— se mueve a un paso posterior, el del SVAR, donde enfrentamos el problema con instrumentos explícitos: restricciones de corto plazo, de largo plazo, o de signo.

4.1.3. Lo que permite el VAR

Un VAR estimado y (opcionalmente) identificado como SVAR permite responder a cinco preguntas:

1. **Pronóstico multivariado coherente:** proyectar simultáneamente todas las variables del sistema, respetando sus co-movimientos. Un VAR suele dominar a modelos univariados independientes en pronóstico.
2. **Funciones impulso-respuesta (IRFs):** ¿cómo responde cada variable ante un shock en otra? La IRF es el objeto de interés en análisis de política.
3. **Descomposición de varianza del error de pronóstico (FEVD):** ¿qué porcentaje de la variabilidad de una variable se explica por cada tipo de shock?

4. **Causalidad de Granger:** ¿agrega el pasado de una variable poder predictivo sobre otra?
5. **Contraste con teoría:** las IRFs estructurales pueden compararse con predicciones de modelos DSGE o marcos estructurales.

Adicionalmente, el VAR es la infraestructura técnica sobre la que se construyen los módulos siguientes: BVAR (Módulo 4) reemplaza la estimación frecuentista por una bayesiana; FAVAR (Módulo 5) extiende el VAR a un gran conjunto de variables vía factores dinámicos; los modelos de stress testing de pensiones que estás desarrollando usan VARs (o BVARs) como motor de proyección.

4.2. El VAR reducido

4.2.1. Definición y notación

Definición 4.1 (VAR(p) reducido). Sea $\mathbf{Y}_t \in \mathbb{R}^n$ un vector de n variables. El VAR de orden p en forma reducida es

$$\mathbf{Y}_t = \mathbf{c} + \mathbf{A}_1 \mathbf{Y}_{t-1} + \mathbf{A}_2 \mathbf{Y}_{t-2} + \cdots + \mathbf{A}_p \mathbf{Y}_{t-p} + \mathbf{u}_t, \quad (4.1)$$

donde $\mathbf{A}_i \in \mathbb{R}^{n \times n}$, $\mathbf{c} \in \mathbb{R}^n$, y $\mathbf{u}_t$ son los *residuos reducidos*, con

$$\mathbb{E}[\mathbf{u}_t] = \mathbf{0}, \quad \mathbb{E}[\mathbf{u}_t \mathbf{u}_s^\top] = \begin{cases} \Sigma_u & t = s, \\ \mathbf{0} & t \neq s, \end{cases}$$

Σ_u simétrica positiva definida.

Usando el operador de rezagos y $\mathbf{A}(L) = \mathbf{I}_n - \mathbf{A}_1 L - \cdots - \mathbf{A}_p L^p$:

$$\mathbf{A}(L) \mathbf{Y}_t = \mathbf{c} + \mathbf{u}_t. \quad (4.2)$$

Cada ecuación del VAR es:

$$Y_{i,t} = c_i + \sum_{k=1}^n \sum_{j=1}^p a_{ik,j} Y_{k,t-j} + u_{i,t},$$

es decir, cada variable se regresa sobre rezagos de todas las variables del sistema. Esto es lo que distingue al VAR del ARMA univariado ecuación por ecuación.

4.2.2. Estacionariedad

Teorema 4.2 (Estacionariedad del VAR). *El VAR(p) admite una representación estacionaria si y solo si todas las raíces de*

$$\det(\mathbf{I}_n - \mathbf{A}_1 z - \mathbf{A}_2 z^2 - \cdots - \mathbf{A}_p z^p) = 0$$

están fuera del círculo unitario: $|z_i| > 1$ para todo $i = 1, \dots, np$.

Bosquejo. La demostración generaliza la del AR univariado. Si todas las raíces están fuera del círculo unitario, $\det(\mathbf{A}(z))$ no se anula en $|z| \leq 1$, y $\mathbf{A}(L)^{-1}$ existe como serie convergente sobre el espacio de procesos estacionarios. Entonces

$$\mathbf{Y}_t = \mathbf{A}(L)^{-1}\mathbf{c} + \mathbf{A}(L)^{-1}\mathbf{u}_t,$$

que es un proceso estacionario con media $\boldsymbol{\mu} = \mathbf{A}(1)^{-1}\mathbf{c}$ y estructura lineal en los ruidos.

La recíproca requiere análisis más técnico: si alguna raíz está dentro del círculo unitario, el sistema no tiene solución estacionaria. Detalles en Lütkepohl (2005, cap. 2) o Hamilton (1994, cap. 10). $\square$

4.2.3. La forma compañera

Una representación equivalente que facilita análisis es la *forma compañera*, que reduce cualquier $\text{VAR}(p)$ a un $\text{VAR}(1)$ de dimensión mayor.

Proposición 4.3 (Forma compañera). *Definamos*

$$\tilde{\mathbf{Y}}_t = \begin{pmatrix} \mathbf{Y}_t \\ \mathbf{Y}_{t-1} \\ \vdots \\ \mathbf{Y}_{t-p+1} \end{pmatrix} \in \mathbb{R}^{np}, \quad \tilde{\mathbf{c}} = \begin{pmatrix} \mathbf{c} \\ \mathbf{0} \\ \vdots \\ \mathbf{0} \end{pmatrix}, \quad \tilde{\mathbf{u}}_t = \begin{pmatrix} \mathbf{u}_t \\ \mathbf{0} \\ \vdots \\ \mathbf{0} \end{pmatrix},$$

y la matriz compañera

$$\mathbf{F} = \begin{pmatrix} \mathbf{A}_1 & \mathbf{A}_2 & \cdots & \mathbf{A}_{p-1} & \mathbf{A}_p \\ \mathbf{I}_n & \mathbf{0} & \cdots & \mathbf{0} & \mathbf{0} \\ \mathbf{0} & \mathbf{I}_n & \cdots & \mathbf{0} & \mathbf{0} \\ \vdots & & \ddots & & \vdots \\ \mathbf{0} & \mathbf{0} & \cdots & \mathbf{I}_n & \mathbf{0} \end{pmatrix} \in \mathbb{R}^{np \times np}.$$

Entonces el $\text{VAR}(p)$ se puede reescribir como $\text{VAR}(1)$:

$$\tilde{\mathbf{Y}}_t = \tilde{\mathbf{c}} + \mathbf{F}\tilde{\mathbf{Y}}_{t-1} + \tilde{\mathbf{u}}_t.$$

Corolario 4.4. *El $\text{VAR}(p)$ es estacionario si y solo si todos los eigenvalores de $\mathbf{F}$ tienen módulo estrictamente menor que 1.*

La forma compañera es útil computacionalmente: todas las propiedades dinámicas del sistema se reducen a propiedades de una única matriz $\mathbf{F}$.

4.2.4. Media incondicional y representación $\text{MA}(\infty)$

Bajo estacionariedad, tomando esperanza en (??):

$$\boldsymbol{\mu} = \mathbf{A}(1)^{-1} \mathbf{c} = (\mathbf{I}_n - \mathbf{A}_1 - \cdots - \mathbf{A}_p)^{-1} \mathbf{c}.$$

Invertir $\mathbf{A}(L)$ da la *representación $\text{MA}(\infty)$ reducida*:

$$\mathbf{Y}_t - \boldsymbol{\mu} = \mathbf{A}(L)^{-1} \mathbf{u}_t = \sum_{j=0}^{\infty} \boldsymbol{\Psi}_j \mathbf{u}_{t-j}, \quad (4.3)$$

con $\boldsymbol{\Psi}_0 = \mathbf{I}_n$ y matrices $\boldsymbol{\Psi}_j \in \mathbb{R}^{n \times n}$ que se calculan recursivamente.

Proposición 4.5 (Recursión de $\boldsymbol{\Psi}_j$).

$$\boldsymbol{\Psi}_0 = \mathbf{I}_n, \quad \boldsymbol{\Psi}_j = \sum_{i=1}^{\min(j,p)} \boldsymbol{\Psi}_{j-i} \mathbf{A}_i, \quad j \geq 1. \quad (4.4)$$

Demostración. De (??), $\mathbf{A}(L) \left[\sum_{j \geq 0} \boldsymbol{\Psi}_j L^j \right] \mathbf{u}_t = \mathbf{u}_t$. Igualando coeficientes de L^j :

- $j = 0$: $\boldsymbol{\Psi}_0 = \mathbf{I}$.
- $j \geq 1$: $\boldsymbol{\Psi}_j - \sum_{i=1}^{\min(j,p)} \mathbf{A}_i \boldsymbol{\Psi}_{j-i} = \mathbf{0}$.

Reordenando y teniendo cuidado con el orden de multiplicación:

$$\boldsymbol{\Psi}_j = \sum_{i=1}^{\min(j,p)} \mathbf{A}_i \boldsymbol{\Psi}_{j-i},$$

(o equivalentemente la forma dada, según convención de orden). Ambas son correctas; verificar la convención del software usado. $\square$

Los Ψ_j capturan el efecto dinámico de un shock en los residuos reducidos sobre las variables del sistema. **Crucialmente**, los $\mathbf{u}_t$ tienen covarianza cruzada no nula en general: no son shocks económicamente interpretables. Esto motiva la teoría de identificación de la Sección ??.

4.2.5. Autocovarianzas del VAR

Proposición 4.6. Sea $\Gamma(h) = \mathbb{E}[(\mathbf{Y}_t - \boldsymbol{\mu})(\mathbf{Y}_{t-h} - \boldsymbol{\mu})^\top]$. Entonces:

1. $\Gamma(0) = \sum_{j=0}^{\infty} \Psi_j \Sigma_u \Psi_j^\top$.
2. $\Gamma(h) = \sum_{j=0}^{\infty} \Psi_{j+h} \Sigma_u \Psi_j^\top$ para $h \geq 0$.
3. $\Gamma(-h) = \Gamma(h)^\top$.

Todas las series convergen bajo estacionariedad.

Alternativamente, $\Gamma(h)$ satisface las ecuaciones de Yule-Walker matriciales:

$$\Gamma(h) = \sum_{i=1}^p \mathbf{A}_i \Gamma(h-i), \quad h \geq 1.$$

4.2.6. Estimación por MCO: un resultado notable

Teorema 4.7 (MV = MCO ecuación por ecuación). En un VAR reducido con $\mathbf{u}_t \sim \mathcal{N}(\mathbf{0}, \Sigma_u)$ iid, el estimador de máxima verosimilitud de $\mathbf{c}$ y $\{\mathbf{A}_i\}_{i=1}^p$ coincide con MCO aplicado ecuación por ecuación.

Idea. La log-verosimilitud del VAR con regresores $\mathbf{X}_t = (1, \mathbf{Y}_{t-1}^\top, \dots, \mathbf{Y}_{t-p}^\top)^\top$ y matriz de coeficientes $\mathbf{B} = (\mathbf{c}, \mathbf{A}_1, \dots, \mathbf{A}_p)$ es

$$\ell(\mathbf{B}, \Sigma_u) = -\frac{Tn}{2} \log(2\pi) - \frac{T}{2} \log |\Sigma_u| - \frac{1}{2} \sum_{t=1}^T (\mathbf{Y}_t - \mathbf{B}\mathbf{X}_t)^\top \Sigma_u^{-1} (\mathbf{Y}_t - \mathbf{B}\mathbf{X}_t).$$

Concentrando en Σ_u (lo cual da $\hat{\Sigma}_u = T^{-1} \sum \hat{\mathbf{u}}_t \hat{\mathbf{u}}_t^\top$) y maximizando en $\mathbf{B}$:

$$\hat{\mathbf{B}} = \left(\sum_t \mathbf{Y}_t \mathbf{X}_t^\top \right) \left(\sum_t \mathbf{X}_t \mathbf{X}_t^\top \right)^{-1}.$$

Dado que todas las ecuaciones del VAR comparten los mismos regresores $\mathbf{X}_t$, el sistema SUR de Zellner colapsa a MCO por ecuación independientemente de Σ_u . Esto es lo que hace al VAR computacionalmente simple: `lm()` por ecuación es estimación eficiente. $\square$

4.2.7. Distribución asintótica

Teorema 4.8 (Normalidad asintótica de $\hat{\mathbf{B}}$). *Bajo estacionariedad y momentos cuartos finitos, $\text{vec}(\hat{\mathbf{B}})$ es consistente y*

$$\sqrt{T} [\text{vec}(\hat{\mathbf{B}}) - \text{vec}(\mathbf{B})] \xrightarrow{d} \mathcal{N}(\mathbf{0}, \Sigma_u \otimes \Gamma_X^{-1}),$$

con $\Gamma_X = \mathbb{E}[\mathbf{X}_t \mathbf{X}_t^\top]$.

Los errores estándar se construyen desde el producto Kronecker $\hat{\Sigma}_u \otimes (\sum_t \mathbf{X}_t \mathbf{X}_t^\top)^{-1} \cdot T$. Para una ecuación individual, el bloque correspondiente da los errores estándar por ecuación, que coinciden con los errores estándar OLS estándar.

4.2.8. Selección del orden p

Tres criterios estándar:

$$\text{AIC}(p) = \log |\hat{\Sigma}_u(p)| + \frac{2}{T} \cdot pn^2, \quad (4.5)$$

$$\text{BIC}(p) = \log |\hat{\Sigma}_u(p)| + \frac{\log T}{T} \cdot pn^2, \quad (4.6)$$

$$\text{HQC}(p) = \log |\hat{\Sigma}_u(p)| + \frac{2 \log \log T}{T} \cdot pn^2. \quad (4.7)$$

El término pn^2 es el número de parámetros en las matrices $\mathbf{A}_i$; captura el costo de complejidad. La *maldición de la dimensionalidad* es visible: para $n = 4$ variables y $p = 2$, hay $4 \cdot 4 \cdot 2 = 32$ coeficientes de rezago, más 4 de intercepto, más $4 \cdot 5/2 = 10$ de Σ_u : 46 parámetros totales. Con $T = 200$ observaciones mensuales, eso es 4.3 observaciones por parámetro. El Módulo 5 abordará este problema con LASSO y factores; el Módulo 4 con priors bayesianos.

La elección habitual en VAR macroeconómicos: HQC en datos mensuales de frecuencia moderada ($T \approx 200$), BIC con muestras más pequeñas, AIC si el objetivo es pronóstico puro y se puede permitir más parámetros.

4.2.9. Diagnóstico

Los diagnósticos estándar del VAR son análogos multivariados de los del ARMA:

- **Autocorrelación residual:** test portmanteau multivariado (Hosking, Li-McLeod). En R: `vars::serial.test`. Bajo H_0 de residuos no autocorrelacionados, el estadístico es aproximadamente χ^2 .
- **Heterocedasticidad:** test ARCH multivariado; en R: `vars::arch.test`.

- **Normalidad:** test de Jarque-Bera multivariado; en R: `vars::normality.test`. La normalidad no es requerida para consistencia pero afecta bandas de confianza de IRFs.
- **Estabilidad:** eigenvalores de la matriz compañera $\mathbf{F}$ dentro del círculo unitario.

Cuando el diagnóstico falla, las direcciones habituales de mejora son: aumentar p ; incluir variables adicionales que absorben autocorrelación residual; modelar cambios estructurales o no linealidades.

4.3. Causalidad de Granger

4.3.1. Concepto y definición formal

Definición 4.9 (No-causalidad de Granger). En un sistema bivariado (Y_t, X_t) , X *no causa Granger a* Y si, una vez controlado por el pasado de Y , los rezagos de X no aportan poder predictivo lineal:

$$\mathbb{E}[Y_t \mid Y_{t-1}, \dots, X_{t-1}, \dots] = \mathbb{E}[Y_t \mid Y_{t-1}, \dots]. \quad (4.8)$$

Equivalentemente, la varianza del error de pronóstico óptimo de Y_t no se reduce al agregar el pasado de X .

La definición se generaliza a un VAR de n variables: X no causa Granger a Y *dado el resto del sistema* si los coeficientes de rezagos de X en la ecuación de Y son todos cero.

4.3.2. Test en un VAR

Consideremos la ecuación de Y_t en un VAR bivariado:

$$Y_t = c_1 + \sum_{j=1}^p a_{11,j} Y_{t-j} + \sum_{j=1}^p a_{12,j} X_{t-j} + u_{1,t}.$$

Teorema 4.10 (Test de no-causalidad de Granger). X *no causa Granger a* Y *si y solo si* $a_{12,1} = a_{12,2} = \dots = a_{12,p} = 0$.

El test es de Wald (o equivalentemente F) sobre p restricciones lineales. En R: `vars::causality(fit, cause = "X")`. Bajo H_0 y regularidad, el estadístico sigue χ_p^2 asintóticamente.

4.3.3. Granger $\neq$ causalidad filosófica

Observación 4.11 (Advertencia conceptual fundamental). La causalidad.^{en} sentido de Granger es precedencia temporal en el poder predictivo. **No es causalidad en sentido estructural o filosófico**. Tres ejemplos clásicos ilustran la diferencia:

1. **Expectativas racionales:** los precios de futuros causan Granger a los precios spot porque incorporan información anticipada, no porque los determinen causalmente.
2. **Variable omitida:** si Z causa tanto a X como a Y con diferentes rezagos, X puede aparecer causando a Y sin relación estructural directa.
3. **Anuncios anticipados:** anuncios de política monetaria mueven expectativas de inflación antes de afectar la inflación misma.

El mismo Granger (1969) llamó a su concepto "*precedencia temporal*" ("temporal precedence"); el término causalidad se popularizó en la literatura subsecuente y ha generado décadas de confusión. La práctica recomendada es reportar tests de Granger con cuidado interpretativo y distinguirlos claramente de análisis estructurales (SVAR).

4.3.4. Usos legítimos del test de Granger

A pesar de la advertencia, el test tiene usos defendibles:

- **Diagnóstico de especificación:** verificar que variables incluidas "pertenecen al sistema en sentido predictivo.
- **Simplificación:** si X no Granger-causa a Y , podemos considerar excluir X de la ecuación de Y (no del sistema).
- **Detección de direcciones:** entre dos variables, identificar cuál "lidera" en sentido predictivo.

4.4. VAR estructural: identificación

4.4.1. El problema fundamental de identificación

El VAR reducido es *estadísticamente completo*: describe la dinámica conjunta de las variables. Pero los residuos reducidos $\mathbf{u}_t$ no son shocks económicamente interpretables: tienen covarianza cruzada Σ_u no diagonal, y un "shock en u_1 " ejerce efectos que mezclan influencias de múltiples fuentes económicas (demanda, oferta, política, etc.).

Para análisis causal estructural necesitamos descomponer $\mathbf{u}_t$ en *shocks estructurales* $\boldsymbol{\varepsilon}_t$ ortogonales e interpretables. Formalmente:

Definición 4.12 (SVAR). El VAR estructural es

$$\mathbf{B}_0 \mathbf{Y}_t = \mathbf{b}_0 + \mathbf{B}_1 \mathbf{Y}_{t-1} + \cdots + \mathbf{B}_p \mathbf{Y}_{t-p} + \boldsymbol{\varepsilon}_t, \quad (4.9)$$

con $\boldsymbol{\varepsilon}_t \sim (\mathbf{0}, \mathbf{I}_n)$: shocks estructurales *ortogonales* y de *varianza unitaria*.

Pre-multiplicando (??) por $\mathbf{B}_0^{-1}$ se obtiene el VAR reducido (??) con

$$\mathbf{A}_i = \mathbf{B}_0^{-1} \mathbf{B}_i, \quad \mathbf{u}_t = \mathbf{B}_0^{-1} \boldsymbol{\varepsilon}_t, \quad \Sigma_u = \mathbf{B}_0^{-1} (\mathbf{B}_0^{-1})^\top. \quad (4.10)$$

La relación $\Sigma_u = \mathbf{B}_0^{-1} (\mathbf{B}_0^{-1})^\top$ es el corazón del problema. De los datos estimamos $\hat{\Sigma}_u$, que es simétrica y tiene $n(n+1)/2$ elementos únicos. Queremos recuperar $\mathbf{B}_0^{-1}$, matriz $n \times n$ con n^2 elementos. Contamos:

- Información: $n(n+1)/2$ ecuaciones (los elementos únicos de Σ_u).
- Incógnitas: n^2 elementos de $\mathbf{B}_0^{-1}$.
- Déficit: $n^2 - n(n+1)/2 = n(n-1)/2$ restricciones adicionales **necesarias**.

Por ejemplo, con $n = 3$ variables: 6 ecuaciones, 9 incógnitas, 3 restricciones faltantes. Con $n = 4$: 10 ecuaciones, 16 incógnitas, 6 restricciones faltantes. El problema de identificación escala cuadráticamente: sistemas grandes requieren muchas más restricciones.

4.4.2. Identificación recursiva (Cholesky)

La solución más simple y más usada fue propuesta por Sims (1980) mismo: imponer que $\mathbf{B}_0^{-1}$ sea *triangular inferior*. Esto da exactamente $n(n-1)/2$ ceros (los elementos sobre la diagonal), lo que identifica exactamente el sistema.

Teorema 4.13 (Identificación por Cholesky). *Dada Σ_u positiva definida, la descomposición de Cholesky produce una única matriz $\mathbf{P}$ triangular inferior con diagonal positiva tal que*

$$\Sigma_u = \mathbf{P}\mathbf{P}^\top.$$

Tomando $\mathbf{B}_0^{-1} = \mathbf{P}$ identifica exactamente el SVAR.

La descomposición existe y es única por construcción. Computacionalmente, `chol(Sigma_u)` en R devuelve $\mathbf{P}$ (o su traspuesta, según convención).

Supuesto económico detrás de Cholesky

Tomar $\mathbf{B}_0^{-1}$ triangular inferior equivale a imponer que:

- La variable 1 no responde contemporáneamente a shocks de variables $2, \dots, n$.
- La variable 2 responde contemporáneamente solo al shock de variable 1.
- La variable 3 responde contemporáneamente solo a shocks de variables 1 y 2.
- ...

- La variable n responde contemporáneamente a todos los shocks.

Es decir, hay un orden "de la más lenta a la más rápida.^{en} la respuesta contemporánea. El ordenamiento es una decisión del investigador y debe ser defendido económicamente.

Ordenamiento típico para transmisión monetaria

En un VAR de política monetaria con cuatro variables, un orden estándar es:

1. Actividad real (PIB o IMAE): variables de lado real reaccionan lentamente.
2. Inflación: responde a actividad contemporánea (Curva de Phillips).
3. Tasa de política: el banco central observa actividad e inflación y reacciona (regla de Taylor).
4. Tipo de cambio o precios de activos: reaccionan a todo lo anterior; mercados financieros son los más rápidos.

Supuestos implícitos (defendibles con datos mensuales):

- La actividad del mes no responde dentro del mismo mes a un shock cambiario: razonable porque los efectos reales de devaluaciones toman tiempo.
- El banco central no conoce la inflación del mes actual al fijar la tasa: razonable porque el IPC se publica con rezago.

Dependencia del ordenamiento

El resultado estructural depende del orden elegido. Diferentes órdenes producen diferentes IRFs. Práctica recomendada: reportar el orden base y uno o dos órdenes alternativos como chequeo de robustez. Si las conclusiones cualitativas cambian con el orden, el hallazgo es frágil.

4.4.3. Restricciones de corto plazo no recursivas

Una generalización de Cholesky es imponer ceros en posiciones específicas de $\mathbf{B}_0$ o $\mathbf{B}_0^{-1}$ motivadas por teoría, no necesariamente formando un triángulo.

Caso justo-identificado

Si imponemos $n(n-1)/2$ ceros linealmente independientes, el sistema es exactamente identificado. La estimación se hace por MV numérica: maximizar ℓ sujeto a las restricciones.

Caso sobre-identificado

Si imponemos *más* de $n(n-1)/2$ ceros, hay restricciones de sobra. Estas pueden testearse: bajo H_0 de restricciones válidas,

$$LR = T[\log |\hat{\Sigma}_u^R| - \log |\hat{\Sigma}_u|] \xrightarrow{d} \chi_q^2,$$

con $q = (\text{número de restricciones}) - n(n-1)/2$. $\hat{\Sigma}_u^R$ es la estimación con restricciones impuestas, $\hat{\Sigma}_u$ la sin restricciones.

Ejemplo: modelo de oferta y demanda

Sea $\mathbf{Y}_t = (p_t, q_t)^\top$ precio y cantidad. El modelo estructural es:

$$\begin{cases} p_t = -\alpha q_t + \varepsilon_t^D & (\text{demanda: pendiente negativa}) \\ p_t = \beta q_t + \varepsilon_t^S & (\text{oferta: pendiente positiva}) \end{cases}$$

En forma matricial:

$$\begin{pmatrix} 1 & \alpha \\ 1 & -\beta \end{pmatrix} \begin{pmatrix} p_t \\ q_t \end{pmatrix} = \begin{pmatrix} \varepsilon_t^D \\ \varepsilon_t^S \end{pmatrix}.$$

Aquí $\mathbf{B}_0$ tiene α y $-\beta$ libres —dos parámetros— y la restricción de que los elementos diagonales son 1 (normalización).

Con dos variables, $n(n-1)/2 = 1$ restricción es necesaria para identificar; la normalización $[\mathbf{B}_0]_{11} = [\mathbf{B}_0]_{22} = 1$ provee lo que necesitamos.

En R, la función `SVAR(fit, Amat = matriz_de_restricciones)` del paquete `vars` permite especificar patrones arbitrarios.

4.4.4. Restricciones de largo plazo: Blanchard-Quah (1989)

Una estrategia conceptualmente distinta: en vez de restricciones sobre el efecto *contemporáneo*, imponer restricciones sobre el efecto *de largo plazo* de ciertos shocks.

El efecto de largo plazo

En la representación $\text{MA}(\infty)$ estructural,

$$\mathbf{Y}_t - \boldsymbol{\mu} = \sum_{j=0}^{\infty} \boldsymbol{\Theta}_j \boldsymbol{\varepsilon}_{t-j},$$

el *efecto acumulado* de un shock es

$$\boldsymbol{\Theta}(1) = \sum_{j=0}^{\infty} \boldsymbol{\Theta}_j = \mathbf{A}(1)^{-1} \mathbf{B}_0^{-1},$$

donde $\mathbf{A}(1) = \mathbf{I} - \mathbf{A}_1 - \dots - \mathbf{A}_p$.

Restricciones del tipo $[\boldsymbol{\Theta}(1)]_{ij} = 0$ imponen que cierto shock j tenga efecto cero a largo plazo sobre cierta variable i . Estas restricciones se traducen a restricciones lineales en $\mathbf{B}_0^{-1}$ vía $\mathbf{B}_0^{-1} = \mathbf{A}(1)\boldsymbol{\Theta}(1)$.

Ejemplo: Blanchard-Quah

Sea $\mathbf{Y}_t = (\Delta \text{GDP}_t, \text{unemp}_t)^\top$. Blanchard y Quah (1989) postulan:

1. Shock de oferta: puede tener efecto permanente sobre el nivel de GDP (mueve la productividad).

2. Shock de demanda: solo tiene efecto *transitorio* sobre GDP; el efecto de largo plazo es cero.

La restricción "shock de demanda no mueve GDP en el largo plazo" se traduce a un cero en la posición apropiada de $\Theta(1)$. Combinado con la normalización de $\Theta(0)\Theta(0)^\top = \Sigma_u$, identifica el SVAR.

Generalización: Galí (1999)

Galí extendió la idea a sistemas más grandes: el shock tecnológico es definido como el único con efecto permanente sobre productividad. Este enfoque es estándar en análisis de ciclos reales y en evaluación de fuentes de fluctuaciones.

4.4.5. Restricciones de signo: Uhlig (2005)

Un giro conceptual relativamente reciente: en vez de imponer restricciones *cuantitativas* (ceros, valores específicos), imponer restricciones *cualitativas* sobre los signos de las IRFs.

Motivación

Restricciones de ceros son fuertes: afirman que cierto efecto es *exactamente* cero. En la práctica económica, estamos más seguros del *signo* de un efecto que de su magnitud. Por ejemplo:

- Un aumento de tasa de política debería bajar inflación (y no subirla).
- Un shock de demanda positivo debería subir precios y cantidad.
- Un shock adverso de oferta debería bajar producción y subir precios.

Imponer solo signos es menos restrictivo que imponer valores específicos. Uhlig argumenta que es más creíble.

Algoritmo

El algoritmo básico (Uhlig 2005, Rubio-Ramírez *et al.* 2010) es:

1. Descomponer $\hat{\Sigma}_u = \mathbf{P}\mathbf{P}^\top$ por Cholesky.
2. Generar una matriz ortogonal aleatoria $\mathbf{Q}$ ($\mathbf{Q}\mathbf{Q}^\top = \mathbf{I}$).
3. Candidato: $\mathbf{B}_0^{-1} = \mathbf{P}\mathbf{Q}$. Esto preserva $\Sigma_u = \mathbf{B}_0^{-1}(\mathbf{B}_0^{-1})^\top$.
4. Computar IRFs del candidato.
5. Aceptar la rotación si las IRFs satisfacen las restricciones de signo en los horizontes especificados.
6. Repetir muchas veces.

El resultado no es un único $\hat{\mathbf{B}}_0^{-1}$, sino un *conjunto* de matrices compatibles, y correspondientemente un conjunto de IRFs con bandas de identificación. Es un cambio conceptual: abandonamos identificación puntual por identificación por conjunto.

Implementación y limitaciones

En R: `VARsignR::uhlig.reject()` para el algoritmo de rechazo (aceptación/rechazo), `bsvars` para implementaciones más sofisticadas y bayesianas.

Críticas importantes (Baumeister-Hamilton 2015): las bandas de credibilidad pueden ser muy anchas porque cualquier rotación ortogonal consistente con los signos es considerada igualmente plausible. Restricciones adicionales (e.g., magnitudes mínimas) reducen esta indeterminación.

	Cholesky	Largo plazo	Signo
Tipo de restric- ción	Ceros contemporá- neos	Ceros en $\Theta(1)$	Desigu
Identificación	Puntual	Puntual	Conjun
Simplicidad	Máxima	Media	Media
Credibilidad	Depende del orden	Depende de largo pla- zo	Alta
Implementación	Trivial	Restricciones lineales	Monte
Uso típico	Política monetaria	Ciclos reales	Shocks micos

Tabla 4.1: Comparación entre estrategias de identificación.

4.4.6. Comparación de estrategias de identificación

En la práctica moderna es común reportar análisis bajo múltiples identificaciones como chequeo de robustez. Si los resultados cualitativos son consistentes entre estrategias, la evidencia es sólida.

4.5. IRFs y descomposición de varianza

4.5.1. Funciones impulso-respuesta estructurales

Una vez identificado $\mathbf{B}_0^{-1}$, las IRFs estructurales se computan vía:

Definición 4.14 (IRF estructural).

$$\Theta_j = \Psi_j \mathbf{B}_0^{-1}, \quad j = 0, 1, 2, \dots \quad (4.11)$$

El elemento $[\Theta_j]_{ik}$ mide el efecto de un shock estructural de magnitud uno en ε_k sobre Y_i al horizonte j .

Los Ψ_j se calculan con la recursión (??) a partir de las matrices $\mathbf{A}_i$ estimadas. La identificación solo modifica la "transformación final" vía $\mathbf{B}_0^{-1}$.

Convención: shock de magnitud unitaria vs. una desviación estándar

Dos convenciones coexisten:

- **Shock unitario:** $\varepsilon_k = 1$. Los elementos $[\Theta_j]_{ik}$ son interpretables como "efecto de un aumento de 1 en el shock estructural k ".
- **Shock de una desviación estándar:** $\varepsilon_k = 1$ dado que $\mathbb{V}(\varepsilon_k) = 1$ por normalización, ambas convenciones coinciden en la parametrización estándar.
- **Shock típico:** algunos análisis usan el shock que produce un movimiento específico (e.g., un shock que sube la tasa en 25 puntos base"). Esto requiere normalización adicional.

En R, el paquete `vars` usa por defecto shocks de una desviación estándar (consistente con $\mathbb{V}(\varepsilon_k) = 1$).

4.5.2. Intervalos de confianza para IRFs

Las IRFs estructurales son funciones no lineales de los parámetros estimados. La construcción de intervalos requiere cuidado.

Método delta asintótico

Si $\boldsymbol{\theta} = (\text{vec}(\mathbf{B})^\top, \text{vec}(\Sigma_u)^\top)^\top$ contiene todos los parámetros, la IRF es una función $\boldsymbol{\theta} \mapsto \boldsymbol{\Theta}_j(\boldsymbol{\theta})$. Por método delta:

$$\sqrt{T}[\text{vec}(\hat{\boldsymbol{\Theta}}_j) - \text{vec}(\boldsymbol{\Theta}_j)] \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathbf{G}_j \mathbb{V}(\hat{\boldsymbol{\theta}}) \mathbf{G}_j^\top),$$

con $\mathbf{G}_j = \partial \text{vec}(\boldsymbol{\Theta}_j) / \partial \boldsymbol{\theta}^\top$ el Jacobiano. Cerrado en forma pero complejo, especialmente para horizontes grandes.

Bootstrap residual

Es el método dominante en la práctica. El procedimiento:

1. Estimar el VAR y obtener residuos $\hat{\mathbf{u}}_t$.
2. Remuestrear con reemplazo $\hat{\mathbf{u}}_t^*$ de $\{\hat{\mathbf{u}}_1, \dots, \hat{\mathbf{u}}_T\}$.
3. Simular una serie artificial $\mathbf{Y}_t^*$ usando el VAR estimado y $\hat{\mathbf{u}}_t^*$.
4. Re-estimar el VAR en $\mathbf{Y}_t^*$ y computar IRFs $\hat{\boldsymbol{\Theta}}_j^*$.
5. Repetir $B = 500$ o 1000 veces.
6. Intervalo de confianza al 95 %: cuantiles 2.5 % y 97.5 % de la distribución bootstrap.

Bootstrap de bloques

Si hay autocorrelación residual remanente (diagnóstico falla), el bootstrap estándar es incorrecto. Alternativas:

- **Bootstrap de bloques** (Künsch, 1989): remuestrear bloques contiguos de residuos de longitud fija ℓ .
- **Bootstrap estacionario** (Politis-Romano, 1994): longitudes de bloque aleatorias.

En R, `vars::irf` implementa bootstrap residual estándar.

4.5.3. Descomposición de varianza del error de pronóstico (FEVD)

Definición 4.15 (FEVD). La varianza del error de pronóstico a h pasos para la variable i es

$$\mathbb{V}[Y_{i,T+h} - \hat{Y}_{i,T+h|T}] = \sum_{j=0}^{h-1} \sum_{k=1}^n [\Theta_j]_{ik}^2,$$

y la proporción atribuible al shock estructural k es

$$\omega_{ik}(h) = \frac{\sum_{j=0}^{h-1} [\Theta_j]_{ik}^2}{\sum_{j=0}^{h-1} \sum_{m=1}^n [\Theta_j]_{im}^2}. \quad (4.12)$$

Proposición 4.16. $\sum_{k=1}^n \omega_{ik}(h) = 1$ para todo i y h .

Demostración. Se sigue directamente de la definición: el denominador es la suma del numerador sobre k . $\square$

La FEVD descompone la variabilidad de cada variable en contribuciones de los n shocks estructurales. Interpretaciones típicas:

- .^A horizonte de 12 meses, el 45 % de la variabilidad del IPC se explica por shocks de política monetaria, 30 % por shocks cambiarios, 15 % por shocks de oferta y 10 % por shocks propios".
- Evolución de la descomposición con h : a corto plazo dominan shocks propios de la variable (si es Cholesky); a largo plazo se estabiliza la descomposición estructural.

4.6. Cointegración y VECM

4.6.1. El problema motivador

Hasta ahora hemos asumido que $\mathbf{Y}_t$ es estacionario. ¿Qué pasa si algunas variables son $I(1)$? Recordemos las opciones:

1. **VAR en niveles:** inválido. Produce regresiones espurias por no estacionariedad.
2. **VAR en primeras diferencias:** $\Delta \mathbf{Y}_t$ es $I(0)$, válido estadísticamente, pero **pierde la relación de largo plazo** entre variables.
3. **VECM:** captura tanto la dinámica de corto plazo en diferencias como las desviaciones del equilibrio de largo plazo.

La tercera opción requiere un concepto nuevo: cointegración.

4.6.2. Cointegración: definición y ejemplos

Definición 4.17 (Cointegración — Engle y Granger, 1987). Sea $\mathbf{Y}_t \in \mathbb{R}^n$ con componentes $I(1)$. $\mathbf{Y}_t$ está *cointegrado* con rango r ($0 < r < n$) si existen r vectores linealmente independientes $\beta_1, \dots, \beta_r \in \mathbb{R}^n$ (llamados *vectores de cointegración*) tales que

$$\beta_i^\top \mathbf{Y}_t \sim I(0) \quad \text{para } i = 1, \dots, r.$$

La matriz $\beta = (\beta_1, \dots, \beta_r) \in \mathbb{R}^{n \times r}$ se llama *matriz de cointegración*.

Interpretación: aunque cada Y_{it} vaga individualmente, ciertas combinaciones lineales $\beta_i^\top \mathbf{Y}_t$ son estacionarias. Estas combinaciones representan **relaciones de equilibrio de largo plazo**: las variables pueden alejarse transitoriamente pero regresan al equilibrio.

Ejemplo 1: paridad de tasas

Considere tres variables $I(1)$: tasa interés doméstica i_t , tasa externa i_t^* , depreciación esperada Δe_t^e . La paridad descubierta dice:

$$i_t = i_t^* + \Delta e_t^e + \pi_t,$$

con $\pi_t \sim I(0)$ (prima de riesgo transitoria). El vector $\beta = (1, -1, -1)^\top$ cointegra el sistema: $i_t - i_t^* - \Delta e_t^e = \pi_t \sim I(0)$.

Ejemplo 2: consumo y renta

Consumo C_t e ingreso disponible Y_t son típicamente $I(1)$. Si la teoría de la renta permanente es correcta, la propensión a consumir es estable y $C_t - \theta Y_t \sim I(0)$. Vector de cointegración: $(1, -\theta)^\top$.

Ejemplo 3: paridad de poder adquisitivo (PPP)

Tipo de cambio real $e_t + p_t^* - p_t$ debería ser estacionario bajo PPP. Vector de cointegración: $(1, -1, 1)$ sobre $(e_t, p_t, p_t^*)^\top$. La evidencia empírica de PPP es mixta, pero el marco de cointegración provee el test formal.

Caso límite: $r = 0$ y $r = n$

- $r = 0$: no hay cointegración. Las variables $I(1)$ son completamente no relacionadas; usar VAR en diferencias.
- $r = n$: las variables son $I(0)$ por sí mismas. Equivale a decir que $\mathbf{Y}_t$ es estacionario; usar VAR en niveles.
- $0 < r < n$: cointegración parcial. Usar VECM.

4.6.3. Representación VECM: teorema de Engle-Granger

Teorema 4.18 (Teorema de representación de Engle-Granger, 1987). *Si $\mathbf{Y}_t$ es $I(1)$ con cointegración de rango r ($0 < r < n$), entonces el $\text{VAR}(p)$ en niveles admite la representación vector de corrección de errores (VECM):*

$$\Delta \mathbf{Y}_t = \boldsymbol{\alpha} \boldsymbol{\beta}^\top \mathbf{Y}_{t-1} + \sum_{i=1}^{p-1} \boldsymbol{\Gamma}_i \Delta \mathbf{Y}_{t-i} + \mathbf{u}_t, \quad (4.13)$$

donde $\boldsymbol{\alpha} \in \mathbb{R}^{n \times r}$ es la matriz de velocidades de ajuste, $\boldsymbol{\beta} \in \mathbb{R}^{n \times r}$ es la matriz de cointegración, y $\boldsymbol{\alpha} \boldsymbol{\beta}^\top = -(\mathbf{I} - \mathbf{A}_1 - \cdots - \mathbf{A}_p) = -\mathbf{A}(1)$ tiene rango r .

Bosquejo. Comenzando con el $\text{VAR}(p)$ en niveles,

$$\mathbf{Y}_t = \mathbf{A}_1 \mathbf{Y}_{t-1} + \cdots + \mathbf{A}_p \mathbf{Y}_{t-p} + \mathbf{u}_t,$$

restamos $\mathbf{Y}_{t-1}$ de ambos lados:

$$\Delta \mathbf{Y}_t = (\mathbf{A}_1 - \mathbf{I}) \mathbf{Y}_{t-1} + \mathbf{A}_2 \mathbf{Y}_{t-2} + \cdots + \mathbf{A}_p \mathbf{Y}_{t-p} + \mathbf{u}_t.$$

Ahora sumamos y restamos cuidadosamente para agrupar términos en diferencias. Es una manipulación algebraica estándar. El resultado es (??) con

$$\boldsymbol{\Pi} \equiv \boldsymbol{\alpha} \boldsymbol{\beta}^\top = -(\mathbf{I} - \mathbf{A}_1 - \cdots - \mathbf{A}_p) = -\mathbf{A}(1),$$

$$\boldsymbol{\Gamma}_i = -(\mathbf{A}_{i+1} + \cdots + \mathbf{A}_p), \quad i = 1, \dots, p-1.$$

La estacionariedad del sistema ($I(1)$ con cointegración) implica $\text{rank}(\boldsymbol{\Pi}) = r$, que admite la factorización $\boldsymbol{\Pi} = \boldsymbol{\alpha} \boldsymbol{\beta}^\top$ con ambas matrices de rango r . Detalles completos en Lütkepohl (2005, cap. 6) o Johansen (1995). $\square$

Interpretación de los términos

En la ecuación VECM:

- $\beta^\top \mathbf{Y}_{t-1}$: *desviaciones del equilibrio* de largo plazo. Si $\mathbf{Y}_{t-1}$ está "en equilibrio" ($\beta^\top \mathbf{Y}_{t-1} = \mathbf{0}$), este término no empuja el sistema.
- α : *velocidades de ajuste*. $\alpha_{ij} < 0$ significa que variable i tiende a corregir desviaciones del j -ésimo equilibrio.
- $\Gamma_i \Delta \mathbf{Y}_{t-i}$: *dinámica de corto plazo*, en primeras diferencias.

Ejemplo numérico

Supongamos $n = 2$ con $r = 1$, $\beta = (1, -1)^\top$, $\alpha = (-0,3, 0,1)^\top$. Entonces

$$\begin{aligned}\Delta Y_{1,t} &= -0,3(Y_{1,t-1} - Y_{2,t-1}) + \Gamma \Delta \mathbf{Y}_{t-1} + u_{1,t}, \\ \Delta Y_{2,t} &= +0,1(Y_{1,t-1} - Y_{2,t-1}) + \Gamma \Delta \mathbf{Y}_{t-1} + u_{2,t}.\end{aligned}$$

Si $Y_{1,t-1} > Y_{2,t-1}$ (equilibrio violado positivamente), Y_1 baja ($\alpha_1 < 0$) y Y_2 sube ($\alpha_2 > 0$), ambos empujando el sistema de vuelta al equilibrio $Y_1 = Y_2$.

4.6.4. Procedimiento de Johansen

Engle-Granger es simple pero limitado: supone $r = 1$ y requiere elegir una variable "dependiente" (rompiendo simetría). Johansen (1988) propuso un enfoque de MV que estima el rango r y las matrices α, β simultáneamente, tratando todas las variables simétricamente.

Derivación compacta

El test de Johansen se basa en MV gaussiana del VECM (??) con $\Pi = \alpha\beta^\top$. Concentrando ℓ en Γ_i y Σ_u (regresiones

auxiliares sobre $\Delta \mathbf{Y}_{t-i}$), el problema se reduce a encontrar α, β que maximicen una función cuadrática generalizada, que se resuelve por problema de eigenvalores generalizados:

$$\det(\lambda \mathbf{S}_{11} - \mathbf{S}_{10} \mathbf{S}_{00}^{-1} \mathbf{S}_{01}) = 0,$$

con $\mathbf{S}_{ij}$ matrices de momentos construidas a partir de residuos auxiliares.

Esto produce n eigenvalores $\hat{\lambda}_1 > \hat{\lambda}_2 > \dots > \hat{\lambda}_n \geq 0$. Intuitivamente, $\hat{\lambda}_i$ grande corresponde a una combinación lineal "muy estacionaria" (candidato a vector de cointegración); $\hat{\lambda}_i$ cerca de cero corresponde a una combinación "residual".

Tests del rango

Dos estadísticos complementarios:

Definición 4.19 (Test de traza).

$$\text{Traza}(r_0) = -T \sum_{i=r_0+1}^n \log(1 - \hat{\lambda}_i). \quad (4.14)$$

$$H_0 : \text{rank}(\Pi) \leq r_0. \quad H_1 : \text{rank}(\Pi) > r_0.$$

Definición 4.20 (Test de máximo eigenvalor).

$$\lambda_{\text{máx}}(r_0) = -T \log(1 - \hat{\lambda}_{r_0+1}). \quad (4.15)$$

$$H_0 : \text{rank} = r_0. \quad H_1 : \text{rank} = r_0 + 1.$$

Ambos son tests de razón de verosimilitud, pero con distribuciones asintóticas *no estándar* (funcionales de procesos brownianos multivariados, similares a Dickey-Fuller). Los cuantiles están tabulados: Johansen (1988, 1995) y Osterwald-Lenum (1992).

Procedimiento secuencial

Para determinar r :

1. Testear $r_0 = 0$. Si no se rechaza: $r = 0$ (no cointegración).
2. Si se rechaza, testear $r_0 = 1$. Si no se rechaza: $r = 1$.
3. Continuar hasta no rechazar o agotar $r_0 = n - 1$.

En caso de discrepancia entre traza y max-eigen, prevalece el criterio del traza (más robusto en muestras pequeñas según simulaciones de Johansen).

Inclusión de términos determinísticos

Una sutileza importante: la tabla de valores críticos depende de qué términos determinísticos se incluyen. Cinco casos estándar (Johansen, 1995):

1. Sin constante ni tendencia (raro).
2. Constante restringida al espacio de cointegración (la constante solo aparece en la relación de equilibrio).
3. Constante no restringida (drift en la dinámica de $\Delta \mathbf{Y}$).
4. Constante no restringida + tendencia restringida.
5. Constante y tendencia no restringidas.

En `urca::ca.jo`, el argumento `ecdet` controla estos casos: `"none"`, `"const"`, `"trend"`. Elegir correctamente es importante: los valores críticos difieren.

	Engle-Granger (1987)	Johansen (1988)
Filosofía	Dos pasos separables	Un paso, MV sistema
Asume $r = 1$	Sí (solo permite una)	No, estima r
Dependencia del orden	Sí (variable dep.)	No (simétrico)
Simplicidad	Máxima	Moderada
Tests disponibles	Solo ADF sobre residuos	Traza, max-eigen, test
Recomendado para	$n = 2$, pedagogía	$n \geq 3$, práctica profesio- nal

Tabla 4.2: Comparación de enfoques de cointegración.

4.6.5. Engle-Granger vs. Johansen: cuándo usar cada uno

En análisis aplicado macroeconómico moderno, **Johansen es estándar**. Engle-Granger sobrevive por simplicidad conceptual y por su rol histórico. En el curso enseñamos ambos, pero el taller usa Johansen.

4.6.6. SVECM: identificación en sistemas cointegrados

La identificación del SVAR se extiende a sistemas cointegrados —el *SVECM*—. El procedimiento es esencialmente idéntico: estimar el VECM, obtener $\hat{\Sigma}_u$, aplicar restricciones de identificación. Las restricciones estándar son las mismas (Cholesky, corto plazo, largo plazo, signo), adaptadas al hecho de que ahora trabajamos con $\Delta \mathbf{Y}_t$.

Una especificidad del SVECM: las restricciones de largo plazo tienen forma especial porque el efecto de largo plazo de un shock depende de la estructura de cointegración. Para variables cointegradas, algunas direcciones de largo plazo "no existen" (están acotadas por el equilibrio). Los detalles técnicos están en Lütkepohl (2005, cap. 9) y Kilian-Lütkepohl (2017, cap. 3).

4.7. Local Projections

4.7.1. Una alternativa a los VAR para construir IRFs

Òscar Jordà (2005) propuso un enfoque radicalmente distinto para estimar IRFs: en vez de especificar un modelo completo (VAR) y derivar las IRFs, estimar *una regresión separada por horizonte*.

Definición 4.21 (Local Projections). Para cada horizonte $h = 0, 1, 2, \dots, H$:

$$Y_{i,t+h} = \alpha_i^{(h)} + \theta_{ik}^{(h)} \varepsilon_{k,t} + \sum_{j=1}^p \phi_{i,j}^{(h)\top} \mathbf{Y}_{t-j} + \eta_{i,t+h}^{(h)}, \quad (4.16)$$

donde $\varepsilon_{k,t}$ es el shock estructural de interés y $\mathbf{Y}_{t-j}$ son controles.

La IRF al horizonte h es directamente el coeficiente $\hat{\theta}_{ik}^{(h)}$: no requiere acumulación o transformación. Para estimar la IRF completa sobre horizontes 0 a H , se corren $H + 1$ regresiones separadas.

4.7.2. Identificación del shock

LP requiere un shock $\varepsilon_{k,t}$ *ya identificado*. Tres enfoques comunes:

1. **Cholesky sobre residuos VAR**: estimar un VAR, obtener $\hat{\mathbf{u}}_t$, aplicar Cholesky. Usar la componente $\hat{\varepsilon}_{k,t}$ como regresor en (??).
2. **Proxy SVAR / IV externo**: el shock se mide directamente con una variable exógena (Romer-Romer narrative, high-frequency surprises).
3. **Instrumentos internos**: usar una variable proxy como instrumento para $\mathbf{u}_t$ en una primera etapa.

La identificación es conceptualmente separable de la estimación: podemos usar la misma identificación en un VAR o en LP, y comparar resultados.

4.7.3. Ventajas y desventajas

Ventajas de LP

- **Robustez a mala especificación:** si el DGP no es un VAR finito, las IRFs del VAR son sesgadas. Las IRFs de LP son consistentes bajo condiciones más débiles (solo requieren que $\phi^{(h)}$ capture la dinámica relevante).
- **Horizontes largos:** el VAR propaga errores de especificación; LP trata cada horizonte independientemente.
- **No linealidades naturales:** permite especificaciones dependientes del estado (regime-dependent LP), tendencias deterministas, etc.
- **Simplicidad conceptual:** una regresión por horizonte; cualquier técnica de regresión moderna (variables instrumentales, penalización, machine learning) se adapta directamente.

Desventajas de LP

- **Menor eficiencia bajo especificación correcta:** si el DGP es VAR, las IRFs VAR son asintóticamente más eficientes.
- **Bandas de confianza más anchas:** cada regresión separada introduce variabilidad muestral.
- **Inconsistencia horizontal:** las IRFs LP en horizontes vecinos pueden lucir ruidosas porque se estiman independientemente.

4.7.4. Inferencia: el problema de la superposición

En (??), $\eta_{t+h}^{(h)}$ contiene innovaciones futuras que se superponen entre ecuaciones de horizontes sucesivos. Específicamente:

$$\text{Cov}(\eta_{t+h}^{(h)}, \eta_{t+h-k}^{(h)}) \neq 0 \text{ para } k < h.$$

Consecuencia: los residuos de una LP son autocorrelacionados por construcción de orden h . Errores estándar MCO son inválidos. La solución estándar:

- **Errores estándar HAC (Newey-West):** robustos a heterocedasticidad y autocorrelación hasta un lag máximo. El lag recomendado es $\geq h$ (típicamente $h+1$ o $1,5h$).
- **Bootstrap residual:** alternativa robusta pero computacionalmente más costosa.

En R: `lpirfs::lp_lin` maneja HAC automáticamente con `use_nw = TRUE`.

4.7.5. Identificación del shock: enfoques recientes

La literatura moderna ha refinado la identificación del shock en LP:

- **LP-IV:** Stock-Watson (2018) proponen usar instrumentos externos en LP, paralelo al proxy SVAR.
- **LP con shocks identificados:** Ramey (2016) compila una serie de shocks narrativos identificados, usados directamente como $\varepsilon_{k,t}$.
- **Regime-dependent LP:** Auerbach-Gorodnichenko (2012), Ramey-Zubairy (2018) estiman IRFs dependientes del estado (recesión vs. expansión).

4.7.6. Plagborg-Møller & Wolf (2021): equivalencia conceptual

Un resultado reciente importante: Plagborg-Møller y Wolf demostraron que, bajo cierta identificación, VAR y LP estiman el mismo objeto poblacional y son asintóticamente equivalentes. Las diferencias son enteramente de eficiencia en muestra finita, no de sesgo asintótico. Esto matiza algunas afirmaciones tempranas de la literatura sobre las ventajas de LP.

La práctica recomendada —y la que seguiremos en el curso— es **reportar ambos**: si coinciden, la evidencia es sólida; si divergen, investigar por qué (mala especificación del VAR, muestra pequeña, identificación frágil).

4.8. Implementación en R

4.8.1. Datos: canal de transmisión monetaria RD

Suponemos datos mensuales desde enero 2005 de:

- `tmpm`: Tasa de política monetaria (TPM) del BCRD.
- `infla`: Inflación interanual (% YoY) del IPC.
- `imae`: Variación interanual del IMAE.
- `tc`: Log-variación del tipo de cambio peso/dólar ($\cdot 100$).

```

1 library(vars)
2 library(urca)
3 library(lpirfs)
4 library(VARsignR)
5
6 datos <- read.csv("vars_monetario_rd.csv")
7 Y <- ts(datos[,c("tmpm", "infla", "imae", "tc")],
8         start = c(2005,1), frequency = 12)
9 plot(Y, main = "Variables del canal monetario RD")

```

4.8.2. Tests de raíz unitaria y decisión de especificación

```

1 # Tests individuales
2 library(tseries)
3 sapply(colnames(Y), function(v) adf.test(Y[,v])$p.
4       value)
5
6 sapply(colnames(Y), function(v) kpss.test(Y[,v])$p.
7       value)
8
9 # Si TMPM, infla e IMAE son I(0) y solo TC es I(1):
10 # podriamos trabajar con Delta(log(TC)) (retornos) en
11 # niveles
12
13 # Si hay variables I(1) con cointegracion: VECM
14
15 # Si todas I(0): VAR en niveles

```

4.8.3. Estimación del VAR reducido

```
1 # Selección de p
2 VARselect(Y, lag.max = 12, type = "const")$selection
3 # Sugerencia típica: p = 2 o 3 según criterio
4
5 # Estimación
6 fit_var <- VAR(Y, p = 2, type = "const")
7 summary(fit_var)
8
9 # Estabilidad
10 roots(fit_var) # deberían ser < 1 en módulo
```

4.8.4. Diagnóstico

```
1 # Autocorrelación residual
2 serial.test(fit_var, lags.pt = 12, type = "PT.
   asymptotic")
3
4 # Heterocedasticidad ARCH multivariada
5 arch.test(fit_var, lags.multi = 5)
6
7 # Normalidad multivariada
8 normality.test(fit_var)
9
10 # Estabilidad estructural (CUSUM de residuos)
11 stab <- stability(fit_var, type = "OLS-CUSUM")
12 plot(stab)
```

4.8.5. Causalidad de Granger

```
1 # Tasa causa Granger al resto?
2 causality(fit_var, cause = "tmpm")
3
4 # Bloqueos por grupo de variables
5 causality(fit_var, cause = c("tmpm", "tc"))
```

4.8.6. IRFs por Cholesky

```

1  # IRF de un shock positivo en la tasa de politica
2  irf_cholesky <- irf(
3    fit_var,
4    impulse = "tmpm",
5    response = c("infla", "imae", "tc"),
6    n.ahead = 24,
7    ortho = TRUE, # Cholesky
8    cumulative = FALSE,
9    boot = TRUE,
10   runs = 1000,
11   ci = 0.95
12 )
13 plot(irf_cholesky)
14
15 # FEVD
16 fevd_out <- fevd(fit_var, n.ahead = 24)
17 plot(fevd_out)

```

4.8.7. SVAR con restricciones de corto plazo

```

1  # Matriz de restricciones sobre B_0
2  # NA = libre (a estimar), 0 = restringido
3  # Ordenamiento: tmpm, infla, imae, tc
4  Amat <- diag(4)
5  # Ejemplo: imponer que TC no afecta a las demas
   contemporaneamente
6  # (triangular con TC al final = Cholesky con orden
   propuesto)
7  # Para restricciones mas creativas, especificar NA/0 a
   mano
8
9  svar_ct <- SVAR(fit_var, Amat = NULL, Bmat = diag(4),
10    max.iter = 500)
11 summary(svar_ct)

```

4.8.8. SVAR con restricciones de signo (Uhlig)

```

1  # Shock de politica monetaria: sube tmpm, baja infla,
    baja imae
2  # Signos: +1 en variable 1, -2 en 2, -3 en 3
3  constr_signo <- c(+1, -2, -3) # tmpm +, infla -, imae
    -
4
5  set.seed(2026)
6  svar_sign <- uhlig.reject(
7    Y = as.matrix(Y),
8    nlags = 2,
9    draws = 1000,
10   subdraws = 500,
11   nkeep = 1000,
12   KMIN = 1,
13   KMAX = 4,
14   constrained = constr_signo,
15   constant = TRUE,
16   steps = 24
17 )
18
19 irfplot(
20   svar_sign$IRFS,
21   type = "mean",
22   labels = colnames(Y),
23   save = FALSE
24 )

```

4.8.9. Cointegración y VECM

```

1  # Test de Johansen (si hay variables I(1))
2  joh <- ca.jo(Y, type = "trace", ecdet = "const", K =
    2,
3      spec = "transitory")
4  summary(joh)
5
6  # Si rango r >= 1: estimar VECM
7  fit_vecm <- cajorls(joh, r = 1)
8  summary(fit_vecm$rlm)

```



```

9
10 # Vector de cointegracion estimado
11 cointeg <- fit_vecm$beta
12 print(cointeg)
13
14 # Graficar la relacion de cointegracion
15 z_t <- Y %*% cointeg
16 plot(z_t, main = "Relacion de cointegracion estimada")
17
18 # Convertir a VAR en niveles para IRFs
19 var_from_vecm <- vec2var(joh, r = 1)
20 irf(var_from_vecm, impulse = "tmpm", n.ahead = 24)

```

4.8.10. Local Projections

```

1 # LP lineal con shock identificado por Cholesky
2 lp_out <- lp_lin(
3   endog_data = Y,
4   lags_endog_lin = 2,
5   trend = 0,
6   shock_type = 1, # Cholesky
7   confint = 1.96, # 95%
8   hor = 24,
9   use_nw = TRUE # Newey-West HAC
10 )
11 plot_lin(lp_out)
12
13 # Comparar con IRFs del VAR
14 # Ambos estiman el mismo objeto poblacional;
15 # divergencias sugieren misspecification del VAR

```

4.8.11. Reporte final y comparación

```

1 # Tabla resumen
2 library(dplyr)
3 irfs_comp <- data.frame(
4   horizonte = 0:24,
5   var_cholesky = irf_cholesky$irf$tmpm[, "infla"],
6   lp = lp_out$irf_lin_mean[2, 1] # tmpm -> infla

```

```
7 )  
8 print(head(irfs_comp, 10))  
9  
10 # Grafico comparativo  
11 library(ggplot2)  
12 ggplot(irfs_comp, aes(x = horizonte)) +  
13   geom_line(aes(y = var_cholesky, colour = "VAR-  
14     Cholesky"), linewidth = 1) +  
15   geom_line(aes(y = lp, colour = "Local Projections"),  
16     linewidth = 1) +  
17   labs(y = "Efecto sobre inflacion",  
18     title = "IRF: shock de politica monetaria") +  
19   theme_minimal()
```

4.9. Ejercicios

Ejercicio 4.9.1 (Estacionariedad VAR(2) bivariado). Sea $\mathbf{Y}_t = \mathbf{A}_1 \mathbf{Y}_{t-1} + \mathbf{A}_2 \mathbf{Y}_{t-2} + \mathbf{u}_t$ con

$$\mathbf{A}_1 = \begin{pmatrix} 0,5 & 0,2 \\ 0,1 & 0,6 \end{pmatrix}, \quad \mathbf{A}_2 = \begin{pmatrix} 0,1 & 0 \\ 0,2 & 0,1 \end{pmatrix}.$$

- (a) Construya la matriz compañera $\mathbf{F}$ (4×4).
- (b) Calcule los eigenvalores de $\mathbf{F}$. ¿Es estacionario?
- (c) Calcule Ψ_j para $j = 0, 1, 2, 3$ usando la recursión.

Ejercicio 4.9.2 (MV $\equiv$ MCO: demostración). Demuestre que en un VAR con $\mathbf{u}_t \sim \mathcal{N}(\mathbf{0}, \Sigma_u)$, la solución de las condiciones de primer orden de ℓ respecto a $\mathbf{A}_i$ coincide con MCO ecuación por ecuación, *independientemente* de Σ_u . (*Hint: use la propiedad de que los regresores son comunes.*)

Ejercicio 4.9.3 (Identificación por Cholesky: dependencia del orden). Simule un VAR(1) bivariado con $\mathbf{A}_1 = \text{diag}(0,7, 0,5)$ y Σ_u con correlación $\rho = 0,6$.

- (a) Estime un VAR(1) y calcule IRFs por Cholesky con orden (Y_1, Y_2) .
- (b) Repita con orden (Y_2, Y_1) .
- (c) Compare las IRFs. ¿Cuáles coinciden? ¿Cuáles difieren?
- (d) Interprete: ¿qué dice esto sobre la importancia de justificar el orden?

Ejercicio 4.9.4 (Causalidad de Granger y expectativas). Simule un sistema donde X_t incorpore expectativas racionales sobre Y_{t+1} :

$$Y_t = 0,5Y_{t-1} + \varepsilon_t^Y, \quad X_t = \mathbb{E}_t[Y_{t+1}] + \eta_t = 0,5 \cdot 0,5Y_{t-1} + \eta_t.$$

- (a) Simule $T = 500$ observaciones.
- (b) Aplique test de Granger: ¿ X causa Granger a Y ?
- (c) Interprete: ¿hay causalidad estructural real?

Ejercicio 4.9.5 (FEVD: interpretación). Con los datos del canal monetario RD, estime un SVAR con Cholesky y reporte la FEVD a horizontes $h = 1, 6, 12, 24$.

- (a) ¿Qué fracción de la variabilidad de inflación se explica por shocks monetarios a 12 meses?
- (b) ¿Qué fracción se explica por shocks cambiarios?
- (c) ¿Evoluciona la contribución de cada shock con h ? Explique por qué.

Ejercicio 4.9.6 (Regresión espuria en niveles). Simule dos paseos aleatorios independientes X_t, Y_t de $T = 500$ observaciones. Estime un VAR(1) en niveles.

- (a) Reporte coeficientes y tests de Granger.
- (b) ¿Cuántas veces (en 500 réplicas) rechaza Granger a 5 %? Compare con el nivel nominal.
- (c) Repita con ΔX_t y ΔY_t (I(0)). ¿Desaparece el problema?

Ejercicio 4.9.7 (Cointegración: paridad de tasas RD-US). Descargue series mensuales: (i) tasa TPM RD, (ii) federal funds rate US, (iii) log de peso/dólar desde 2005.

- (a) Verifique que cada serie es I(1) con ADF y KPSS.
- (b) Aplique test de Johansen con $n = 3$. ¿Cuál es el rango estimado?
- (c) Si $r = 1$: interprete el vector $\hat{\beta}$. ¿Es consistente con paridad?

- (d) Estime el VECM. ¿Cuáles son las velocidades de ajuste α ?
- (e) Haga IRFs: ¿cómo responde el TPM RD a un shock en la tasa US?

Ejercicio 4.9.8 (LP vs. VAR: comparación). Con los datos del canal monetario RD:

- (a) Estime IRFs del VAR por Cholesky a horizonte 24.
- (b) Estime IRFs por Local Projections con la misma identificación.
- (c) Grafique ambos conjuntos de IRFs en la misma figura, con bandas de confianza.
- (d) Interprete divergencias. ¿Hay evidencia de misspecification del VAR?

Ejercicio 4.9.9 (Restricciones de signo: sensibilidad). Con los datos del canal monetario RD, estime un SVAR por restricciones de signo (Uhlig).

- (a) Configure las restricciones para un shock de política monetaria contractivo.
- (b) Varíe el horizonte de imposición de signos: $[1, 2]$, $[1, 4]$, $[1, 6]$. ¿Cómo cambian las IRFs?
- (c) Agregue una restricción sobre el tipo de cambio (se aprecia). ¿Se estrechan las bandas?

Bibliografía

- [1] Auerbach, A. J. & Gorodnichenko, Y. (2012). Measuring the output responses to fiscal policy. *American Economic Journal: Economic Policy*, 4(2), 1–27.
- [2] Baumeister, C. & Hamilton, J. D. (2015). Sign restrictions, structural vector autoregressions, and useful prior information. *Econometrica*, 83(5), 1963–1999.
- [3] Blanchard, O. J. & Quah, D. (1989). The dynamic effects of aggregate demand and supply disturbances. *American Economic Review*, 79(4), 655–673.
- [4] Engle, R. F. & Granger, C. W. J. (1987). Co-integration and error correction: Representation, estimation, and testing. *Econometrica*, 55(2), 251–276.
- [5] Galí, J. (1999). Technology, employment, and the business cycle. *American Economic Review*, 89(1), 249–271.
- [6] Granger, C. W. J. (1969). Investigating causal relations by econometric models and cross-spectral methods. *Econometrica*, 37(3), 424–438.
- [7] Hamilton, J. D. (1994). *Time Series Analysis*. Princeton University Press. [Capítulos 10–11.]
- [8] Johansen, S. (1988). Statistical analysis of cointegration vectors. *Journal of Economic Dynamics and Control*, 12(2–3), 231–254.
- [9] Johansen, S. (1995). *Likelihood-Based Inference in Cointegrated Vector Autoregressive Models*. Oxford University Press.
- [10] Jordà, Ò. (2005). Estimation and inference of impulse responses by local projections. *American Economic Review*, 95(1), 161–182.

- [11] Kilian, L. & Lütkepohl, H. (2017). *Structural Vector Autoregressive Analysis*. Cambridge University Press.
- [12] Künsch, H. R. (1989). The jackknife and the bootstrap for general stationary observations. *Annals of Statistics*, 17(3), 1217–1241.
- [13] Lütkepohl, H. (2005). *New Introduction to Multiple Time Series Analysis*. Springer.
- [14] Osterwald-Lenum, M. (1992). A note with quantiles of the asymptotic distribution of the maximum likelihood cointegration rank test statistics. *Oxford Bulletin of Economics and Statistics*, 54(3), 461–472.
- [15] Plagborg-Møller, M. & Wolf, C. K. (2021). Local projections and VARs estimate the same impulse responses. *Econometrica*, 89(2), 955–980.
- [16] Politis, D. N. & Romano, J. P. (1994). The stationary bootstrap. *JASA*, 89(428), 1303–1313.
- [17] Ramey, V. A. (2016). Macroeconomic shocks and their propagation. En *Handbook of Macroeconomics*, vol. 2A, cap. 2. Elsevier.
- [18] Ramey, V. A. & Zubairy, S. (2018). Government spending multipliers in good times and in bad. *Journal of Political Economy*, 126(2), 850–901.
- [19] Rubio-Ramírez, J. F., Waggoner, D. F. & Zha, T. (2010). Structural vector autoregressions: Theory of identification and algorithms for inference. *Review of Economic Studies*, 77(2), 665–696.
- [20] Sims, C. A. (1980). Macroeconomics and reality. *Econometrica*, 48(1), 1–48.

- [21] Stock, J. H. & Watson, M. W. (2018). Identification and estimation of dynamic causal effects in macroeconomics using external instruments. *Economic Journal*, 128(610), 917–948.
- [22] Uhlig, H. (2005). What are the effects of monetary policy on output? Results from an agnostic identification procedure. *Journal of Monetary Economics*, 52(2), 381–419.

Capítulo 5

Métodos Bayesianos

Contenido

4.1. Del AR al VAR: motivación . . .	129
4.1.1. La crítica de Sims (1980)	129
4.1.2. Por qué importa: endogeneidad en política monetaria	129
4.1.3. Lo que permite el VAR	130
4.2. El VAR reducido	132
4.2.1. Definición y notación	132
4.2.2. Estacionariedad	132
4.2.3. La forma compañera	133
4.2.4. Media incondicional y represen- tación $MA(\infty)$	134
4.2.5. Autocovarianzas del VAR	135
4.2.6. Estimación por MCO: un resul- tado notable	135
4.2.7. Distribución asintótica	136
4.2.8. Selección del orden p	137
4.2.9. Diagnóstico	137
4.3. Causalidad de Granger	139
4.3.1. Concepto y definición formal . . .	139
4.3.2. Test en un VAR	139
4.3.3. Granger $\neq$ causalidad filosófica .	139
4.3.4. Usos legítimos del test de Granger	140
4.4. VAR estructural: identificación .	141
4.4.1. El problema fundamental de iden- tificación	141
4.4.2. Identificación recursiva (Cholesky)	142
4.4.3. Restricciones de corto plazo no recursivas	144

4.4.4.	Restricciones de largo plazo: Blanchard-Quah (1989)	145
4.4.5.	Restricciones de signo: Uhlig (2005)	146
4.4.6.	Comparación de estrategias de identificación	148
4.5.	IRFs y descomposición de varianza	149
4.5.1.	Funciones impulso-respuesta estructurales	149
4.5.2.	Intervalos de confianza para IRFs	150
4.5.3.	Descomposición de varianza del error de pronóstico (FEVD) . . .	151
4.6.	Cointegración y VECM	152
4.6.1.	El problema motivador	152
4.6.2.	Cointegración: definición y ejemplos	152
4.6.3.	Representación VECM: teorema de Engle-Granger	154
4.6.4.	Procedimiento de Johansen . . .	155
4.6.5.	Engle-Granger vs. Johansen: cuándo usar cada uno	158
4.6.6.	SVECM: identificación en sistemas cointegrados	158
4.7.	Local Projections	159
4.7.1.	Una alternativa a los VAR para construir IRFs	159
4.7.2.	Identificación del shock	159
4.7.3.	Ventajas y desventajas	160
4.7.4.	Inferencia: el problema de la superposición	161
4.7.5.	Identificación del shock: enfoques recientes	161

4.7.6. Plagborg-Møller & Wolf (2021): equivalencia conceptual	162
4.8. Implementación en R	163
4.8.1. Datos: canal de transmisión mo- netaria RD	163
4.8.2. Tests de raíz unitaria y decisión de especificación	163
4.8.3. Estimación del VAR reducido	164
4.8.4. Diagnóstico	164
4.8.5. Causalidad de Granger	164
4.8.6. IRFs por Cholesky	165
4.8.7. SVAR con restricciones de corto plazo	165
4.8.8. SVAR con restricciones de signo (Uhlig)	166
4.8.9. Cointegración y VECM	166
4.8.10. Local Projections	167
4.8.11. Reporte final y comparación	167
4.9. Ejercicios	169
Bibliografía	172

Resumen

Este capítulo introduce los métodos bayesianos como marco alternativo —y a menudo superior— para la estimación de modelos multivariados de series de tiempo. Se motiva el cambio desde consideraciones prácticas (la maldición de la dimensionalidad en VAR frecuentistas) y filosóficas (la cuantificación explícita de incertidumbre paramétrica). Se revisan los fundamentos: regla de Bayes, priors conjugados, distribuciones posterior, y la interpretación bayesiana de intervalos. Se desarrolla el BVAR con prior Normal-Inverse-Wishart, demostrando la forma cerrada de la posterior y la interpretación del estimador posterior como promedio ponderado entre prior y datos. El prior Minnesota de Litterman se presenta con detalle, incluyendo sus hiperparámetros, la implementación via dummy observations, y las extensiones sum-of-coefficients. Se introducen los muestreadores MCMC —Gibbs y Metropolis-Hastings— con énfasis en su uso operativo más que en teoría de convergencia. Se desarrollan las extensiones modernas: BVAR con stochastic volatility (Kim-Shephard-Chib), TVP-VAR (Primiceri), y pronóstico densitario con fan charts. El capítulo cierra con implementación completa en R usando BVAR, `bsvars` y `bvarsu`, aplicada a datos macroeconómicos dominicanos, y ejercicios que incluyen comparación rigurosa con VAR frecuentistas del Módulo 3.

5.1. Motivación: ¿por qué bayesiano?

5.1.1. La maldición de la dimensionalidad en VAR frecuentistas

El VAR del Módulo 3 es un motor elegante pero hambriento de datos. Un $\text{VAR}(p)$ con n variables tiene:

- pn^2 coeficientes en las matrices $\mathbf{A}_1, \dots, \mathbf{A}_p$,

- n coeficientes en $\mathbf{c}$,
- $n(n+1)/2$ elementos únicos en Σ_u .

El conteo práctico es elocuente. Para un VAR pequeño de $n = 4$ variables macroeconómicas con $p = 4$ rezagos: $4 \cdot 16 + 4 + 10 = 78$ parámetros. Para un VAR mediano de $n = 7$ con $p = 4$: $7 \cdot 49 + 7 + 28 = 378$. Para $n = 20$, un BVAR de la literatura más reciente (Bańbura, Giannone y Reichlin, 2010): $4 \cdot 400 + 20 + 210 = 1830$ parámetros.

Con datos macroeconómicos mensuales desde el 2000, una muestra típica es $T \approx 240$ observaciones. La razón observaciones/parámetros en el VAR de $n = 20, p = 4$ es menor a uno. MCO es inviable.

Las consecuencias operativas del VAR de alta dimensionalidad con muestras limitadas son:

1. **Sobreajuste:** el modelo memoriza el ruido muestral. Pronósticos in-sample excelentes, pronósticos out-of-sample pésimos.
2. **Errores estándar enormes:** los coeficientes individuales son muy imprecisos. Tests de hipótesis no rechazan casi nada.
3. **IRFs con bandas de confianza enormes:** las bandas se cruzan con cero en la mayoría de los horizontes; no se puede concluir nada sustantivo.
4. **No identificación práctica:** matriz de información cercana a singular; inversión numérica inestable.

El enfoque bayesiano resuelve este problema imponiendo *información previa* —priors— que regulariza la estimación. Con priors razonables, podemos estimar VAR grandes con muestras moderadas y obtener IRFs bien definidas. Esta es la primera y más importante razón pragmática para adoptar el enfoque bayesiano en series de tiempo.

5.1.2. Cuantificación de incertidumbre paramétrica

Una segunda razón, más sutil pero igualmente importante, es cómo el enfoque bayesiano trata la incertidumbre sobre los parámetros.

En inferencia frecuentista, θ_0 es un valor fijo y desconocido. Estimamos $\hat{\theta}$ y reportamos errores estándar que describen cómo variaría $\hat{\theta}$ *si repitiéramos el experimento muchas veces*. Esta interpretación es elegante en teoría pero a menudo contraintuitiva: cuando decimos "el IC al 95 % para θ es $[0,3, 0,5]$ ", no estamos diciendo que θ esté en ese intervalo con probabilidad 95 %; estamos diciendo que, de construir intervalos de esa manera en muestras repetidas, el 95 % de ellos cubrirían θ .

En inferencia bayesiana, θ es una variable aleatoria, y nuestro objeto de interés es $p(\theta \mid \mathbf{y})$ —nuestra creencia actualizada sobre θ después de ver los datos—. Un intervalo de *credibilidad* al 95 % es exactamente lo que la intuición sugiere: la región donde θ está con probabilidad 95 % dado los datos. Esta interpretación natural es especialmente valiosa en comunicación de resultados a audiencias no técnicas.

5.1.3. Pronóstico densitario

Una tercera motivación es el pronóstico. En el enfoque frecuentista:

$$\hat{Y}_{T+h|T} = g(\hat{\theta}, \mathbf{Y}_{1:T}), \quad \mathbb{V}[\text{error}] = \text{algún estimador asintótico.}$$

Las bandas de pronóstico consideran solo la incertidumbre residual —el componente de innovación futura— e ignoran la incertidumbre paramétrica, o la incluyen asintóticamente.

En el enfoque bayesiano, el *pronóstico densitario* integra ambas fuentes de incertidumbre:

$$p(\mathbf{Y}_{T+h} \mid \mathbf{Y}_{1:T}) = \int p(\mathbf{Y}_{T+h} \mid \theta, \mathbf{Y}_{1:T})p(\theta \mid \mathbf{Y}_{1:T})d\theta.$$

La primera componente captura incertidumbre sobre innovaciones futuras; la segunda, sobre los parámetros. El resultado es una distribución predictiva completa, a partir de la cual podemos calcular cualquier cantidad: media, mediana, cuantiles, probabilidades de eventos ("probabilidad de inflación $>5\%$ a 12 meses"), fan charts.

Los fan charts —el formato de visualización estándar en Informes de Política Monetaria del BCE, BoE, BCRD— son esencialmente densidades predictivas visualizadas por cuantiles. Son intrínsecamente bayesianos en espíritu, aunque algunas implementaciones frecuentistas los aproximen vía bootstrap.

5.2. Fundamentos bayesianos

5.2.1. La regla de Bayes aplicada a inferencia

El objeto fundamental es el teorema de Bayes:

Definición 5.1 (Posterior). Dada una muestra $\mathbf{y}$ y un parámetro $\boldsymbol{\theta}$, la *distribución posterior* es:

$$\underbrace{p(\boldsymbol{\theta} | \mathbf{y})}_{\text{posterior}} = \frac{\overbrace{p(\mathbf{y} | \boldsymbol{\theta})}^{\text{verosimilitud}} \cdot \overbrace{p(\boldsymbol{\theta})}^{\text{prior}}}{p(\mathbf{y})} \propto \mathcal{L}(\boldsymbol{\theta}; \mathbf{y}) \cdot p(\boldsymbol{\theta}). \quad (5.1)$$

El denominador $p(\mathbf{y}) = \int \mathcal{L}(\boldsymbol{\theta}; \mathbf{y}) p(\boldsymbol{\theta}) d\boldsymbol{\theta}$ es la *verosimilitud marginal*, una constante de normalización respecto a $\boldsymbol{\theta}$.

La interpretación es poderosa: la verosimilitud $\mathcal{L}(\boldsymbol{\theta}; \mathbf{y})$ es el mismo objeto del Módulo 0. El prior $p(\boldsymbol{\theta})$ codifica información pre-muestral. Su producto, normalizado, es la distribución que describe nuestra creencia posterior sobre $\boldsymbol{\theta}$.

La constante de normalización

En la práctica, no necesitamos computar $p(\mathbf{y})$ para la mayoría de los fines. Los muestreadores MCMC trabajan con proporcionalidad: $p(\boldsymbol{\theta} | \mathbf{y}) \propto \mathcal{L} \cdot p(\boldsymbol{\theta})$ es suficiente. Solo para comparación de modelos (factores de Bayes) necesitamos $p(\mathbf{y})$, y ahí existen métodos específicos: Chib (1995), bridge sampling, etc.

5.2.2. Priors: tipos y roles

Los priors $p(\boldsymbol{\theta})$ se clasifican según su contenido informativo:

- **Priors difusos / planos:** $p(\boldsymbol{\theta}) \propto 1$ sobre un rango amplio. Reflejan "poca información previa". La posterior queda esencialmente determinada por la verosimilitud.

- **Priors informativos:** codifican creencias específicas (e.g., el coeficiente está centrado en 1 con desviación 0.3). Regularizan la estimación hacia la creencia.
- **Priors jerárquicos:** los hiperparámetros del prior tienen a su vez su propia distribución. Permiten "dejar que los datos decidan" la fuerza del prior.
- **Priors no informativos de referencia:** contruidos con criterios formales (Jeffreys, priors objetivos).

En BVAR el prior Minnesota que veremos es informativo con estructura específica. La motivación es pragmática: obtener regularización útil con justificación económica.

Propiedad fundamental

Proposición 5.2. *Si el prior asigna masa positiva al verdadero θ_0 y la verosimilitud es bien comportada, la posterior se concentra asintóticamente alrededor de θ_0 :*

$$p(\theta \mid \mathbf{y}) \rightarrow \delta_{\theta_0} \quad \text{cuando } T \rightarrow \infty.$$

Esto es el análogo bayesiano de la consistencia del EMV. El prior, por fuerte que sea, *pierde influencia* relativa conforme más datos acumulamos. Con T grande, la posterior es dominada por la verosimilitud.

5.2.3. Priors conjugados

Definición 5.3 (Prior conjugado). Un prior $p(\theta)$ es *conjugado* a una verosimilitud $\mathcal{L}(\theta; \mathbf{y})$ si la posterior $p(\theta \mid \mathbf{y})$ pertenece a la misma familia paramétrica que el prior.

La conjugación es una propiedad computacional extraordinariamente útil: cuando aplica, la posterior tiene forma cerrada, sin necesidad de MCMC. Los casos clásicos:

- **Normal + Normal = Normal:** si $y \sim \mathcal{N}(\theta, \sigma^2)$ con σ^2 conocido y $\theta \sim \mathcal{N}(\mu_0, \tau_0^2)$, entonces $\theta \mid y \sim \mathcal{N}(\mu_1, \tau_1^2)$ con actualización en forma cerrada.
- **Gauss multivariado + NIW = NIW:** el caso que usaremos para BVAR. La verosimilitud gaussiana con $\boldsymbol{\theta} = (\boldsymbol{\mu}, \Sigma)$ se conjuga con el prior Normal-Inverse-Wishart.
- **Bernoulli + Beta = Beta:** clásico en aplicaciones discretas.

5.2.4. Posterior normal con normal conjugada: caso escalar

Como ilustración paso a paso, consideremos $y_1, \dots, y_T \stackrel{iid}{\sim} \mathcal{N}(\theta, \sigma^2)$ con σ^2 conocido, y prior $\theta \sim \mathcal{N}(\mu_0, \tau_0^2)$.

Proposición 5.4. *La posterior es $\theta \mid \mathbf{y} \sim \mathcal{N}(\mu_1, \tau_1^2)$ con:*

$$\tau_1^2 = \left(\frac{1}{\tau_0^2} + \frac{T}{\sigma^2} \right)^{-1}, \quad (5.2)$$

$$\mu_1 = \tau_1^2 \left(\frac{\mu_0}{\tau_0^2} + \frac{T\bar{y}}{\sigma^2} \right). \quad (5.3)$$

Demostración. La log-posterior (a una constante):

$$\begin{aligned} \log p(\theta \mid \mathbf{y}) &= -\frac{1}{2\sigma^2} \sum (y_t - \theta)^2 - \frac{1}{2\tau_0^2} (\theta - \mu_0)^2 + C \\ &= -\frac{1}{2} \left[\frac{T}{\sigma^2} \theta^2 - \frac{2T\bar{y}}{\sigma^2} \theta + \frac{1}{\tau_0^2} \theta^2 - \frac{2\mu_0}{\tau_0^2} \theta \right] + C'. \end{aligned}$$

Completando el cuadrado en θ con $\tau_1^{-2} = \sigma^{-2}T + \tau_0^{-2}$:

$$\log p(\theta \mid \mathbf{y}) = -\frac{1}{2\tau_1^2} (\theta - \mu_1)^2 + C'',$$

con μ_1 como se afirma. Esto es una normal. □

Interpretación del resultado

La media posterior μ_1 es un promedio ponderado del prior μ_0 y la media muestral $\bar{y}$, con pesos dados por las precisiones (inverso de varianzas):

$$\mu_1 = \underbrace{\frac{1/\tau_0^2}{1/\tau_0^2 + T/\sigma^2}}_{\text{peso prior}} \mu_0 + \underbrace{\frac{T/\sigma^2}{1/\tau_0^2 + T/\sigma^2}}_{\text{peso datos}} \bar{y}.$$

Cuando $\tau_0 \rightarrow \infty$ (prior difuso), $\mu_1 \rightarrow \bar{y}$: recupera la solución frecuentista. Cuando $T \rightarrow \infty$, también $\mu_1 \rightarrow \bar{y}$: los datos dominan. Cuando $\tau_0 \rightarrow 0$, $\mu_1 \rightarrow \mu_0$: prior domina. Estas limitaciones reflejan la intuición correcta sobre cómo priors y datos interactúan.

5.2.5. Intervalos de confianza vs. credibilidad

Definición 5.5 (Intervalo de credibilidad). Un *intervalo de credibilidad* al $(1 - \alpha) \cdot 100\%$ para θ es un intervalo $[a, b]$ tal que

$$\mathbb{P}(\theta \in [a, b] \mid \mathbf{y}) = 1 - \alpha.$$

Esta definición es interpretativamente natural: el parámetro está en el intervalo con la probabilidad declarada, dado los datos observados. Contrasta con el intervalo de confianza frecuentista, que tiene interpretación basada en muestreo repetido.

Para construir un intervalo de credibilidad: tomar los cuantiles $\alpha/2$ y $1 - \alpha/2$ de la posterior. En el caso normal-normal: $\mu_1 \pm z_{1-\alpha/2}\tau_1$.

Observación 5.6. En muchos problemas, intervalos de credibilidad bayesianos con priors difusos coinciden numéricamente con intervalos de confianza frecuentistas. Pero la interpretación difiere: "probabilidad 95 % condicional a datos" vs. "cobertura 95 % en repetidas muestras".

5.3. BVAR: formulación y posterior conjugada

5.3.1. El VAR en notación matricial

Para derivar el BVAR de forma limpia, necesitamos reescribir el VAR en notación compacta. Recordemos del Módulo 3:

$$\mathbf{Y}_t = \mathbf{c} + \mathbf{A}_1 \mathbf{Y}_{t-1} + \cdots + \mathbf{A}_p \mathbf{Y}_{t-p} + \mathbf{u}_t, \quad \mathbf{u}_t \sim \mathcal{N}(\mathbf{0}, \Sigma_u).$$

Definamos:

- $\mathbf{X}_t = (1, \mathbf{Y}_{t-1}^\top, \dots, \mathbf{Y}_{t-p}^\top)^\top \in \mathbb{R}^k$ con $k = np + 1$.
- $\mathbf{B} = (\mathbf{c}, \mathbf{A}_1, \dots, \mathbf{A}_p) \in \mathbb{R}^{n \times k}$.
- $\mathbf{Y} = (\mathbf{Y}_1, \dots, \mathbf{Y}_T)^\top \in \mathbb{R}^{T \times n}$.
- $\mathbf{X} = (\mathbf{X}_1, \dots, \mathbf{X}_T)^\top \in \mathbb{R}^{T \times k}$.
- $\mathbf{U} = (\mathbf{u}_1, \dots, \mathbf{u}_T)^\top \in \mathbb{R}^{T \times n}$.

El VAR se escribe:

$$\mathbf{Y} = \mathbf{X}\mathbf{B}^\top + \mathbf{U}. \quad (5.4)$$

La verosimilitud gaussiana con $\mathbf{u}_t$ iid es:

$$p(\mathbf{Y} \mid \mathbf{B}, \Sigma_u) = (2\pi)^{-Tn/2} |\Sigma_u|^{-T/2} \exp \left\{ -\frac{1}{2} \text{tr}[\Sigma_u^{-1} (\mathbf{Y} - \mathbf{X}\mathbf{B}^\top)^\top (\mathbf{Y} - \mathbf{X}\mathbf{B}^\top)] \right\} \quad (5.5)$$

5.3.2. Prior Normal-Inverse-Wishart

El prior conjugado natural es:

Definición 5.7 (Prior NIW).

$$\Sigma_u \sim \mathcal{IW}(\mathbf{S}_0, \nu_0), \quad (5.6)$$

$$\text{vec}(\mathbf{B}^\top) \mid \Sigma_u \sim \mathcal{N}(\text{vec}(\mathbf{B}_0^\top), \Sigma_u \otimes \Omega_0). \quad (5.7)$$

Los parámetros del prior son:

- $\mathbf{B}_0 \in \mathbb{R}^{n \times k}$: **media prior** de los coeficientes.
- $\Omega_0 \in \mathbb{R}^{k \times k}$, positiva definida: **matriz de precisión** del prior sobre $\mathbf{B}$. Valores pequeños en la diagonal de Ω_0^{-1} significan "prior fuerte".
- $\mathbf{S}_0 \in \mathbb{R}^{n \times n}$: **escala** del Inverse-Wishart.
- $\nu_0 > n$: **grados de libertad** del Inverse-Wishart.

La densidad del Inverse-Wishart es:

$$p(\Sigma_u; \mathbf{S}_0, \nu_0) \propto |\Sigma_u|^{-(\nu_0+n+1)/2} \exp \left\{ -\frac{1}{2} \text{tr}(\mathbf{S}_0 \Sigma_u^{-1}) \right\}.$$

5.3.3. Posterior en forma cerrada

Teorema 5.8 (Posterior NIW del BVAR). *Con prior $NIW(\mathbf{B}_0, \Omega_0, \mathbf{S}_0, \nu_0)$ y verosimilitud (??), la posterior es $NIW(\mathbf{B}_1, \Omega_1, \mathbf{S}_1, \nu_1)$ con:*

$$\Omega_1 = (\Omega_0^{-1} + \mathbf{X}^\top \mathbf{X})^{-1}, \quad (5.8)$$

$$\mathbf{B}_1 = (\mathbf{B}_0 \Omega_0^{-1} + \mathbf{Y}^\top \mathbf{X}) \Omega_1, \quad (5.9)$$

$$\nu_1 = \nu_0 + T, \quad (5.10)$$

$$\mathbf{S}_1 = \mathbf{S}_0 + \mathbf{Y}^\top \mathbf{Y} + \mathbf{B}_0 \Omega_0^{-1} \mathbf{B}_0^\top - \mathbf{B}_1 \Omega_1^{-1} \mathbf{B}_1^\top. \quad (5.11)$$

Bosquejo. Multiplicando prior y verosimilitud y completando el cuadrado en $\text{vec}(\mathbf{B}^\top)$: las propiedades de la distribución Normal matricial y del producto Kronecker permiten identificar la forma NIW. Los detalles algebraicos son extensos pero mecánicos; Karlsson (2013) presenta la derivación paso a paso. $\square$

Interpretación del estimador posterior

La matriz $\mathbf{B}_1$ es un *promedio ponderado* entre $\mathbf{B}_0$ (prior) y $\hat{\mathbf{B}}_{MCO} = \mathbf{Y}^\top \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1}$ (estimador MCO):

Proposición 5.9.

$$\mathbf{B}_1 = \mathbf{B}_0 \mathbf{W}_0 + \hat{\mathbf{B}}_{MCO} \mathbf{W}_1,$$

con $\mathbf{W}_0 = \Omega_0^{-1} \Omega_1$ (peso del prior), $\mathbf{W}_1 = (\mathbf{X}^\top \mathbf{X}) \Omega_1$ (peso de los datos), y $\mathbf{W}_0 + \mathbf{W}_1 = \mathbf{I}$.

El mecanismo de encogimiento (shrinkage) es transparente:

- Prior fuerte (Ω_0^{-1} grande, Ω_0 pequeño): $\mathbf{W}_0 \rightarrow \mathbf{I}$, $\mathbf{B}_1 \rightarrow \mathbf{B}_0$.
- Datos fuertes (T grande, $\mathbf{X}^\top \mathbf{X}$ grande): $\mathbf{W}_1 \rightarrow \mathbf{I}$, $\mathbf{B}_1 \rightarrow \hat{\mathbf{B}}_{MCO}$.
- Balance: posterior entre ambos, según precisiones relativas.

Este es el **principio de regularización bayesiana**: la estimación se encoge hacia el prior en la medida en que los datos son débiles para los parámetros en cuestión.

5.3.4. Muestreo de la posterior NIW

Aunque la posterior es analítica, para cálculos operativos (IRFs, fan charts) necesitamos muestras de ella. El procedimiento estándar:

1. $\Sigma_u^{(s)} \sim \mathcal{IW}(\mathbf{S}_1, \nu_1)$: usar $\Sigma_u = (\mathbf{W}^\top \mathbf{W})^{-1}$ donde $\mathbf{W}$ son ν_1 vectores aleatorios de $\mathcal{N}(\mathbf{0}, \mathbf{S}_1^{-1})$.
2. $\text{vec}(\mathbf{B}_1^{(s)\top}) \mid \Sigma_u^{(s)} \sim \mathcal{N}(\text{vec}(\mathbf{B}_1^\top), \Sigma_u^{(s)} \otimes \Omega_1)$: muestreo gaussiano estándar.

Con $S = 5000$ muestras, podemos computar cualquier cantidad de interés: IRFs con bandas de credibilidad, densidades predictivas, FEVDs, etc.

5.4. El prior Minnesota

5.4.1. La intuición de Litterman

Robert Litterman propuso en su tesis doctoral (1980, publicada 1986) un prior específico para BVAR, motivado por una observación empírica simple: en datos macroeconómicos, una buena aproximación primitiva es que cada variable siga su propio paseo aleatorio. Los precios son $I(1)$, el PIB es casi $I(1)$, tasas de interés son muy persistentes. El prior Minnesota encoge el BVAR hacia esta estructura.

5.4.2. Especificación

Medias priors

Para cada ecuación i del VAR:

- **Coefficiente del primer rezago propio**, $[\mathbf{A}_1]_{ii}$: centrado en 1 si Y_i es $I(1)$ en niveles; centrado en 0 si Y_i es $I(0)$.
- **Todos los demás coeficientes de rezagos** (propios $j \geq 2$ y cruzados $j \geq 1$): centrados en 0.
- **Intercepto**: centrado en 0 con prior muy difuso.

Formalmente, si Y_i es $I(1)$: $[\mathbf{B}_0]_{i,0} = 0$ (intercepto), $[\mathbf{B}_0]_{i,i} = 1$ (primer rezago propio), todo lo demás 0.

Varianzas priors

La varianza prior de un coeficiente captura qué tan seguros estamos de que el verdadero valor está cerca del prior. Litterman propone una estructura jerárquica con tres hiperparámetros:

Definición 5.10 (Varianzas Minnesota). ■ Coeficiente propio al rezago j : $\mathbb{V}[a_{ii,j}] = \lambda_1^2/j^2$.

- Coeficiente cruzado (variable k en ecuación i , $k \neq i$) al rezago j : $\mathbb{V}[a_{ik,j}] = \lambda_1^2 \lambda_2^2 \sigma_i^2 / (j^2 \sigma_k^2)$.
- Intercepto: $\mathbb{V}[c_i] = \lambda_1^2 \lambda_3^2$.

Tres observaciones:

1. **Decaimiento con el rezago:** $1/j^2$ significa que creemos más firmemente que rezagos largos están cerca de cero. Rezago 1 tiene varianza λ_1^2 ; rezago 2, $\lambda_1^2/4$; rezago 3, $\lambda_1^2/9$.
2. **Encogimiento cruzado:** el factor $\lambda_2^2 \leq 1$ impone que creemos más firmemente en que coeficientes cruzados están cerca de cero que los propios. Si $\lambda_2 = 0,5$, cruzados se encogen al doble.
3. **Escalado por σ_i/σ_k :** corrige diferencias de escala entre variables. Si Y_k tiene varianza σ_k^2 mucho mayor que Y_i , su coeficiente debe ser proporcionalmente menor para tener el mismo efecto; el escalado lo ajusta.

Los σ_i^2 se estiman típicamente de AR(1) o AR(p) univariados aplicados a cada Y_i separadamente.

5.4.3. Los hiperparámetros λ

λ_1 : la tightness general

Es el hiperparámetro más importante. Controla qué tan informativo es el prior globalmente:

- $\lambda_1 \rightarrow 0$: prior muy fuerte. $\hat{\mathbf{B}} \rightarrow \mathbf{B}_0$ (todas las variables siguen paseos aleatorios independientes).
- $\lambda_1 \rightarrow \infty$: prior difuso. $\hat{\mathbf{B}} \rightarrow \hat{\mathbf{B}}_{MCO}$.
- Valores estándar: $\lambda_1 \in [0,1,0,3]$. Litterman original: $\lambda_1 = 0,2$.

λ_2 : cruzados vs. propios

Controla qué tanto más encogemos cruzados que propios. Con $\lambda_2 = 1$: igual encogimiento. Con $\lambda_2 < 1$: cruzados encogidos más fuertemente (hacia cero). Valor estándar: $\lambda_2 = 0,5$ o 1 .

 λ_3 : tightness del intercepto

Controla el encogimiento del término constante. Típicamente $\lambda_3 \gg 1$ (p.ej. 10^3) para hacer el prior del intercepto muy difuso; el intercepto se ajusta libremente a los datos.

5.4.4. Elección de los λ : tres enfoques**Calibración fija**

Usar valores estándar: $\lambda_1 = 0,2, \lambda_2 = 0,5, \lambda_3 = 10^5$. Simple; razonable para un primer análisis.

Validación cruzada

Elegir los λ que minimicen el RMSE de pronóstico rolling-origin. Mecánica: rejilla de valores candidatos, para cada uno estimar BVAR y computar RMSE, elegir el mínimo. Riguroso pero computacionalmente costoso.

Bayesiano jerárquico (Giannone, Lenza, Primiceri 2015)

El enfoque más sofisticado. Tratamos $\boldsymbol{\lambda} = (\lambda_1, \lambda_2, \lambda_3)$ como parámetros adicionales con sus propios priors, e integramos la posterior completa sobre $\boldsymbol{\lambda}$:

$$p(\mathbf{B}, \Sigma_u \mid \mathbf{Y}) = \int p(\mathbf{B}, \Sigma_u \mid \boldsymbol{\lambda}, \mathbf{Y}) p(\boldsymbol{\lambda} \mid \mathbf{Y}) d\boldsymbol{\lambda}.$$

La posterior de λ se construye vía la verosimilitud marginal:

$$p(\lambda \mid \mathbf{Y}) \propto p(\mathbf{Y} \mid \lambda)p(\lambda) = \left[\int p(\mathbf{Y} \mid \mathbf{B}, \Sigma_u)p(\mathbf{B}, \Sigma_u \mid \lambda)d\mathbf{B}d\Sigma_u \right] p(\lambda).$$

La verosimilitud marginal $p(\mathbf{Y} \mid \lambda)$ tiene forma cerrada bajo el prior NIW. El muestreo se hace por MCMC sobre λ , y los resultados son IRFs/forecasts que *promedian* sobre diferentes niveles de encogimiento, ponderados por su plausibilidad posterior.

Este es el enfoque default en el paquete BVAR de R, con argumento `hyper = .auto`.

5.4.5. Implementación vía dummy observations

Una implementación elegante del prior Minnesota: convertir las creencias del prior en *observaciones artificiales* que, al añadirse a la muestra, inducen la posterior correcta.

Proposición 5.11. *Existen matrices $\mathbf{Y}^*, \mathbf{X}^*$ tales que MCO aplicado a $(\mathbf{Y}^*, \mathbf{X}^*)$ apilado con los datos reales produce el mismo estimador $\mathbf{B}_1$ que la fórmula posterior del Teorema 5.8.*

Idea. Si queremos que $[\mathbf{B}]_{ik} = b_0$ con precisión $1/\sigma^2$, construimos una observación dummy con $Y_i^* = b_0/\sigma$, $X_k^* = 1/\sigma$, y todo lo demás cero. Al correr MCO sobre $(\mathbf{Y}, \mathbf{Y}^*)$ apilado, el efecto neto es centrar el estimador en b_0 con el peso deseado. $\square$

Ventajas del enfoque:

- Computacionalmente: cualquier rutina de MCO estándar estima el BVAR.
- Pedagógicamente: las dummies hacen explícitas las creencias.

- Conceptualmente: se ve que el prior es información equivalente.^a datos artificiales.

Los paquetes modernos (BVAR) usan implementaciones matriciales directas por eficiencia, pero la equivalencia persiste.

5.4.6. Priors adicionales: sum-of-coefficients e initial observation

Dos extensiones estándar:

Sum-of-coefficients prior (Doan, Litterman, Sims 1984)

Encoge la suma de coeficientes AR de cada variable hacia 1, consistente con persistencia tipo random walk:

$$\sum_{j=1}^p [\mathbf{A}_j]_{ii} \approx 1.$$

Controlado por un hiperparámetro adicional μ_1 . Intuición: evita que el VAR pierda persistencia por sobre-ajuste.

Dummy initial observation (Sims 1993)

Encoge el sistema a tener una solución estacionaria con media cerca del valor inicial. Reduce sesgos en horizontes largos de pronóstico. Controlado por μ_2 .

Ambos se implementan como dummy observations adicionales y son parte estándar del BVAR moderno.

5.5. Muestreadores MCMC

5.5.1. Cuándo necesitamos MCMC

La posterior del BVAR estándar con prior Minnesota es analítica: NIW con parámetros explícitos. Pero las extensiones importantes rompen la conjugación:

- **BVAR-SV**: varianza variable en el tiempo, con un proceso latente de volatilidad.
- **TVP-VAR**: coeficientes variables en el tiempo.
- **Priors no conjugados**: priors con estructura más compleja (sparsity, horseshoe, etc.).
- **Modelos no lineales**: threshold BVAR, Markov-switching BVAR.

En estos casos necesitamos Markov Chain Monte Carlo (MCMC): un algoritmo que genera una cadena $\{\boldsymbol{\theta}^{(s)}\}_{s=1}^S$ cuya distribución límite es la posterior $p(\boldsymbol{\theta} \mid \mathbf{y})$.

5.5.2. Gibbs sampler

Definición 5.12 (Gibbs sampler). Dado $\boldsymbol{\theta} = (\theta_1, \dots, \theta_k)$, el Gibbs sampler genera muestras iterando:

1. Inicializar $\boldsymbol{\theta}^{(0)}$.
2. Para $s = 1, 2, \dots, S$:
 - $\theta_1^{(s)} \sim p(\theta_1 \mid \theta_2^{(s-1)}, \theta_3^{(s-1)}, \dots, \mathbf{y})$.
 - $\theta_2^{(s)} \sim p(\theta_2 \mid \theta_1^{(s)}, \theta_3^{(s-1)}, \dots, \mathbf{y})$.
 - $\vdots$
 - $\theta_k^{(s)} \sim p(\theta_k \mid \theta_1^{(s)}, \dots, \theta_{k-1}^{(s)}, \mathbf{y})$.

El Gibbs funciona cuando las distribuciones *condicionales completas* $p(\theta_j \mid \theta_{-j}, \mathbf{y})$ son tratables (pertenecen a familias conocidas con muestreadores eficientes). La cadena construida tiene la propiedad notable:

Teorema 5.13 (Convergencia del Gibbs). *Bajo condiciones de regularidad (ergodicidad), la distribución de $\boldsymbol{\theta}^{(s)}$ converge a $p(\boldsymbol{\theta} \mid \mathbf{y})$ cuando $s \rightarrow \infty$.*

En la práctica, se descarta un *burn-in* inicial (las primeras S_0 muestras, que dependen del punto inicial) y se retiene el resto.

Aplicación al BVAR estándar

Incluso cuando la posterior es analítica, el Gibbs es útil para muestrear. Para BVAR NIW:

- $\Sigma_u^{(s)} \mid \mathbf{B}^{(s-1)}, \mathbf{Y} \sim \mathcal{IW}(\mathbf{S}', \nu')$ (actualizada con los residuos).
- $\text{vec}(\mathbf{B}^{(s)\top}) \mid \Sigma_u^{(s)}, \mathbf{Y} \sim \mathcal{N}(\text{vec}(\mathbf{B}_1^\top), \Sigma_u^{(s)} \otimes \Omega_1)$.

Las condicionales son exactamente las del Teorema 5.8, evaluadas con parámetros actualizados. El Gibbs produce muestras conjuntas de $(\mathbf{B}, \Sigma_u)$ de la posterior NIW.

5.5.3. Metropolis-Hastings

Cuando incluso las condicionales son intratables, el Metropolis-Hastings (MH) provee una solución más general.

Definición 5.14 (Metropolis-Hastings). Dada una posterior objetivo $\pi(\boldsymbol{\theta}) = p(\boldsymbol{\theta} \mid \mathbf{y})$ y una distribución propuesta $q(\boldsymbol{\theta}^* \mid \boldsymbol{\theta}^{(s-1)})$:

1. Proponer $\boldsymbol{\theta}^* \sim q(\cdot \mid \boldsymbol{\theta}^{(s-1)})$.

2. Computar probabilidad de aceptación:

$$\alpha = \min \left\{ 1, \frac{\pi(\boldsymbol{\theta}^*) \cdot q(\boldsymbol{\theta}^{(s-1)} \mid \boldsymbol{\theta}^*)}{\pi(\boldsymbol{\theta}^{(s-1)}) \cdot q(\boldsymbol{\theta}^* \mid \boldsymbol{\theta}^{(s-1)})} \right\}.$$

3. Con probabilidad α : $\boldsymbol{\theta}^{(s)} = \boldsymbol{\theta}^*$. De lo contrario: $\boldsymbol{\theta}^{(s)} = \boldsymbol{\theta}^{(s-1)}$.

Random-walk Metropolis

El caso especial más común es $q(\boldsymbol{\theta}^* \mid \boldsymbol{\theta}^{(s-1)}) = \mathcal{N}(\boldsymbol{\theta}^{(s-1)}, \Sigma_{MH})$: proposición gaussiana centrada en el valor actual. Es simétrica, $q(a \mid b) = q(b \mid a)$, así que la regla de aceptación simplifica a:

$$\alpha = \min \{1, \pi(\boldsymbol{\theta}^*) / \pi(\boldsymbol{\theta}^{(s-1)})\}.$$

Interpretación: si el candidato tiene mayor posterior, siempre aceptar. Si menor, aceptar con probabilidad proporcional al ratio.

Tuning de Σ_{MH}

El paso Σ_{MH} controla la tasa de aceptación:

- Σ_{MH} grande: propuestas lejanas, a menudo rechazadas.
- Σ_{MH} pequeño: propuestas cercanas, casi siempre aceptadas pero exploración lenta.
- **Óptimo**: tasa de aceptación alrededor de 23 % (multivariado) o 44 % (univariado) — Roberts-Gelman-Gilks (1997).

En la práctica, se hace un "adaptive burn-in" donde Σ_{MH} se ajusta para lograr la tasa óptima antes de iniciar la fase de muestreo real.

5.5.4. Diagnóstico de convergencia

Una cadena MCMC que corrió no garantiza que haya convergido a la posterior. Diagnósticos estándar:

1. **Traceplots:** graficar $\theta_i^{(s)}$ contra s . Cadena estacionaria (mezclándose bien) vs. cadena con tendencia (no convergió).
2. **ACF de la cadena:** la autocorrelación debe decaer rápidamente. Alta autocorrelación indica exploración lenta.
3. **Effective sample size (ESS):** $ESS = S / (1 + 2 \sum_{j \geq 1} \rho_j)$ mide cuántas muestras efectivamente independientes tenemos. Para resultados confiables, $ESS \geq 500$ por parámetro.
4. **Gelman-Rubin $\hat{R}$:** correr múltiples cadenas desde diferentes inicios; $\hat{R}$ compara varianza inter-cadena contra intra-cadena. $\hat{R} < 1,05$ indica convergencia.
5. **Test de Geweke:** comparar la media del primer 10 % de la cadena con el último 50 %. Si son muy distintas, hay falta de convergencia.

5.5.5. Trade-offs prácticos

- **Longitud de cadena:** típicamente 10,000–50,000 iteraciones para BVAR-SV. Primeras 10-20 % como burn-in.
- **Thinning:** retener cada k -ésima muestra para reducir autocorrelación. Con storage moderno, raramente necesario.
- **Múltiples cadenas paralelas:** útil para diagnóstico y para paralelización en CPUs/GPUs.

5.6. Stochastic volatility en BVAR

5.6.1. Motivación: la Gran Moderación

Desde mediados de los 80s hasta 2007, la volatilidad macroeconómica en economías avanzadas (y en varios emergentes) disminuyó notablemente. Luego, la crisis de 2008 y la pandemia de 2020 trajeron de vuelta volatilidad alta. Un BVAR con Σ_u constante no puede capturar esto: sobreestima volatilidad en tiempos tranquilos, subestima en crisis, y produce IRFs que "promedian" efectos de diferentes regímenes.

La solución es dejar que Σ_u varíe en el tiempo. El enfoque dominante es *stochastic volatility* (SV) en el sentido de Taylor (1982) y Kim-Shephard-Chib (1998), adaptado al contexto multivariado por Primiceri (2005), Cogley-Sargent (2005), Koop-Korobilis (2010).

5.6.2. El modelo BVAR-SV

Definición 5.15 (BVAR-SV).

$$\mathbf{Y}_t = \mathbf{B}\mathbf{X}_t + \mathbf{A}^{-1}\Sigma_t^{1/2}\boldsymbol{\varepsilon}_t, \quad \boldsymbol{\varepsilon}_t \sim \mathcal{N}(\mathbf{0}, \mathbf{I}_n), \quad (5.12)$$

donde $\Sigma_t = \text{diag}(h_{1,t}, \dots, h_{n,t})$ y cada log-volatilidad sigue:

$$\log h_{i,t} = \mu_i + \phi_i(\log h_{i,t-1} - \mu_i) + \eta_{i,t}, \quad \eta_{i,t} \sim \mathcal{N}(0, \sigma_{\eta_i}^2). \quad (5.13)$$

Estructura:

- $\mathbf{A}$: matriz triangular inferior con unos en la diagonal. Captura la estructura de correlación contemporánea entre innovaciones.
- Σ_t : diagonal con varianzas variables en el tiempo.
- La varianza total de los residuos reducidos es $\mathbf{A}^{-1}\Sigma_t\mathbf{A}^{-1\top}$.
- Cada $\log h_{i,t}$ es un AR(1) estacionario ($|\phi_i| < 1$) con media μ_i y varianza de innovación $\sigma_{\eta_i}^2$.

5.6.3. SV vs. GARCH: diferencias conceptuales

Comparemos con GARCH del Módulo 2:

	GARCH	SV
Volatilidad	Determinística función del pasado	Variable aleatoria latente
Ecuación h_t	$\omega + \alpha \varepsilon_{t-1}^2 + \beta h_{t-1}$	AR(1) en $\log h_t$ con shock propio
Fuente de variación	Shocks pasados de retornos	Shock estocástico propio de volatilidad
Estimación	MV directa, forma cerrada posible	MCMC (Gibbs con Lman)
Tradición	Finanzas empíricas	Macro bayesiana
Flexibilidad	Moderada	Alta (shocks independientes)

La diferencia conceptual más importante: en GARCH, la volatilidad es una función determinística de los shocks pasados de retornos. En SV, la volatilidad tiene su *propio* proceso estocástico, independiente de los retornos (salvo por correlación instantánea que algunos modelos permiten). SV es más flexible pero computacionalmente más costoso.

Para macroeconomía, SV es preferido porque:

1. Los cambios de volatilidad macro (Gran Moderación, crisis) son graduales, no dictados por shocks discretos.
2. SV permite un proceso suave del $\log h_t$ que captura estos cambios.
3. El enfoque bayesiano (MCMC) es natural para SV.

5.6.4. Estimación de BVAR-SV: el muestreador de Kim-Shephard-Chib

El desafío computacional del SV está en muestrear la trayectoria latente $\{h_{i,t}\}_{t=1}^T$ condicional al resto de parámetros. La verosimilitud condicional de $h_{i,t}$ involucra $\varepsilon_{i,t}^2 = z_{i,t}^2 h_{i,t}$ con $z_{i,t} \sim \mathcal{N}(0, 1)$, lo que hace que $\log \varepsilon_{i,t}^2 = \log h_{i,t} + \log z_{i,t}^2$ donde $\log z_{i,t}^2 \sim \log \chi_1^2$: una distribución no gaussiana.

Kim-Shephard-Chib (1998) propusieron una aproximación clave: la distribución de $\log z^2$ para $z \sim \mathcal{N}(0, 1)$ se aproxima muy bien por una mezcla de 7 gaussianas con pesos, medias y varianzas específicas (tabuladas). Con esta aproximación:

1. Condicional al indicador de componente de la mezcla, $\log \varepsilon_{i,t}^2$ es gaussiana.
2. Entonces $\log h_{i,t}$ está en un modelo de estado-espacio lineal gaussiano.
3. Se aplica el algoritmo de simulación suavizada (FFBS: Forward Filter Backward Sampler) de Carter-Kohn (1994).
4. Luego se muestrea el indicador de componente para cada t .

El muestreador general para BVAR-SV:

1. Muestrear $\mathbf{B}$ condicional a $\{h_{i,t}\}$, $\mathbf{A}$: gaussiano estándar.
2. Muestrear elementos libres de $\mathbf{A}$ condicional a $\mathbf{B}$, $\{h_{i,t}\}$: gaussiano.
3. Muestrear $\{h_{i,t}\}_{t=1}^T$ usando KSC + FFBS.
4. Muestrear $(\mu_i, \phi_i, \sigma_{\eta_i}^2)$: gaussiano (para μ, ϕ), Inverse-Gamma (para σ_{η}^2).

Implementaciones eficientes: **stochvol** (Kastner) para la parte SV; **bsvars** (Wozniak) y **BVAR** (Kuschnig-Vashold) para el paquete completo.

5.7. TVP-VAR

5.7.1. Motivación: cambios estructurales

La Fed de Burns (1970s) no tenía la misma función de reacción que la Fed de Volcker (1980s) o Bernanke (2000s). Si estimamos un VAR con coeficientes constantes sobre 1970-2020, estamos promediando sobre regímenes fundamentalmente distintos. Los coeficientes estimados son un tipo de "promedio ponderado" que puede no corresponder a ningún régimen específico.

La solución es permitir que los coeficientes del VAR varíen suavemente en el tiempo.

5.7.2. El modelo TVP-VAR

Definición 5.16 (TVP-VAR).

$$\mathbf{Y}_t = \mathbf{B}_t \mathbf{X}_t + \mathbf{u}_t, \quad (5.14)$$

$$\text{vec}(\mathbf{B}_t) = \text{vec}(\mathbf{B}_{t-1}) + \boldsymbol{\xi}_t, \quad \boldsymbol{\xi}_t \sim \mathcal{N}(\mathbf{0}, \mathbf{Q}). \quad (5.15)$$

Los coeficientes siguen un paseo aleatorio multivariado. $\mathbf{Q}$ controla la velocidad de cambio:

- $\mathbf{Q}$ pequeño: coeficientes casi constantes.
- $\mathbf{Q}$ grande: coeficientes que pueden cambiar rápidamente.

$\mathbf{Q}$ se estima junto con el resto: el modelo aprende "qué tan variables en el tiempo" son los coeficientes.

5.7.3. El modelo de Primiceri (2005): TVP-VAR + SV

Primiceri propuso combinar TVP (coeficientes variables) con SV (volatilidad variable) en un único modelo:

$$\mathbf{Y}_t = \mathbf{B}_t \mathbf{X}_t + \mathbf{A}_t^{-1} \Sigma_t^{1/2} \boldsymbol{\varepsilon}_t, \quad (5.16)$$

con:

- $\text{vec}(\mathbf{B}_t) = \text{vec}(\mathbf{B}_{t-1}) + \boldsymbol{\xi}_t$: coeficientes variables.
- Elementos libres de $\mathbf{A}_t$ también siguen paseos aleatorios.
- $\log h_{i,t}$: SV como antes.

Este modelo tiene cientos de parámetros efectivos en una muestra típica, pero con priors y restricciones suaves es identificable. El artículo de Primiceri en REStud (2005) aplicó este modelo para investigar cambios en la política monetaria estadounidense; encontró que tanto los coeficientes como la volatilidad cambiaron substancialmente alrededor del Volcker shift.

5.7.4. Estimación

El muestreador sigue la misma filosofía de Gibbs en bloques:

1. Muestrear trayectorias $\{\mathbf{B}_t\}_{t=1}^T$ usando Kalman smoother bayesiano (FFBS).
2. Muestrear elementos de $\{\mathbf{A}_t\}$ análogamente.
3. Muestrear $\{\log h_{i,t}\}$ usando KSC.
4. Muestrear hiperparámetros.

En R: paquete `bvarsv` (Krueger) implementa Primiceri (2005) completo.

5.7.5. IRFs variables en el tiempo

Una ventaja del TVP-VAR es que permite calcular IRFs *para cada fecha*:

$$\Theta_j(t) = \Psi_j(\mathbf{B}_t) \cdot \mathbf{B}_{0,t}^{-1}.$$

Esto permite visualizar cómo la estructura de transmisión cambió en el tiempo. Por ejemplo, "el efecto de un shock de 100 pb en la tasa sobre inflación en 1980 vs. 2000 vs. 2020".

Para la RD, aplicaciones potenciales incluyen cuantificar cómo la adopción del esquema de metas de inflación (2012) cambió la función de reacción del BCRD y la transmisión monetaria.

5.8. Pronóstico densitario y fan charts

5.8.1. La distribución predictiva

El pronóstico bayesiano se formaliza como la *distribución predictiva*:

Definición 5.17 (Distribución predictiva).

$$p(\mathbf{Y}_{T+h} \mid \mathbf{Y}_{1:T}) = \int p(\mathbf{Y}_{T+h} \mid \boldsymbol{\theta}, \mathbf{Y}_{1:T}) \cdot p(\boldsymbol{\theta} \mid \mathbf{Y}_{1:T}) d\boldsymbol{\theta}. \quad (5.17)$$

Esta expresión integra dos fuentes de incertidumbre:

- $p(\mathbf{Y}_{T+h} \mid \boldsymbol{\theta}, \mathbf{Y}_{1:T})$: **incertidumbre residual**. Dado $\boldsymbol{\theta}$, la distribución del valor futuro dada las innovaciones futuras.
- $p(\boldsymbol{\theta} \mid \mathbf{Y}_{1:T})$: **incertidumbre paramétrica**. Nuestra posterior sobre $\boldsymbol{\theta}$.

El pronóstico frecuentista estándar considera principalmente la primera, asumiendo $\hat{\boldsymbol{\theta}}$ como si fuera conocido. El enfoque bayesiano combina ambas de forma coherente.

5.8.2. Simulación de la distribución predictiva

Para BVAR, la distribución predictiva no tiene forma cerrada para $h \geq 2$ debido a la composición dinámica. Pero su simulación es trivial:

1. Para $s = 1, \dots, S$:
 - (a) Extraer una muestra $\boldsymbol{\theta}^{(s)} = (\mathbf{B}^{(s)}, \Sigma_u^{(s)})$ de la posterior.
 - (b) Simular una trayectoria futura $(\mathbf{Y}_{T+1}^{(s)}, \dots, \mathbf{Y}_{T+H}^{(s)})$ usando la ecuación VAR con $\boldsymbol{\theta}^{(s)}$ e innovaciones frescas $\mathbf{u}_{T+h}^{(s)} \sim \mathcal{N}(\mathbf{0}, \Sigma_u^{(s)})$.

2. La nube $\{(\mathbf{Y}_{T+1}^{(s)}, \dots, \mathbf{Y}_{T+H}^{(s)})\}_{s=1}^S$ es una muestra de la distribución predictiva conjunta.

A partir de esta nube podemos calcular cualquier cantidad:

- Media/mediana predictiva: $\bar{\mathbf{Y}}_{T+h} = S^{-1} \sum_s \mathbf{Y}_{T+h}^{(s)}$.
- Intervalos de credibilidad: cuantiles empíricos.
- Probabilidad de eventos: $\mathbb{P}(Y_{i,T+h} > c) \approx S^{-1} \sum_s \mathbf{1}\{Y_{i,T+h}^{(s)} > c\}$.
- VaR a largo plazo, expected shortfall, etc.

5.8.3. Fan charts

El fan chart es la visualización canónica del pronóstico densitario:

Definición 5.18 (Fan chart). Gráfico que muestra cuantiles de la distribución predictiva $p(Y_{i,T+h} \mid \mathbf{Y}_{1:T})$ como bandas coloreadas que se ensanchan con h .

Típicamente se muestran cuantiles:

- 10 %, 20 %, 30 %, 40 %, 50 %, 60 %, 70 %, 80 %, 90 %: nueve niveles simétricos.
- Mediana en el centro.
- Colores más oscuros cerca de la mediana, más claros en las colas.

Uso institucional

Los fan charts son formato estándar en:

- **Bank of England**: los inventó en 1996 para el Inflation Report.

- **Banco Central Europeo:** reportes periódicos.
- **Riksbank:** Monetary Policy Report.
- **BCRD:** Informe de Política Monetaria, para inflación proyectada.

Ventajas sobre puntos + banda simple

1. Visualmente intuitivo: comunica riesgo de forma directa.
2. Captura asimetrías: si la distribución predictiva es sesgada, el fan lo muestra.
3. Muestra evolución de incertidumbre con el horizonte.

Limitación: puede dar falsa impresión de precisión cuando los supuestos del modelo son cuestionables.

5.9. Implementación en R

5.9.1. Paquetes principales

- BVAR (Kuschnig & Vashold): BVAR con prior Minnesota jerárquico. Estándar profesional actual.
- bsvars (Wozniak): BVAR-SV y SVAR bayesiano con identificación por signos.
- bvarsv (Krueger): Primiceri (2005) TVP-VAR + SV.
- stochvol (Kastner): stochastic volatility univariado; base para extensiones.
- BGVAR (Böck *et al.*): global VARs bayesianos.

5.9.2. BVAR estándar con prior Minnesota jerárquico

```
1 library(BVAR)
2
3 # Datos del canal monetario RD
4 datos <- cbind(tmpm, infla, imae, tc)
5 Y <- ts(datos, start = c(2005, 1), frequency = 12)
6
7 # Especificacion del prior Minnesota
8 # Hiperparametros jerarquicos: la tightness lambda
9 # se estima automaticamente desde la posterior
10 prior_mn <- bv_priors(
11   hyper = "auto", # jerarquico: lambda tiene su propia
12                 posterior
13   mn = bv_mn(
14     lambda = bv_lambda(mode = 0.2, sd = 0.4, min = 1e
15                      -4, max = 5),
16     alpha = bv_alpha(mode = 2), # cruzados vs propios
17     var = 1e7 # intercepto muy difuso
18   )
19 )
```

```

19 # Estimacion
20 set.seed(2026)
21 fit_bvar <- bvar(
22   Y,
23   lags = 4,
24   n_draw = 20000,
25   n_burn = 10000,
26   priors = prior_mn,
27   mh = bv_mh(scale_hess = 0.01, adjust_acc = TRUE),
28   verbose = FALSE
29 )
30
31 # Diagnostico
32 summary(fit_bvar)
33 plot(fit_bvar, type = "trace") # traceplots de lambda

```

5.9.3. Inferencia posterior: IRFs y FEVD

```

1 # Identificacion por Cholesky
2 irf_bvar <- irf(
3   fit_bvar,
4   horizon = 24,
5   identification = TRUE,
6   sign_restr = NULL, # para signos: matriz de
                        restricciones
7   fevd = TRUE
8 )
9
10 # Grafico de IRFs con bandas de credibilidad posterior
11 plot(irf_bvar, vars_impulse = "tmpm",
12       vars_response = c("infla", "imae"))
13
14 # Descomposicion de varianza
15 fevd_bvar <- fevd(fit_bvar, horizon = 24)
16 summary(fevd_bvar)

```

5.9.4. Pronóstico densitario y fan chart

```

1 # Distribucion predictiva

```

```
2 fc <- predict(fit_bvar, horizon = 24)
3 summary(fc)
4
5 # Grafico con bandas (incluye fan chart)
6 plot(fc, vars = c("infla", "imae"),
7       col = list(
8         line = "darkblue",
9         fill = "lightblue"
10      ))
11
12 # Extraer draws para fan chart personalizado
13 pred_mat <- fc$fcast[,,"infla"] # dim: draws x
    horizonte
14 str(pred_mat)
15
16 library(ggplot2)
17 library(dplyr)
18 library(tidyr)
19
20 # Tidy: un largo
21 df_fan <- as.data.frame(pred_mat) %>%
22   mutate(draw = row_number()) %>%
23   pivot_longer(-draw, names_to = "h", values_to = "
    valor") %>%
24   mutate(h = as.integer(gsub("V", "", h)))
25
26 # Cuantiles por horizonte
27 qs <- c(0.05, 0.10, 0.25, 0.40, 0.50, 0.60, 0.75,
    0.90, 0.95)
28 fan <- df_fan %>%
29   group_by(h) %>%
30   summarise(
31     q05 = quantile(valor, 0.05),
32     q10 = quantile(valor, 0.10),
33     q25 = quantile(valor, 0.25),
34     q40 = quantile(valor, 0.40),
35     q50 = quantile(valor, 0.50),
36     q60 = quantile(valor, 0.60),
37     q75 = quantile(valor, 0.75),
38     q90 = quantile(valor, 0.90),
39     q95 = quantile(valor, 0.95)
40   )
41
```

```

42 ggplot(fan, aes(x = h)) +
43   geom_ribbon(aes(ymin = q05, ymax = q95), fill = "
      lightblue", alpha = 0.3) +
44   geom_ribbon(aes(ymin = q10, ymax = q90), fill = "
      lightblue", alpha = 0.5) +
45   geom_ribbon(aes(ymin = q25, ymax = q75), fill = "
      lightblue", alpha = 0.7) +
46   geom_ribbon(aes(ymin = q40, ymax = q60), fill = "
      lightblue", alpha = 0.9) +
47   geom_line(aes(y = q50), colour = "darkblue",
      linewidth = 1) +
48   labs(x = "Horizonte (meses)",
49        y = "Inflacion interanual (%)",
50        title = "Fan chart bayesiano: proyeccion de
      inflacion a 24 meses") +
51   theme_minimal()

```

5.9.5. BVAR con stochastic volatility

```

1  library(bsvars)
2
3  # Especificacion con SV
4  spec_sv <- specify_bsvar_sv$new(Y, p = 2)
5
6  # Estimacion por Gibbs (tomara unos minutos)
7  set.seed(2026)
8  fit_sv <- estimate(spec_sv, S = 50000, thin = 10,
9                    show_progress = TRUE)
10
11 # Volatilidades estimadas (con bandas posteriores)
12 plot(fit_sv, type = "volatility")
13
14 # IRFs estructurales con SV
15 irf_sv <- compute_impulse_responses(fit_sv, horizon =
16                                     24)
17 plot(irf_sv)
18
19 # Comparar IRF fijo vs. dependiente de fecha
20 # bsvars permite IRFs condicionadas a distintos
21   estados del sistema

```

5.9.6. TVP-VAR con bvarsv

```

1 library(bvarsv)
2
3 # Estimacion Primiceri (2005)
4 fit_tvp <- bvar.sv.tvp(
5   Y,
6   p = 2,
7   nf = 24, # horizonte de pronostico
8   nrep = 10000,
9   nburn = 5000,
10  tau = 40 # prior para la volatilidad de coefs
11 )
12
13 # Extraer coeficientes variables en el tiempo
14 # fit_tvp$Beta.postmean tiene dim (T x variables x
15   variables*p+1)
16 plot(fit_tvp$Beta.postmean[, 1, 2], # coef de infla en
17      eq. de tmpm
18      type = "l",
19      main = "Coeficiente variable: infla -> tmpm",
20      xlab = "Tiempo", ylab = "coef")

```

5.9.7. Comparación rigurosa con VAR frecuentista

```

1 library(vars)
2 library(BVAR)
3
4 # VAR frecuentista del Modulo 3
5 fit_var_freq <- VAR(Y, p = 4, type = "const")
6
7 # BVAR
8 fit_var_bay <- bvar(Y, lags = 4, n_draw = 10000,
9   n_burn = 5000,
10   priors = prior_mn, verbose = FALSE)
11
12 # Comparar pronosticos rolling
13 # Metrica: continuous ranked probability score (CRPS)
14 library(scoringRules)

```

```

15 # Dividir muestra para validacion rolling
16 T_obs <- nrow(Y)
17 T_inicial <- 180
18 crps_freq <- numeric()
19 crps_bay <- numeric()
20
21 for (t in T_inicial:(T_obs - 1)) {
22   Y_train <- window(Y, end = time(Y)[t])
23
24   # Frecuentista
25   f_f <- VAR(Y_train, p = 4, type = "const")
26   p_f <- predict(f_f, n.ahead = 1, ci = 0.95)
27   mu_f <- p_f$fcst$infla[1, "fcst"]
28   sd_f <- (p_f$fcst$infla[1, "upper"] - mu_f) / 1.96
29   crps_freq[t] <- crps_norm(Y[t+1, "infla"], mean =
      mu_f, sd = sd_f)
30
31   # Bayesiano
32   f_b <- bvar(Y_train, lags = 4, n_draw = 2000, n_burn
      = 1000,
33     priors = prior_mn, verbose = FALSE)
34   pred_b <- predict(f_b, horizon = 1)
35   draws <- pred_b$fcst[, 1, "infla"]
36   crps_bay[t] <- crps_sample(Y[t+1, "infla"], dat =
      draws)
37 }
38
39 # CRPS: menor es mejor
40 mean(crps_freq, na.rm = TRUE)
41 mean(crps_bay, na.rm = TRUE)

```


5.10. Ejercicios

Ejercicio 5.10.1 (Posterior normal-normal: derivación). Sea $y_1, \dots, y_T \stackrel{iid}{\sim} \mathcal{N}(\theta, \sigma^2)$ con σ^2 conocido. Prior $\theta \sim \mathcal{N}(\mu_0, \tau_0^2)$.

- (a) Derive μ_1, τ_1^2 completando el cuadrado.
- (b) Verifique que μ_1 es un promedio ponderado de μ_0 y $\bar{y}$, con pesos proporcionales a precisiones.
- (c) Muestre que $\tau_1^2 \rightarrow 0$ y $\mu_1 \rightarrow \bar{y}$ cuando $T \rightarrow \infty$ (consistencia bayesiana).
- (d) Grafique la posterior para $T = 10$ y $T = 1000$ con $\mu_0 = 0, \tau_0 = 1, \sigma = 1, \bar{y} = 0,5$.

Ejercicio 5.10.2 (Prior Minnesota: comprensión). Considere un VAR bivariado con $p = 2$. Los coeficientes son $a_{11,1}, a_{11,2}, a_{12,1}, a_{12,2}$ (y simétricos en ecuación 2).

- (a) Con Minnesota estándar, ¿cuáles son las medias priors de cada uno?
- (b) Con $\lambda_1 = 0,2, \lambda_2 = 0,5, \sigma_1 = \sigma_2 = 1$, calcule las varianzas priors.
- (c) Si $\lambda_2 \rightarrow 0$: ¿qué estructura VAR obtenemos? (*Hint*: pensar en ecuaciones desconectadas.)
- (d) Simule un VAR(1) con $a_{12,1}$ moderado y $T = 100$. Compare MCO con BVAR(Minnesota) en precisión de estimación.

Ejercicio 5.10.3 (Gibbs sampler en un modelo conjugado). Considere $y_1, \dots, y_T \stackrel{iid}{\sim} \mathcal{N}(\mu, \sigma^2)$ con priors independientes:

$$\mu \sim \mathcal{N}(0, 10), \quad \sigma^2 \sim \text{InvGamma}(2, 1).$$

- (a) Derive las condicionales completas $\mu \mid \sigma^2, \mathbf{y}$ y $\sigma^2 \mid \mu, \mathbf{y}$.

- (b) Implemente un Gibbs sampler con $S = 10000$ iteraciones sobre datos simulados con $\mu = 2, \sigma^2 = 4, T = 100$.
- (c) Graf traceplots, ACF y compare posterior empírica con la exacta (normal-inverse-gamma conjugada).
- (d) Compute ESS; ¿es suficiente?

Ejercicio 5.10.4 (BVAR Minnesota aplicado). Para datos mensuales de tmpm, infla, imae, tc del BCRD:

- (a) Estime un BVAR(4) con prior Minnesota jerárquico.
- (b) Reporte la distribución posterior de λ_1 . ¿Qué valor es modal?
- (c) Calcule IRFs del shock de política monetaria con Cholesky. Compare amplitudes con las del Módulo 3.
- (d) Interprete: ¿el encogimiento bayesiano cambia significativamente las conclusiones?

Ejercicio 5.10.5 (Fan chart bayesiano). Continuando del ejercicio anterior:

- (a) Calcule la distribución predictiva de inflación a 24 meses.
- (b) Construya un fan chart con cuantiles 5 %, 10 %, 25 %, 50 %, 75 %, 90 %, 95 %.
- (c) Reporte la probabilidad posterior de que inflación supere 5 % en cada mes del horizonte.
- (d) Compare bandas bayesianas con bandas del VAR frecuentista (bootstrap). ¿Cuáles son más anchas?

Ejercicio 5.10.6 (SV vs. Gran Moderación). Simule un VAR(1) con tres regímenes de varianza:

- $t = 1, \dots, 100$: $\Sigma_u = \mathbf{I}$.

- $t = 101, \dots, 250$: $\Sigma_u = 0,3\mathbf{I}$ (moderación).
 - $t = 251, \dots, 300$: $\Sigma_u = 2\mathbf{I}$ (crisis).
- (a) Estime BVAR-SV sobre los datos simulados.
 - (b) Grafique $\hat{h}_{i,t}$ estimado con bandas posteriores. ¿Recupera los tres regímenes?
 - (c) Compare con un BVAR estándar (varianza constante): ¿qué pierde?

Ejercicio 5.10.7 (Cambio estructural en función de reacción). Con datos del BCRD 2005-2024:

- (a) Estime un TVP-VAR con `bvarsv`.
- (b) Grafique el coeficiente variable *inflación* $\rightarrow$ *tmpm* (función de reacción).
- (c) Identifique fechas de cambio: ¿coincide con la introducción de metas explícitas (2012)?
- (d) Calcule IRFs de shock monetario condicionadas a 2008 vs. 2020. ¿Cambió la transmisión?

Ejercicio 5.10.8 (Comparación predictiva: CRPS). Use los datos del canal monetario RD:

- (a) Defina una validación rolling con ventana inicial de $T_0 = 180$ meses.
- (b) Para cada t , pronostique inflación a $h = 1, 3, 6, 12$ con VAR frecuentista y con BVAR.
- (c) Calcule CRPS de cada pronóstico.
- (d) Reporte CRPS promedio por horizonte. ¿En cuáles horizontes domina el BVAR?
- (e) Test de Diebold-Mariano entre ambos.

Bibliografía

- [1] Bańbura, M., Giannone, D. & Reichlin, L. (2010). Large Bayesian vector auto regressions. *Journal of Applied Econometrics*, 25(1), 71–92.
- [2] Carter, C. K. & Kohn, R. (1994). On Gibbs sampling for state space models. *Biometrika*, 81(3), 541–553.
- [3] Chib, S. (1995). Marginal likelihood from the Gibbs output. *JASA*, 90(432), 1313–1321.
- [4] Cogley, T. & Sargent, T. J. (2005). Drifts and volatilities: Monetary policies and outcomes in the post WWII US. *Review of Economic Dynamics*, 8(2), 262–302.
- [5] Doan, T., Litterman, R. B. & Sims, C. A. (1984). Forecasting and conditional projection using realistic prior distributions. *Econometric Reviews*, 3(1), 1–100.
- [6] Giannone, D., Lenza, M. & Primiceri, G. E. (2015). Prior selection for vector autoregressions. *Review of Economics and Statistics*, 97(2), 436–451.
- [7] Karlsson, S. (2013). Forecasting with Bayesian vector autoregression. En *Handbook of Economic Forecasting*, vol. 2B, cap. 15. Elsevier.
- [8] Kim, S., Shephard, N. & Chib, S. (1998). Stochastic volatility: Likelihood inference and comparison with ARCH models. *Review of Economic Studies*, 65(3), 361–393.
- [9] Koop, G. & Korobilis, D. (2010). Bayesian multivariate time series methods for empirical macroeconomics. *Foundations and Trends in Econometrics*, 3(4), 267–358.
- [10] Kuschnig, N. & Vashold, L. (2021). BVAR: Bayesian vector autoregressions with hierarchical prior selection in R. *Journal of Statistical Software*, 100(14).

- [11] Litterman, R. B. (1986). Forecasting with Bayesian vector autoregressions: Five years of experience. *Journal of Business & Economic Statistics*, 4(1), 25–38.
- [12] Primiceri, G. E. (2005). Time varying structural vector autoregressions and monetary policy. *Review of Economic Studies*, 72(3), 821–852.
- [13] Roberts, G. O., Gelman, A. & Gilks, W. R. (1997). Weak convergence and optimal scaling of random walk Metropolis algorithms. *Annals of Applied Probability*, 7(1), 110–120.
- [14] Sims, C. A. (1993). A nine-variable probabilistic macroeconomic forecasting model. En J. H. Stock & M. W. Watson (eds.), *Business Cycles, Indicators and Forecasting*. University of Chicago Press.
- [15] Sims, C. A. & Zha, T. (1998). Bayesian methods for dynamic multivariate models. *International Economic Review*, 39(4), 949–968.
- [16] Taylor, S. J. (1982). Financial returns modelled by the product of two stochastic processes: A study of daily sugar prices. En O. D. Anderson (ed.), *Time Series Analysis: Theory and Practice*, 1. North-Holland.

Capítulo 6

Datos de Alta Dimensión y Modelos de Factores

Contenido**5.1. Motivación: ¿por qué bayesiano? 179**

5.1.1. La maldición de la dimensionalidad en VAR frecuentistas 179

5.1.2. Cuantificación de incertidumbre paramétrica 181

5.1.3. Pronóstico densitario 181

5.2. Fundamentos bayesianos 183

5.2.1. La regla de Bayes aplicada a inferencia 183

5.2.2. Priors: tipos y roles 183

5.2.3. Priors conjugados 184

5.2.4. Posterior normal con normal conjugada: caso escalar 185

5.2.5. Intervalos de confianza vs. credibilidad 186

5.3. BVAR: formulación y posterior conjugada 187

5.3.1. El VAR en notación matricial . . 187

5.3.2. Prior Normal-Inverse-Wishart . . 187

5.3.3. Posterior en forma cerrada . . . 188

5.3.4. Muestreo de la posterior NIW . . 189

5.4. El prior Minnesota 190

5.4.1. La intuición de Litterman 190

5.4.2. Especificación 190

5.4.3. Los hiperparámetros λ 191

5.4.4. Elección de los λ : tres enfoques . 192

5.4.5. Implementación vía dummy observations 193

5.4.6.	Priors adicionales: sum-of-coefficients e initial observation	194
5.5.	Muestreadores MCMC	195
5.5.1.	Cuándo necesitamos MCMC . . .	195
5.5.2.	Gibbs sampler	195
5.5.3.	Metropolis-Hastings	196
5.5.4.	Diagnóstico de convergencia . . .	198
5.5.5.	Trade-offs prácticos	198
5.6.	Stochastic volatility en BVAR . .	199
5.6.1.	Motivación: la Gran Moderación	199
5.6.2.	El modelo BVAR-SV	199
5.6.3.	SV vs. GARCH: diferencias con- ceptuales	200
5.6.4.	Estimación de BVAR-SV: el mues- treador de Kim-Shephard-Chib .	201
5.7.	TVP-VAR	203
5.7.1.	Motivación: cambios estructurales	203
5.7.2.	El modelo TVP-VAR	203
5.7.3.	El modelo de Primiceri (2005): TVP-VAR + SV	203
5.7.4.	Estimación	204
5.7.5.	IRFs variables en el tiempo . . .	205
5.8.	Pronóstico densitario y fan charts	206
5.8.1.	La distribución predictiva	206
5.8.2.	Simulación de la distribución pre- dictiva	206
5.8.3.	Fan charts	207
5.9.	Implementación en R	209
5.9.1.	Paquetes principales	209
5.9.2.	BVAR estándar con prior Min- nesota jerárquico	209

5.9.3.	Inferencia posterior: IRFs y FEVD	210
5.9.4.	Pronóstico densitario y fan chart	210
5.9.5.	BVAR con stochastic volatility	212
5.9.6.	TVP-VAR con <code>bvarsv</code>	213
5.9.7.	Comparación rigurosa con VAR frecuentista	213
5.10.	Ejercicios	215
	Bibliografía	218

Resumen

Este capítulo aborda el desafío de trabajar con grandes paneles de series de tiempo macroeconómicas y financieras. Los datos modernos (bases como FRED-MD con 130+ series, la base del BCRD con cientos de indicadores) exceden la capacidad de los VAR convencionales. Se presentan tres respuestas metodológicas complementarias. Primero, los modelos de factores dinámicos (DFM): si n variables son altamente correlacionadas, un pequeño número r de factores latentes las resume. Se desarrolla la estimación por componentes principales con su justificación asintótica (Bai-Ng 2002) y los criterios de información para seleccionar r . Segundo, el FAVAR (Bernanke-Boivin-Eliasz 2005) combina factores con VAR: un VAR pequeño sobre factores y variables clave provee análisis estructural con información amplia, resolviendo el price puzzle. Tercero, el nowcasting: estimación del presente de una variable baja frecuencia usando indicadores alta frecuencia asincrónicos, desarrollado vía DFM con filtro de Kalman (Giannone-Reichlin-Small 2008) y regresiones MIDAS (Ghysels-Santa-Clara-Valkanov 2004). El capítulo cierra con regularización: LASSO, ridge y elastic net como métodos de penalización, y su interpretación bayesiana como priors específicos. Se discute la inferencia post-selección (Belloni-Chernozhukov) y el desafío de validación cruzada temporal correcta. Implementación completa en R con `dfms`, `nowcasting`, `midasr`, `BigVAR` y `glmnet`, aplicada al nowcasting del PIB dominicano.

6.1. Motivación: el problema de alta dimensión

6.1.1. La riqueza de los datos modernos

La economía moderna genera un volumen y variedad de datos que supera ampliamente la capacidad analítica de los VAR convencionales. El Banco Central de la República Dominicana publica aproximadamente 200 series mensuales: componentes del IPC (alimentos, transporte, educación, etc.), agregados monetarios (M1, M2, base monetaria), balanza de pagos (exportaciones por rubro, remesas, turismo), financieras (tasas activas por segmento, crédito por destino), fiscales (recaudación, gasto). La base FRED-MD desarrollada por McCracken-Ng (2016) contiene 130 series mensuales de Estados Unidos organizadas en ocho grupos sectoriales.

A esta riqueza macroeconómica tradicional se suman fuentes nuevas: datos de transacciones (tarjetas de crédito, Point-of-Sale), encuestas de alta frecuencia, indicadores en tiempo real (búsquedas de Google, menciones en redes sociales), precios spot de alta granularidad. La dimensionalidad efectiva de los datos macro creció de $n \sim 5$ en los VAR originales de Sims (1980) a $n \sim 500$ en big data macroeconómico actual.

6.1.2. Por qué los VAR convencionales fallan

El conteo aritmético es elocuente. Un VAR(p) con n variables tiene $pn^2 + n + n(n+1)/2$ parámetros. Para casos representativos:

- $n = 4, p = 4$ (VAR pequeño clásico): 78 parámetros.
- $n = 20, p = 4$ (BVAR mediano tipo Bańbura-Giannone-Reichlin): 1830 parámetros.

- $n = 100, p = 4$: 40,450 parámetros.
- $n = 200, p = 4$: 161,300 parámetros.

Con datos mensuales desde 2000, la muestra típica es $T \sim 250$. La razón observaciones/parámetros en los dos últimos casos es 10^{-2} o menor; MCO es matemáticamente indefinido (la matriz de momentos $\mathbf{X}^\top \mathbf{X}$ es singular cuando el número de regresores excede T).

6.1.3. Las tres respuestas metodológicas

La literatura ha desarrollado tres estrategias para manejar la alta dimensión, cada una con filosofía y trade-offs distintos:

1. **Reducción de dimensión por factores.** Si las n variables son altamente correlacionadas, se mueven coherentemente: unos pocos *factores latentes* pueden resumirlas. Estimamos factores por componentes principales o máxima verosimilitud, y trabajamos con el espacio de baja dimensión ($r \ll n$). Métodos: DFM, FAVAR, ambos con tradición en macroeconometría aplicada desde Stock-Watson (2002).
2. **Selección y penalización.** Dejamos que un criterio automático decida qué variables importan, o penalizamos coeficientes pequeños hacia cero. Induce *esparsidad* en la estimación. Métodos: LASSO (Tibshirani 1996), ridge (Hoerl-Kennard 1970), elastic net (Zou-Hastie 2005). Tradición en estadística y machine learning.
3. **Shrinkage bayesiano.** Priors informativos que regularizan la estimación sin eliminar variables. Métodos: BVAR grande con prior Minnesota (Bańbura-Giannone-Reichlin 2010), BVAR con priors SSVS o sparsity, tratados en el Módulo 4.

Los tres enfoques no son mutuamente excluyentes. El FAVAR bayesiano combina factores con shrinkage; el BVAR-LASSO combina penalización con priors; los Bayesian model averaging promedian entre subconjuntos seleccionados. En este capítulo cubrimos los primeros dos enfoques detalladamente.

6.2. Modelos de factores dinámicos

6.2.1. La idea fundamental

La motivación empírica de los modelos de factores se resume en una observación robusta: en datos macroeconómicos modernos, las series están altamente correlacionadas entre sí. Si calculamos la descomposición en eigenvalores de la matriz de correlación muestral de un panel de 100 variables macroeconómicas, típicamente:

- Los primeros 2-4 eigenvalores capturan 50-80 % de la varianza total.
- Los restantes 95+ eigenvalores son colectivamente pequeños.

Este patrón sugiere que la "dimensionalidad efectiva" del panel es mucho menor a n : unas pocas dimensiones latentes explican la mayor parte del co-movimiento. Los modelos de factores formalizan y explotan esta observación.

6.2.2. Modelo de factores estático

Definición 6.1 (Modelo de factores estático). Para cada variable $i \in \{1, \dots, n\}$ y tiempo $t \in \{1, \dots, T\}$:

$$X_{it} = \boldsymbol{\lambda}_i^\top \mathbf{F}_t + e_{it}, \quad (6.1)$$

con $\mathbf{F}_t \in \mathbb{R}^r$ factores comunes no observables, $\boldsymbol{\lambda}_i \in \mathbb{R}^r$ cargas factoriales, y e_{it} componente idiosincrásica.

Matricialmente, con $\mathbf{X} = (X_{it}) \in \mathbb{R}^{T \times n}$, $\mathbf{F} = (\mathbf{F}_t^\top) \in \mathbb{R}^{T \times r}$ y $\boldsymbol{\Lambda} = (\boldsymbol{\lambda}_i^\top) \in \mathbb{R}^{n \times r}$:

$$\mathbf{X} = \mathbf{F}\boldsymbol{\Lambda}^\top + \mathbf{E}. \quad (6.2)$$

Supuestos del modelo

Para que el modelo sea identificable y estimable:

- **Normalización:** $\Lambda^\top \Lambda / n = \mathbf{I}_r$ y $\mathbb{E}[\mathbf{F}_t \mathbf{F}_t^\top]$ diagonal. Esto fija rotación y escala de los factores.
- **Factor común:** los $\mathbf{F}_t$ son los mismos para todas las series i .
- **Idiosincráticas débilmente correlacionadas:** $\text{Cov}(e_{it}, e_{jt})$ es "pequeña" para $i \neq j$, en sentido asintótico (factor model *aproximado* de Chamberlain-Rothschild 1983).

6.2.3. Modelo de factores dinámico

Definición 6.2 (DFM — Stock-Watson 2002, Forni-Hallin-Lippi-Reichlin 2000).

$$X_{it} = \lambda_i(L)^\top \mathbf{f}_t + e_{it}, \quad (6.3)$$

$$\mathbf{f}_t = \Psi_1 \mathbf{f}_{t-1} + \cdots + \Psi_p \mathbf{f}_{t-p} + \boldsymbol{\eta}_t, \quad (6.4)$$

con $\boldsymbol{\eta}_t \sim \mathcal{N}(\mathbf{0}, \Sigma_\eta)$.

Dos extensiones sobre el modelo estático:

1. **Cargas dinámicas** $\lambda_i(L)$: permiten que las variables respondan con distintos rezagos a los factores. Por ejemplo, una serie puede cargar solo en $\mathbf{f}_t$ y $\mathbf{f}_{t-1}$, otra solo en $\mathbf{f}_{t-3}$.
2. **Dinámica autorregresiva:** los factores siguen su propio VAR.

Para propósitos aplicados, es común trabajar con la *versión estática aumentada*: si cargas dinámicas tienen s rezagos, se define un vector expandido de factores $\tilde{\mathbf{F}}_t = (\mathbf{f}_t^\top, \mathbf{f}_{t-1}^\top, \dots, \mathbf{f}_{t-s}^\top)^\top$. Con esta expansión, la estimación por PCA del modelo estático sigue siendo válida y simple.

6.2.4. Estimación por componentes principales

El método de estimación más usado es el análisis de componentes principales (PCA). Es computacionalmente eficiente, no requiere supuestos distribucionales fuertes, y tiene propiedades asintóticas bien establecidas.

El algoritmo

Dado $\mathbf{X} \in \mathbb{R}^{T \times n}$ estandarizado (cada columna media cero, varianza uno):

1. Calcular la matriz de covarianza muestral: $\hat{\mathbf{S}} = T^{-1} \mathbf{X}^\top \mathbf{X} \in \mathbb{R}^{n \times n}$.
2. Calcular la eigen-descomposición: $\hat{\mathbf{S}} = \hat{\mathbf{V}} \hat{\mathbf{D}} \hat{\mathbf{V}}^\top$, con $\hat{\mathbf{D}}$ diagonal de eigenvalores ordenados $\hat{d}_1 \geq \hat{d}_2 \geq \dots \geq \hat{d}_n \geq 0$.
3. Retener las primeras r columnas de $\hat{\mathbf{V}}$: $\hat{\mathbf{\Lambda}} = \sqrt{n} \cdot \hat{\mathbf{V}}_{[:,1:r]}$.
4. Estimador de factores: $\hat{\mathbf{F}} = \mathbf{X} \hat{\mathbf{\Lambda}} / n$.

El escalado por $\sqrt{n}$ y $1/n$ respeta la normalización $\mathbf{\Lambda}^\top \mathbf{\Lambda} / n = \mathbf{I}_r$.

Interpretación geométrica

PCA encuentra las direcciones en $\mathbb{R}^n$ que maximizan la varianza explicada, sujeto a ortogonalidad. El primer componente principal es la combinación lineal $\mathbf{X} \mathbf{v}_1$ con mayor varianza; el segundo, con mayor varianza entre los ortogonales al primero; y así sucesivamente. Si los r primeros componentes capturan casi toda la varianza, una buena aproximación es $\mathbf{X} \approx \hat{\mathbf{F}} \hat{\mathbf{\Lambda}}^\top$ con $r \ll n$.

6.2.5. Propiedades asintóticas

Teorema 6.3 (Consistencia de PCA — Bai-Ng 2002). *Bajo supuestos del factor model aproximado (incluyendo que los eigenvalores poblacionales de la matriz de cargas son del orden $O(n)$), cuando $n, T \rightarrow \infty$:*

$$\frac{1}{T} \sum_{t=1}^T \|\hat{\mathbf{F}}_t - \mathbf{H}\mathbf{F}_t\|^2 = O_p(\min(n, T)^{-1}),$$

para alguna matriz rotacional $\mathbf{H}$.

El resultado dice que los factores estimados convergen a una rotación de los verdaderos; la rotación es inevitable por la no-identificabilidad inherente, pero no afecta propiedades interpretativas básicas (el espacio lineal es recuperable).

La tasa $\min(n, T)^{-1}$ es la tasa estándar en alta dimensión: n grande mejora la precisión (más cross-section information), T grande también. Si $n, T \rightarrow \infty$ al mismo ritmo, la tasa es n^{-1} o T^{-1} .

6.2.6. Selección del número de factores

Determinar r correctamente es crucial. Muy pocos factores: pérdida de información. Muchos: sobreajuste. Los principales criterios son:

Criterios de información de Bai-Ng (2002)

Análogos de AIC/BIC para modelos de factores. Definamos el MSE total con k factores:

$$\hat{V}(k) = \frac{1}{nT} \sum_{i=1}^n \sum_{t=1}^T (X_{it} - \hat{\lambda}_i(k)^\top \hat{\mathbf{F}}_t(k))^2.$$

Los criterios son:

$$IC_{p1}(k) = \log \hat{V}(k) + k \cdot \frac{n+T}{nT} \log \left[\frac{nT}{n+T} \right], \quad (6.5)$$

$$IC_{p2}(k) = \log \hat{V}(k) + k \cdot \frac{n+T}{nT} \log[\min(n, T)], \quad (6.6)$$

$$IC_{p3}(k) = \log \hat{V}(k) + k \cdot \frac{\log \min(n, T)}{\min(n, T)}. \quad (6.7)$$

Se selecciona $\hat{r} = \arg \min_k IC_p(k)$. Bai-Ng mostraron consistencia: $\hat{r} \rightarrow r_0$ cuando $n, T \rightarrow \infty$.

Criterio de ratio de eigenvalores (Ahn-Horenstein 2013)

$$ER(k) = \frac{\hat{d}_k}{\hat{d}_{k+1}}.$$

Se elige $\hat{r}$ como el k que maximiza ER . Intuición: los eigenvalores genuinamente asociados a factores son mucho mayores que los idiosincráticos; el "salto"(gap) identifica el corte.

Criterio de Onatski (2010)

Basado en la distribución asintótica de los eigenvalores idiosincráticos. Más riguroso matemáticamente pero más sensible a la estructura del ruido.

Recomendación práctica

Reportar varios criterios y buscar consenso. Si dan $\hat{r}$ distinto, elegir el más parsimonioso si la diferencia es pequeña, y hacer análisis de sensibilidad.

6.2.7. Interpretación económica de los factores

Los factores estimados son combinaciones lineales de las variables originales. Su interpretación económica surge de examinar *qué cargas son grandes*:

- **Primer factor** en paneles macro típicos: típicamente un "factor de actividad real" que pondera positivamente producción industrial, empleo, ventas, negativamente desempleo.
- **Segundo factor**: a menudo asociado a precios/inflación, cargando positivamente en índices de precios y tasas.
- **Tercer factor**: frecuentemente ligado a condiciones financieras o tipo de cambio.

La interpretación no es automática; requiere examen económico de las cargas. En análisis aplicado profesional, se reportan las variables con mayores cargas en cada factor, y se discute la intuición.

6.2.8. Usos de los factores estimados

Con factores estimados $\hat{\mathbf{F}}_t$, podemos:

1. **Pronóstico**: regresar Y_{t+h} sobre $\hat{\mathbf{F}}_t$ y rezagos de Y . Con $r \sim 3$ factores, capturamos información de 100+ variables en una regresión manejable.
2. **Construcción de indicadores sintéticos**: el primer factor de un panel de actividad es un indicador compuesto que resume condiciones económicas.
3. **Análisis estructural (FAVAR)**: combinar factores con VAR pequeño para IRFs con información amplia. Lo desarrollamos a continuación.

4. **Análisis de co-movimientos:** visualizar cómo variables cargan en factores revela grupos de variables que se mueven juntas.

6.3. FAVAR

6.3.1. Motivación: el problema de información en VAR pequeños

El VAR convencional del Módulo 3 usa 4-7 variables seleccionadas por el investigador. Esta selección conlleva dos costos:

1. **Omisión de información relevante:** variables importantes pero "secundarias" quedan fuera. Por ejemplo, en un VAR monetario con tasa, inflación, producto, se omiten precios sectoriales, condiciones de crédito, expectativas.
2. **Inconsistencia con el set de información del banco central:** el banco observa *todas* las variables al fijar política. Un VAR con 5 variables asume implícitamente que el banco solo observa esas 5.

Estos costos tienen consecuencias empíricas documentadas. El más famoso es el *price puzzle*: en VAR monetarios pequeños, un shock de subida de tasa a menudo se asocia con *subida* de precios (contradicción con teoría). La interpretación de Bernanke-Boivin-Eliasz (2005) es que el puzzle es un artefacto de información insuficiente: el VAR no distingue entre shock "puro" de política y un ajuste endógeno ante inflación anticipada que el banco observa pero no el econometrista.

El FAVAR resuelve el problema agregando información al VAR vía factores.

6.3.2. Formulación del FAVAR

Definición 6.4 (FAVAR — Bernanke, Boivin & Eliasz 2005). Sean $\mathbf{Y}_t \in \mathbb{R}^m$ variables “clave” observables (típicamente tasa de política + quizá otras específicas), y $\mathbf{F}_t \in \mathbb{R}^r$ factores

latentes que resumen la información restante de un gran panel $\mathbf{X}_t \in \mathbb{R}^N$.

$$\begin{pmatrix} \mathbf{F}_t \\ \mathbf{Y}_t \end{pmatrix} = \Phi(L) \begin{pmatrix} \mathbf{F}_{t-1} \\ \mathbf{Y}_{t-1} \end{pmatrix} + \mathbf{v}_t, \quad (6.8)$$

$$\mathbf{X}_t = \Lambda^F \mathbf{F}_t + \Lambda^Y \mathbf{Y}_t + \mathbf{e}_t. \quad (6.9)$$

La ecuación (??) es un VAR estándar sobre $(\mathbf{F}_t, \mathbf{Y}_t)$ de dimensión $r + m$ (típicamente 5-10). La ecuación (??) es un modelo de factores que vincula los factores latentes al panel observado de información.

Crucialmente, las variables clave $\mathbf{Y}_t$ aparecen explícitamente en el VAR (para poder identificar sus shocks) y también como cargas en el panel (por si afectan directamente a variables del panel, e.g., la tasa de política afecta directamente tasas de mercado).

6.3.3. Estimación en dos pasos

El método original de Bernanke-Boivin-Eliasz es un procedimiento de dos pasos, transparente y fácil de implementar:

1. **Extraer factores:** aplicar PCA al panel $\mathbf{X}_t$ *ortogonalizado* respecto a $\mathbf{Y}_t$. Específicamente:
 - (a) Regresar cada columna de $\mathbf{X}$ sobre $\mathbf{Y}_t$; obtener residuos $\hat{\mathbf{X}}_t^\perp$.
 - (b) Aplicar PCA a $\hat{\mathbf{X}}_t^\perp$ para extraer $\hat{\mathbf{F}}_t$.

Esto garantiza que los factores no contengan información redundante con $\mathbf{Y}_t$.

2. **Estimar VAR:** correr el VAR estándar (??) sobre $(\hat{\mathbf{F}}_t, \mathbf{Y}_t)$. Obtener coeficientes $\hat{\Phi}_i$ y residuos $\hat{\mathbf{v}}_t$.
3. **Identificación estructural:** aplicar Cholesky, restricciones de signo, u otra estrategia del Módulo 3, sobre el VAR reducido.

4. **IRFs en el panel:** para cualquier variable X_{it} , el efecto de un shock estructural se calcula vía:

$$\text{IRF}_{X_i}(h) = \hat{\lambda}_i^{F\top} \cdot \text{IRF}_F(h) + \hat{\lambda}_i^{Y\top} \cdot \text{IRF}_Y(h).$$

6.3.4. Estimación conjunta bayesiana

El método de dos pasos ignora la incertidumbre de los factores estimados al hacer inferencia sobre el VAR. Una alternativa más rigurosa es estimación conjunta por MCMC:

1. Gibbs sampler sobre: factores, cargas, coeficientes VAR, matrices de covarianza.
2. Paso de factores: usar FFBS (Forward Filter Backward Sampler) dado el resto.
3. Pasos restantes: condicionales gaussianas estándar.

El enfoque bayesiano provee bandas de credibilidad que incorporan la incertidumbre factorial. Es la "mejor práctica.^a actual, implementada en paquetes como `bvartools::bvarfactor`.

6.3.5. Resolución del price puzzle: evidencia empírica

Bernanke-Boivin-Eliasz aplicaron el FAVAR a datos de Estados Unidos con 120 variables en el panel. Resultados clave:

- Con VAR estándar de 5 variables: price puzzle presente (precios suben tras shock monetario contractivo).
- Con FAVAR (2 factores + tasa): price puzzle desaparece; precios bajan como esperado.
- Las IRF de múltiples series individuales (vía reconstrucción) son coherentes con teoría.

La interpretación: la información adicional codificada en los factores permite identificar mejor los shocks "puros" de política monetaria, filtrando respuestas endógenas que antes contaminaban la identificación.

6.3.6. FAVAR en la RD: aplicación potencial

Para el canal de transmisión monetaria dominicano, un FAVAR sería particularmente útil dada la riqueza del panel BCRD:

- Variable clave $\mathbf{Y}_t$: tasa de política monetaria, quizá tipo de cambio.
- Panel $\mathbf{X}_t$: 40-80 series mensuales (componentes IPC, M1/M2, IMAE sectorial, crédito por destino, tasas activas).
- $r = 2-3$ factores esperados (actividad real, precios, condiciones financieras).
- IRFs a 24-36 meses sobre variables específicas (inflación por rubro, crédito por sector).

6.4. Nowcasting y MIDAS

6.4.1. El problema del nowcasting

Las variables económicas clave se publican con rezago. El PIB se publica con 30-90 días de rezago según el país; cifras revisadas, aún más tarde. Para política económica y gestión de riesgo, esto es costoso: las decisiones del presente se toman sin conocer el presente.

El *nowcasting* es la estimación del valor actual (o muy reciente) de una variable baja frecuencia usando información alta frecuencia ya disponible. Específicamente:

- Y_t^Q : variable objetivo, baja frecuencia (típicamente trimestral).
- $\mathbf{X}_t^M$: conjunto de indicadores de frecuencia más alta (mensuales, semanales, diarios).
- Objetivo: en cualquier fecha τ dentro del trimestre actual, producir estimación $\hat{Y}_{Q(\tau)}^Q$ usando la información $\mathbf{X}_\tau^M$ hasta τ .

6.4.2. El patrón de ragged edges

En aplicación real, la estructura de datos tiene *ragged edges*: diferentes variables se publican en distintas fechas dentro de cada mes. Por ejemplo, a finales de enero:

- IMAE: última observación diciembre (publicado en enero).
- IPC: ya tenemos enero (publicación al final del mes).
- Crédito: última noviembre (rezago de 2 meses).
- PIB: último trimestre disponible es $Q3$ del año anterior.

Un sistema de nowcasting profesional maneja estos rezagos asimétricos correctamente, actualizando estimaciones conforme llega nueva información.

6.4.3. DFM para nowcasting: Giannone-Reichlin-Small (2008)

El enfoque dominante en bancos centrales usa el DFM en formato de estado-espacio, con el filtro de Kalman manejando datos faltantes.

Formulación estado-espacio

Todas las variables se representan en frecuencia mensual. Las trimestrales tienen observaciones cada tercer mes (meses 3, 6, 9, 12) y NA en los otros. El modelo es:

$$\begin{pmatrix} X_t^M \\ Y_t^Q \end{pmatrix} = \Lambda \mathbf{F}_t + \mathbf{e}_t, \quad (6.10)$$

$$\mathbf{F}_t = \Psi_1 \mathbf{F}_{t-1} + \Psi_2 \mathbf{F}_{t-2} + \boldsymbol{\eta}_t. \quad (6.11)$$

Para variables trimestrales tratadas como agregación de mensuales:

$$Y_t^Q = Y_t^m + Y_{t-1}^m + Y_{t-2}^m,$$

donde Y_t^m es el "PIB mensual no observado."equivalente. Esto se incorpora vía una restricción adicional en el estado-espacio.

Filtro de Kalman

Dado el modelo de estado-espacio con datos faltantes:

1. **Predicción:** con $\hat{\mathbf{F}}_{t-1}$ del período anterior, predecir $\hat{\mathbf{F}}_t$ por la dinámica.
2. **Actualización:** si hay observación en t , usar Kalman para actualizar $\hat{\mathbf{F}}_t$. Si no, mantener la predicción.

3. Iterar a través de toda la muestra.

El filtro de Kalman maneja datos faltantes naturalmente: si una variable no se observa en t , simplemente no entra en el paso de actualización de ese período, sin requerir imputación ad-hoc.

Ganancia de información en tiempo real

Una ventaja central de este enfoque es la actualización en tiempo real. Cada nueva publicación de un indicador mensual produce una *revisión* del nowcast del PIB trimestral actual. Esta evolución puede visualizarse: al inicio del trimestre, el nowcast es esencialmente la media incondicional; conforme entra información, se refina. Al final del trimestre, el nowcast es muy cercano al valor que se publicará semanas después.

6.4.4. MIDAS: una alternativa parsimoniosa

Mixed Data Sampling (MIDAS), propuesto por Ghysels-Santa-Clara-Valkanov (2004), es una alternativa conceptualmente distinta.

Motivación

Considerar regresar PIB trimestral sobre IMAE mensual. Dos enfoques ingenuos:

1. **Agregación temporal:** convertir IMAE a frecuencia trimestral (promedio o suma) y regresar. Pierde información sobre estructura intra-trimestral.
2. **Un coeficiente por observación mensual:** $PIB_q = \beta_1 IMAE_{q,m1} + \beta_2 IMAE_{q,m2} + \beta_3 IMAE_{q,m3} + \dots$ más rezagos. Sobreajuste con muchos rezagos.

MIDAS busca un punto medio: incluye todas las observaciones mensuales pero con pesos *parametrizados* por una función de pocos parámetros.

Formulación

Definición 6.5 (Regresión MIDAS).

$$Y_t^Q = \alpha + \beta \cdot B(L^{1/3}; \boldsymbol{\theta}) X_t^M + \varepsilon_t,$$

con

$$B(L^{1/3}; \boldsymbol{\theta}) = \sum_{k=0}^K b(k; \boldsymbol{\theta}) L^{k/3},$$

y pesos $b(k; \boldsymbol{\theta})$ parametrizados por $\boldsymbol{\theta}$ con $\dim(\boldsymbol{\theta}) \ll K$.

Los pesos $b(k; \boldsymbol{\theta})$ siguen formas funcionales específicas:

Peso de Almon exponencial

$$b(k; \theta_1, \theta_2) = \frac{\exp(\theta_1 k + \theta_2 k^2)}{\sum_{j=0}^K \exp(\theta_1 j + \theta_2 j^2)}.$$

Con solo dos parámetros, produce perfiles flexibles (creciente, decreciente, con forma de campana). La normalización garantiza que los pesos sumen 1.

Peso Beta

$$b(k; \theta_1, \theta_2) = \frac{f(k/K; \theta_1, \theta_2)}{\sum_{j=0}^K f(j/K; \theta_1, \theta_2)}, \quad f(x; \theta_1, \theta_2) = x^{\theta_1-1} (1-x)^{\theta_2-1}.$$

Particularmente útil para bases Beta truncadas. Ghysels et al. recomiendan combinaciones del peso Beta con parámetro adicional.

6.4.5. **Estimación MIDAS**

La regresión MIDAS es no lineal en parámetros (los pesos b son no lineales en $\boldsymbol{\theta}$). Se estima por MCO no lineal:

$$\hat{\boldsymbol{\beta}}, \hat{\boldsymbol{\theta}} = \arg \min \sum_{t=1}^T (Y_t^Q - \alpha - \beta \sum_k b(k; \boldsymbol{\theta}) X_{t-k/3}^M)^2.$$

En R, `midasr::midas_r` maneja la estimación automáticamente.

6.4.6. **DFM vs. MIDAS: trade-offs**

	DFM Nowcasting	MIDAS
Filosofía	Modelo latente multivariado	Regresión directa parsimoniosa
Número de indicadores	Muchos ($n = 20\text{-}100$)	Pocos (< 10)
Manejo de asincronía	Kalman + estado-espacio	Pesos polinomiales
Eficiencia info	Agregación "óptima"	Limitada por especificación
Complejidad computacional	Media-alta	Baja
Transparencia	Factor caja negra	Interpretable directamente
Software R	<code>nowcasting</code> , <code>dfms</code>	<code>midasr</code>

En la práctica profesional, los sistemas de nowcasting de bancos centrales combinan ambos: DFM como motor principal, MIDAS y modelos bridge específicos como verificación cruzada. El Banco Central de Brasil, la Fed de New York, y el ECB usan todos esquemas híbridos.

6.4.7. Métricas de evaluación de nowcasting

- **RMSE por horizonte intra-trimestre:** error promedio por "vintage" de información (nowcast al inicio, medio, fin del trimestre).
- **Reducción relativa a benchmark:** típicamente contra AR simple o media histórica.
- **Test de Diebold-Mariano:** comparación estadística formal entre dos nowcasters.
- **Calibración:** si se produce nowcast densitario, cobertura nominal vs. empírica.

En la RD, un nowcasting del PIB con error cuadrático medio en el rango 0.3-0.5 puntos porcentuales (de crecimiento) es razonable para evaluar viabilidad.

6.5. Regularización: LASSO, ridge, elastic net

6.5.1. El enfoque de penalización

La regularización es una familia distinta de respuestas a la alta dimensión. En lugar de reducir dimensionalidad (factores) o imponer priors bayesianos explícitos, modificamos la función objetivo de estimación añadiendo una *penalización* sobre la complejidad de los coeficientes.

Definición 6.6 (Estimación regularizada).

$$\hat{\beta} = \arg \min_{\beta} \left\{ \underbrace{\sum_{t=1}^T (y_t - \mathbf{x}_t^\top \beta)^2}_{\text{MCO}} + \underbrace{\mathcal{P}_\lambda(\beta)}_{\text{penalización}} \right\}. \quad (6.12)$$

La penalización castiga "valores grandes de β ", empujando la solución hacia coeficientes pequeños. La forma específica de $\mathcal{P}_\lambda$ distingue los métodos.

6.5.2. Ridge regression

Definición 6.7 (Ridge — Hoerl-Kennard 1970).

$$\hat{\beta}^R = \arg \min_{\beta} \left\{ \|\mathbf{y} - \mathbf{X}\beta\|^2 + \lambda \|\beta\|_2^2 \right\}. \quad (6.13)$$

Forma cerrada

Proposición 6.8. *La solución de ridge tiene forma cerrada:*

$$\hat{\beta}^R = (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^\top \mathbf{y}.$$

Demostración. Derivando (??) respecto a β : $-2\mathbf{X}^\top(\mathbf{y} - \mathbf{X}\beta) + 2\lambda\beta = \mathbf{0}$. Despejando: $(\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})\beta = \mathbf{X}^\top \mathbf{y}$, de donde sale el resultado. $\square$

Propiedades

- **Existencia:** $(\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})$ es siempre invertible para $\lambda > 0$, aun si $\mathbf{X}^\top \mathbf{X}$ es singular (caso $n < p$). Esto resuelve el problema de identificación MCO en alta dimensión.
- **Encogimiento:** para cada β_j , el estimador ridge es $\hat{\beta}_j^R = \hat{\beta}_j^{MCO} / (1 + \lambda/d_j)$ donde d_j es el eigenvalor correspondiente. Todos los coeficientes se encogen proporcionalmente.
- **No selecciona:** ridge no produce ceros exactos; todos los coeficientes se mantienen en la solución, solo pequeños.
- **Interpretación bayesiana:** ridge es MAP con prior gaussiano $\beta \sim \mathcal{N}(\mathbf{0}, (\sigma^2/\lambda)\mathbf{I})$.

6.5.3. LASSO

Definición 6.9 (LASSO — Tibshirani 1996).

$$\hat{\beta}^L = \arg \min_{\beta} \left\{ \|\mathbf{y} - \mathbf{X}\beta\|^2 + \lambda \|\beta\|_1 \right\}. \quad (6.14)$$

La diferencia con ridge es sutil pero fundamental: penalizamos la norma L_1 en vez de L_2 .

Propiedades clave

- **Selección de variables:** la penalización L_1 induce *esparsidad*: para λ suficientemente grande, muchos $\hat{\beta}_j$ son *exactamente* cero. LASSO selecciona variables automáticamente.
- **No forma cerrada:** (??) no es diferenciable en $\beta_j = 0$. Se resuelve por algoritmos iterativos: coordinate descent, LARS.

- **Sesgado:** al encoger coeficientes significativamente distintos de cero, LASSO es sesgado. El sesgo puede ser corregido ex-post con post-LASSO.
- **Interpretación bayesiana:** LASSO es MAP con prior Laplace $\beta \sim \text{Laplace}(\mathbf{0}, \sigma^2/\lambda)$.

La "propiedad de oráculo"

Teorema 6.10 (Fan-Li 2001, Zou 2006). *Bajo condiciones apropiadas (beta-min, strong irrepresentable), LASSO tiene la propiedad de oráculo:*

1. *Con probabilidad tendiendo a 1, $\hat{\beta}^L$ es esparsa y selecciona el subconjunto verdadero de variables no nulas.*
2. *Los $\hat{\beta}_j$ para variables seleccionadas son asintóticamente normales con la misma varianza que si supiéramos ex-ante cuáles son las variables relevantes.*

Esta propiedad justifica el uso de LASSO para selección de variables en alta dimensión. Las condiciones técnicas requieren discusión: *strong irrepresentable* dice esencialmente que variables relevantes no están demasiado correlacionadas con irrelevantes. En series de tiempo con multicolinealidad fuerte, la propiedad puede fallar parcialmente.

6.5.4. Geometría: por qué LASSO selecciona y ridge no

Una visualización clásica: el problema penalizado es equivalente a

$$\arg \min \|\mathbf{y} - \mathbf{X}\beta\|^2 \quad \text{sujeto a } \|\beta\|_p \leq t,$$

para $p = 2$ (ridge) o $p = 1$ (LASSO), con t determinado por λ .

Las regiones de restricción tienen forma distinta:

- Ridge (L_2): bola circular.
- LASSO (L_1): rombo con esquinas en los ejes.

Las curvas de nivel de la función objetivo MCO son elipses. El óptimo se encuentra donde la elipse toca la región factible. Con rombo L_1 , el contacto típicamente ocurre en una esquina, que corresponde a algún $\beta_j = 0$. Con círculo L_2 , el contacto raramente está sobre los ejes.

Esta es la intuición geométrica de por qué LASSO induce esparsidad y ridge no.

6.5.5. Elastic Net

Definición 6.11 (Elastic Net — Zou-Hastie 2005).

$$\hat{\beta}^{EN} = \arg \min_{\beta} \left\{ \|\mathbf{y} - \mathbf{X}\beta\|^2 + \lambda \left[(1 - \alpha) \|\beta\|_2^2 / 2 + \alpha \|\beta\|_1 \right] \right\}. \quad (6.15)$$

Elastic Net combina las penalizaciones de ridge y LASSO, con $\alpha \in [0, 1]$ controlando la mezcla:

- $\alpha = 0$: ridge puro.
- $\alpha = 1$: LASSO puro.
- $\alpha \in (0, 1)$: combinación.

Ventaja sobre LASSO: en presencia de variables altamente correlacionadas, LASSO tiende a seleccionar arbitrariamente una y descartar las otras. Elastic Net tiende a seleccionarlas o descartarlas como grupo, lo cual es conductivamente más razonable en series macroeconómicas.

6.5.6. Selección de λ : validación cruzada temporal

Observación 6.12 (Error crítico a evitar). La validación cruzada estándar (k -fold, leave-one-out) **no es válida** en series de tiempo: rompe la estructura temporal.

Definición 6.13 (Validación rolling-origin). Para cada candidato λ en una grilla:

1. Fijar una ventana inicial de entrenamiento de tamaño T_0 .
2. Para $t = T_0, T_0 + 1, \dots, T - h$:
 - (a) Estimar el modelo con datos hasta t , usando λ .
 - (b) Pronosticar $\hat{y}_{t+h}$.
 - (c) Registrar error $e_{t+h}(\lambda) = y_{t+h} - \hat{y}_{t+h}$.
3. Calcular MSE: $\text{MSE}(\lambda) = (T - T_0 - h + 1)^{-1} \sum e_{t+h}^2$.

Seleccionar $\hat{\lambda} = \arg \min_{\lambda} \text{MSE}(\lambda)$.

Validación expansiente vs. deslizante

Dos variantes:

- **Expansiente:** la ventana de entrenamiento crece monótonicamente. Respeta que más datos ayudan.
- **Deslizante:** ventana de tamaño fijo que "desliza.^{en} el tiempo. Útil si hay cambios estructurales.

En series económicas con relaciones estables, expansiente es típicamente superior; en series con régimen cambiante, deslizante.

6.5.7. VAR-LASSO y extensiones

Definición 6.14 (VAR-LASSO).

$$\hat{\mathbf{B}}^L = \arg \min_{\mathbf{B}} \left\{ \sum_{t=1}^T \|\mathbf{Y}_t - \mathbf{B}\mathbf{X}_t\|^2 + \lambda \mathcal{P}(\mathbf{B}) \right\}.$$

La penalización $\mathcal{P}$ admite varias estructuras:

- **LASSO plano:** $\mathcal{P} = \|\text{vec}(\mathbf{B})\|_1$. Penaliza todos los coeficientes por igual.
- **Group LASSO:** $\mathcal{P} = \sum_k \|\mathbf{B}_{\cdot, g_k}\|_2$. Penaliza grupos de coeficientes conjuntamente. Típico grupo: todos los rezagos de la variable k en la ecuación i .
- **Hierarchical LASSO (HLag):** estructura de rezagos coherente. Si no se selecciona rezago j , tampoco se selecciona $j' > j$. Evita .agujeros.^{en} la estructura dinámica.

Nicholson-Bien-Matteson (2017) desarrollan el framework BigVAR con estas extensiones y derivaciones asintóticas.

6.5.8. Inferencia post-selección

Observación 6.15 (El problema). Una vez seleccionadas variables con LASSO, correr MCO estándar sobre el subconjunto y usar errores estándar MCO **no es válido**. La selección introduce sesgo en la inferencia.

Soluciones principales

1. **Post-LASSO OLS** (Belloni-Chernozhukov 2013): bajo condiciones, MCO sobre variables seleccionadas es consistente. Errores estándar siguen siendo condicionalmente inválidos pero el efecto asintóticamente es menor bajo supuestos.
2. **Double LASSO / doubly robust** (Belloni-Chernozhukov-Hansen 2014): para inferencia sobre un parámetro causal específico θ_0 :
 - (a) LASSO de y sobre controles $\mathbf{z}$: obtener $\hat{\beta}_y$.
 - (b) LASSO de d (variable de interés) sobre $\mathbf{z}$: obtener $\hat{\beta}_d$.

(c) Regresar residuos: $(y - \mathbf{z}\hat{\beta}_y) = \theta(d - \mathbf{z}\hat{\beta}_d) + \text{error}$.

La inferencia sobre $\hat{\theta}$ es asintóticamente válida.

3. **Debiased LASSO** (van de Geer *et al.* 2014): corrige el sesgo de LASSO explícitamente mediante proyecciones; provee intervalos de confianza asintóticamente válidos.

6.5.9. Regularización en series de tiempo: consideraciones específicas

Tres consideraciones particulares al aplicar regularización a series de tiempo:

1. **Autocorrelación en errores:** las derivaciones asintóticas estándar asumen errores iid. Con autocorrelación, se requieren modificaciones (Kock, 2016).
2. **Multicolinealidad entre rezagos:** X_{t-1} y X_{t-2} son típicamente correlacionados. LASSO puede seleccionar inestablemente entre ellos; elastic net o group-LASSO son mejor opción.
3. **Estabilidad de la selección:** en muestras diferentes (ej. validación rolling), las variables seleccionadas pueden cambiar. Reportar "frecuencia de selección" de cada variable a través de ventanas.

6.6. Implementación en R

6.6.1. DFM con dfms

El paquete `dfms` de Krantz-Bagdziunas implementa DFM clásico con opciones flexibles.

```
1 library(dfms)
2 library(ggplot2); library(dplyr)
3
4 # Supongamos Y_panel: matriz T x n de panel macro RD
5 # Estandarizar
6 Y_std <- scale(Y_panel)
7
8 # Seleccionar numero de factores
9 ic <- ICr(Y_std)
10 print(ic)
11 # ic$r.star tiene los 3 criterios de Bai-Ng
12
13 # Ajustar DFM con 2 factores
14 fit_dfm <- DFM(Y_std, r = 2, p = 2, method = "PCA")
15 summary(fit_dfm)
16
17 # Factores estimados
18 F_hat <- fit_dfm$F_pca
19 colnames(F_hat) <- c("F1", "F2")
20
21 # Graficar primer factor contra IMAE (tipo validacion
22   cualitativa)
23 df_plot <- data.frame(
24   fecha = time(Y_panel),
25   F1 = F_hat[,1],
26   IMAE = Y_panel[, "IMAE"]
27 )
28 ggplot(df_plot, aes(x = fecha)) +
29   geom_line(aes(y = scale(F1), colour = "Primer factor
30   ")) +
31   geom_line(aes(y = scale(IMAE), colour = "IMAE (
32   estandarizado)")) +
33   labs(y = "Valores estandarizados", title = "Primer
34   factor vs. IMAE") +
35   theme_minimal()
```

6.6.2. Nowcasting DFM con nowcasting

```

1 library(nowcasting)
2
3 # Panel con PIB trimestral expandido a mensual (NA en
  # meses intra-trimestre)
4 # e indicadores mensuales
5 # Formato: columnas son variables, NA para
  # observaciones faltantes
6
7 # Ejecutar nowcasting
8 nc_out <- nowcast(
9   formula = PIB ~ ., # todas las demas como
    predictores
10  data = datos_nc,
11  r = 2, # factores
12  p = 2, # lags VAR
13  q = 2, # dynamic factors
14  method = "2s_agg" # dos pasos con agregacion
    trimestral
15 )
16
17 # Evolucion del nowcast para el trimestre actual
18 plot(nc_out, type = "fcst")
19
20 # Contribucion de cada variable al cambio del nowcast
21 news <- nc_out$news
22 barplot(news, las = 2, main = "Contribucion a la
    revision del nowcast")

```

6.6.3. MIDAS con midasr

```

1 library(midasr)
2
3 # Regresion MIDAS simple: PIB trimestral ~ IMAE
  # mensual
4 # IMAE: 3 obs por trimestre; 6 rezagos mensuales
5 # Pesos Almon normalizado
6
7 fit_midas <- midas_r(
8   PIB ~ trend + mls(IMAE, 0:5, 3, nealmon),

```



```

9   data = list(PIB = PIB_trim, IMAE = IMAE_mens),
10   start = list(IMAE = c(1, 0, 0))
11 )
12 summary(fit_midás)
13
14 # Ver los pesos estimados
15 pesos <- weights_midás(fit_midás, "IMAE")
16 plot(pesos, type = "h", main = "Pesos MIDAS estimados"
17      )
18
19 # Pronostico
20 pred_midás <- forecast(fit_midás, newdata = list(IMAE
21      = IMAE_reciente))

```

6.6.4. LASSO/Ridge/ElasticNet con glmnet

```

1  library(glmnet)
2
3  # Para una ecuación del VAR (infla en función de
4    rezagos)
5  # X: matriz de rezagos de todas las variables
6  # y: inflación en t
7
8  # Validación cruzada estándar (incorrecta en series de
9    tiempo, pero rápida):
10 cv_lasso <- cv.glmnet(X, y, alpha = 1, nfolds = 10)
11 plot(cv_lasso)
12 coef(cv_lasso, s = "lambda.min")
13
14 # Validación rolling-origin (correcta):
15 T_obs <- nrow(X)
16 T_0 <- 120
17 lambdas <- 10^seq(-4, 1, length.out = 50)
18 mse_lambda <- numeric(length(lambdas))
19
20 for (l in seq_along(lambdas)) {
21   err <- numeric(T_obs - T_0)
22   for (t in T_0:(T_obs - 1)) {
23     fit_t <- glmnet(X[1:t,], y[1:t], alpha = 1,
24                    lambda = lambdas[l])

```

```

23     pred <- predict(fit_t, newx = X[t+1, , drop =
24         FALSE])
25     err[t - T_0 + 1] <- y[t+1] - pred
26   }
27   mse_lambda[l] <- mean(err^2, na.rm = TRUE)
28 }
29 lambda_opt <- lambdas[which.min(mse_lambda)]
30 fit_final <- glmnet(X, y, alpha = 1, lambda =
31     lambda_opt)
32 coef(fit_final)

```

6.6.5. VAR-LASSO con BigVAR

```

1  library(BigVAR)
2
3  # Panel macroeconomico: 15-20 variables mensuales RD
4  Y_big <- as.matrix(datos_macro_rd)
5
6  # Configurar modelo con HLAG
7  spec_big <- constructModel(
8    Y_big,
9    p = 12,
10    struct = "HLag", # hierarchical LASSO
11    gran = c(50, 10), # grilla lambda: 50 valores, 10
12        rolling folds
13    h = 1,
14    verbose = FALSE,
15    model.controls = list(
16      intercept = TRUE
17    )
18  )
19
20 # CV y estimacion
21 res <- cv.BigVAR(spec_big)
22
23 # Camino de penalizacion
24 plot(res)
25
26 # Coeficientes seleccionados (la mayoria cero)
27 B_hat <- res@betaPred[, , 1]

```

```
27 # Cuantos coeficientes son no-cero?  
28 sum(abs(B_hat) > 1e-6)  
29 # Total de parametros posibles  
30 length(B_hat)
```

6.7. Ejercicios

Ejercicio 6.7.1 (DFM: simulación y recuperación). Simule un DFM con $n = 50$ variables, $T = 200$, $r = 2$ factores:

- (a) Generar factores $\mathbf{F}_t$ como VAR(1) bivariado estacionario.
- (b) Generar cargas $\boldsymbol{\lambda}_i$ iid $\mathcal{N}(0, 1)$ y idiosincráticas $e_{it} \sim \mathcal{N}(0, 0.5)$.
- (c) Construir $\mathbf{X}$ y estimar DFM por PCA.
- (d) Verificar que los factores estimados son una rotación de los verdaderos (compare correlaciones).
- (e) Aplicar los tres criterios de Bai-Ng; ¿recuperan $r = 2$?

Ejercicio 6.7.2 (FAVAR sobre datos BCRD). Construya un panel de 30 series mensuales del BCRD (componentes IPC, monetarios, sector externo, financieros) desde 2005.

- (a) Estime 2 factores por PCA tras estandarizar.
- (b) Ajuste un FAVAR con (F_1, F_2, tmpm) de orden 4.
- (c) Aplique Cholesky con tasa de política al final.
- (d) Calcule IRFs de shock monetario sobre: factores y variables individuales (reconstruyendo vía cargas).
- (e) ¿Aparece price puzzle en VAR con solo 4 variables?
¿Desaparece con FAVAR?

Ejercicio 6.7.3 (Nowcasting del PIB RD). Con datos reales o simulados:

- (a) Construya panel con PIB trimestral y 10 indicadores mensuales (IMAE, IVU, cemento, consumo eléctrico, empleo SIPEN, turismo, ...).

- (b) Implemente nowcasting con DFM usando `nowcasting::nowcast`.
- (c) Implemente MIDAS simple (PIB sobre IMAE mensual).
- (d) Compare errores rolling-origin de ambos métodos.
- (e) Grafique la "evolución intra-trimestral" del nowcast conforme entran más datos.

Ejercicio 6.7.4 (Interpretación bayesiana de ridge y LASSO). (a)

Muestre que minimizar $\|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|^2 + \lambda\|\boldsymbol{\beta}\|_2^2$ es equivalente a MAP bajo verosimilitud gaussiana y prior $\boldsymbol{\beta} \sim \mathcal{N}(\mathbf{0}, (\sigma^2/\lambda)\mathbf{I})$.

- (b) Análogamente para LASSO con prior Laplace.
- (c) ¿Cómo conecta esto con el prior Minnesota del Módulo 4?

Ejercicio 6.7.5 (Validación temporal incorrecta: evidencia simulada). Simule un AR(1) con $\phi = 0,9$, $T = 300$.

- (a) Elija λ LASSO por k -fold estándar (`cv.glmnet`, default).
- (b) Elija λ LASSO por rolling-origin.
- (c) Evalúe ambos en una ventana de pronóstico out-of-sample posterior.
- (d) Repita 100 veces. ¿Cuál elección produce menor MSE out-of-sample?

Ejercicio 6.7.6 (VAR-LASSO: selección de estructura). Simule un VAR(4) esparso: solo 20 % de los coeficientes son no-nulos.

- (a) Aplique `BigVAR` con estructura "Basic", "Lag", y "HLag".

- (b) Compare fracción de variables verdaderamente no-nulas recuperadas.
- (c) Compare fracción de variables nulas incorrectamente seleccionadas.
- (d) ¿Qué estructura es más apropiada cuando existe "sparsity estructurada"(grupos coherentes)?

Ejercicio 6.7.7 (Indicador sintético de actividad). Con un panel de actividad real mensual RD (IMAE, empleo, cemento, electricidad, ventas):

- (a) Estime DFM con 1 factor común.
- (b) Use el primer factor estandarizado como "Índice Sintético de Actividad".
- (c) Compare con el crecimiento del IMAE: correlación, lead/lag.
- (d) Interprete cambios del indicador en fechas clave: 2008 (crisis), 2020 (COVID), 2023 (desaceleración).

Bibliografía

- [1] Ahn, S. C. & Horenstein, A. R. (2013). Eigenvalue ratio test for the number of factors. *Econometrica*, 81(3), 1203–1227.
- [2] Bańbura, M., Giannone, D. & Reichlin, L. (2010). Large Bayesian vector auto regressions. *Journal of Applied Econometrics*, 25(1), 71–92.
- [3] Bai, J. & Ng, S. (2002). Determining the number of factors in approximate factor models. *Econometrica*, 70(1), 191–221.
- [4] Belloni, A. & Chernozhukov, V. (2013). Least squares after model selection in high-dimensional sparse models. *Bernoulli*, 19(2), 521–547.
- [5] Belloni, A., Chernozhukov, V. & Hansen, C. (2014). Inference on treatment effects after selection among high-dimensional controls. *Review of Economic Studies*, 81(2), 608–650.
- [6] Bernanke, B. S., Boivin, J. & Elias, P. (2005). Measuring the effects of monetary policy: A FAVAR approach. *Quarterly Journal of Economics*, 120(1), 387–422.
- [7] Chamberlain, G. & Rothschild, M. (1983). Arbitrage, factor structure, and mean-variance analysis on large asset markets. *Econometrica*, 51(5), 1281–1304.
- [8] Fan, J. & Li, R. (2001). Variable selection via nonconcave penalized likelihood and its oracle properties. *JASA*, 96(456), 1348–1360.
- [9] Forni, M., Hallin, M., Lippi, M. & Reichlin, L. (2000). The generalized dynamic factor model: Identification and estimation. *REStat*, 82(4), 540–554.

- [10] Ghysels, E., Santa-Clara, P. & Valkanov, R. (2004). The MIDAS touch: Mixed data sampling regression models. Working paper.
- [11] Giannone, D., Reichlin, L. & Small, D. (2008). Nowcasting: The real-time informational content of macroeconomic data. *Journal of Monetary Economics*, 55(4), 665–676.
- [12] Hoerl, A. E. & Kennard, R. W. (1970). Ridge regression: Biased estimation for nonorthogonal problems. *Technometrics*, 12(1), 55–67.
- [13] Kock, A. B. (2016). Consistent and conservative model selection with the adaptive LASSO in stationary and nonstationary autoregressions. *Econometric Theory*, 32(1), 243–259.
- [14] McCracken, M. W. & Ng, S. (2016). FRED-MD: A monthly database for macroeconomic research. *JBES*, 34(4), 574–589.
- [15] Nicholson, W. B., Bien, J. & Matteson, D. S. (2017). High dimensional forecasting via interpretable vector autoregression. Working paper.
- [16] Onatski, A. (2010). Determining the number of factors from empirical distribution of eigenvalues. *REStat*, 92(4), 1004–1016.
- [17] Stock, J. H. & Watson, M. W. (2002). Forecasting using principal components from a large number of predictors. *JASA*, 97(460), 1167–1179.
- [18] Tibshirani, R. (1996). Regression shrinkage and selection via the LASSO. *Journal of the Royal Statistical Society, Series B*, 58(1), 267–288.

- [19] van de Geer, S., Bühlmann, P., Ritov, Y. & Dezeure, R. (2014). On asymptotically optimal confidence regions and tests for high-dimensional models. *Annals of Statistics*, 42(3), 1166–1202.
- [20] Zou, H. (2006). The adaptive LASSO and its oracle properties. *JASA*, 101(476), 1418–1429.
- [21] Zou, H. & Hastie, T. (2005). Regularization and variable selection via the elastic net. *JRSS-B*, 67(2), 301–320.

Capítulo 7

Machine Learning para Series de Tiempo

Contenido

6.1. Motivación: el problema de alta dimensión	226
6.1.1. La riqueza de los datos modernos	226
6.1.2. Por qué los VAR convencionales fallan	226
6.1.3. Las tres respuestas metodológicas	227
6.2. Modelos de factores dinámicos	229
6.2.1. La idea fundamental	229
6.2.2. Modelo de factores estático	229
6.2.3. Modelo de factores dinámico	230
6.2.4. Estimación por componentes principales	231
6.2.5. Propiedades asintóticas	232
6.2.6. Selección del número de factores	232
6.2.7. Interpretación económica de los factores	234
6.2.8. Usos de los factores estimados	234
6.3. FAVAR	236
6.3.1. Motivación: el problema de información en VAR pequeños	236
6.3.2. Formulación del FAVAR	236
6.3.3. Estimación en dos pasos	237
6.3.4. Estimación conjunta bayesiana	238
6.3.5. Resolución del price puzzle: evidencia empírica	238
6.3.6. FAVAR en la RD: aplicación potencial	239
6.4. Nowcasting y MIDAS	240
6.4.1. El problema del nowcasting	240

6.4.2.	El patrón de ragged edges	240
6.4.3.	DFM para nowcasting: Giannone-Reichlin-Small (2008)	241
6.4.4.	MIDAS: una alternativa parsimoniosa	242
6.4.5.	Estimación MIDAS	244
6.4.6.	DFM vs. MIDAS: trade-offs	244
6.4.7.	Métricas de evaluación de nowcasting	245
6.5.	Regularización: LASSO, ridge, elastic net	246
6.5.1.	El enfoque de penalización	246
6.5.2.	Ridge regression	246
6.5.3.	LASSO	247
6.5.4.	Geometría: por qué LASSO selecciona y ridge no	248
6.5.5.	Elastic Net	249
6.5.6.	Selección de λ : validación cruzada temporal	249
6.5.7.	VAR-LASSO y extensiones	250
6.5.8.	Inferencia post-selección	251
6.5.9.	Regularización en series de tiempo: consideraciones específicas	252
6.6.	Implementación en R	253
6.6.1.	DFM con <code>dfms</code>	253
6.6.2.	Nowcasting DFM con <code>nowcasting</code>	254
6.6.3.	MIDAS con <code>midasr</code>	254
6.6.4.	LASSO/Ridge/ElasticNet con <code>glmnet</code>	255
6.6.5.	VAR-LASSO con <code>BigVAR</code>	256
6.7.	Ejercicios	258
	Bibliografía	261

Resumen

Este último capítulo del curso trata el uso de métodos de machine learning (ML) para series de tiempo, posicionándolos con precisión respecto a la econometría clásica. Se abre con una discusión metodológica crucial —el artículo de Breiman (2001) sobre las "dos culturas"— y evidencia empírica reciente (Medeiros et al. 2021) sobre cuándo ML supera a benchmarks econométricos en pronóstico macroeconómico. Se desarrolla rigurosamente la validación cruzada temporal: por qué k-fold estándar es inválido y cómo implementar rolling-origin correctamente. Se cubren tres familias de métodos algorítmicos: random forests (Breiman 2001) con su mecanismo de reducción de varianza vía bagging; gradient boosting con la implementación dominante XGBoost (Chen-Guestrin 2016); e introductoriamente redes recurrentes (RNN, LSTM) con sus trade-offs. Se trata la combinación de pronósticos con atención al forecast combination puzzle (igual peso suele dominar a combinaciones optimizadas) y stacking. La evaluación formal de pronósticos se aborda con rigor: test de Diebold-Mariano con corrección HLN, test de Giacomini-White condicional, y métricas de pronóstico densitario (CRPS, log-score, PIT). El capítulo cierra con implementación integrada usando el ecosistema `tidymodels + modeltime`, y un horse race ML vs econométrico sobre datos macroeconómicos dominicanos, preparatorio para el proyecto final del curso.

7.1. ML vs. econometría: una discusión metodológica

7.1.1. Las dos culturas de Breiman

Leo Breiman publicó en 2001 un ensayo titulado *Statistical Modeling: The Two Cultures* que articuló una tensión

metodológica de larga data. Su tesis central: la comunidad estadística estaba dominada por una cultura de "modelado estocástico" (data modeling) que daba por sentado que los datos provenían de un modelo paramétrico identificable, y relegaba a una minoría la cultura "algorítmica" (algorithmic modeling) que se enfoca en la predicción como fin en sí mismo. Breiman argumentó que esta elección metodológica había costado a la estadística oportunidades de contribuir al avance científico, especialmente en dominios con datos abundantes y relaciones complejas.

La distinción es más sutil que interpretable vs. caja negra". Las dos culturas difieren en:

1. **Objetivo primario.** Modelado clásico: inferir parámetros y testear hipótesis. Algorítmico: predecir fuera de muestra.
2. **Supuestos distribucionales.** Clásico: familia paramétrica especificada (gaussiana, Poisson). Algorítmico: agnóstico sobre el mecanismo generador.
3. **Criterio de éxito.** Clásico: consistencia, eficiencia asintótica, poder de tests. Algorítmico: error cuadrático medio out-of-sample, AUC, log-loss.
4. **Manejo de complejidad.** Clásico: restringir el modelo para permitir inferencia. Algorítmico: permitir complejidad y controlar sobreajuste empíricamente.

Dos décadas después del artículo de Breiman, la tensión se ha resuelto parcialmente: ambas culturas coexisten, y los mejores practicantes las combinan según la pregunta. Este capítulo posiciona ML como *herramienta complementaria*, no sustitutiva, de la econometría que el curso ha construido en los módulos previos.

7.1.2. ¿Cuándo domina cada enfoque?

La pregunta pragmática no es "¿ML o econometría?" sino "¿cuándo cada uno?". Los factores relevantes:

Condiciones que favorecen ML

- **Muchos predictores:** con $n \gtrsim 20$ variables candidatas, los métodos ML (que manejan alta dimensión nativamente) a menudo superan a VAR/BVAR.
- **Relaciones no lineales:** umbrales, interacciones, regímenes no claramente especificados. Árboles y boosting los capturan automáticamente.
- **Muchas observaciones:** $T \gtrsim 1000$ permite que ML aprenda patrones complejos sin sobreajustar.
- **Objetivo estrictamente de pronóstico:** no interesan IRFs, causalidad, parámetros interpretables.

Condiciones que favorecen econometría

- **Muestras pequeñas:** con $T < 200$, ML típicamente sobreajusta; modelos paramétricos parsimoniosos son más robustos.
- **Interés estructural:** IRFs, descomposición de varianza, tests de políticas alternativas requieren identificación explícita.
- **Inferencia causal:** con identificación adecuada, SVAR/LP proveen inferencia causal; ML típicamente captura solo asociación.
- **Extrapolación fuera del rango muestral:** árboles y forests no extrapolan; modelos paramétricos sí.
- **Interpretabilidad como requerimiento:** regulación, audiencia no técnica, obligación de explicar.

7.1.3. Evidencia empírica: Medeiros et al. (2021)

Uno de los estudios más completos comparando ML y econometría en contexto macroeconómico es Medeiros, Vasconcelos, Veiga y Zilberman (2021) sobre pronóstico de inflación en Estados Unidos.

Diseño del estudio

- Variable objetivo: inflación mensual del CPI.
- Predictores: 122 series de FRED-MD.
- Horizontes: 1, 3, 6, 12 meses.
- Benchmarks econométricos: AR, UC-SV, FAVAR, BVAR Minnesota.
- Métodos ML: ridge, LASSO, elastic net, random forest, XGBoost, redes neuronales.
- Evaluación: rolling-origin 1990-2015.

Resultados principales

1. **ML domina en horizontes ≥ 3 meses:** random forest y XGBoost superan consistentemente a benchmarks econométricos.
2. **A 12 meses:** la reducción de RMSE de XGBoost vs. AR(1) es 15-25 %, estadísticamente significativa por DM.
3. **A 1 mes:** diferencias menores; el AR simple es competitivo.
4. **Contribución de predictores "blandos":** sentiment, indicadores financieros alternativos añaden valor.

7.1. ML VS. ECONOMETRÍA: UNA DISCUSIÓN METODOLÓGICA

El estudio es robusto por múltiples especificaciones, horizontes, y esquemas de validación. La conclusión práctica: en pronóstico de variables macroeconómicas centrales con muchos predictores disponibles, ML es hoy competitivo o superior a econometría tradicional.

7.1.4. Lecciones para el practicante

1. **Usar ML como benchmark mínimo:** incluso cuando se prefiere un VAR estructural por razones interpretativas, comparar pronósticos con un XGBoost bien tuneado informa sobre si el modelo estructural "deja valor predictivo sobre la mesa".
2. **Ensamblados híbridos:** combinar pronósticos de BVAR con ML suele mejorar ambos.
3. **Preservar separación funcional:** usar econometría donde aporta (IRFs, identificación), ML donde aporta (pronóstico puro).
4. **Validación rigurosa:** el ganador depende sensiblemente del esquema de validación. Rolling-origin, no shuffle.

7.2. Validación cruzada temporal

7.2.1. Por qué el shuffle estándar falla

En ML estándar (regresión o clasificación sobre datos transversales iid), la validación cruzada k -fold funciona así:

1. Dividir aleatoriamente los datos en k folds de tamaño similar.
2. Para cada fold: entrenar con los restantes $k - 1$, evaluar en el fold retenido.
3. Promediar los k errores.

Este esquema descansa en un supuesto crucial: **las observaciones son intercambiables**. Con observaciones iid, cualquier partición aleatoria respeta la estructura probabilística.

En series de tiempo, la intercambiabilidad falla por dos razones:

1. **Estructura temporal**: cada y_t depende de $y_{t-1}, y_{t-2}, \dots$. Mezclar aleatoriamente rompe esta estructura.
2. **Data leakage**: al usar observaciones futuras para predecir pasadas, el modelo "ve el futuro". El error reportado es artificialmente optimista.

Ejemplo 7.1 (Ilustración concreta). Suponga que $y_t = 0,95y_{t-1} + \varepsilon_t$ y estimamos el coeficiente AR por k -fold shuffle. Con 1000 observaciones y 10 folds, cada fold de test tiene 100 observaciones. Muchas de estas observaciones tienen rezagos en el conjunto de entrenamiento (observaciones adyacentes en el tiempo). El modelo memoriza la dinámica muy bien y predice los folds de test con error artificialmente bajo. Cuando se aplica a datos realmente futuros, el error explota.

7.2.2. Rolling-origin: el esquema correcto

Definición 7.2 (Validación rolling-origin). Dado $\{y_1, \dots, y_T\}$, tamaño inicial T_0 , horizonte h , y paso Δ :

1. Para cada $t \in \{T_0, T_0 + \Delta, T_0 + 2\Delta, \dots, T - h\}$:
 - (a) Entrenar el modelo con $\{y_s\}_{s=1}^t$.
 - (b) Pronosticar $\hat{y}_{t+h}$ (y opcionalmente $\hat{y}_{t+1}, \dots, \hat{y}_{t+h}$).
 - (c) Registrar el error $e_{t+h} = y_{t+h} - \hat{y}_{t+h}$.
2. Métrica de evaluación: $\text{MSE} = N^{-1} \sum e_{t+h}^2$, con N el número de fechas evaluadas.

Variantes

- **Expansiva**: la ventana de entrenamiento crece, $\{y_1, \dots, y_t\}$ siempre desde el inicio. Cada pronóstico usa más datos. Recomendada por defecto.
- **Deslizante**: ventana de tamaño fijo w , $\{y_{t-w+1}, \dots, y_t\}$. Robusta ante cambios estructurales donde datos antiguos son menos informativos.

Parámetros operativos

- T_0 : suficiente para estimar el modelo. Típicamente 50-70 % de la muestra total.
- h : horizonte de interés. Modelos óptimos pueden diferir por horizonte.
- Δ : paso. $\Delta = 1$ evalúa cada fecha; $\Delta = 3$ cada tres (trimestralmente si datos mensuales). Más grande: menos cómputo.

7.2.3. Gap entre entrenamiento y prueba

Una sutileza adicional: cuando hay *autocorrelación residual* fuerte, puede ser deseable un *gap* entre el final del entrenamiento y el inicio del test. Si entrenamos con $\{1, \dots, t\}$ y testeamos en $t + 1$, los residuos en $t + 1$ pueden estar correlacionados con los de t , contaminando la evaluación.

Definición 7.3 (Validación con gap). Entrenar con $\{1, \dots, t\}$; saltar $\{t + 1, \dots, t + g\}$; testear en $\{t + g + 1, \dots, t + g + h\}$. El gap g se elige mayor que la escala de autocorrelación.

En la práctica, con $h \geq 3$ el gap es raramente necesario. Con $h = 1$ y series muy persistentes, $g = 1$ es defensivo.

7.2.4. Implementación en R

Los paquetes modernos implementan rolling-origin correctamente:

- `rsample::rolling_origin`: el estándar en `tidymodels`.
- `caret::trainControl(method = "timeslice")`: interfaz clásica.
- `modeltime::time_series_cv`: diseñado para series de tiempo.
- `tscv de forecast`: interfaz simple.

Observación 7.4 (Avisos específicos). Estas son trampas comunes documentadas en foros de ciencia de datos:

- `caret::trainControl(method=cv)` por defecto es k -fold aleatorio. Cambiar a `"timeslice"`.
- `glmnet::cv.glmnet(...)` con default usa k -fold. Implementar el rolling manualmente.
- `h2o::grid_search` con CV default: shuffle. Configurar explícitamente.

7.3. Random forest

7.3.1. Árbol de regresión: el ingrediente base

Antes de random forest, entendamos su componente: un árbol de regresión (CART, Breiman et al. 1984).

Construcción del árbol

Un árbol particiona recursivamente el espacio de predictores en regiones rectangulares. En cada región, la predicción es una constante (la media muestral de y en esa región).

El algoritmo es greedy:

1. Empezar con todo el espacio de predictores como una única región.
2. Para cada variable x_j y cada valor candidato c :
 - (a) Dividir: $\{x_j \leq c\}$ y $\{x_j > c\}$.
 - (b) Calcular el MSE total resultante.
3. Elegir la división (j^*, c^*) que minimiza el MSE total.
4. Dividir la región; aplicar recursivamente a cada sub-región.
5. Parar cuando:
 - El tamaño de la región es menor que un umbral.
 - La reducción de MSE es menor que un umbral.
 - Se alcanza profundidad máxima.

Propiedades

- **Flexibilidad:** captura relaciones no lineales e interacciones automáticamente.
- **Interpretabilidad:** un árbol pequeño es visualizable y transparente.
- **Robustez a escala:** no requiere estandarización.
- **Maneja missing values:** hay extensiones nativas.

La limitación fundamental

Los árboles individuales tienen *alta varianza*: pequeños cambios en los datos producen árboles muy distintos. Un árbol profundo sobreajusta severamente: memoriza el ruido muestral.

El árbol podría ser "podado" (pruned) para controlar complejidad, pero el compromiso sesgo-varianza es difícil de calibrar. Random forest resuelve esto de otra manera: no poda, sino que promedia muchos árboles ruidosos.

7.3.2. Random forest: construcción

Definición 7.5 (Random Forest — Breiman 2001). Un random forest para regresión es:

1. Para $b = 1, \dots, B$:
 - (a) Tomar una muestra bootstrap de tamaño T de los datos originales.
 - (b) Construir un árbol T_b sobre esa muestra, con la modificación: en cada nodo, solo m predictores elegidos aleatoriamente (de los p totales) se consideran para división.

2. Predicción final:

$$\hat{y}_{RF}(\mathbf{x}) = \frac{1}{B} \sum_{b=1}^B \hat{y}_{T_b}(\mathbf{x}).$$

Las dos inyecciones de aleatoriedad

1. **Bagging (Bootstrap Aggregating, Breiman 1996):** entrenar cada árbol en una muestra bootstrap. Reduce varianza por el mismo mecanismo que la combinación de pronósticos.
2. **Random subspace:** en cada nodo, solo m variables consideradas. Esto *descorrelaciona* los árboles. Sin este paso, todos los árboles dependerían fuertemente de la variable más predictiva, volviéndose similares y limitando la ganancia de promediar.

Por qué funciona

Proposición 7.6. *Si los árboles individuales tienen sesgo β y varianza σ^2 , y están correlacionados con coeficiente ρ entre pares:*

$$\mathbb{V}[\hat{y}_{RF}] = \rho\sigma^2 + (1 - \rho)\sigma^2/B.$$

Demostración. Sea $\hat{y}_b$ las predicciones individuales. Por álgebra elemental de varianza:

$$\mathbb{V}\left[\frac{1}{B} \sum_b \hat{y}_b\right] = \frac{1}{B^2} \left[\sum_b \mathbb{V}(\hat{y}_b) + \sum_{b \neq b'} \text{Cov}(\hat{y}_b, \hat{y}_{b'}) \right] = \frac{\sigma^2}{B} + \frac{B-1}{B} \rho\sigma^2.$$

Cuando $B \rightarrow \infty$, el primer término desaparece y queda $\rho\sigma^2$. $\square$

Implicación: para B grande, la varianza del RF es $\rho\sigma^2$. Si $\rho \approx 0$ (árboles independientes), la varianza colapsa. El random subspace, al forzar a los árboles a "ver" variables distintas, reduce ρ y por tanto la varianza del forest.

7.3.3. Hiperparámetros

Los principales hiperparámetros de un RF:

- **n_{tree}** (B): número de árboles. Típicamente 500 – 2000. Más es mejor (o igual) hasta saturación.
- **m_{try}** (m): predictores por nodo. Default para regresión: $p/3$. Para clasificación: $\sqrt{p}$.
- **min_n**: tamaño mínimo de hoja. Controla profundidad de árboles. Default 5 para regresión.
- **max_depth**: profundidad máxima (alternativa a **min_n**).

En la práctica, RF tiene fama de "funcionar bien out-of-box": los defaults razonables dan buen rendimiento sin tuning extensivo. Ajustar **m_{try}** y **min_n** con validación rolling mejora modestamente.

7.3.4. RF para series de tiempo: consideraciones

Feature engineering

RF no tiene concepto de tiempo: requiere que las dependencias temporales estén codificadas explícitamente en los features. Típicamente:

- **Rezagos del target**: $y_{t-1}, y_{t-2}, \dots, y_{t-p}$.
- **Rezagos de regresores**: $x_{1,t-j}, x_{2,t-j}, \dots$.
- **Features calendario**: mes, trimestre, día de la semana.
- **Features derivados**: medias móviles, desviaciones estándar rolling, diferencias.

- **Features de estacionalidad de Fourier:** $\sin(2\pi kt/s)$, $\cos(2\pi kt/s)$ para diversas frecuencias k .

La calidad del feature engineering es frecuentemente más importante que el método ML elegido. Un XGBoost con features pobres pierde ante un ARIMA con diagnóstico cuidadoso.

Limitación: no extrapola

Observación 7.7 (Característica crítica a entender). Random Forest predice promedios de y en regiones del espacio de features. Consecuencia: **nunca predice valores fuera del rango observado de y .**

Para una serie con tendencia creciente, RF sub-pronostica el futuro. Para una serie en contracción prolongada, sobrepronostica. Esto es opuesto a modelos lineales que extrapolan tendencias naturalmente.

Solución: diferenciar antes de aplicar RF

La práctica recomendada:

1. Quitar tendencia y estacionalidad de la serie original (diferenciación, estacionalidad determinística, o ajuste de un modelo lineal simple).
2. Aplicar RF sobre los residuos o la serie diferenciada.
3. Reconstruir el pronóstico final sumando tendencia y estacionalidad.

Este esquema híbrido combina lo mejor: el modelo lineal captura patrones tendenciales y estacionales extrapolables; RF captura no linealidades residuales.

Importancia de variables

Un beneficio diagnóstico del RF: puede computar *importancia de variables* de dos formas:

- **Mean Decrease in Impurity (MDI)**: suma la reducción de MSE atribuida a cada variable en todos los nodos donde se usa. Rápido pero sesgado hacia variables con muchos niveles.
- **Permutation importance**: permuta aleatoriamente una variable y mide la caída en precisión. Más confiable pero costoso.

En análisis exploratorio, la importancia de variables ayuda a identificar qué rezagos, qué variables, qué features calendáricos son más relevantes.

7.4. Gradient boosting

7.4.1. La idea del boosting

Random forest combina árboles *independientes* entrenados en paralelo. Gradient boosting toma otra estrategia: construir una secuencia donde cada árbol nuevo corrige los errores del anterior. El resultado es un modelo aditivo altamente flexible.

Definición 7.8 (Gradient Boosting — Friedman 2001). Dado una función de pérdida $L(y, \hat{y})$ (típicamente cuadrática), se construye la función predictora iterativamente:

1. Inicializar: $\hat{F}_0(\mathbf{x}) = \arg \min_c \sum_t L(y_t, c) = \bar{y}$ (para pérdida cuadrática).
2. Para $m = 1, \dots, M$:
 - (a) Calcular los *pseudo-residuos*:

$$r_{t,m} = - \left[\frac{\partial L(y_t, F(\mathbf{x}_t))}{\partial F(\mathbf{x}_t)} \right]_{F=\hat{F}_{m-1}}.$$

Para pérdida cuadrática: $r_{t,m} = y_t - \hat{F}_{m-1}(\mathbf{x}_t)$.

- (b) Ajustar un árbol $T_m(\mathbf{x})$ a los pseudo-residuos $\{r_{t,m}\}$.
 - (c) Actualizar: $\hat{F}_m(\mathbf{x}) = \hat{F}_{m-1}(\mathbf{x}) + \nu \cdot T_m(\mathbf{x})$, con $\nu \in (0, 1]$ la *tasa de aprendizaje*.
3. Predicción final: $\hat{F}_M(\mathbf{x})$.

Lectura geométrica

Boosting puede entenderse como descenso de gradiente en el espacio de funciones. La "dirección" óptima en cada paso es el negativo del gradiente funcional de la pérdida: en caso cuadrático, los residuos. Cada árbol aproxima esta dirección, y ν controla el tamaño del paso.

Pérdidas alternativas

El framework acomoda múltiples pérdidas:

- **Cuadrática:** $L(y, \hat{y}) = (y - \hat{y})^2/2$. Residuos simples.
- **Absoluta:** $L(y, \hat{y}) = |y - \hat{y}|$. Robusta a outliers.
- **Huber:** interpolación suave entre cuadrática y absoluta.
- **Quantile:** para pronóstico de cuantiles específicos. Base para pronóstico densitario con gradient boosting.

7.4.2. XGBoost: la implementación moderna

Chen y Guestrin (2016) desarrollaron XGBoost (*eXtreme Gradient Boosting*), que ha dominado competencias de Kaggle y producción empresarial desde 2014. Las mejoras clave:

Regularización explícita

La función objetivo de XGBoost añade regularización sobre los pesos de las hojas:

$$\text{Obj} = \sum_t L(y_t, \hat{y}_t) + \sum_m \Omega(T_m),$$

con

$$\Omega(T) = \gamma \cdot |\text{hojas}(T)| + \frac{\lambda}{2} \sum_j w_j^2 + \alpha \sum_j |w_j|,$$

donde w_j es el peso de la hoja j , γ penaliza la complejidad estructural, y λ, α son regularización L_2 y L_1 .

Esta regularización explícita controla mejor el sobreajuste que gradient boosting clásico.

Aproximación de segundo orden

XGBoost usa una aproximación de Taylor de segundo orden de la pérdida:

$$L(y, \hat{y} + \Delta) \approx L(y, \hat{y}) + g\Delta + \frac{1}{2}h\Delta^2,$$

con $g = \partial L / \partial \hat{y}$, $h = \partial^2 L / \partial \hat{y}^2$. Esto permite computar los pesos óptimos de las hojas en forma cerrada.

Optimizaciones computacionales

- Paralelización en construcción de árboles.
- Soporte para GPU.
- Manejo nativo de missing values (aprende en qué dirección enviar NA en cada nodo).
- Histograma de splits: discretiza variables continuas para acelerar búsqueda de cortes.

7.4.3. Hiperparámetros y tuning

XGBoost tiene muchos hiperparámetros. Los críticos:

- **nrounds** (M): número de iteraciones. Usar *early stopping* (detener cuando no hay mejora en validación) es esencial.
- **eta** (ν): tasa de aprendizaje. 0.01-0.3. Menor = más árboles necesarios pero menos sobreajuste.
- **max_depth**: profundidad máxima. 3-8 típico. Más profundo = más interacciones capturadas pero más sobreajuste.
- **min_child_weight**: peso mínimo acumulado en hoja. Análogo al **min_n** de RF.

- `subsample`: fracción de observaciones por árbol. 0.5-1.0.
- `colsample_bytree`: fracción de features por árbol. Análogo a `mtry` de RF.
- `gamma`, `lambda`, `alpha`: parámetros de regularización.

Protocolo de tuning recomendado

1. Fijar `eta=0.1`, `nrounds=1000` con early stopping.
2. Tunear `max_depth` y `min_child_weight` por grid search en validación rolling.
3. Tunear `subsample` y `colsample_bytree`.
4. Tunear `gamma`.
5. Reducir `eta` (a 0.01-0.05) y aumentar `nrounds` proporcionalmente. Mejora suele ser modesta pero consistente.

7.4.4. XGBoost vs. Random Forest

En competencias y producción, XGBoost suele dominar ligeramente cuando está bien tuneado. Sin tuning cuidadoso, RF es más defensivo. Para el practicante: RF como baseline robusto, XGBoost para empujar rendimiento.

	Random Forest	XGBoost
Construcción	Paralela (árboles independientes)	Secuencial (aditiva)
Fuente de reducción de varianza	Bagging + random subpace	Regularización + shrinkage
Hiperparámetros críticos	Pocos (mtry, min_n)	Muchos
Sensibilidad a HP	Baja	Alta
Velocidad	Rápido	Muy rápido (optimizado)
Rendimiento out-of-box	Bueno	Bueno (mediocre sin tuning)
Rendimiento con tuning	Buenas mejoras modestas	Gran mejora posible

Tabla 7.1: Comparación de random forest y XGBoost.

7.5. Redes recurrentes: una introducción

7.5.1. Motivación y posicionamiento

Las redes neuronales —y en particular las recurrentes (RNN)— han revolucionado dominios como procesamiento de lenguaje natural y visión computacional. Para series de tiempo económicas, su uso es más matizado. Esta sección es intencionalmente introductoria: describe el concepto, no busca dominio profundo.

Cuándo considerar RNN/LSTM

- Muestras grandes ($T \gtrsim 1000$): necesario para aprender parámetros.
- Dinámicas complejas: no lineales, con dependencias

largas.

- Datos secuenciales de alta frecuencia: retornos diarios o intradiarios, flujos de órdenes.
- Disponibilidad de GPU: entrenamiento en CPU es prohibitivamente lento para redes grandes.

Cuándo no considerar RNN/LSTM

- Datos macroeconómicos mensuales típicos ($T \sim 200 - 500$): insuficientes.
- Requerimiento de interpretabilidad.
- Necesidad de inferencia estructural (RNN no identifica shocks).
- Presupuesto computacional limitado.

Para el curso, RNN/LSTM es un *teaser*: describimos la arquitectura sin entrar en el detalle de entrenamiento, que merece un curso aparte.

7.5.2. Red neuronal feedforward: el precursor

Una red neuronal feedforward con una capa oculta es simplemente una función:

$$\hat{y} = \mathbf{W}_2 \cdot \sigma(\mathbf{W}_1 \mathbf{x} + \mathbf{b}_1) + b_2,$$

con $\sigma(\cdot)$ una no linealidad (típicamente ReLU, $\sigma(z) = \max(0, z)$, o tanh). Los parámetros $\mathbf{W}_1, \mathbf{W}_2, \mathbf{b}_1, b_2$ se aprenden minimizando una pérdida sobre datos de entrenamiento.

Con varias capas (*deep neural network*), la red puede aproximar funciones arbitrariamente complejas. Teorema

de aproximación universal (Hornik 1991): una red feedforward con una capa oculta lo suficientemente ancha puede aproximar cualquier función continua.

El entrenamiento se hace por *backpropagation*: cálculo de gradientes por regla de la cadena, seguido de descenso de gradiente (típicamente con Adam o variantes).

7.5.3. RNN: Recurrent Neural Network

La limitación del feedforward para series de tiempo: no tiene memoria. Cada input se procesa independientemente. Para series, necesitamos que la red recuerde. estados pasados.

Definición 7.9 (RNN vainilla).

$$\mathbf{h}_t = \sigma(\mathbf{W}_h \mathbf{h}_{t-1} + \mathbf{W}_x \mathbf{x}_t + \mathbf{b}_h), \quad (7.1)$$

$$\hat{y}_t = \mathbf{W}_y \mathbf{h}_t + b_y, \quad (7.2)$$

con $\mathbf{h}_t$ el *estado oculto* (memoria) en el tiempo t .

Los pesos $\mathbf{W}_h$, $\mathbf{W}_x$, $\mathbf{W}_y$ se comparten a través del tiempo: el mismo conjunto de parámetros se aplica en cada paso. Esta compartición hace que la red sea escalable a secuencias de cualquier longitud.

El problema del gradiente desvaneciente

El entrenamiento de RNN usa *backpropagation through time* (BPTT): desenrollar la red para T pasos y aplicar backpropagation estándar. El gradiente de la pérdida respecto a $\mathbf{W}_h$ involucra productos de $\partial \mathbf{h}_t / \partial \mathbf{h}_{t-k}$ para $k = 0, \dots, T-1$.

Cada factor es aproximadamente $\mathbf{W}_h \cdot \sigma'$. Si $\|\mathbf{W}_h \sigma'\| < 1$, el producto decae exponencialmente (vanishing gradient). Si > 1 , explota.

Consecuencia: RNN vainilla no aprende dependencias de más de 10-20 pasos. Es inútil para series con dinámicas de largo plazo.

7.5.4. LSTM: la arquitectura que resolvió el problema

Hochreiter y Schmidhuber (1997) propusieron la arquitectura *Long Short-Term Memory* (LSTM). La idea: agregar un estado celular con caminos que evitan las multiplicaciones recurrentes, permitiendo que los gradientes fluyan intactos a través de largos horizontes.

Los gates de LSTM

LSTM tiene tres "gates" (compuertas), cada uno con pesos aprendibles:

- **Forget gate f_t** : qué fracción de memoria olvidar del paso anterior.
- **Input gate i_t** : qué información nueva incorporar.
- **Output gate o_t** : qué parte de la memoria exponer como output.

Las ecuaciones son (sin entrar en todos los detalles):

$$f_t = \sigma(\mathbf{W}_f[\mathbf{h}_{t-1}, \mathbf{x}_t]), \quad (7.3)$$

$$i_t = \sigma(\mathbf{W}_i[\mathbf{h}_{t-1}, \mathbf{x}_t]), \quad (7.4)$$

$$o_t = \sigma(\mathbf{W}_o[\mathbf{h}_{t-1}, \mathbf{x}_t]), \quad (7.5)$$

$$\tilde{\mathbf{c}}_t = \tanh(\mathbf{W}_c[\mathbf{h}_{t-1}, \mathbf{x}_t]), \quad (7.6)$$

$$\mathbf{c}_t = f_t \odot \mathbf{c}_{t-1} + i_t \odot \tilde{\mathbf{c}}_t, \quad (7.7)$$

$$\mathbf{h}_t = o_t \odot \tanh(\mathbf{c}_t). \quad (7.8)$$

El estado celular $\mathbf{c}_t$ es la cinta transportadora "de memoria. Puede preservar información por cientos de pasos.

7.5.5. GRU: alternativa más simple

Cho et al. (2014) propusieron *Gated Recurrent Unit* (GRU), que simplifica LSTM fusionando forget e input gate en un único "update gate":

$$\mathbf{z}_t = \sigma(\mathbf{W}_z[\mathbf{h}_{t-1}, \mathbf{x}_t]) \quad (\text{update gate}) \quad (7.9)$$

$$\mathbf{r}_t = \sigma(\mathbf{W}_r[\mathbf{h}_{t-1}, \mathbf{x}_t]) \quad (\text{reset gate}) \quad (7.10)$$

$$\tilde{\mathbf{h}}_t = \tanh(\mathbf{W}_h[\mathbf{r}_t \odot \mathbf{h}_{t-1}, \mathbf{x}_t]) \quad (7.11)$$

$$\mathbf{h}_t = (1 - \mathbf{z}_t) \odot \mathbf{h}_{t-1} + \mathbf{z}_t \odot \tilde{\mathbf{h}}_t. \quad (7.12)$$

GRU tiene menos parámetros y es frecuentemente competitivo con LSTM en rendimiento. Para series de tiempo económicas con muestras moderadas, GRU a menudo es preferible.

7.5.6. Evidencia empírica: RNN vs. métodos clásicos

¿Vale la pena usar RNN para series económicas? La evidencia es mixta:

- **En finanzas de alta frecuencia:** LSTM compite con y a veces supera a GARCH/HAR. Muestras grandes ($T \gtrsim 10^5$) y patrones complejos.
- **En macro mensual:** RNN raramente domina a XGBoost con feature engineering adecuado. Muestras pequeñas, dinámicas simples.
- **En competencia M4** (Makridakis et al. 2020): híbridos de ML y métodos estadísticos dominan; LSTM puro tuvo rendimiento modesto.

Nuestra recomendación para el curso: entender el concepto, usar XGBoost como workhorse de ML en macro, explorar LSTM si se tiene datos abundantes y motivación específica.

7.6. Ensamblés y combinación de pronósticos

7.6.1. La sabiduría de combinar

Una de las regularidades más robustas en pronóstico empírico: combinar pronósticos de modelos distintos frecuentemente mejora la precisión. El resultado se remonta a Bates y Granger (1969).

Proposición 7.10 (Reducción de varianza por combinación). Sean $\hat{y}^{(1)}, \hat{y}^{(2)}$ dos pronósticos con errores e_1, e_2 de varianzas σ_1^2, σ_2^2 y correlación ρ . La combinación $\hat{y}^{comb} = w\hat{y}^{(1)} + (1 - w)\hat{y}^{(2)}$ tiene error con varianza:

$$\sigma_{comb}^2(w) = w^2\sigma_1^2 + (1 - w)^2\sigma_2^2 + 2w(1 - w)\rho\sigma_1\sigma_2.$$

El w óptimo minimizando σ_{comb}^2 es:

$$w^* = \frac{\sigma_2^2 - \rho\sigma_1\sigma_2}{\sigma_1^2 + \sigma_2^2 - 2\rho\sigma_1\sigma_2}.$$

Siempre que $\rho < \min(\sigma_1/\sigma_2, \sigma_2/\sigma_1)$, la combinación óptima tiene menor varianza que ambos modelos individuales.

Demostración. Derivar $\sigma_{comb}^2(w)$ respecto a w e igualar a cero. $\square$

Interpretación: los errores de modelos distintos son típicamente correlacionados pero no perfectamente. Hay siempre algún w^* que aprovecha esta diversidad.

7.6.2. El forecast combination puzzle

Aunque la teoría dice que estimar w^* óptimamente es mejor, Stock y Watson (2004) y otros han documentado empíricamente un fenómeno sorprendente: la combinación de **pesos iguales** frecuentemente iguala o supera a combinaciones óptimas estimadas.

Observación 7.11 (El puzzle).

$$w^{\text{igual}} = 1/K \quad \text{suele dominar a} \quad \hat{w}^{\text{óptimo}}$$

Por qué

Tres explicaciones complementarias:

1. **Incertidumbre de estimación:** $\hat{w}^*$ es una función compleja de $\hat{\sigma}_k^2$ y $\hat{\rho}$, estimadores con error. El ruido en $\hat{w}$ puede dominar la ganancia teórica.
2. **Inestabilidad:** los pesos óptimos cambian con la muestra; "optimizar" sobre una ventana específica sobreajusta a las peculiaridades de esa ventana.
3. **Prior razonable:** $w = 1/K$ es equivalente a un prior fuerte pero razonable de "ignorancia" sobre cuál modelo es mejor. Con suficiente incertidumbre, este prior vence la evidencia empírica ruidosa.

Regla práctica

Empezar con combinación de igual peso como benchmark. Desviarse solo si hay evidencia clara y consistente de mejora en validación rolling genuina (fuera del periodo usado para estimar los pesos). La evidencia debe ser fuerte porque la inestabilidad es un riesgo real.

7.6.3. Stacking

Una generalización sofisticada: usar los pronósticos de modelos base como *features* de un modelo *meta*. Popularizado por Wolpert (1992) bajo el nombre de *stacked generalization*.

Procedimiento correcto en series de tiempo

1. Dividir la muestra de entrenamiento en K folds temporales (rolling).
2. Para cada fold: entrenar modelos base en el resto; obtener predicciones out-of-fold $\hat{y}_t^{(k)}$ para el fold retenido.
3. Al final, tenemos un "dataset meta": para cada t , el tuple $(\hat{y}_t^{(1)}, \dots, \hat{y}_t^{(K)}) \rightarrow y_t$ con las predicciones out-of-fold.
4. Entrenar un meta-modelo (regresión lineal, ridge, o XGBoost pequeño) sobre el dataset meta.
5. Para nuevas predicciones: refit todos los modelos base sobre la muestra completa; aplicar meta-modelo a sus predicciones.

Punto crítico

Los pronósticos que alimentan al meta-modelo deben ser *out-of-fold*. Usar predicciones in-sample produce sobreajuste severo. Esta es la trampa más común en stacking mal implementado.

Ganancia típica

Stacking bien implementado gana 5-15 % en RMSE sobre el mejor modelo individual, a veces más. Es el método de combinación más potente cuando hay suficientes datos para estimar el meta-modelo sin ruido.

7.6.4. Ensamblés por modelo distinto

Una forma de ensamble sin estimar pesos: *promedio bayesiano de modelos* (BMA). En el contexto bayesiano de curso

anterior:

$$p(y_{T+h} \mid \mathbf{Y}) = \sum_{k=1}^K p(y_{T+h} \mid \mathbf{Y}, \mathcal{M}_k) \cdot p(\mathcal{M}_k \mid \mathbf{Y}).$$

Los pesos $p(\mathcal{M}_k \mid \mathbf{Y})$ son posteriors de modelo, que se computan vía verosimilitud marginal. BMA provee tanto pronóstico puntual como densitario, con incertidumbre de modelo incorporada.

7.7. Evaluación formal de pronósticos

7.7.1. El problema

Supongamos dos modelos producen pronósticos rolling con RMSE 1.20 y 1.15. ¿La diferencia refleja mejora real, o es ruido muestral? La respuesta importa: decisiones de política basadas en el "mejor" modelo requieren que "mejor" sea estadísticamente significativo.

Las pruebas formales de comparación de pronósticos están bien desarrolladas en la literatura.

7.7.2. Test de Diebold-Mariano

Definición 7.12 (Estadístico DM — Diebold y Mariano 1995). Sean $e_{1,t}, e_{2,t}$ los errores de pronóstico de dos modelos para el mismo objetivo, y $L(\cdot)$ una función de pérdida. Definamos $d_t = L(e_{1,t}) - L(e_{2,t})$. Bajo H_0 de igual precisión ($\mathbb{E}[d_t] = 0$):

$$DM = \frac{\bar{d}}{\sqrt{\hat{\mathbb{V}}(\bar{d})}} \xrightarrow{d} \mathcal{N}(0, 1), \quad (7.13)$$

donde $\hat{\mathbb{V}}(\bar{d})$ es un estimador HAC (Newey-West) de la varianza de largo plazo de d_t .

Por qué HAC

Los d_t son típicamente autocorrelacionados. Si ambos modelos pronostican a horizonte h con rolling-origin, los d_t adyacentes usan predicciones que se superponen parcialmente. La autocorrelación hace que los errores estándar MCO sean inválidos.

El estimador Newey-West:

$$\hat{\mathbb{V}}(\bar{d}) = \frac{1}{T} \left[\hat{\gamma}_0 + 2 \sum_{j=1}^q \left(1 - \frac{j}{q+1} \right) \hat{\gamma}_j \right],$$

con $\hat{\gamma}_j = T^{-1} \sum_t (d_t - \bar{d})(d_{t-j} - \bar{d})$ y q un lag máximo (típicamente $q \sim T^{1/3}$ o $q = h - 1$).

Corrección de Harvey-Leybourne-Newbold

En muestras pequeñas, DM tiene distribución más dispersa que $\mathcal{N}(0, 1)$. Harvey, Leybourne y Newbold (1997) proponen:

$$DM^* = DM \cdot \sqrt{\frac{T + 1 - 2h + h(h - 1)/T}{T}},$$

y comparar con distribución t de Student con $T - 1$ grados de libertad. En muestras pequeñas ($T < 50$ pronósticos), esta corrección mejora la tasa de rechazo nominal.

Implementación en R

El paquete `forecast` implementa el test:

- `forecast::dm.test(e1, e2, h = h, power = 2)` para pérdida cuadrática.
- `power = 1` para pérdida absoluta.
- Default usa la corrección de HLN.

7.7.3. Test de Giacomini-White

DM compara precisión *marginal promedio*. A veces queremos preguntas más sutiles: ¿es el modelo A mejor que B en *recesiones* pero no en *expansiones*?

Definición 7.13 (Test de Giacomini-White 2006). Sea $\mathbf{z}_t$ un vector de variables observables (incluyendo constante). Bajo H_0 de igual precisión predictiva condicional a $\mathbf{z}_t$:

$$GW = T \bar{\mathbf{g}}^\top \hat{\mathbf{V}}^{-1} \bar{\mathbf{g}} \xrightarrow{d} \chi_q^2, \quad (7.14)$$

con $\mathbf{g}_t = d_t \mathbf{z}_t$ y $\hat{\mathbf{V}}$ estimador HAC de $\mathbb{V}(\mathbf{g}_t)$.

$\mathbf{z}_t$ puede incluir indicadores de régimen (dummy de recesión), magnitudes de shocks, niveles de volatilidad, etc. Rechazo de H_0 indica que la diferencia de precisión depende de $\mathbf{z}_t$.

Aplicaciones

- "¿XGBoost domina a BVAR en períodos de alta volatilidad?"
- "¿El modelo con variables financieras domina en períodos de stress?"
- "¿La precisión relativa depende del horizonte?"

Si GW rechaza, podemos usar $\mathbf{z}_t$ para construir pronósticos *híbridos* que usen diferentes modelos según el estado.

7.7.4. Evaluación de pronóstico densitario

Cuando los modelos producen distribuciones predictivas completas (BVAR, BMA, quantile regression, ensemble), podemos evaluar más que la precisión puntual.

Log-score

Definición 7.14. El *log-score* para una predicción densitaria f en la realización y es:

$$\text{LogS}(f, y) = \log f(y).$$

Penaliza asignar baja probabilidad a valores que realmente ocurren. Mayor log-score promedio indica mejor calibración.

CRPS: Continuous Ranked Probability Score

Definición 7.15 (CRPS — Matheson y Winkler 1976). Para una predicción F (función de distribución) y realización y :

$$\text{CRPS}(F, y) = \int_{-\infty}^{\infty} [F(z) - \mathbf{1}\{y \leq z\}]^2 dz.$$

Proposición 7.16. *CRPS es una generalización de MAE al caso densitario: si F es una distribución degenerada en un punto μ , $\text{CRPS}(F, y) = |y - \mu|$.*

CRPS es más robusto que log-score (penaliza menos outliers) y es una regla de puntuación *propia*: el mínimo esperado se alcanza con F igual a la verdadera distribución condicional.

Probability Integral Transform (PIT)

Definición 7.17 (PIT). Para predicción F_t y realización y_t : $\text{PIT}_t = F_t(y_t)$.

Proposición 7.18. *Si las predicciones están bien calibradas (F_t es la verdadera distribución condicional), entonces $\{\text{PIT}_t\}$ son iid $U(0, 1)$.*

La distribución empírica de los PITs se compara con $U(0, 1)$:

- Histograma relativamente uniforme: buena calibración.
- Concentración en extremos: intervalos demasiado estrechos (sub-dispersión).
- Concentración en el centro: intervalos demasiado anchos (sobre-dispersión).
- Asimetría: sesgo en un lado.

Implementación

El paquete `scoringRules` implementa:

- `crps_norm`, `crps_t`: CRPS analítico para distribuciones paramétricas.
- `crps_sample`: CRPS a partir de muestras (para posteriors bayesianas).
- `logs_norm`, `logs_sample`: log-score.

7.8. Implementación integrada en R

Esta sección presenta un pipeline integrado para horse race ML vs. econometría, usando el ecosistema moderno `tidymodels` + `modeltime`. El código está diseñado como plantilla para el proyecto final del curso.

7.8.1. Preparación del entorno

```
1 library(tidyverse)
2 library(tidymodels)
3 library(modeltime)
4 library(modeltime.ensemble)
5 library(timetk)
6 library(scoringRules)
7
8 # Datos: inflacion mensual RD (IPC interanual)
9 datos <- read.csv("inflacion_rd.csv") %>%
10   mutate(fecha = as.Date(fecha)) %>%
11   arrange(fecha)
12
13 # Visualizar
14 datos %>% plot_time_series(fecha, infla)
```

7.8.2. Split temporal

```
1 # Ultimo 24 meses como test
2 splits <- time_series_split(
3   datos,
4   date_var = fecha,
5   assess = "24 months",
6   cumulative = TRUE
7 )
8
9 # Visualizar el split
10 splits %>%
11   tk_time_series_cv_plan() %>%
```

```
12 plot_time_series_cv_plan(fecha, infla)
```

7.8.3. Modelos base

ARIMA

```
1 mod_arima <- arima_reg() %>%  
2   set_engine("auto_arima") %>%  
3   fit(infla ~ fecha, training(splits))
```

Prophet (baseline popular)

```
1 mod_prophet <- prophet_reg(seasonality_yearly = TRUE)  
  %>%  
2   set_engine("prophet") %>%  
3   fit(infla ~ fecha, training(splits))
```

Recipe con feature engineering para ML

```
1 # Recipe: rezagos + features calendaricos +  
  estacionalidad  
2 recipe_ml <- recipe(infla ~ ., training(splits)) %>%  
3   step_timeseries_signature(fecha) %>%  
4   step_rm(contains("iso"), contains("xts"),  
5         contains("hour"), contains("minute"),  
6         contains("second"),  
7         contains("am.pm")) %>%  
8   step_lag(infla, lag = 1:12) %>%  
9   step_naomit(all_predictors(), all_outcomes()) %>%  
   step_normalize(all_numeric_predictors())
```

Random Forest

```
1 mod_rf <- workflow() %>%  
2   add_model(  
3     rand_forest(mode = "regression",  
4                 trees = 1000,
```



```

5         mtry = 10,
6         min_n = 5) %>%
7         set_engine("ranger", importance = "permutation")
8     ) %>%
9     add_recipe(recipe_ml) %>%
10    fit(training(splits))

```

XGBoost

```

1 mod_xgb <- workflow() %>%
2   add_model(
3     boost_tree(mode = "regression",
4               trees = 1000,
5               learn_rate = 0.05,
6               tree_depth = 5,
7               min_n = 5,
8               mtry = 10,
9               sample_size = 0.8) %>%
10    set_engine("xgboost", objective = "reg:
11               squarederror",
12               early_stopping_rounds = 50, verbose =
13                 0)
14  ) %>%
15  add_recipe(recipe_ml) %>%
16  fit(training(splits))

```

GLMNET (ridge/LASSO/elastic net con búsqueda de λ)

```

1 mod_glmnet <- workflow() %>%
2   add_model(
3     linear_reg(penalty = tune(), mixture = 0.5) %>%
4     set_engine("glmnet")
5   ) %>%
6   add_recipe(recipe_ml) %>%
7   fit(training(splits))
8   # Nota: en produccion tunear penalty con rolling-
9         origin CV

```

7.8.4. Validación rolling-origin

```
1 # Configurar resamples temporales
2 resamples <- time_series_cv(
3   training(splits),
4   date_var = fecha,
5   initial = "5 years",
6   assess = "12 months",
7   skip = "6 months",
8   cumulative = TRUE,
9   slice_limit = 10
10 )
11
12 # Visualizar
13 resamples %>% tk_time_series_cv_plan() %>%
14   plot_time_series_cv_plan(fecha, infla)
```

7.8.5. Tabla de modelos y evaluación rolling

```
1 # Agrupar todos los modelos
2 tabla_modelos <- modeltime_table(
3   mod_arima, mod_prophet, mod_rf, mod_xgb, mod_glmnet
4 )
5
6 # Validacion rolling
7 fit_resamples <- tabla_modelos %>%
8   modeltime_fit_resamples(resamples)
9
10 # Precision por modelo
11 fit_resamples %>%
12   modeltime_resample_accuracy(metric_set = metric_set(
13     rmse, mae, mape))
```

7.8.6. Test de Diebold-Mariano

```
1 library(forecast)
2
3 # Extraer errores de dos modelos para comparacion
```

```

4 errores_xgb <- predict(mod_xgb, testing(splits))$.pred
  - testing(splits)$infla
5 errores_arima <- predict(mod_arima, testing(splits))$.
  pred - testing(splits)$infla
6
7 # Test DM con correccion HLN
8 dm_test <- dm.test(errores_xgb, errores_arima,
9                   alternative = "less", # H1: xgb mejor
                                (errores menores)
10                   h = 1,
11                   power = 2) # perdida cuadratica
12 print(dm_test)

```

7.8.7. Ensamble

```

1 # Ensamble de peso igual sobre los 5 modelos
2 ensemble_igual <- tabla_modelos %>%
3   ensemble_average(type = "mean")
4
5 # Ensamble ponderado (pesos inversamente proporcional
6   a RMSE validacion)
7 # requiere stacking mas sofisticado via
8   ensemble_model_spec
9
10 # Calibrar con testing set
11 calibrated <- modeltime_table(ensemble_igual) %>%
12   modeltime_calibrate(testing(splits))
13
14 # Precision final out-of-sample
15 calibrated %>% modeltime_accuracy()

```

7.8.8. Pronóstico futuro (fuera de muestra)

```

1 # Refit el ensamble con TODA la muestra (train + test)
2 refit_ensemble <- calibrated %>%
3   modeltime_refit(data = datos)
4
5 # Pronostico a 12 meses futuros

```

```

6 future_dates <- datos %>%
7   future_frame(fecha, .length_out = "12 months")
8
9 pred_futuro <- refit_ensemble %>%
10  modeltime_forecast(
11    new_data = future_dates,
12    actual_data = datos,
13    conf_interval = 0.95
14  )
15
16 # Visualizar
17 pred_futuro %>% plot_modeltime_forecast()

```

7.8.9. CRPS para pronóstico densitario

Si el modelo produce cuantiles o muestras (p.ej., bayesiano del Módulo 4):

```

1 library(scoringRules)
2
3 # Si tenemos muestras MCMC de la posterior predictiva
4   para cada t
5 # pred_draws: matriz (n_draws x n_fechas_test)
6
7 crps_por_fecha <- numeric(ncol(pred_draws))
8 for (t in seq_along(crps_por_fecha)) {
9   crps_por_fecha[t] <- crps_sample(
10     y = testing(splits)$infla[t],
11     dat = pred_draws[, t]
12   )
13 }
14 mean(crps_por_fecha)
15
16 # Tambien log-score
17 logs_por_fecha <- numeric(ncol(pred_draws))
18 for (t in seq_along(logs_por_fecha)) {
19   logs_por_fecha[t] <- logs_sample(
20     y = testing(splits)$infla[t],
21     dat = pred_draws[, t]
22   )
23 }
24 mean(logs_por_fecha)

```

7.8.10. PIT histogram para diagnóstico de calibración

```
1 library(ggplot2)
2
3 pit_values <- numeric(length(crps_por_fecha))
4 for (t in seq_along(pit_values)) {
5   pit_values[t] <- mean(pred_draws[, t] <= testing(
6     splits)$infla[t])
7 }
8
9 tibble(pit = pit_values) %>%
10   ggplot(aes(x = pit)) +
11     geom_histogram(bins = 10, fill = "steelblue", colour =
12       "white") +
13     geom_hline(yintercept = length(pit_values)/10,
14       colour = "red", linetype = "dashed") +
15     labs(title = "PIT histogram: evaluacion de
16       calibracion",
17       x = "PIT", y = "Frecuencia") +
18     theme_minimal()
19 # Si la línea horizontal pasa por el tope de las
20   barras: bien calibrado
```

7.9. Ejercicios

Ejercicio 7.9.1 (Validación temporal incorrecta: simulación). Simule un AR(1) con $\phi = 0,9$, $T = 500$.

- (a) Entrene un XGBoost con features $Y_{t-1}, \dots, Y_{t-5}$ y evalúe RMSE con k -fold aleatorio estándar (`vfold_cv` de `rsample`).
- (b) Re-evalúe con rolling-origin (`time_series_cv`).
- (c) Retenga las últimas 50 obs como test genuino fuera de muestra; evalúe RMSE allí.
- (d) Compare los tres RMSE. ¿Cuál estimación es más confiable de la performance real?

Ejercicio 7.9.2 (Random forest vs. ARIMA sobre IPC RD). Use datos mensuales del IPC general RD (2000-2024).

- (a) Ajuste un ARIMA por `auto.arima` y un RF con rezagos 1-12 + features calendáricos.
- (b) Evaluar ambos con rolling-origin en los últimos 36 meses.
- (c) Compare RMSE por horizonte $h = 1, 3, 6, 12$.
- (d) Test de Diebold-Mariano para cada horizonte.
- (e) ¿Gana ML en algún horizonte? ¿Por qué podría ser?

Ejercicio 7.9.3 (XGBoost con tuning). Repita el ejercicio anterior con XGBoost, aplicando tuning con validación rolling:

- (a) Grilla sobre `max_depth`, `eta`, `min_child_weight`.
- (b) Use `modeltime::modeltime_fit_resamples` para tuning.

- (c) Compare precisión final con RF y ARIMA.
- (d) ¿Cuánto gana el tuning vs. defaults?

Ejercicio 7.9.4 (No extrapolación de RF: evidencia). Simule una serie con tendencia lineal: $y_t = 0,02t + \varepsilon_t$.

- (a) Entrene un RF con rezagos.
- (b) Pronostique 24 periodos fuera de muestra.
- (c) Grafique pronóstico vs. verdadero. ¿Qué observa?
- (d) Aplique ahora RF sobre Δy_t (diferenciada) y reconstruya. ¿Mejora?

Ejercicio 7.9.5 (Ensamble con pesos iguales). Para inflación RD, construya cinco modelos: AR(1), BVAR(Minnesota), RF, XGBoost, LASSO.

- (a) Evalúe rolling-origin de cada uno: RMSE a $h = 6$.
- (b) Construya ensamble de pesos iguales; compute su RMSE.
- (c) Construya ensamble con pesos óptimos estimados (regresión y sobre predicciones): compute RMSE.
- (d) ¿Cuál ensamble gana? ¿Es consistente con el "forecast combination puzzle"?

Ejercicio 7.9.6 (Test de Giacomini-White: especificidad condicional). Compute errores rolling-origin de XGBoost y ARIMA sobre inflación RD.

- (b) Test DM estándar: ¿uno domina al otro en promedio?
- (c) Test GW con $\mathbf{z}_t = (1, \text{vola}_t)$ donde vola_t es la volatilidad rolling de inflación. ¿La diferencia es condicional en volatilidad?

- (d) Si hay especificidad condicional: construya un modelo híbrido que use XGBoost cuando vola es alta, ARIMA cuando baja.

Ejercicio 7.9.7 (CRPS y calibración de BVAR). (a) Estime un BVAR(Minnesota) sobre datos RD.

- (b) Compute CRPS rolling para pronósticos densitarios de inflación.
- (c) Compute PITs y grafique histograma.
- (d) ¿Está bien calibrado? Si no, ¿los intervalos son demasiado anchos o estrechos?

Ejercicio 7.9.8 (Proyecto final: horse race). Este ejercicio es la semilla del proyecto final del curso. Elija una serie macrofinanciera dominicana (inflación, tipo de cambio, tasa, producción).

- (a) Justifique la elección: relevancia, disponibilidad, horizonte económico.
- (b) Implemente al menos tres modelos de familias distintas:
 - Univariado clásico (ARIMA/SARIMA).
 - Multivariado bayesiano (BVAR con Minnesota).
 - ML (XGBoost o RF con features cuidadosos).
- (c) Evalúe rolling-origin con RMSE, MAE, y CRPS (para el bayesiano).
- (d) Tests formales: DM pairwise y GW condicional a al menos una variable de estado.
- (e) Construya un ensamble y compárelo con los individuales.
- (f) Redacte un paper corto (8-12 páginas) con resultados, interpretación y código reproducible.

7.10. Cierre del curso

Este módulo cierra el arco temático del curso: desde el marco de máxima verosimilitud del Módulo 0 hasta los métodos de frontera en machine learning. Vale la pena sintetizar el aprendizaje en perspectiva.

7.10.1. El camino recorrido

1. **Módulo 0 — MV.** Construimos el andamiaje de inferencia paramétrica: verosimilitud, score, información de Fisher, propiedades asintóticas del EMV, tests Wald/LR/LM, optimización numérica. Este aparato es la columna vertebral de todo lo que siguió.
2. **Módulo 1 — Dinámica univariada.** Procesos estocásticos, ARIMA, Box-Jenkins, tests de raíz unitaria, SARIMA. La base de series de tiempo; todo VAR posterior es su generalización vectorial.
3. **Módulo 2 — Volatilidad y no linealidad.** GARCH y sus extensiones, TAR/TVAR, MS-AR. Respuesta a fenómenos que un ARMA lineal no captura: volatility clustering y cambios de régimen.
4. **Módulo 3 — Multivariado clásico.** VAR, SVAR con identificación (Cholesky, largo plazo, signos), cointegración, VECM, Local Projections. El corazón de la econometría de política aplicada.
5. **Módulo 4 — Bayesiano moderno.** BVAR con priors Minnesota, BVAR-SV, TVP-VAR, fan charts. La alternativa bayesiana con sus ventajas en regularización, incertidumbre paramétrica y pronóstico densitario.

6. **Módulo 5 — Alta dimensión.** DFM, FAVAR, now-casting con Kalman, MIDAS, LASSO. La respuesta metodológica a la abundancia de datos.
7. **Módulo 6 — Machine learning.** Random forest, XGBoost, RNN/LSTM, ensambles, evaluación formal. El método algorítmico moderno y sus criterios de evaluación.

7.10.2. El mensaje metodológico final

No existe "el mejor método". Existen preguntas y existen herramientas. La competencia del economista aplicado maduro es emparejar pregunta con herramienta:

- **¿Pronosticar inflación a 12 meses con muchos predictores disponibles?** XGBoost con tuning cuidadoso probablemente domina.
- **¿Cuantificar incertidumbre sobre un pronóstico con fan chart?** BVAR con stochastic volatility es natural.
- **¿Identificar el efecto de política monetaria?** SVAR estructural con identificación defendible.
- **¿Estimar el estado actual del PIB?** DFM de now-casting con filtro de Kalman.
- **¿Testar una hipótesis estructural sobre cambios de régimen?** MS-AR con probabilidades suavizadas.
- **¿Modelar el riesgo de un portafolio?** GARCH con t -Student para VaR, BVAR-SV para stress.

Cada pregunta admite múltiples enfoques razonables; ningún enfoque resuelve todas las preguntas. El juicio para navegar esta elección es lo que distingue al analista sofisticado.

7.10.3. Más allá del curso

El campo sigue en expansión acelerada. Direcciones que el estudiante interesado puede explorar:

- **Inferencia causal en series:** Synthetic Control, event studies, diff-in-diff para datos de panel con series largas.
- **Bayesian nonparametrics:** Gaussian processes, Dirichlet process mixtures aplicados a series.
- **Deep learning para series:** Transformers, attention mechanisms, foundation models temporales (TimeGPT, Chronos).
- **Modelos híbridos:** combinación estructurada de econometría + ML, como el ES-RNN ganador de M4.
- **Inferencia robusta:** identificación bajo violaciones de supuestos, análisis de sensibilidad.
- **Datos de alta dimensión causal:** Chernozhukov et al. (2018) sobre ML en econometría causal.

7.10.4. Cierre

La econometría de series de tiempo combina elegancia matemática, relevancia política y riqueza metodológica. Desde Sims y Granger hasta Breiman y Chen, la disciplina ha evolucionado respondiendo a nuevas preguntas y nuevos datos. El estudiante que ha seguido este curso tiene hoy el aparato conceptual y las herramientas computacionales para contribuir profesionalmente a ese desarrollo.

El trabajo aplicado serio exige disciplina: validación correcta, diagnóstico cuidadoso, inferencia rigurosa, comunicación transparente. Las herramientas sofisticadas son peligrosas si se usan con negligencia. Pero aplicadas con cuidado, producen análisis que informan decisiones importantes:

política monetaria del banco central, gestión de riesgo de pensiones, proyecciones empresariales, estudios académicos.

En el contexto de MACROPOL y la economía dominicana, hay un agenda amplia de aplicación: nowcasting del PIB, evaluación del canal monetario post-metas, modelado del mercado cambiario, stress testing del sistema previsional, estudios de pass-through cambiario, evaluación de efectos de reformas. Cada estudiante del curso puede ahora abordar estas preguntas con rigor moderno.

Bibliografía

- [1] Bates, J. M. & Granger, C. W. J. (1969). The combination of forecasts. *OR*, 20(4), 451–468.
- [2] Breiman, L. (2001). Statistical modeling: The two cultures. *Statistical Science*, 16(3), 199–231.
- [3] Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.
- [4] Breiman, L., Friedman, J. H., Olshen, R. A. & Stone, C. J. (1984). *Classification and Regression Trees*. Wadsworth.
- [5] Chen, T. & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. En *Proceedings of the 22nd ACM SIGKDD Conference*, 785–794.
- [6] Cho, K., van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H. & Bengio, Y. (2014). Learning phrase representations using RNN encoder-decoder for statistical machine translation. *EMNLP*.
- [7] Diebold, F. X. & Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
- [8] Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, 29(5), 1189–1232.
- [9] Giacomini, R. & White, H. (2006). Tests of conditional predictive ability. *Econometrica*, 74(6), 1545–1578.
- [10] Gneiting, T. & Raftery, A. E. (2007). Strictly proper scoring rules, prediction, and estimation. *JASA*, 102(477), 359–378.

- [11] Harvey, D., Leybourne, S. & Newbold, P. (1997). Testing the equality of prediction mean squared errors. *International Journal of Forecasting*, 13(2), 281–291.
- [12] Hastie, T., Tibshirani, R. & Friedman, J. (2009). *The Elements of Statistical Learning*, 2da ed. Springer.
- [13] Hochreiter, S. & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735–1780.
- [14] Hornik, K. (1991). Approximation capabilities of multilayer feedforward networks. *Neural Networks*, 4(2), 251–257.
- [15] Makridakis, S., Spiliotis, E. & Assimakopoulos, V. (2020). The M4 competition: 100,000 time series and 61 forecasting methods. *International Journal of Forecasting*, 36(1), 54–74.
- [16] Matheson, J. E. & Winkler, R. L. (1976). Scoring rules for continuous probability distributions. *Management Science*, 22(10), 1087–1096.
- [17] Medeiros, M. C., Vasconcelos, G. F. R., Veiga, Á. & Zilberman, E. (2021). Forecasting inflation in a data-rich environment: The benefits of machine learning methods. *Journal of Business & Economic Statistics*, 39(1), 98–119.
- [18] Stock, J. H. & Watson, M. W. (2004). Combination forecasts of output growth in a seven-country data set. *Journal of Forecasting*, 23(6), 405–430.
- [19] Smith, J. & Wallis, K. F. (2009). A simple explanation of the forecast combination puzzle. *Oxford Bulletin of Economics and Statistics*, 71(3), 331–355.
- [20] Wolpert, D. H. (1992). Stacked generalization. *Neural Networks*, 5(2), 241–259.